

정밀 연구 보고서 · 개정판

경마 예측모델 시장대조 보고서

문헌 표준과 KHUDA 3조 프로젝트의 정밀 대조

경마를 전혀 모르는 독자를 위해 배경과 수식을 처음부터 풀어 씀

항목	내용
작성 기준일	2026년 8월 20일
대상 프로젝트	khuda-data/10th-toy-team3 (KHUDA 10기 3조 토이프로젝트)
초판	『경마_시장모델_구축방법_및_현프로젝트_정밀비교』
개정 내용	문헌 조사 대폭 확장(3장), 원인 분석 8갈래로 재구성(5장), 전면 재서술
성격	연구·모델 설계용 문서. 실전 베팅을 권유하지 않음

목차

이 보고서는 여섯 개 장과 네 개 부록으로 되어 있습니다. 경마를 처음 접하는 독자는 1장부터 순서대로 읽으시면 됩니다. 이미 배경을 아신다면 3장(문헌 지형)과 5장(원인 분석)이 본론입니다.

장	제목	이 장을 읽으면
0	이 보고서를 읽는 법	무엇을 묻고 무엇을 답했는지
1	경마와 배당률 — 최소한의 배경	배당률이 왜 '예측'인지
2	수식 — 숫자를 넣어가며	기대수익 계산법 전부
3	경마 예측 모델의 문헌 지형	다섯 계층, 핵심 문헌, 참고할 연구 전부
4	우리 프로젝트의 현재 좌표	지금까지의 성과와 정확한 위치
5	왜 시장을 이기지 못하는가	여덟 가지 원인과 각각의 크기
부록 A	용어 사전	모르는 단어가 나올 때
부록 B	수식 모음	구현할 때 참조
부록 C	참고 문헌	계층별로 정리한 24편
부록 D	출처와 주의	수치의 근거와 한계

0. 이 보고서를 읽는 법

0.1 한 문단 요약

우리 프로젝트는 **시장을 이기는 예측 모델이 아니라, 시장 확률을 아주 조금 다듬는 보정기**입니다. 그런데 이것은 실패가 아닙니다. 문헌을 확인해보니 **실제로 시장을 이겨 돈을 번 유일한 검증 사례조차 모델 단독 정확도는 시장보다 낮았습니다**. 문제는 성능이 아니라 **무엇을 재고 있었는가**였습니다. 우리는 '모델이 시장보다 정확한가'를 물었지만, 물어야 할 것은 '모델이 시장에 무엇을 더하는가'였습니다. 그 지표로 다시 재보니 우리 모델은 0이 아니지만 수익 전환에 필요한 수준의 5분의 1이었습니다. 이 보고서는 그 판단의 근거가 되는 문헌을 계층별로 정리하고(3장), 왜 그 격차가 생겼는지를 여덟 갈래로 분해합니다(5장).

0.2 이 보고서가 답하는 세 가지 질문

Q1. 경마 시장에는 어떤 예측 모델이 존재하는가?

3장. 레이팅·속도지수, 경주 단위 확률 모형, 랭킹 학습, 시장 결합, 실행 시스템의 다섯 계층으로 나뉩니다. 각 계층의 대표 문헌과 상용 서비스를 정리했습니다.

Q2. 우리 모델은 그중 어디에 있는가?

3.9절과 4장. 계층 ②와 ④의 초기 단계입니다. 방향은 문헌과 같지만 결합 방식이 단순하고 실행 계층이 비어 있습니다.

Q3. 왜 우리 모델은 시장을 이기지 못했는가?

5장. 여덟 가지 원인을 크기 순으로 나눴습니다. 넷은 구조적이고 넷은 설계로 고칠 수 있습니다.

0.3 초판과 달라진 점

초판 보고서는 구조와 경제성 수학이 매우 정확했습니다. 이 개정판은 초판의 뼈대를 유지하되 다음을 더했습니다.

구분	내용	위치
구조	문헌 조사와 원인 분석에 집중. 검증·과제 장은 덜어냄	전체
확장	문헌을 다섯 계층으로 재정리. 상용 서비스·구현 라이브러리까지 포함	3.1~3.7
신규	시장을 이기지 못한 연구도 참고할 가치가 있다 — 국내외 12편 정리	3.8
신규	피처 공학 사례 비교 — 같은 개념도 설계에 따라 정보량이 달라진다	3.8.3

구분	내용	위치
신규	ΔR^2 지표 도입과 Benter 기준선 대조	3.5.5, 5.2
신규	결합 계수 α 가 작다는 것의 의미를 역산으로 설명	5.3
신규	시장 효율성은 시간이 갈수록 높아진다	5.7
신규	학습 목적과 평가 목적의 불일치	5.8
신규	실제 베팅 시뮬레이션 637경주 전수	5.2
재서술	전 장을 경마 문외한이 읽을 수 있게 다시 씀	전체

1. 경마와 배당률 — 최소한의 배경

이 장은 경마를 한 번도 본 적 없는 독자를 위한 것입니다. 이 장만 읽어도 나머지를 따라올 수 있습니다.

1.1 배당률은 '주최측이 매긴 가격'이 아닙니다

가장 먼저 버려야 할 오해입니다. 스포츠 도박에서 흔히 보는 방식은 북메이커(사설 업체)가 자기 판단으로 배당을 정하고, 손님과 업체가 맞붙는 구조입니다. 경마는 다릅니다.

한국 경마는 **파리뮤추엘(pari-mutuel)** 방식입니다. 프랑스어로 '서로(mutuel) 내기(pari)'라는 뜻입니다.

참가자들이 낸 돈을 한 통에 모으고, 주최측이 정해진 몫을 먼저 떼어간 뒤, 남은 돈을 맞힌 사람들끼리 나눠 갖습니다.

주최측은 결과에 아무 이해관계가 없습니다. 누가 이기든 자기 몫은 이미 챙겼기 때문입니다.

숫자로 보면

어떤 경주의 단승(1등 맞히기) 판돈이 1억 원 모였다고 합시다. 주최측이 20%인 2천만 원을 떼어가면 8천만 원이 남습니다.

만약 A라는 말에 1천만 원이 걸렸고 A가 우승하면, A에 건 사람들이 8천만 원을 나눠 갖습니다. 1천만 원을 걸어 8천만 원을 받으니 배당률은 8.0배입니다.

반대로 인기가 많아 4천만 원이 걸린 말이 우승하면 8천만 / 4천만 = 2.0배입니다.

여기서 핵심이 나옵니다. **배당률은 사람들이 어디에 얼마를 걸었는지의 결과일 뿐입니다.** 즉 배당률이 낮다는 것은 '많은 사람이 그 말을 유력하다고 봤다'는 뜻입니다. 배당률은 그 자체로 **수만 명의 판단을 합산한 예측치**입니다. 우리가 '시장'이라고 부르는 것이 바로 이것입니다.

1.2 배당률을 확률로 뒤집기

배당률 8.0배는 '1을 걸면 8을 받는다'는 뜻입니다. 이것 확률로 바꾸려면 그냥 뒤집으면 됩니다.

$$\text{암묵 확률} = 1 / \text{배당률}$$

$$\text{배당} 8.0 \text{ 배} \rightarrow 1 / 8.0 = 0.125 = 12.5\%$$

사람들이 이 말에 판돈의 12.5%를 걸었다는 뜻이고, 곧 '집단이 보기에 이 말의 우승 확률이 대략 12.5%'라는 의미입니다.

1.3 그런데 확률을 다 더하면 1이 넘습니다

한 경주에 나온 모든 말의 암묵 확률을 더해보면 1.0이 아니라 1.25쯤 나옵니다. 이상해 보이지만 당연합니다. 주최측이 20%를 먼저 떼어갔기 때문입니다.

우리 데이터 실측 (서울 경매 test 637경주)

경주별 $\Sigma(1/\text{배당률})$ 평균 1.2484 중앙값 1.2497

$1 / 1.2497 = 0.8002 \rightarrow$ 환급률 약 80%

이 **1.25**라는 숫자가 이 보고서 전체에서 가장 중요한 장벽입니다. 뒤에서 계속 나옵니다. 이것을 **오버라운드 (overround)** 또는 **S**라고 부르겠습니다.

주의 — 73%와 80%는 다른 숫자입니다

한국마사회 공식 경영공시는 전체 경매 매출액 중 환급금 73%, 제세금 16%, 운영비용 7%, 이익금 4%라고 밝히고 있습니다.

반면 우리가 데이터에서 계산한 단승 환급률은 약 80%입니다. 둘은 모순이 아닙니다. 73%는 모든 승식(단승·연승·복승·쌍승 등)과 전체 매출을 아우른 회사 차원의 수치이고, 80%는 단승 한 종목의 종가 배당에서 역산한 값입니다. 이 보고서에서 '공제율 20%'라고 하면 후자를 뜻합니다.

1.4 그래서 '시장을 이긴다'는 두 가지 뜻입니다

이 구분을 못 하면 프로젝트 전체의 결론이 뒤집힙니다.

	(A) 정확도로 이기기	(B) 수익으로 이기기
묻는 것	모델 예측이 시장보다 정확한가?	배당 대비 값싼 말을 찾아낼 수 있는가?
재는 법	AUC, Log Loss 같은 예측 정확도	기대수익, ROI
난이도	거의 불가능 (5장 참조)	어렵지만 입증된 사례 있음
핵심	(B)는 (A)를 필요로 하지 않습니다	이 보고서 전체의 출발점입니다

우리 조는 지금까지 (A)만 재고 있었습니다. 모델 AUC 0.77이 시장 0.81보다 낮으니 실패라고 판단했습니다. **그러나 문헌 기준으로 이것은 성립하지 않는 판정입니다.** 3장에서 그 이유를 봅니다.

2. 수식 — 숫자를 넣어가며

이 장에는 수식이 다섯 개 나옵니다. 전부 사칙연산이고, 각각 바로 옆에 숫자를 대입한 예를 붙였습니다.

2.1 기대수익 — 걸 만한가?

어떤 말에 1원을 걸었을 때 평균적으로 얼마가 돌아오는지를 계산합니다. 우승 확률을 p , 배당률을 O 라고 하면

$$EV = p \times O - 1$$

예: 우승 확률 20%인 말의 배당이 6.0배면 $\rightarrow 0.20 \times 6.0 - 1 = +0.20$ (평균 20% 이익)

EV가 0보다 크면 걸 가치가 있고, 0보다 작으면 평균적으로 잃습니다. 뒤집으면 이렇게도 쓸 수 있습니다.

$$\text{걸 가치가 있는 조건: } p > 1 / O$$

배당 6.0배라면 우승 확률이 $1 / 6.0 = 16.7\%$ 를 넘어야 함

자주 하는 실수 — 공제율을 두 번 빼면 안 됩니다

배당률 6.0배는 이미 주최측이 20%를 떼어간 뒤에 계산된 숫자입니다. 여기에 다시 0.8을 곱하면 공제를 두 번 적용하는 셈이 됩니다.

표시된 배당률을 그대로 쓰면 됩니다. 초판 보고서가 이 점을 정확히 지적했고, 우리 계산도 그렇게 했습니다.

2.2 시장 확률 — 합이 1이 되도록 고치기

1/배당률을 다 더하면 1.25가 나오므로, 그대로는 확률로 쓸 수 없습니다. 전체로 나눠서 합이 1이 되게 맞춥니다.

이것을 시장 확률 q 라고 부릅니다.

$$q = (1 / O) / S \quad (\text{단, } S = \text{모든 말의 } 1/O \text{를 더한 값})$$

예: 배당 6.0배, 경주 전체 $S = 1.25 \rightarrow q = (1/6.0) / 1.25 = 0.1667 / 1.25 = 0.1333 = 13.3\%$

즉 시장은 이 말의 우승 확률을 13.3%로 보고 있는데, 실제로 돈을 벌려면 16.7%는 넘어야 합니다. 그 사이의 3.4% 포인트가 바로 주최측이 가져간 몫입니다.

2.3 결정적인 조건 — 시장보다 25% 더 정확해야 합니다

앞의 두 식을 합치면 이렇게 정리됩니다.

$$EV > 0 \text{ 이려면 } p / q > S$$

우리 데이터에서 $S \approx 1.25$ 이므로 $\rightarrow$ 모델 확률이 시장 확률의 1.25배를 넘어야 함

이 한 줄이 이 프로젝트의 벽입니다. '시장보다 조금 더 정확하다'로는 안 됩니다. 특정 말에 대해 시장보다 25% 더 높게 봐야 하고, 그 판단이 실제로 맞아야 합니다.

시장 확률 q	배당률 O	손익분기 확률 $1/O$	모델 확률 p	기대수익 EV	판정
60%	1.333	75.0%	61%	-18.7%	손해
60%	1.333	75.0%	70%	-6.7%	손해
60%	1.333	75.0%	80%	+6.6%	이익

모델이 60%를 70%로 올려 봐야 여전히 손해입니다. 80%까지 가야 겨우 이익이 납니다. 이것이 '조금 더 정확함'과 '배당을 이김' 사이의 간격입니다.

2.4 우리 데이터의 실제 숫자

서울 경마 test 637경주 · 6,650출전 실측

경주당 평균 출주두수	10.46두	
실제 우승률	9.56% (= 1 / 10.46)	
우승마 평균 배당	8.10배	중앙값 4.30배
경주별 S 중앙값	1.2497	
환급률 1/S	80.02%	

우승마 평균 배당 8.10배는 이론값 $10.46 / 1.25 = 8.37$ 과 거의 일치합니다. 데이터가 정상이라는 뜻입니다.

3. 경마 예측 모델의 문헌 지형

이 장이 이 보고서의 중심입니다. '경마 예측 모델'이라는 말은 하나의 대상을 가리키지 않습니다. 서로 다른 다섯 개의 층이 있고, 각 층은 푸는 문제도 평가 기준도 다릅니다. 우리 프로젝트가 어느 층에 있는지 알아야 무엇이 부족한지 말할 수 있습니다.

3.1 다섯 계층 — 전체 지도

계층	무엇을 만드나	대표	출력이 확률인가	우리 위치
① 레이팅·속도 지수	말의 능력을 하나의 숫자로 압축	Timeform, Equibase	아니오	일부 피쳐로만
② 경주 단위 확률 모형	경주 안에서 합이 1인 승률	다항 로짓, 조건부 로짓	예	사후 정규화로 흉내
③ 랭킹 학습 (LTR)	출전마의 상대 순서	LambdaMART, YetiRank	아니오 (순위 점수)	v5에서 일부 도입
④ 시장 결합	펀더멘탈 확률 + 배당률	Benter형 하이브리드	예	여기 있음
⑤ 실행 시스템	언제 얼마를 어떻게 거나	CAW, Kelly, 주문 최적화	해당 없음	없음

계층을 나눠 봐야 하는 이유

①과 ③은 '누가 잘 달리나'를 답합니다. ②는 '그래서 몇 %인가'를 답합니다. ④는 '지금 배당에 비해 싼가'를 답합니다. ⑤는 '그 가격에 실제로 살 수 있나'를 답합니다.
수익은 ④와 ⑤를 통과해야 비로소 주장할 수 있습니다. ①·②·③이 아무리 좋아도 그 자체로는 돈이 되지 않습니다.

3.2 계층 ① — 레이팅과 속도 지수

가장 오래되고 가장 널리 쓰이는 층입니다. 과거 경주의 질을 서로 비교 가능한 하나의 수치로 압축합니다.

서비스	무엇을 제공하나	공개 범위
Timeform	말의 현재 능력을 파운드(lb) 단위 레이팅으로 표현. 부담중량·연령·거리·주로·페이스 적합성을 함께 해석	산출 원리는 설명하나 계수는 비공개
Equibase	실제 기록에 트랙 상태를 결합한 Speed Figure, 구간별 Pace Figure	입력 범주는 공개, 알고리즘 전체는 비공개
Racing Post Smart View	능력·기수·조교사·코스·거리·주로·게이트 등 다속성 점수 (0~100). 전적이 적은 말에는 머신러닝 사용	0~100 점수는 승률이 아니라고 명시

서비스	무엇을 제공하나	공개 범위
여기서 배울 점 — 점수는 확률이 아닙니다 Racing Post가 명시적으로 밝히듯, 0~100 점수는 우승 확률이 아닙니다. Timeform도 동점 레이팅이 곧 동일 승률을 뜻하지 않는다고 씁니다. 즉 이 층은 사용자 의사결정 도구이지 그 자체로 공정 배당·기대수익 모델이 아닙니다. 배당과 비교하려면 반드시 ② 층을 거쳐 확률로 바꿔야 합니다.		

레이팅을 직접 만들 때 지켜야 할 원칙이 하나 있습니다. 원기록을 그대로 쓰지 않고 날짜 시점별 트랙 변이, 상대마 강도, 거리·주로 간 척도 변환, 부담중량, 착차, 휴식일을 재귀적으로 추정하되,

오늘 결과를 과거 레이팅 계산에 절대 섞지 않는 **as-of 업데이트**가 핵심입니다. 우리 프로젝트의 확장창(expanding window) 피처가 같은 발상입니다.

3.3 계층 ② — 경주 단위 확률 모형

3.3.1 Bolton & Chapman (1986) — 이 분야의 원전

Management Science에 실린 이 논문이 경마를 다항 로짓으로 모형화한 최초의 본격 연구입니다. 200경주를 대상으로 말·기수 특성과 경주별 변수를 넣어 승률을 추정했고, 순서가 있는 선택 집합(rank ordered choice sets)의 정보를 활용해 더 효율적인 모수 추정을 얻는 절차를 제시했습니다.

결론은 '장기 베팅을 배제하는 제약을 두고 눈에 띄지 않는 규모로 베팅하면 양의 기대수익이 가능해 보인다'였습니다. 실제 운용 검증은 없었지만,

이 논문이 제시한 모형 구조가 이후 모든 연구의 표준이 됐습니다.

3.3.2 왜 경주 단위여야 하는가

각 말에 점수 u 를 매긴 뒤, 지수함수에 넣고 경주 전체로 나눕니다.

$$p_i = \exp(u_i) / \sum \exp(u_j)$$

한 경주 안에서 확률의 합이 자동으로 정확히 1이 됩니다

경마에는 '한 경주에 우승마가 정확히 하나'라는 강한 제약이 있습니다. 말마다 따로 '이 말이 이길까?'를 이진분류로 예측하면 이 제약이 손실 함수에 들어가지 않습니다. 학습이 끝난 뒤 나눠서 합을 1로 맞추는 것은 사후 처리일 뿐, 모델은 학습 중에 경쟁 구조를 보지 못합니다.

	행 단위 이진분류 + 사후 정규화	경주 단위 softmax
손실 계산	말 하나씩 독립적으로	경주 전체를 한 번에

	행 단위 이진분류 + 사후 정규화	경주 단위 softmax
'승자는 하나' 제약	반영 안 됨	구조적으로 반영
출주두수 차이	별도 처리 필요	분모가 자동으로 흡수
구현 난이도	쉬움	custom objective 필요
우리 프로젝트	이 방식	미도입

3.3.3 로짓에서 프로빗으로 — Gu, Huang & Benter (2003)

Benter는 이후 다항 로짓을 다항 프로빗(multinomial probit)으로 바꿉니다. 로짓은 오차가 극단값 분포를 따른다고 가정하고, 프로빗은 정규분포를 가정합니다. 프로빗이 계산은 훨씬 무겁지만 말들 사이의 상관을 다룰 수 있다는 장점이 있습니다.

주목할 점은 그의 최대우도 추정 절차가 오늘날 우리가 listwise Learning-to-Rank라고 부르는 것과 사실상 같다는 것입니다. 1990년대 통계학과 2010년대 기계학습이 서로 다른 이름으로 같은 곳에 도착했습니다.

3.4 계층 ③ — 랭킹 학습(LTR)

경주 하나를 검색 질의(query)로 보고, 출전마를 그 질의에 대한 문서로 보아 상대 순서를 학습하는 접근입니다. 정보검색에서 온 방법론이 그대로 이식됐습니다.

방식	학습 대상	장점	한계
Pointwise	말 하나씩 점수화 후 정렬	구현이 가장 쉬움	경쟁 관계가 손실에 약하게만 반영
Pairwise	같은 경주의 두 말 중 누가 앞섰나	상위 순위에 강함	확률 합 1과 보정을 보장하지 않음
Listwise	출전 목록 전체의 순서를 한 번에	경주 구조에 가장 맞춤	NDCG가 좋다고 승률 확률이 좋지는 않음

주요 라이브러리가 제공하는 목적함수입니다.

라이브러리	목적함수	비고
XGBoost	rank:pairwise, rank:ndcg, LambdaMART	qid로 경주를 그룹 지정
LightGBM	lambdarank, rank_xendcg	우리 v5에서 사용
CatBoost	PairLogit, YetiRank, QuerySoftMax	고카디널리티 범주에 강함

주의 — NDCG가 좋다고 베팅이 되는 것은 아닙니다

랭킹 지표(NDCG, MAP, MRR)는 '순서를 잘 맞췄나'를 잹니다. 배당과 비교하려면 확률이 필요한데, 순위 점수는

라이브러리	목적함수	비고
확률이 아닙니다. 권장 순서는 이렇습니다. LTR을 후보 중 하나로 두되, 최종 승률은 group-softmax나 별도 보정으로 변환한 뒤, 시장 확률과 같은 잣대(Log Loss, ΔR^2)로 비교합니다.		

3.5 계층 ④ — 시장 결합, 유일하게 검증된 수익 경로

여기가 이 보고서 전체에서 가장 중요한 절입니다.

3.5.1 Benter가 한 일

William Benter는 1994년 보고서에서 홍콩 경마에 적용한 시스템을 공개했습니다. 5년간 실제 운용했고 다섯 시즌 중 네 시즌에서 흑자를 냈습니다. 손실 시즌의 손실 폭은 초기 자본의 약 20%였습니다.

항목	내용
개발 기간	모델 개발 5인년(man-year) + 운영 고도화 5인년
초기 표본	약 2,000경주
연간 베팅	약 470경주 (전 경주의 95%, 신마만 나온 경주는 제외)
공제율	평균 19%
베팅 방식	보수적 부분 Kelly, 단승과 복합승식 모두
결과	5시즌 중 4시즌 흑자, 개선에 따라 수익률 상승 추세

3.5.2 그가 발견한 편향

Benter는 자기 모델의 확률이 시장과 어긋날 때 어느 쪽이 맞는지를 데이터로 확인했습니다. 결과는 그가 '베팅 관점에서 재앙적'이라고 표현할 만큼 명확했습니다.

원문 Table 3·4가 보여준 것

모델이 시장보다 낮게 본 말들 → 실제 승률은 모델 예측보다 높았고, 시장 쪽에 가까웠습니다.

모델이 시장보다 높게 본 말들 → 실제 승률은 모델 예측보다 낮았고, 역시 시장 쪽에 가까웠습니다.

즉 모델과 시장이 다를 때 진실은 거의 항상 시장 쪽이었습니다. 특히 두 번째 경우가 치명적입니다. 그 말들이 바로 모델이 '싸다'고 판단해 걸라고 지시하는 후보이기 때문입니다.

결론은 이렇습니다. **펀더멘털 모델의 확률은 시장과 독립적인 불편(unbiased) 추정치가 아닙니다.** 이 편향을 고치지 않으면 베팅 우위를 정확히 계산할 수 없습니다.

3.5.3 결합식

해결책으로 그는 두 확률을 로그 공간에서 결합하는 2단계 로짓을 씁니다. 이 발상 자체는 Asch와 Quandt(1986)가 정리한 '두 전문가의 판단을 합치는 방법'에서 왔습니다.

$$c_i \propto \exp(\alpha \times \log f_i + \beta \times \log q_i)$$

쉽게 쓰면: $c_i \propto (\text{모델 확률})^\alpha \times (\text{시장 확률})^\beta$ 를 경주 안에서 다시 정규화

기호	뜻	우리 프로젝트 추정값
f_i	편더멘탈 모델의 out-of-sample 확률	—
q_i	배당률에서 환산한 시장 확률	—
α	모델의 상대적 정확도. 클수록 모델이 좋음	0.0526 ~ 0.1401
β	시장의 비중	1.0000 ~ 1.0002

확률이 아니라 로그 확률을 쓰는 이유는 Benter의 표현대로 '그 변환이 더 잘 맞기(better fit)' 때문입니다. 곱셈 구조가 되면서 각 정보원의 기여를 지수 하나로 조절할 수 있게 됩니다.

3.5.4 out-of-sample이 아니면 전부 무의미합니다

이 조건을 어기면 생기는 일

$\alpha \cdot \beta$ 를 추정할 때 넣는 모델 확률 f 는 반드시 그 데이터를 학습에 쓰지 않은 모델이 만든 값이어야 합니다.

학습에 쓴 데이터로 만든 확률을 넣으면, 모델이 자기 답을 외운 부분까지 '실제 정보'로 오인됩니다. α 가 과대추정되고, 결국 존재하지 않는 우위를 믿고 베팅하게 됩니다.

Benter는 이를 '모델 개발 표본에 대한 custom-fitting'이라 부르며, 반드시 별도 표본에서 만든 확률을 쓰라고 못 박았습니다.

3.5.5 평가 지표 — pseudo- R^2 와 ΔR^2

Benter는 예측 성능을 AUC가 아니라 pseudo- R^2 로 잽니다. Bolton & Chapman이 제안한 형태입니다.

$$R^2 = 1 - L(\text{모델}) / L(\text{균등 추측})$$

L 은 로그우도. '아무것도 모르고 찍었을 때' 대비 얼마나 나아졌는지를 0~1로 표현

R^2 가 0이면 무작위 추측과 같고 1이면 완벽합니다. 그런데 진짜 중요한 것은 모델 단독 R^2 가 아니라, 시장에 었었을 때 늘어나는 양입니다.

$$\Delta R^2 = R^2(\text{시장} + \text{모델 결합}) - R^2(\text{시장 단독})$$

모델이 시장에 추가로 더한 정보량

Benter는 이 값을 '전체 베팅 시뮬레이션이라는 시간 많이 드는 절차 없이 모델의 잠재 수익성을 재고 비교할 수 있는 지표'라고 설명하며, 자신의 경험상 ΔR^2 가 클수록 예외 없이 시뮬레이션 수익성도 높았다고 썼습니다.

3.5.6 결정적 예시 — 단독 성능은 같은데 가치는 정반대

이 표 하나가 우리 프로젝트의 판정 기준을 바꿉니다. 그는 두 모델을 비교했습니다. 하나는 9개 변수를 쓴 펀더멘털 모델, 다른 하나는 신문 예사가 48명의 픽을 점수화해 집계한 것입니다.

모델	단독 R^2	시장과 결합 후 ΔR^2	실전 가치
펀더멘털 모델 (9개 변수)	0.1016	+0.0090	수익 발생
신문 예사가 48명 집계	0.1014	+0.0002	무가치
(참고) 시장 단독	0.1237	—	—

이 표에서 읽어야 할 세 가지

첫째 — 두 모델의 단독 성능은 사실상 같습니다(0.1016 대 0.1014). 그런데 가치는 정반대입니다. 단독 지표만 보면 절대 구분할 수 없었습니다.

둘째 — 수익을 낸 그 모델조차 단독 R^2 (0.1016)가 시장(0.1237)보다 낮았습니다. 즉 '모델이 시장보다 못하다'는 사실은 실패의 근거가 되지 못합니다.

셋째 — 예사가 모델의 ΔR^2 가 0.0002라는 것은, 그 모델이 시장과 다른 의견을 낼 때 항상 시장이 옳았다는 뜻입니다. Benter의 표현으로 '2단계를 거쳤다면 그 사람은 돈을 잃지 않았을 것'입니다.

3.5.7 예측할 수 없는 말은 시장을 그대로 씁니다

첫 출전마처럼 과거 기록이 없어 모델이 확률을 낼 수 없는 말이 있습니다. Benter는 이런 말을 unratable로 표시하고 시장 확률을 그대로 부여한 뒤 나머지 말의 확률을 재정규화합니다. '시장의 판단에 이의를 제기할 정보가 없으니 그대로 받아들이다'는 원칙입니다.

우리 프로젝트는 신마의 결측을 0으로 채웁니다. 문헌 기준으로는 시장 확률을 대입하는 편이 맞습니다.

3.6 계층 ⑤ — 실행 시스템

3.6.1 얼마를 걸 것인가 — Kelly

Kelly(1956)가 제시한 전략은 자산의 로그 기댓값을 최대화하는 베팅 비율을 알려줍니다. 고정 비율 전략이라 원리적으로 파산하지 않습니다.

$$\text{걸 비율 } k = EV / (\text{배당률} - 1)$$

예: $EV +20\%$, 배당 6.0배 $\rightarrow k = 0.20 / 5.0 = 4\%$ (자산의 4%)

Benter가 전액 Kelly를 말리는 세 가지 이유

우위를 두 배 과대추정하면 Kelly 베팅은 오히려 자산 성장률을 음수로 만듭니다. 그리고 실전에서 우위를 두 배 과대추정하는 일은 쉽게 일어납니다.

생활비나 이익 실현으로 자금을 빼 쓴다면 실효 자산은 장부상 자산보다 적습니다.

전액 Kelly는 자산의 50% 이상이 날아가는 하락 구간이 흔합니다. 그래서 권고액의 1/2 또는 1/3만 거는 부분 Kelly를 씁니다. 이 위험·수익 절충의 정량 분석은 MacLean, Ziemba & Blazenko(1992)에 있습니다.

3.6.2 자기 베팅이 자기 우위를 지웁니다

파리뮤추얼에서는 내가 건 돈이 그 말의 베팅 총액을 늘려 배당을 낮춥니다. 총풀 T, 그 말에 이미 걸린 금액 B, 환급 비율 ρ , 추가 베팅 x라 하면

$$O(x) \approx \rho(T + x) / (B + x)$$

x가 커질수록 분모가 더 빨리 늘어 기대 우위가 줄어듭니다

따라서 무한한 자금이 있어도 기대 이익을 최대로 만드는 베팅액에 상한이 존재합니다. Benter는 이것을 Kelly 비율과 별개의 핵심 문제로 다뤘습니다.

3.6.3 오늘날의 실행 경쟁 — CAW와 거래소

최신 경쟁의 핵심은 모델 점수가 아니라 주문 시각과 시장 충격으로 옮겨갔습니다.

- **CAW (Computer Assisted Wagering)** — 특정 알고리즘 이름이 아니라 고속 데이터·주문 인프라를 갖춘 운영 형태를 말합니다. NYRA는 2026년 정책에서 초당 6건을 넘는 실행을 CAW로 정의하고, 막판 배당 급변을 줄이기 위해 일부 풀에서 출발 1분 전 활동 중단을 요구했습니다.
- **Betfair 거래소 API** — 실시간 시장 데이터 읽기, 자동 주문, 주문 상태 확인, 시각이 찍힌 과거 데이터와 Stream API를 제공합니다. 거래소는 파리뮤추얼과 가격 형성 방식이 다르지만, '시점별 가격 데이터가 있어야 실행 가능한 백테스트가 된다'는 원칙은 같습니다.

3.7 복합승식으로 확장할 때 — 순서 확률

1등만이 아니라 '3등 안에 들 확률'이나 '1·2등 조합'을 구하려면 순서의 결합 확률이 필요합니다. 가장 단순한 형태가 Harville(1973) 공식입니다.

$$P(i가\ 1등,\ j가\ 2등) = p_i \times p_j / (1 - p_i)$$

i가 이기고 나면 남은 확률을 나머지 말끼리 다시 나눠 갖는다는 발상

이 공식은 계산이 간단하지만 알려진 결함이 있습니다. 인기마의 입상 확률을 체계적으로 과대평가하고 비인기마를 과소평가합니다. 원인은 가정에 있습니다. Harville 식은 주파 기록이 독립적인 지수분포나 극단값 분포를 따른다고 암묵적으로 가정하는데, 실제 경주 기록은 그렇지 않습니다.

보정 방식	가정	특징
Harville (1973)	지수·극단값 분포	가장 단순. 인기마 과대평가
Henery (1981)	정규분포	적합도는 좋으나 계산이 무거움
Stern (1990)	감마분포	위와 같음
Lo & Bacon-Shone	지수 할인 도입	실용적 절충. 널리 쓰임

Lo와 Bacon-Shone의 할인 형태는 이렇습니다.

$$P(2\text{등} = i \mid 1\text{등} = j) = q_i^\lambda / \sum q_k^\lambda$$

$\lambda = 1$ 이면 원래 Harville. $\lambda < 1$ 이면 인기마 몫을 덜 줍니다

그들이 제시한 값은 2등에 약 0.89, 3등에 약 0.80입니다. 우리 데이터로 최대우도 추정했을 때는 각각 0.80과 0.75가 나왔습니다.

한국 시장의 인기마 편향이 홍콩보다 크다는 뜻이고, 이 자체가 우리 프로젝트가 문헌에 더할 수 있는 관찰입니다.

3.8 시장을 이기지 못한 연구도 참고할 가치가 있습니다

문헌을 훑다 보면 '결국 시장을 못 이겼다'로 끝나는 연구가 대부분입니다. 그렇다고 참고 가치가 없는 것은 아닙니다. 결론과 방법론은 별개이기 때문입니다.

왜 참고하는가

결론이 부정적이어도 그 연구가 쓴 피쳐 설계, 검증 절차, 실패 원인의 진단은 그대로 쓸 수 있습니다.

오히려 '무엇을 해도 안 되더라'는 기록이야말로 우리가 같은 벽에 다시 부딪히지 않게 해 줍니다.

그리고 실무적으로 — 우리 발표에서 '선행연구도 같은 결론에 도달했다'는 것은 우리 결과가 구현 실패가 아니라는 가장 강한 근거입니다.

3.8.1 국내 연구

연구	무엇을 했나	결론	우리가 가져올 것
정준형 외 (2024) 응용통계연구 37(2) 서울대 통계학과	서울 경마에 point-wise와 pair-wise LTR 적용. 선형회귀·랜덤포레스트 대	pair-wise가 point-wise보다 우수. CatBoost Ranker 최고	경주기록을 거리로 표준화해 불균형을 해소한 전처리. 우리는 하지 않은 처리

연구	무엇을 했나	결론	우리가 가져올 것
	RankNet·LambdaMART(XGB/LGBM/CatBoost Ranker)		
So·Woo·Lee (2025) 한국컴퓨터정보학회논문 지 30(11) 명지대	KRA 2024.05~2025.04 자료 9,140건에 Listwise LambdaRank 적용. NDCG·MAP·MRR로 평가	CatBoost가 NDCG 0.8895·MAP 0.4204로 최고. 다만 실제 베팅 시나리오에서는 LightGBM·XGBoost가 적중률 우수	랭킹 지표와 베팅 적중률이 어긋난다는 관찰. 3.4절 경고의 실증
Choe 외 (2015) 응용통계연구 28(6)	국내 경마 우승마 예측에 통계 모형 적용	국내 경마 통계 모형 연구의 초기 문헌	위 두 논문이 모두 인용하는 출발점. 국내 계보를 설명할 때 필요
Park·Park·Song (2017) 응용통계연구 30(1)	경륜(사이클) 순위를 통계 예측 모형으로 분석	종목은 다르나 문제 구조가 동일	'다수가 동시에 경쟁하는 종목의 순위 예측'이라는 틀. 방법 이전 가능

세 국내 연구의 공통점이 하나 있습니다. **전부 시장 배당률을 기준선으로 쓰지 않습니다.** 순위 예측 자체가 목표라서 '시장을 이기는가'를 묻지 않습니다. 이 점에서 우리 프로젝트는 국내 선행연구보다 앞서 있습니다.

한 가지 더. 2024년 논문이 SHAP으로 뽑은 상위 변수에 출발훈련 횟수와 질병 진단횟수가 들어 있습니다. 우리 데이터의 train_runs_14와 clinic_30d에 정확히 대응하고, 우리 v5 합의형 중요도에서도 각각 5위와 15위입니다. 서로 독립적으로 같은 신호를 찾아냈다는 뜻이고, 우리 피쳐 설계가 틀리지 않았다는 방증입니다.

3.8.2 해외 연구·자료

문헌	핵심	우리가 가져올 것
Bolton & Chapman (1986)	다항 로짓 경마 모형의 원전. 200경주. 장기마 배제 제약 하에서 양의 기대수익 가능성 시사	모형 구조 자체. 그리고 '작은 표본으로도 방법론은 세울 수 있다'
Chapman, Still Searching for Positive Returns at the Track	홍콩 2,000경주로 후속 검증	같은 방법을 다른 시장에 옮겼을 때 무엇이 달라지는가
Gu·Huang·Benter (2003)	다항 프로빗으로 확장. 말 사이 상관관계를 다룸	로짓의 독립 가정이 한계일 때의 다음 수
Benter·Miel·Turnboug h (1996)	경주마의 거리 선호를 모델링	피쳐 공학의 정석 사례. 3.9절 참조
Kholkin 외 (2021)	도로 사이클 경기 결과를 LTR로 예측	경마 밖에서 같은 구조를 다룬 사례. 방법 이전 가능
Grinsztajn 외 (2022)	정형 데이터에서는 여전히 트리 모델이 딥러닝보다 낫다	우리 v5에서 딥러닝이 근소 우위였던 결과를 해석할 때의 대조군

문헌	핵심	우리가 가져올 것
Wong (2011), Precision	경마의 통계·수학적 방법을 정리한 실무서	구현 단계에서의 참고서
Chellal (2018), Bloomberg	Benter를 다룬 심층 기사	발표에서 배경 서사가 필요할 때

3.8.3 피쳐 공학에서 배울 구체적인 사례

Benter가 '거리 선호'라는 하나의 변수를 어떻게 정교하게 만들었는지 보면, 같은 개념도 설계에 따라 정보량이 크게 달라진다는 것을 알 수 있습니다.

출처	정의	정보량
Bolton & Chapman (1986)	직전 4경주 중 3경주를 1마일 미만에서 뛰었으면 1, 아니면 0	이진값 하나
Brecher (1980)	오늘 거리 $\pm 1/16$ 마일 안에서 상위 50% 또는 승자와 6.25마신 이내로 들어온 적이 있으면 1	이진값 하나, 조건이 더 정교
Benter의 모델	거리와 무관한 모든 요인으로 과거 각 경주의 예상 착순을 회귀로 구한 뒤, 실제 착순과의 잔차를 계산. 그 잔차와 '오늘 거리와의 유사도' 사이의 선형 관계를 추정하고, 표본이 적을 때의 불확실성으로 크기를 축소 보정	연속값 + 신뢰도 반영

여기서 배울 것

같은 '거리 적성'인데 첫 두 개는 0 또는 1이고, 세 번째는 잔차 기반 연속값에 표본 크기까지 반영합니다.

Benter는 '각 영역의 데이터에서 최대한 많은 정보를 뽑아내도록 변수를 정의하는 것이 중요하다'고 썼습니다. 모델을 바꾸는 것보다 변수 하나를 제대로 만드는 편이 나을 때가 많습니다.

우리 데이터의 hr_dist_winrate는 첫 번째에 가깝습니다. 잔차 기반으로 다시 만들 여지가 있습니다.

3.9 문헌 지형에서 우리 프로젝트의 위치

항목	문헌 표준	우리 프로젝트	격차
문제 단위	경주 후보집합을 직접 모델링	행 단위 이진분류 후 정규화	구조적
모델 계열	다항 로짓 / 프로빗 / listwise	GBDT 이진분류 + v5에서 listwise 일부	부분 충족
시장 사용	OOF 펀더멘탈 + 시점별 시장	확정 종가 + 고정 혼합비율	운영 누수 위험
결합 방식	$\alpha \cdot \beta$ 를 최대우도로 추정	$\lambda \cdot T$ 를 격차 탐색	유사하나 단순
평가 지표	pseudo- R^2 , ΔR^2	ROC-AUC, Log Loss, Brier	ΔR^2 미도입

항목	문헌 표준	우리 프로젝트	격차
확률 보정	구간별 calibration 확인	Platt·Isotonic 적용	충족
시간 분할	walk-forward	시간순 1회 분할	부분 충족
베팅 전략	부분 Kelly + 풀 충격 반영	상위 N% 균등 선택	미충족
실행 시스템	시점별 스냅샷·주문·감사	없음	미충족
복합승식	순서 확률 모형	단승에 집중	미착수

정리하면 — 우리는 **계층 ②와 ④의 초기 단계**에 있습니다. 방법론의 방향은 문헌과 같지만, 결합 방식이 단순하고 평가 지표가 다르며 실행 계층이 통째로 비어 있습니다.

4. 우리 프로젝트의 현재 좌표

4.1 데이터

한국마사회 공공데이터 API 11종에서 3년치를 수집했습니다.

구분	출전 행	경주	비고
원천 (final.csv.gz)	56,648	5,361	156개 열, 2023-08 ~ 2026-08
└ 서울	32,888	3,172	실제 분석에 사용
└ 부산경남	23,760	2,189	미사용

서울 데이터를 시간 순서대로 6:2:2로 잘랐습니다. 무작위로 섞지 않은 이유는 미래 경주 정보가 과거 학습에 새어 들어가는 것을 막기 위해서입니다.

구간	출전 행	경주	기간	용도
Train	19,617	1,891	2023-08 ~ 2025-05	모델 학습
Calibration	6,582	641	2025-05 ~ 2025-12	혼합비율·온도 선택
Final Test	6,639	635	2025-12 ~ 2026-08	최종 평가 (1회만)

Benter가 '모델 개발과 검증에는 500~1,000경주면 충분하고 1,000을 넘으면 표본 외 정확도가 극적으로 좋아지지는 않는다'고 한 기준에 비추면, 3,172경주는 충분한 규모입니다.

4.2 모델은 세 단계로 진화했습니다

1차 (2026-08-15) — 시장에 완패

모델	Test ROC-AUC	판정
로지스틱 회귀	0.5262	사실상 무작위
랜덤포레스트	0.7495	이 중 최선
XGBoost	0.6846	1착을 거의 못 잡음
시장 (배당률)	0.8168	기준선

여기서 세 갈래 후속 실험이 나왔습니다.

- **방향 1 · 확률 보정** — Platt Scaling으로 확률 오차를 0.3004에서 0.0121로 25배 개선. 단 AUC는 0.7495 그대로. 확률의 크기는 고쳤지만 순위를 가리는 능력은 안 변함

- **방향 2 · 2단계 모델** — 모델 확률·시장 확률·괴리를 피쳐로 넣어 재학습. 최고 0.7173으로 1단계보다 오히려 하락.
변수 중요도를 시장 확률이 독점
- **방향 3 · 이변 예측** — 목표를 '비인기마의 우승'으로 전환. AUC 0.6422지만 상위 10% 그룹의 이변 적중률이 23.8%로 전체 평균 13.2%의 1.81배

방향 2가 실패한 진짜 이유

확률 두 개와 그 차이를 그냥 피쳐로 넣어 트리 모델에 다시 학습시켰습니다. 그러니 시장 확률 하나가 중요도를 독점하고 모델 정보는 버려졌습니다.

Benter의 방식은 다릅니다. 로그 확률 두 개에 지수 $\alpha \cdot \beta$ 만 붙이는 2모수 모형이라, 모델 정보가 구조적으로 버려지지 않습니다.

즉 '결합은 안 된다'가 아니라 '결합 방식이 문헌 표준과 달랐다'가 정확한 진단입니다.

2차 (2026-08-18) — 피쳐 수 실험

'피쳐를 줄이면 일반화가 좋아진다'는 가설을 검증했다가 뒤집혔습니다.

피쳐 수	10	27	43	65	95	100
Valid AUC	0.6795	0.7242	0.7297	0.7510	0.7529	0.7504

95개가 최고였습니다. 시장도 단일 정보가 아니라 여러 약한 신호를 결합한 결과물이므로, 모델도 폭넓은 피쳐를 함께 써야 경쟁이 된다는 해석입니다.

3차 (2026-08-18) — revised_v5, 랭킹 학습 도입

모델	Valid AUC	Test AUC	경주당 1위 적중
Deep listwise ensemble	0.7636	0.7710	33.1%
Plackett-Luce hybrid	0.7515	0.7684	—
LightGBM rank+binary	0.7637	0.7552	29.8%
CatBoost ordered	0.7501	0.7508	—
Random Forest	0.7467	0.7507	—
XGBoost	0.7415	0.7419	—
시장	—	0.8122	37.4%

시장과의 격차가 1차 0.067에서 0.041로 좁혀졌습니다. LightGBM을 경주 단위 5-fold로 검증하면 0.7457 ± 0.0115가 나옵니다.

4.3 최종 모델 — 사실상 시장 그 자체

가장 최근 산출물은 XGBoost 확률과 시장 확률을 섞은 모델입니다. 혼합 비율 λ 와 온도 T 를 Calibration 구간에서 골랐고, 결과는 $\lambda=0.05$, $T=0.95$ 였습니다. 정리하면

$$p_{\text{final}} \propto (\text{시장 확률})^{1.0000} \times (\text{모델 확률})^{0.0526}$$

시장을 그대로 쓰고 모델은 5% 남짓만 얹은 형태

지표	시장 단독	최종 모델	차이
Race Log Loss	1.8173478	1.8134455	0.0039023 개선 (0.21%)
Multiclass Brier	0.7779196	0.7773180	0.0006015 개선 (0.08%)
경주당 1위 적중 (동률 보정 후)	238/635	238/635	동일

5,000회 경주 단위 부트스트랩에서 Log Loss 개선의 95% 신뢰구간은 [0.001085, 0.006721]로 0보다 컸습니다.

반면 Brier 개선은 [-0.000483, 0.001687]로 0을 포함했습니다. 사전에 정한 성공 조건은 두 지표 모두 하한이 0보다 클 것이었으므로 엄격한 기준으로는 미충족입니다.

모델이 시장 확률을 조정한 평균 폭은 0.00291, 최대 0.03153이었고, 635경주 중 최고 확률 말이 바뀐 경주는 8개뿐이었습니다.

4.4 두 독립 계산이 같은 값에 도달했습니다

서로 다른 데이터 분할, 다른 모델, 다른 결합 방식으로 계산했는데 결과가 사실상 같았습니다.

	격자 탐색 방식	최대우도 추정 방식
모델	XGBoost	LightGBM
결합 방법	$\lambda \cdot T$ 격자 탐색	$\alpha \cdot \beta$ 최대우도
시장 지수 β	1.0000	1.0002
모델 지수 α	0.0526	0.1401
양의 기대수익 후보	0건 (최대 0.9653)	1건 / 637경주

Race Log Loss로부터 pseudo- R^2 를 역산하면 이렇게 됩니다.

경주당 기준값 $L0 = \text{mean}(\ln n) = 2.342001$ (637경주, 평균 10.46두)

$$R^2(\text{시장}) = 1 - 1.8173478 / 2.342001 = 0.2240$$

$$R^2(\text{결합}) = 1 - 1.8134455 / 2.342001 = 0.2257$$

$$\Delta R^2 = +0.0017$$

독립적으로 다시 계산한 값 = +0.0018

차이가 0.0001입니다. 이 프로젝트가 시장에 더하고 있는 정보량은 $\Delta R^2 \approx 0.0018$ 로 확정됐다고 봐도 됩니다.

5. 왜 시장을 이기지 못하는가

여덟 가지 원인을 크기 순으로 정리했습니다. 앞의 셋은 구조적이라 바꾸기 어렵고, 뒤의 다섯은 설계로 고칠 수 있습니다.

5.1 정보 비대칭 — 부분집합이 합집합을 이길 수 없습니다

시장 확률은 베팅에 참여한 수만 명이 가진 정보를 전부 합친 결과입니다. 우리 모델이 쓰는 정보는 그 안에 포함됩니다.

정보 종류	우리 모델	시장
과거 성적·착순·기록	있음	있음
기수·조교사·마주 성적	있음	있음
훈련량·휴양일·진료 이력	있음	있음 (공개 자료)
당일 마필 컨디션	없음	현장 관찰자가 반영
마방의 의중·출전 목적	없음	관계자 자금이 반영
장비 변경의 실제 의미	부분적	경험자가 해석
직전 조교 상태	없음	일부 참가자가 관찰

Benter도 같은 말을 합니다. 통계 모형에 실용적으로 포함할 수 없는 유효한 펀더멘털 정보가 존재하며, 따라서 어떤 모형도 언제나 불완전하다는 것입니다.

실측 (서울 경마 test 637경주)

ROC-AUC 시장 0.8126 / 모델 0.7166 / 결합 0.8135

1위 적중률 시장 37.4% / 모델 25.6% / 결합 37.7%

5.2 공제율 장벽이 우리 신호보다 훨씬 큼니다

2장에서 본 조건을 다시 씁니다. 기대수익이 양수이려면 모델 확률이 시장 확률의 S배를 넘어야 하고, 우리 데이터에서 S는 약 1.25입니다.

필요 조건: $p / q > 1.25$

특정 말에 대해 시장보다 25% 높게 봐야 하고, 그 판단이 실제로 맞아야 함

그런데 우리 모델이 시장 확률을 조정한 평균 폭은 0.00291입니다. 시장이 10%로 본 말을 12.5%로 올려야 하는데, 실제로는 10.3%로 올리는 수준입니다.

ΔR^2 로 본 크기 비교

	ΔR^2	판정
Benter의 펀더멘털 모델 (홍콩, 실운용)	+0.0090	5년 중 4년 흑자
우리 프로젝트	+0.0018	수익선의 1/5
Benter의 신문 예상가 모델	+0.0002	무가치

실제로 걸었다면 어땠을까

결합 확률로 기대수익을 계산해 전 경주를 돌려봤습니다. 수수료와 배당 충격은 반영하지 않은, 모델에 가장 유리한 조건입니다.

베팅 규칙	베팅 수	적중률	ROI
결합확률 기대수익 > 1.0	1	0%	-100%
모델 단독 기대수익 > 1.0	3,977	3.82%	-21.95%
매 경주 1인기마	637	37.36%	-15.78%
매 경주 모델 1위	637	25.59%	-6.31%
전 마필 균등 베팅	6,650	9.56%	-22.50%

이 표에서 읽을 것

637경주 전체에서 걸 만한 후보가 단 1건이었고 그마저 빚나갔습니다. 격자 탐색 방식으로도 결과는 같았습니다 — 최대 기대우위 -3.47%, 후보 0건.

전 마필 균등 베팅의 -22.50%는 공제율 그 자체입니다. 어떤 규칙도 이 선을 크게 넘지 못합니다.

'매 경주 모델 1위'가 -6.31%로 가장 덜 잃지만, 637회 표본에서 표준오차가 약 6%포인트라 시장과 뚜렷이 구분되지는 않습니다.

5.3 결합 계수가 이미 답을 말하고 있습니다

두 독립 계산이 모두 $\beta \approx 1.0$, $\alpha \approx 0.05 \sim 0.14$ 를 내놨습니다. 이 숫자의 의미를 풀어 보면 이렇습니다.

$$p_{\text{final}} \propto q^{1.0} \times f^{0.05}$$

시장 확률을 그대로 쓰고, 모델은 0.05 제곱만큼만 곱한다

모델이 시장보다 2배 높게 본 말이 있다고 합시다. 최종 확률에 반영되는 배율은 $2^{0.05} = 1.035$, 즉 3.5%입니다.

공제율 장벽 25%를 넘으려면 모델이 시장보다 몇 배 높게 봐야 하는지 역산하면

$$1.25 = \text{배율}^{0.05} \rightarrow \text{배율} = 1.25^{20} \approx 87\text{배}$$

모델이 시장보다 87배 높게 본 말이 있어야 손익분기

그런 말은 존재하지 않습니다. α 가 이 정도로 작다는 것은 최적화가 '모델을 거의 믿지 말라'고 판정했다는 뜻이고, 그 판정 자체가 데이터에서 나온 결론입니다.

5.4 종가를 보고 판단하지만 종가를 예측하지는 않습니다

가장 과소평가된 문제입니다

우리가 쓰는 배당률은 발매 마감 후 확정된 종가입니다. 그런데 실제로 베팅하는 시점에는 그 종가를 알 수 없습니다.

이 문제는 두 방향으로 동시에 작동합니다.

1. **낙관 편향** — 종가를 입력으로 쓴 백테스트는 실제로는 알 수 없었던 정보를 쓴 것입니다. 그만큼 성과가 부풀려집니다.
2. **실행 실패** — 출발 5분 전에 +8% 기대수익으로 보이던 말이, 막판 자금이 몰리면 종가에서 -5%가 될 수 있습니다. 베팅은 이미 끝난 뒤입니다.

따라서 실전 우위를 얻으려면 두 개의 오차를 동시에 견뎌야 합니다.

	무엇을 예측하나	우리 상태
승률 예측 오차	이 말이 정말 이길 확률	모델 있음
종가 예측 오차	마감 시점에 배당이 얼마가 될까	모델 없음

Benter의 홍콩 시장에서는 이 문제가 상대적으로 작았습니다. 경주당 풀이 1,000만 달러를 넘어 배당 변동성이 낮았고, 그래서 최종 공개 배당을 정확히 추정할 수 있었다고 명시하고 있습니다. 우리는 그 조건이 아닙니다(5.6 절).

5.5 모델이 확률 분포를 날카롭게 만들어 기회를 지웁니다

모델을 섞으면 확률 분포가 뽀족해집니다. 인기마를 더 인기마로 만드는 방향입니다.

평균 엔트로피	1.8193 → 1.7931 (낮아짐 = 뽀족해짐)
최고확률 평균	0.3697 → 0.3788 (높아짐)

문제는 시장이 이미 과신하고 있는 구간에서도 이 일이 일어난다는 점입니다.

시장 확률 0.40 초과 구간

실제 승률	0.4645
시장 예측	0.5061 ← 이미 과대평가
결합 모델	0.5194 ← 더 밀어올림

우승마 배당 3배 이하 구간에서는 Log Loss가 개선되지만, 5~10배와 10배 초과 구간에서는 오히려 악화됐습니다.

왜 이것이 치명적인가

가치 베팅은 본질적으로 '시장이 과소평가한 말'을 찾는 일입니다. 그런 말은 대개 배당이 높습니다.

그런데 우리 모델은 배당이 낮은 인기마 구간에서 개선되고 고배당 구간에서 악화됩니다. 즉 평균 성능은 조금 좋아지면서 정작 돈이 되는 구간은 나빠지는 구조입니다.

평균 Log Loss 하나만 보면 이 문제가 보이지 않습니다. 반드시 배당 구간별로 나눠 봐야 합니다.

5.6 한국 단승 시장은 규모가 작아 실행이 어렵습니다

우위를 찾더라도 그것을 현금화하는 과정에서 스스로 우위를 지워버리는 구조입니다.

서울 경마 test 637경주 실측

경주당 단승 발매금액	평균 3,708만 원
경주당 전체 발매금액	평균 30억 원
단승이 차지하는 비중	1.2%

3.6.2절의 풀 충격 공식에 실제 숫자를 넣어 봅니다. 배당 10배인 말(그 말에 걸린 금액 약 297만 원)에 100만 원을 추가로 걸면

$$O(x) = 0.8 \times (37,080,000 + 1,000,000) / (2,970,000 + 1,000,000) \approx 7.7배$$

10배로 보고 걸었는데 실제로는 7.7배. 기대수익이 23% 깎임

	홍콩 (Benter, 1990년대)	서울 (우리 데이터)
경주당 단승 풀	1,000만 달러 이상	약 3,708만 원
100만 원 베팅의 비중	무시 가능	풀의 2.70%
막판 배당 안정성	낮은 변동성. 증가 추정 가능	소액에도 흔들림
결론	우위를 현금화할 수 있었음	우위가 실행 중에 소멸

5.7 시장은 시간이 갈수록 효율적으로 변합니다

Benter는 보고서 결론에서 스스로 이렇게 경고했습니다. 지금이 이런 시스템의 황금기이고, 컴퓨터 핸디캐퍼가 늘어나거나 경매 매체가 유능한 컴퓨터 레이팅을 발행하기 시작하면 시장이 그런 예측에 대해 효율적으로 바뀔 것이라고. 그리고 수익은 정교한 모델로 먼저 움직인 사람에게 돌아갔고 앞으로도 그럴 것이라고.

실제로 그의 데이터를 1986년부터 2023년까지 10년 단위로 재현한 분석에서, 대중의 확률 추정치가 매 10년 개선되는 것이 확인됐습니다.

우리에게 주는 의미

1990년대 홍콩에서 통했던 우위가 2020년대 서울에서도 통한다는 보장이 없습니다. 오히려 반대일 가능성이 큼니다. 따라서 '문헌에 성공 사례가 있으니 우리도 될 것'이라는 추론은 성립하지 않습니다. 시장 효율성은 시대와 장소에 따라 달라지는 경험적 문제입니다.

우리 결과는 '2020년대 서울 단승 시장은 공개 데이터 기반 모델로는 뚫기 어렵다'는 하나의 관측치입니다. 그 자체가 보고할 가치가 있습니다.

5.8 학습 목적과 평가 목적이 어긋나 있습니다

마지막은 설계 문제입니다. 우리 모델은 세 곳에서 목적이 불일치합니다.

단계	현재	문헌 표준	불일치의 결과
학습 손실	말 단위 이진 로그손실	경주 단위 로그우도	'승자는 하나' 제약을 못 봄
모델 선택	ROC-AUC	pseudo-R ² , ΔR ²	시장 대비 기여도를 못 잴
최종 판정	시장보다 높은가	시장에 무엇을 더하는가	잘못된 실패 판정

이 셋 중 마지막이 가장 큼니다. '**모델 AUC 0.77 < 시장 0.81**이므로 실패'라는 판정은 문헌 기준으로 성립하지 않습니다. Benter의 수익 모델도 단독 성능은 시장보다 낮았습니다(3.5.6절).

5.9 여덟 개 벽의 크기 비교

원인	성격	고칠 수 있나	우선순위
5.1 정보 비대칭	구조적	거의 불가	—
5.2 공제율 장벽	구조적	불가 (제도)	—
5.3 결합 계수가 작음	결과	5.8을 고치면 개선 여지	높음
5.4 증가 미예측	설계	가능 — 스냅샷 수집 필요	가장 높음
5.5 sharpening 편향	설계	가능 — 구간별 보정	높음
5.6 풀 규모	구조적	불가 (승식 변경은 별개)	—
5.7 시장 효율화 추세	구조적	불가	—
5.8 목적 불일치	설계	가능 — 손실·지표 교체	가장 높음

구조적 원인 넷은 우리가 어찌할 수 없습니다. 설계 원인 넷 중에서는 5.8(평가 지표와 학습 손실 교체)과 5.4(증가 예측)가 가장 값이 큼니다. 둘 다 더 복잡한 알고리즘이 아니라 문제 정의를 바꾸는 일입니다.

부록 A. 용어 사전

본문에서 처음 나올 때 설명했지만, 찾아보기 편하도록 한자리에 모았습니다.

A.1 경마 용어

용어	뜻
파리뮤추얼	참가자들이 낸 돈을 모아 주최측 몫을 댄 뒤 맞힌 사람끼리 나누는 방식. 한국 경마가 이 방식이며, 주최측은 결과에 이해관계가 없다
단승	1등을 맞히는 승식. 이 프로젝트의 주 대상
연승	정해진 순위 안에 드는 것을 맞히는 승식. 출주 두수에 따라 2착 또는 3착까지
복승·쌍승·삼복승	두 마리 또는 세 마리의 조합·순서를 맞히는 승식. 순서 확률 모형이 필요하다
배당률 (O)	1을 걸어 받는 금액. 6.0배면 1을 걸어 6을 받는다
종가	발매 마감 후 확정된 배당률. 베팅 시점에는 알 수 없다
공제율	주최측이 판돈에서 먼저 떼어가는 비율. 우리 데이터 단승 기준 약 20%
인기마 / 비인기마	배당률이 낮은 말 / 높은 말. 시장이 유력하다고 본 정도를 뜻한다
이변	비인기마가 우승하는 것. 우리 프로젝트에서는 인기 하위 50% 마필의 1착으로 정의
부담중량	말이 짊어지고 달리는 무게. 능력이 좋을수록 무겁게 준다
각질	선행형·추입형 등 말의 주행 스타일

A.2 통계·모델 용어

용어	뜻
오버라운드 S	한 경주의 1/배당률을 모두 더한 값. 1보다 큰 만큼이 가격 장벽. 우리 데이터 약 1.25
시장 확률 q	배당률을 확률로 바꾸고 경주 내 합이 1이 되게 맞춘 값
기대수익 EV	1을 걸었을 때 평균적으로 돌아오는 금액에서 1을 뺀 값. $p \times O - 1$
ROC-AUC	이길 말을 질 말보다 높게 매기는 능력. 0.5면 무작위, 1이면 완벽
Log Loss	확률 예측의 오차. 낮을수록 좋다. 정답에 낮은 확률을 준 만큼 벌점을 받는다
Brier score	예측 확률과 실제 결과의 제곱오차. Log Loss와 함께 쓰는 proper scoring rule
pseudo-R ²	무작위 추측 대비 얼마나 나아졌는지를 0~1로 표현. $1 - L(\text{모델})/L(\text{균등})$
ΔR^2	시장 단독 대비 모델을 결합했을 때 늘어난 R ² . Benter의 수익성 지표

용어	뜻
Calibration	예측 20%인 사건이 실제로 20% 일어나는 성질. '확률이 믿을 만한가'
Platt Scaling / Isotonic	확률을 실제 빈도에 맞게 교정하는 두 가지 방법
OOF	out-of-fold. 자기 자신을 학습에 쓰지 않은 모델이 만든 예측
다항 로짓	경주 안에서 확률의 합이 1이 되도록 만드는 모형. $p_i = \exp(u_i) / \sum \exp(u_j)$
LTR	Learning-to-Rank. 순위 자체를 학습 목표로 삼는 방법군
NDCG / MAP / MRR	랭킹 품질을 재는 지표들. 확률의 정확도와는 다른 것을 잴다
Harville 공식	1등 확률만으로 2·3등 확률을 순차적으로 계산하는 방법
엔트로피	확률 분포가 얼마나 퍼져 있는지. 낮을수록 뾰족하다
as-of 피쳐	특정 예측 시점까지 실제로 알려진 정보만으로 계산한 피쳐

A.3 베팅·운영 용어

용어	뜻
Kelly	우위가 있을 때 자산의 몇 %를 걸어야 성장률이 최대인지 알려주는 공식
부분 Kelly	모델 오차와 변동성을 줄이기 위해 Kelly 권고액의 1/2 또는 1/3만 거는 전략
풀 충격	내가 베팅해서 그 말의 최종 배당이 낮아지는 효과
no_bet	걸 만한 후보가 없다는 결론. 실패가 아니라 정상 출력
CAW	Computer Assisted Wagering. 고속 데이터와 자동 주문을 쓰는 운영 형태
Shadow mode	실제 돈을 걸지 않고 실시간처럼 예측·가상주문을 기록하는 검증
Slippage	예상한 가격과 실제 체결 가격의 차이

부록 B. 수식 모음

본문 2·3장의 식을 구현 순서대로 모았습니다.

B.1 배당률과 확률

개념	수식	우리 데이터 예시
암묵 확률	$1 / O$	배당 8.0배 → 12.5%
오버라운드	$S = \sum (1 / O_j)$	중앙값 1.2497
시장 확률	$q_i = (1 / O_i) / S$	경주 내 합 = 1
환급률	$1 / S$	약 80.02%

B.2 베틱 판단

개념	수식	해석
기대수익	$EV = p \times O - 1$	표시 배당이면 공제를 다시 빼지 않는다
손익분기 확률	$p_{break} = 1 / O$	이 확률을 넘어야 $EV > 0$
상대우위 조건	$p / q > S$	우리 데이터에서 약 1.25배
Kelly 비율	$k = EV / (O - 1)$	실전은 1/2~1/3만 적용
폴 충격	$O(x) \approx \rho(T + x) / (B + x)$	x가 커질수록 배당이 밀린다

B.3 확률 모형

개념	수식	비고
다항 로짓	$p_i = \exp(u_i) / \sum \exp(u_j)$	경주 내 합 = 1
Benter 결합	$c_i \propto f_i^\alpha \times q_i^\beta$	f는 반드시 out-of-sample
현 프로젝트 결합	$p \propto q^{1.0} \times m^{0.0526}$	$\lambda=0.05$, $T=0.95$ 적용 후
Harville	$P(i \text{ 1등}, j \text{ 2등}) = p_i \cdot p_j / (1 - p_i)$	인기마 과대평가 주의
할인 Harville	$P(2등=i \text{ 1등}=j) = q_i^\lambda / \sum q_k^\lambda$	$\lambda=1$ 이면 원래 Harville

B.4 평가 지표

개념	수식	우리 값
pseudo-R ²	$R^2 = 1 - L(\text{모델}) / L(1/n)$	시장 0.2294, 결합 0.2312
ΔR^2	$R^2(\text{결합}) - R^2(\text{시장})$	+0.0018
기준 로그손실	$L0 = \text{mean}(\ln n)$	2.342001 (평균 10.46두)

B.5 $\lambda \cdot T$ 표기와 $\alpha \cdot \beta$ 표기의 변환

우리 프로젝트는 혼합비율 λ 와 온도 T 로 표기했고, 문헌은 지수 $\alpha \cdot \beta$ 로 표기합니다. 서로 변환됩니다.

$$p_{\text{blend}} \propto q^{(1-\lambda)} \times m^{\lambda}, \quad p_{\text{final}} \propto p_{\text{blend}}^{(1/T)}$$

$$\rightarrow \text{최종 지수는 } \beta = (1-\lambda)/T, \quad \alpha = \lambda/T$$

$\lambda = 0.05, T = 0.95$ 대입

$$\beta = (1 - 0.05) / 0.95 = 1.0000$$

$$\alpha = 0.05 / 0.95 = 0.0526$$

부록 C. 참고 문헌

본문에서 인용한 순서가 아니라 계층별로 묶었습니다. 각 항목의 마지막 칸은 이 프로젝트에서 실제로 쓸 수 있는 부분입니다.

C.1 핵심 문헌 — 반드시 읽어야 할 셋

문헌	출처	핵심	우리에게
Benter, W. (1994) Computer Based Horse Race Handicapping and Wagering Systems: A Report	Efficiency of Racetrack Betting Markets 수록	다항 로짓 + 시장 2단계 결합. ΔR^2 , Kelly, 풀 충격까지. 5년 실운용 보고	이 보고서 3.5절 전체의 근거
Bolton, R. N. & Chapman, R. G. (1986) Searching for Positive Returns at the Track	Management Science 32(8) 1040-1060	경마 다항 로짓의 원전. 200경주. rank-ordered choice set 활용	모형 구조와 pseudo- R^2 정의
Lo, V. & Bacon-Shone, J. The Application of Ranking Probability Models to Racetrack Betting	Management Science 41(6) 1048	Harville 공식의 인기마 편향을 지수 할인으로 보정. 2등 0.89 / 3 등 0.80	복합승식 확장 시 필수. 우리 추정값 0.80 / 0.75

C.2 모형 확장

문헌	핵심	우리에게
Gu, M. G., Huang, C. Q. & Benter, W. (2003) Multinomial Probit Models for Competitive Horse Racing	로짓을 프로빗으로 교체. 말 사이 상관을 다룸	로짓의 독립 가정이 한계로 드러날 때의 대응 수
Benter, W., Miel, G. J. & Turnbough, P. D. (1996) Modelling Distance Preference in Thoroughbred Racehorses	거리 선호를 잔차 기반 연속값으로 정의	피쳐 공학의 정석 사례 (3.8.3절)
Harville, D. A. (1973)	1등 확률로 2·3등 확률을 순차 계산	가장 단순한 순서 확률 모형
Henery (1981) / Stern (1990)	주파 기록에 정규분포 / 감마분포 가정	적합도는 낮지만 계산이 무겁다
Kelly, J. L. (1956)	자산 로그 기댓값을 최대화하는 베팅 비율	베팅액 결정의 표준
MacLean, Ziemba & Blazenko (1992)	부분 Kelly의 위험·수익 절충을 정량 분석	실전 베팅 비율 결정 근거
Asch, P. & Quandt, R. (1986)	두 전문가의 판단을 결합하는 방법	Benter 결합식의 출처

C.3 국내 선행연구

문헌	출처	핵심	우리에게
정준형·신동욱·황세용·박건웅 (2024) Learning-to-rank 기법을 활용한 서울 경마경기 순위 예측	응용통계연구 37(2) 239-253 서울대 통계학과	서울 경마 LTR. pair-wise > point-wise. CatBoost Ranker 최고	우리와 데이터가 같다. 거리 표준화 전처리를 가져올 것
So, Y., Woo, E. & Lee, H. (2025) 머신러닝 기반 랭킹 학습(LTR) 기법을 활용한 경마 예측 및 웹 서비스 개발	한국컴퓨터정보학회논문지 30(11) 311-318 명지대	KRA 9,140건에 Listwise LambdaRank. CatBoost가 NDCG 최고이나 베틱 적응률은 LightGBM·XGBoost 우수	랭킹 지표와 베틱 성과가 어긋난다는 실증
Choe, H. 외 (2015) 경마 분석: 통계 모델을 이용한 경마 우승마 예측	응용통계연구 28(6) 1133-1146	국내 경마 통계 모형 연구의 초기 문헌	위 두 논문이 모두 인용하는 출발점
Park, G., Park, R. & Song, J. (2017) 통계적 예측모형을 이용한 경륜 순위 분석	응용통계연구 30(1) 25-39	경륜 순위 예측. 종목은 다르나 문제 구조가 동일	다수 경쟁 종목의 순위 예측 틀

C.4 랭킹 학습 구현

출처	제공 내용
XGBoost 공식 Learning to Rank 문서	qid 기반 그룹 지정, LambdaMART, rank:ndcg, rank:pairwise
LightGBM 공식 파라미터 문서	lambdarank, rank_xendcg 목적함수
CatBoost ranking objectives 문서	PairLogit, YetiRank, QuerySoftMax 등 groupwise·pairwise 목적
Kholkin 외 (2021), Frontiers in Sports and Active Living 3:714107	도로 사이클 경기 결과를 LTR로 예측한 사례
Grinsztajn, Oyallon & Varoquaux (2022), NeurIPS 35	정형 데이터에서 트리 모델이 여전히 딥러닝보다 나은 이유

C.5 시장·운영 자료

출처	제공 내용	우리에게
한국마사회 경마수익금 사용체제 (공식 경영공시)	전체 매출 기준 환급금 73%, 제세금 16%, 운영비용 7%, 이익금 4%	공제 구조의 공식 근거. 단승 증가 80%와는 다른 층위
Timeform, How the ratings for a race are calculated	파운드 단위 레이팅, 종량·연령·거리·주로·페이스 해석	설명 가능한 기초 피쳐 설계

출처	제공 내용	우리에게
Equibase, race products	Speed Figure와 구간별 Pace Figure의 공개 설명	원기록의 트랙·구간 보정 개념
Racing Post, Smart View	다속성 점수와 희소 전적 머신러닝. 점수는 승률이 아니라고 명시	'점수 ≠ 확률'의 실무 사례
NYRA, CAW guardrails (2026)	초당 6건 초과를 CAW로 정의. 일부 풀에서 출발 1분 전 활동 중단	실행 계층 경쟁의 현재 지형
Betfair Developers	실시간 시장 데이터, 자동 주문, 시각이 찍힌 과거 데이터, Stream API	시점별 가격 데이터의 표준 형태

C.6 실무서·기타

출처	내용
Wong, C. X. (2011), Precision: Statistical and Mathematical Methods in Horse Racing	경마의 통계·수학적 방법을 정리한 실무서
Chellal, K. (2018), The Gambler Who Cracked the Horse-Racing Code, Bloomberg Businessweek	Benter를 다룬 심층 기사. 발표 배경 서사용
Ali, M. (1977) / Figlewski, S. (1979)	Benter가 인용한 시장 편향·신문 예상이 관련 초기 연구
Brecher, S. (1980) / Epstein, R. (1977)	Benter가 인용한 핸디캐핑·도박 이론 문헌

부록 D. 데이터 출처와 해석상 주의

D.1 이 보고서의 수치 출처

수치 종류	출처	확인 방법
원천 데이터 규모	final.csv.gz	직접 로드해 행·열·경주 수 확인
배당률·시장 확률·오버라운드	final.csv.gz의 winOdds	경주별 재계산
모델 성능 (1차·2차·v5)	프로젝트 보고서 6종	HTML 파싱 후 수치 대조
λ ·T·Log Loss·Brier·부트스트랩	초판 보고서	산술 계산
α · β ·pseudo- R^2 · ΔR^2	이 보고서에서 직접 계산	Train 학습 → Calibration 추정 → Test 평가
베팅 시뮬레이션	이 보고서에서 직접 계산	637경주 전수
단승 풀 규모	전처리 데이터셋의 winAmt·totalAmt	경주 단위 집계
공제 구조 73%	한국마사회 공식 경영공시	공식 페이지 확인

D.2 해석상 주의

- 이 문서는 연구·모델 설계용이며 베팅을 권유하지 않습니다.
- 과거의 성과는 미래 수익을 보장하지 않습니다. Benter의 결과가 1990년대 홍콩에서 나왔다는 점을 반드시 함께 읽어야 합니다.
- 상용 서비스(Timeform, Equibase, Racing Post)의 내부 모델은 비공개이므로, 공개된 기능 설명만을 근거로 서술했습니다.
- 베팅 시뮬레이션 결과는 수수료·배당 충격·체결 실패를 반영하지 않은 값입니다. 실제 성과는 이보다 나쁩니다.
- KRA 공시의 73%는 전체 매출 구조이고, 우리가 계산한 약 80%는 특정 기간 단승 증가에서 역산한 암묵값입니다. 서로 다른 층위의 숫자입니다.
- 이 보고서의 α · β 와 ΔR^2 는 종가 배당률을 입력으로 사용해 계산했습니다. 5.4절에서 지적했듯 실제 베팅 시점에는 알 수 없는 정보이므로, 실전 우위의 상한으로 읽어야 합니다.

이 보고서의 결론을 한 문장으로

우리 프로젝트는 시장을 이기는 예측 모델이 아니라 시장 확률을 아주 조금 다듬는 보정기이며, 시장에 더한 정보량은

$\Delta R^2 \approx 0.0018$ 로 문헌상 수익선의 5분의 1이다. 이는 구현 실패가 아니라 2020년대 서울 단승 시장이 공개 데이터 기반 모델로는 뚫기 어려울 만큼 효율적이라는 측정 결과다.