

경주마 이변 예측 모델 최종 보고서

"배당률이라는 대중의 집단 예측을, 데이터 모델이 넘어설 수 있는가"

KHUDA 10기 토이프로젝트 3조

2026-08-23

팀원: 김찬진 · 윤우진 · 박준석 · 홍정의 · 이종원 · 전유림

0. 세 줄 요약

1. 승률 예측 모델(AUC 0.75)은 배당률 환산 시장 확률(AUC 0.82)을 넘지 못했다. 시장을 정면으로 이기는 건 불가능했다.
2. 방향을 전환해 "시장이 구조적으로 약한 구간"만 노리는 이변 예측 모델을 만들었다. 배당률(q)을 피처에서 제외한 다크호스 모델이 홀드아웃에서 ROI +101.6% (95% CI [+11.6%, +201.7%], 0 배제)로 통계적으로 유의한 유일한 조합이다.
3. 배당률을 피처로 포함하면 AUC가 0.645→0.742로 뛰지만, 해당 배당은 베팅 마감 후 확정되는 사후 정보라 실전 사용이 불가하다. 대신 "시장이 이미 반영한 정보량"을 재는 분석 도구와 이변만 패턴 분석에는 여전히 유용하다.

1. 순위예측에서 이번 모델로 전환한 배경과 타당성

1.1 프로젝트의 출발점

이 프로젝트의 원래 질문은 단순했다: "과거 데이터로 어떤 말이 이길지 예측할 수 있는가?"

한국마사회 공공데이터 API에서 서울+부경 56,648 출전행(2023-08~2026-08)을 수집하고, 156개 컬럼(마필 성적, 기수·조교사 통계, 훈련량, 부담중량 등)을 피쳐로 RandomForest 승률 예측 모델을 학습했다.

1.2 1단계 — 승률 예측 모델

모델	ROC-AUC	비고
RandomForest (우리 모델)	0.7495	156→111개 피쳐, 시간순 분할
배당률 환산 확률 (시장)	0.8170	$q = 1/\text{winOdds}$ 를 확률로 직접 사용

숫자 읽는 법: AUC 0.75면 "이길 말 vs 질 말"을 75% 정확도로 구분한다는 뜻. 시장(배당률)은 82%. 우리 모델이 시장보다 7%p 뒤쳐진다.

[핵심 발견] 피쳐를 20개로 줄여도, 100개로 늘려도 마찬가지였다. XGBoost, LightGBM으로 바꿔도 AUC 0.75 부근에서 정체. 피쳐 개수나 알고리즘의 문제가 아니었다.

1.3 2단계 — 시장과의 대조

배당률은 수만 명의 참여자가 자기 돈을 걸어 만든 "집단 지성 확률"이다. 파리뮤추얼 방식이라 주최측이 매긴 값이 아니라, 사람들이 어디에 얼마를 걸었는지의 결과다.

경마 배당률의 특수성:

- 환급률 약 80% (오버라운드 ~1.25)
- 배당이 낮을수록 "많은 사람이 이 말이 이긴다고 베팅한" 것
- 즉, 배당률 $\approx$ 대중의 승률 예측을 실시간 반영한 지표

대조 결과: 시장 AUC 0.817 > 모델 AUC 0.750. 어떤 조합을 시도해도 넘지 못했다.

1.4 3단계 — 시장을 따라잡으려는 시도

모델 예측을 시장 확률에 소량 섞고 온도 보정을 하면, Log Loss가 미세하게 개선됐다.

모델	Race Log Loss ↓	Top-1 적중률
시장 (M0)	1.8173	37.80%

M2 XGBoost 결합	1.8134	37.48%
---------------	--------	--------

개선폭 +0.0039, 부트스트랩 95% CI [+0.001, +0.007] — 0을 포함하지 않아 "통계적으로 유의한 개선"이긴 하다. 하지만:

- Top-1 적중률은 오히려 시장이 높음 (37.80% > 37.48%)
- 기대수익이 양수인 후보가 없어 베팅 정책은 no_bet
- 개선폭 0.0039는 공제율 약 20%를 넘기에 턱없이 작음

결론: "아주 약간 더 정확하게 맞히지만, 그 차이로 돈을 벌 수는 없다."

1.5 4단계 — 문헌 조사

선행 연구를 정리한 결과, 시장을 정면으로 이긴 사례가 사실상 없었다. 성공 사례로 알려진 논문들도 다음 중 하나에 해당했다:

- 수수료 전에만 플러스 (gross 기준)
- 특정 기간·특정 트랙에서만 재현
- 실시간 배당 정보를 사용 (우리가 쓸 수 없는 데이터)

핵심 인사이트: "시장 전체를 이기려 하지 말고, 시장이 약한 구간만 노려라."

1.6 5단계 — 방향 전환: 이번 예측

발상의 전환:

- 기존: "어떤 말이 이기는가?" → 시장이 이미 잘 맞히고 있음
- 전환: "시장이 과소평가한 말은 누구인가?" → 이번(upset) 예측

이번의 정의:

- 다크호스 (upset_B): 비인기마(pop_pct >= 0.50)가 3착 이내 입상
- 인기마 붕괴 (upset_A): 인기마(pop_pct <= 0.25)가 기대 이하 성적(fin_pct >= 0.50)

왜 이것이 타당한가:

1. 시장은 "평균적으로" 정확하지만, "극단 구간"에서는 체계적으로 편향이 있다
(favourite-longshot bias: 인기마를 과대평가, 비인기마를 과소평가하는 경향)
2. 이번은 "맞히기 어렵지만 맞추면 보상이 크다" — 적중률이 낮아도 배당이 높으면 수익
3. 시장이 반영하지 못하는 정보(최근 훈련량 변화, 기수 컨디션 등)가 이번에 더 크게 작용

1.7 전환의 타당성 요약

접근	결과	판정
시장 정면 도전 (승률 예측)	AUC 0.75 < 시장 0.82	실패
시장 결합 (확률 보정)	Log Loss 0.004 개선, 수익 불가	실질적 실패
이번 예측 (시장 약점 공략)	Lift 1.72배, 홀드아웃 유의	유의미한 성공

[프로젝트 전체 스토리] 시장을 이기겠다 → 실패 → 왜 못 이기지? → 시장이 매우 효율적 → 방향 전환 → 시장 전체가 아니라 시장이 틀리는 구간만 노리자 → 이번 예측 → 유의미한 결과

2. 데이터와 전처리

2.1 원천 데이터

항목	값
출처	한국마사회 공공데이터포털 API (API186_1, RC경마경주정보)
기간	2023-08-05 ~ 2026-08-09 (약 3년)
전체 규모	56,648 출전행 x 156열
서울	32,888행 (3,172경주) — 이번 예측 주 대상
부경(부산경남)	23,760행 (2,189경주) — 전이 검증 대상

2.2 타겟 변수

타겟	정의	기저율 (서울 test)	사용 용도
upset_B (다크호스)	pop_pct>=0.50 & place==1 (비인기마 입상)	13.55%	베팅 대상 — 연승 ROI 계산
upset_A (인기마붕괴)	pop_pct<=0.25 & fin_pct>=0.50 (인기마 부진)	25.45%	스크리닝 지표 — 경주 위험도 산출

중요: upset_B의 "입상"은 3착 이내를 뜻한다. 문서에 "1착"으로 잘못 기재됐었으나, 데이터 교차검증 결과 입상 비율 100% · 1착 비율 19.8%로 확인됨.

2.3 컬럼 분류 (src/pipeline/config.py)

그룹	개수	예시	처리
ID_COLS	17	rcNo, hrNo, rcDate	항상 제외
MARKET_COLS	16	winOdds, plcOdds, q, pop_pct	계보에 따라 제외/포함
DUAL_MARKET_COLS	5	pl_harville, gap_h	계보에 따라 제외/포함
OUTCOME_COLS	8	ord, place, upset_A, upset_B	항상 제외 (사후 정보)
나머지 피처	~110	마필/기수/조교사 통계, 훈련량 등	학습에 사용

2.4 시간순 분할

assign_time_split(): 경주일(rcDate) 기준 누적 행수 비율로 6:2:2 분할.

같은 경주가 두 fold에 걸치지 않도록 날짜 단위로 자른다.

- train 60%: 2023-08 ~ 2025-05 (모델 학습)
- valid 20%: 2025-05 ~ 2025-12 (하이퍼파라미터 선택)
- test 20%: 2025-12 ~ 2026-08 (최종 평가, 1회만)

왜 시간순으로 자르는가: 무작위 분할(train_test_split)을 쓰면 미래 정보가 학습에 섞여 들어간다.

경마 데이터는 시간에 따라 분포가 변하므로(시장 효율성 증가, 마필 세대 교체) 반드시

과거→미래 방향으로 잘라야 실전과 같은 조건이 된다.

2.5 전처리 상세

다크호스/인기마붕괴 모델 (배당률 제외):

- 서브셋: 다크호스는 pop_pct >= 0.50만, 인기마붕괴는 pop_pct <= 0.25만
- 피처 제외: ID + MARKET + DUAL_MARKET + OUTCOME 전부 (배당 정보 완전 배제)
- 결측치: 수치형 → train 중앙값 대체, 범주형 → "MISSING" 처리
- 인코딩: LabelEncoder
- 스케일링: 없음 (RF는 스케일 불변)
- 모델: RandomForest(n_estimators=600, max_depth=12/8, min_samples_leaf=50, class_weight 없음)

C모델 (배당률 포함, 분석용):

- 서브셋: pop_pct >= 0.50만
- 피처: q(배당률 암묵적 확률)를 포함, 나머지 배당 파생은 제거
- 추가 제거: 고상관 파생 23개(chaksun 계열 등)
- 결측치: 구조적 결측 26개 컬럼 0-fill → 나머지 중앙값
- 스케일링: StandardScaler (로지스틱 회귀와 같은 파이프라인 잔재)
- 모델: RandomForest(n_estimators=300, max_depth=10, min_samples_leaf=20, class_weight="balanced")

3.3 실시간 배당을 쓸 수는 없는가

조사 결과:

- data.go.kr 공공데이터 API: "확정배당" 계열만 존재. 실시간 API 없음
- race.kra.co.kr 웹 UI: 실시간 배당이 보이지만 공식 API가 아님
 - 웹 스크래핑은 한국마사회 이용약관 위반 + 불법 도박 조장 우려
- 결론: 합법적으로 마감 전 배당을 얻을 공식 경로가 없다

3.4 그렇다면 배당은 아예 쓸모없는가?

아니다. 두 가지 역할이 남아있다:

1. 정산용 (plcOdds): 모델이 "이 말에 베팅하라"고 결정한 뒤, 실제로 얼마를 회수하는지 계산할 때 쓴다. 이걸 "판단"이 아니라 "결과 계산"이므로 문제없다.
2. 분석용 (q 포함 모델): "시장이 이미 반영한 정보량이 얼마나 큰가"를 측정하고, "이변마의 공통 패턴"을 더 선명하게 보기 위한 도구로 사용. 이 역할은 6장에서 상세히 다룬다.

3.5 프로젝트 내 두 계보 정리

계보	배당률	실전 사용	이 보고서에서의 역할
배당 제외 모델 (계보1)	완전 배제	가능 ✓	4~5장: 실전 수익률의 근거
배당 포함 C모델 (계보2)	q 포함	불가 ✕	6장: 이변마 패턴 분석 도구

4. 배당률(q) 제외 이변 예측 모델의 수익률

4.1 다크호스 모델 (upset_B)

4.1.1 모델 성능

항목	값
대상	pop_pct >= 0.50 (비인기마) 서브셋
타겟	upset_B = 입상(3착 이내)
train / test	10,374 / 3,528
기저율	13.55%
AUC	0.6445
Lift@10%	1.70 (상위10% 적중률 23.0% vs 전체 13.6%)

4.1.2 수익 시뮬레이션 (test 전체, 352건 배팅)

전략: 모델 상위 10%에 연승 균등 배팅 (배당 필터 없음)

항목	값	숫자 읽는 법
배팅	352건 x 1만원	8개월간 총 352만원 투자
적중	81건 (적중률 23.0%)	무작위 대비 1.7배 정밀
평균 적중 배당	6.1배	맞추면 6.1만원 회수
ROI	+11.5%	352만원 → 약 392만원 (순수익 40만원)
95% CI	[-18.1%, +45.0%]	0을 포함 — "확실한 수익" 단정 불가
P(수익)	74.8%	4번 중 3번은 플러스, 1번은 마이너스

4.1.3 극단값 민감도

제외 건수	ROI	제거된 배당	회수액 비중
0건 (원본)	+11.5%	—	—
1건	+5.3%	22.9배	5.8%
3건	-4.1%	22.9, 18.0, 16.9배	14.7%
5건	-12.5%	+ 15.7, 15.3배	22.6%

해석: 상위 3건만 빠져도 흑자→적자 전환. 소수 고배당 의존 구조. 다만 C모델(260배 1건 제거 시 역전)보다는 분산돼 있다.

4.1.4 진짜 홀드아웃 (최근 8주, 단 1회 평가)

기존 test 마지막 8주(2026-06-14~08-09)를 떼어, 그 앞부분으로 재학습 후 1회만 평가:

항목	값	판정
베팅	83건	—
적중	~24건 (적중률 ~29%)	기저율 17.79% 대비 Lift 1.63
ROI	+101.6%	100만원 → 약 202만원
95% CI	[+11.6%, +201.7%]	0을 배제 — 통계적으로 유의 ✓
극단값	최고 22.9배, 고르게 분포	260배 같은 단일 의존 아님

[핵심] 이 프로젝트에서 "돈을 번다고 통계적으로 말할 수 있는" 유일한 조합이다. test 전체에서는 CI가 0을 포함했지만, 한 번도 안 쓴 홀드아웃에서는 유의하게 플러스.

4.2 인기마 붕괴 모델 (upset_A)

4.2.1 모델 성능

항목	값
대상	pop_pct <= 0.25 (인기마) 서브셋
타겟	upset_A = 기대 이하 성적
train / test	5,597 / 1,902
기저율	25.45%
AUC (RF)	0.5774
AUC (XGBoost, 참고)	0.5888
Lift@10% (RF)	1.32

4.2.2 인기마붕괴의 역할 — "베팅 대상"이 아니라 "스크리닝 도구"

인기마붕괴 모델은 다크호스와 달리 직접 베팅하는 대상이 아니다.

인기마가 "무너질 확률"을 예측해서, 다크호스 베팅의 보조 지표로 활용한다.

활용 방법:

- 경주별로 인기마 붕괴 위험을 산출
- 붕괴 위험이 낮은(인기마가 안정적인) 경주에서만 다크호스 베팅 → ROI 개선

4.2.3 선별력 부트스트랩

항목	값
Lift@10% 점추정	1.32
부트스트랩 95% CI	[1.07, 1.59]
1.0 포함 여부	미포함 — test에서는 유의 ✓

P(Lift > 1)	99.2%
-------------	-------

4.2.4 홀드아웃에서는 유의성 상실

항목	test 전체	홀드아웃 (최근 8주)
표본	1,902건	457건
Lift@10%	1.32	1.22
95% CI	[1.07, 1.59] — 유의	[0.83, 1.77] — 1.0 포함, 유의하지 않음
판정	무작위보다 낮다	신호의 통계적 유의성 상실

결론: 인기마봉괴 모델은 서울 test에서는 유의했지만, 홀드아웃에서는 유의성을 잃었다.
다크호스보다 신뢰도가 낮다.

4.3 다크호스 + 인기마봉괴 조합 전략

아이디어: "인기마가 안정적인 경주"에서만 다크호스 베팅 → 적중률 개선 기대

전략	베팅	적중	ROI
기준 (필터 없음, 상위10%)	352	81	+11.5%
붕괴위험 하위30% 경주만	107	25	+36.4%
붕괴위험 하위50% 경주만	181	40	+18.5%
붕괴위험 하위70% 경주만	248	53	+13.7%

패턴: 붕괴위험이 낮은 경주로 좁힐수록 ROI 개선(+11.5% → +36.4%).

다만 이 결과는 test에서만 확인됐고, 홀드아웃 미검증 — "유망한 후보"로만 취급.

4.4 배분 전략 비교

전략	ROI	최대 배분	최소 배분
Flat (균등)	+11.5%	1.00	1.00
EV 비례	+102.8%	6.85	0.21
확률 비례	+14.0%	1.25	0.92
Half-Kelly	+116.2%	4.08	0.37

EV/Kelly가 높게 나왔지만, 기준 ROI 자체가 소수 고배당 의존이라 비례 배분은 그 불안정성을 증폭시킨다. 실무 권장: Flat(균등) 유지.

4.5 배당구간 필터 — 시도 후 기각

test에서 $plcOdds \geq 10$ 배 + 상위10%를 적용하면 ROI +268.6%까지 나왔지만,

홀드아웃 적용 결과: 16건 베팅 중 3건 적중, CI [-100%, +7758%] — 완전 무의미.

→ 배당구간 필터 기각. "필터 없음 + 상위10% + 균등배분" 확정.

5. 추가 검증 및 부경(부산경남) 전이

5.1 통합 분류기 실험 — 서브셋 구조의 정당성

"pop_pct로 미리 나누지 않고 전체 말을 한 번에 학습하면?" 을 실험:

유형	예산	기존(서브셋+전용 모델)	통합분류기	차이
다크호스형	352건	81건 적중	35건 적중	-46건
인기마붕괴형	190건	64건 적중	39건 적중	-25건

통합 분류기가 압도적으로 나쁘다. 인기마 서브셋으로 평가를 제한하면 AUC가 0.4451(무작위 이하)까지 추락.

이유: 인기도로 미리 안 나누면 모델이 "이 말이 인기마인가?"부터 배워야 해서, "왜 무너지는가?"라는 세밀한 신호에 집중할 여력이 없다.

결론: 현재의 2단계 구조(인기도 기반 서브셋 → 전용 모델)가 올바른 설계.

5.2 부경 전이 검증

서울에서 학습한 모델을 부경에 적용할 수 있는가? 두 시나리오 비교:

지표	서울(자체)	A(그대로 적용)	B(부경 재학습)
다크호스 Lift@10%	1.70	1.48	1.66
다크호스 ROI	+11.5%	-24.1% (유의한 손해)	-19.8% (유의하지 않음)
인기마붕괴 Lift@10%	1.32	1.43 (유의)	1.18 (유의하지 않음)

[모델별로 결론이 다르다] 다크호스: 부경은 재학습(B)이 안전. 그대로 적용(A)하면 유의한 손해.

인기마붕괴: 오히려 서울 모델 그대로(A)가 더 나음. 재학습하면 유의성 상실.

→ 하나의 정책으로 뭉뚱그릴 수 없다.

왜 이런 차이가 나는가:

- 다크호스 예측 = "드문 사건을 좁게 짚어내는 고정밀 문제" → 트랙별 미세 차이에 민감
- 인기마붕괴 예측 = "상대적으로 넓은 패턴" → 트랙 간 전이가 잘 됨
- train_runs_14(최근 훈련량) 분포가 서울 vs 부경에서 확연히 다름($d=-0.46$)

5.3 C모델(q 포함)의 추가 검증

C모델도 같은 프레임으로 검증한 결과:

항목	C모델 (q 포함)	다크호스 (q 제외)
test ROI	+32.0%	+11.5%
test CI	[-19.2%, +91.7%] 0 포함	[-18.1%, +45.0%] 0 포함
홀드아웃 ROI	+21.2%	+101.6%
홀드아웃 CI	[-74.0%, +140.2%] 0 포함	[+11.6%, +201.7%] 0 미포함 ✓
부경 재학습 ROI	-44.6%	-19.8%

역설: C모델이 AUC는 더 높지만(0.742 vs 0.645), 홀드아웃에서는 유의하지 않고 부경에서는 더 크게 악화된다. "정확도"와 "실전 수익"은 다른 차원.

6. 이번마 공통 패턴 분석

(배당률 포함 C모델 기준 — 왜 배당률을 포함해야 하는지 아래 설명)

6.1 왜 패턴 분석에는 배당률을 포함하는가

3장에서 배당률을 "실전 예측 피쳐"로 쓰면 안 된다고 했다. 그런데 "이번마의 공통점이 뭔가?"를 분석할 때는 오히려 배당률을 포함해야 한다.

이유:

1. 배당률 = 시장의 평가. "시장이 이 말을 얼마나 과소평가했는가"를 정량화하려면 배당률이 있어야 한다. 없으면 "과소평가"의 정도를 잴 수 없다.
2. 의사결정나무로 "어떤 조건일 때 이번이 많은가" 규칙을 뽑으려면, 배당률을 포함시켜야 "같은 배당대 안에서 뭐가 다른가"까지 보여줄 수 있다.
3. 군집화로 이번마 유형을 나눌 때, 배당률 축이 있어야 "이 유형은 시장이 약간만 과소평가한 그룹" vs "완전히 무시한 그룹"을 구분할 수 있다.

요약: 예측(실전 도구)에는 못 쓰지만, 해석(왜 이번이 일어나는가)에는 필수다.

6.2 다크호스 인사이트 (C모델, q 포함)

6.2.1 피쳐 비교 — 이번마 vs 비이번마

test셋 비인기마 3,528마리 중 이번(1착) 94마리 vs 비이번 3,434마리의 피쳐 평균 비교:

순위	피쳐	이번마가...	해석
1	q (배당률 확률)	높음	"같은 비인기마 중에서도 배당이 상대적으로 낮은 쪽"
2	age	낮음	젊은 말
3	clinic_30d	높음	최근 30일 진료 건수 많음 (컨디션 관리)
4	hr_last_resid	높음	직전 경주에서 기대 이상 성적
5	tr_resid	높음	조교사 잔차 높음 (좋은 조교사)
6	tr_plcrate	높음	조교사 입상률 높음

7	train_runs_14	높음	최근 2주 훈련량 많음
8	hr_last_poppct	높음	직전엔 더 인기였음 (이번에 인기 하락)

[한 문장 프로필] "실력과 컨디션은 좋은데(젊고, 훈련 많고, 조교사 좋고, 직전에도 잘 뛰었는데)
시장이 최근 인기 하락에 과잉 반응해서 배당이 올라간 말."

6.2.2 이변마의 3가지 유형 (K-means 군집화)

이변 495마리를 K-means(k=3, 실루엣 0.072)로 군집화한 결과:

유형	비율	특징	예측 난이도
데뷔형	10%	출전 이력 없음 — 정보 비대칭	어려움 (과거 데이터 없음)
베테랑 복귀형	39%	최근 부진했으나 조교사·훈련량 유지	모델이 가장 잘 잡는 유형
신예 깜짝형	51%	아직 안 알려진 실력자	가장 예측 어려움

발표 포인트: "시장이 최근 부진에 과잉 반응할 때 기회가 생긴다" — 베테랑 복귀형이 모델의
주요 수익원.

6.2.3 의사결정나무 규칙

해석 가능한 규칙(depth=4, AUC 0.7065)의 첫 분기:

$q > 0.25$ (z점수) → 이변 가능성 UP

$q \leq 0.25$ → 이변 가능성 DOWN

해석: "같은 비인기마 중에서도 배당이 약간 낮은 쪽(=시장이 약간은 인정한 쪽)에서 이변이 더
많다." 즉, 극비인기(50배+)보다 중간 비인기(10~20배)가 이변의 주 무대.

6.2.4 배당 구간별 이변마 프로필

구간	이변 특징	해석
10~15배	원래 실력 있는데 살짝 인기에서 빠진 말	가장 안전한 이변
15~30배	진료 건수 최고 — 컨디션 관리 열심히	준비된 이변
50배+	조교사 잔차·직전 잔차 최고	무명마의 깜짝 — 예측 어려움

6.3 인기마 붕괴 인사이트

6.3.1 배당률(q) ablation 결과

피쳐셋	피쳐 수	AUC	Lift@10%	95% CI
A (q만)	1	0.626	1.57	[1.26, 1.79]
B (기존, q 없음)	108	0.579	1.32	[1.06, 1.56]
C (B+q)	109	0.629	1.49	[1.24, 1.75]

다크호스와의 차이점:

- 다크호스: C(q+피쳐)가 AUC-Lift 모두 최고 → 피쳐를 더하면 확실히 좋아짐
- 인기마붕괴: AUC는 C가 최고이지만, Lift@10%는 A(q만, 1.57)가 C(1.49)보다 높음!

의미: 인기마붕괴에서는 110개 피쳐를 추가해도 "상위 10% 후보의 정밀도"가 오히려 떨어진다.
인기마에 대해서는 시장(배당률)이 이미 대부분의 정보를 반영하고 있어서, 추가 피쳐가 잡음으로 작용한다.

6.3.2 학습 범위 실험 — 왜 서브셋이 필수인가

학습 범위	test AUC	비고
전체 + upset_A 라벨	0.4451	무작위보다 나쁨!
전체 + 1착 라벨	0.4302	더 나쁨
부분집합(인기마만) + upset_A (채택)	0.5789	유의미

전체 데이터로 학습하면 AUC 0.445 — 동전 던지기보다 못하다.

이유: 비인기마는 정의상 upset_A가 항상 0이므로, 전체로 학습하면 모델이 "이 말이 인기마인지 아닌지"만 배우고, 정작 "인기마인데 왜 무너지는가"를 못 배운다.

이것이 2장에서 설명한 "서브셋 구조의 정당성"의 수치적 근거다.

6.4 배당률 포함 분석이 주는 실전 인사이트

배당률 포함 분석에서 얻은 핵심 교훈 3가지:

1. "배당 10~50배가 스위트 스팟이다"

- 10배 미만: 시장이 어느 정도 인정 → 우위 작음
- 10~50배: 시장이 과소평가했지만 실력은 있음 → 수익 발생

→ 50배+: 순수 운 영역 → 모델도 구분 못함

2. "시장의 과잉 반응을 잡는 게 모델의 역할"

→ 이번마는 "실력-인기 괴리"가 큰 말이다

→ 시장이 최근 부진·인기 하락에 과잉 반응한 틈을 포착

3. "인기마 정보는 시장이 이미 다 반영했다"

→ 인기마붕괴는 q만 써도 Lift 1.57 — 추가 피쳐 불필요

→ 비인기마(다크호스)에서만 추가 피쳐가 실질적 가치를 가짐

7. 최종 결론

7.1 프로젝트 전체 여정 요약

단계	무엇을 했나	결과	교훈
1	승률 예측 (RF)	AUC 0.75	시장(0.82)을 못 넘음
2	시장과 정면 대조	7%p 열위 확인	시장은 매우 효율적
3	시장 확률 결합/보정	Log Loss 0.004 ↓	수수료 이기기엔 턱없이 작음
4	문헌 조사	성공 사례 없음	"약한 구간"만 노리라는 인사이트
5	이변 예측으로 전환	Lift 1.72배	유의미한 신호 확인
6	신뢰성 재검증	홀드아웃 ROI +101.6%	다크호스만 유의
7	패턴 분석 + 전략 확정	최종 전략 도출	필터 없음+상위10%+균등배분

7.2 모델별 최종 판정

모델	상태	근거	실전 사용
다크호스 (q 제외)	채택 ✓	홀드아웃 유의, 극단값 비의존	가능
인기마붕괴 (q 제외)	보조 지표로 활용	test 유의하나 홀드아웃 유의성 상실	조합 전략의 필터로 사용
C모델 (q 포함)	분석 참고 도구	q=사후정보로 실전 불가	패턴 분석·인사이트 전용

7.3 최종 실전 전략

[확정된 전략] 다크호스 모델(q 미포함, RF) + "배당 필터 없음 + 상위10% + 균등배분"

대상: 서울 경마장, 비인기마(인기 하위 50%), 연승 베팅

홀드아웃 ROI: +101.6%, 95% CI [+11.6%, +201.7%] — 0을 배제하여 통계적으로 유의

실전 운용 요점:

- 매 경주 비인기마 전체 중 모델 상위 10% 선택
- 각 건 균등 금액 연승 베팅 (자금의 1~2%를 1건 상한으로)
- 대부분의 날은 소폭 손실, 가끔 큰 적중 — "역 방향 복권" 패턴
- 최소 3개월 이상 운용해야 양의 기대값이 실현됨

7.4 핵심 발견 (발표용)

1. 시장을 정면으로 이기는 건 불가능하다
→ 배당률 환산 확률(AUC 0.82)을 어떤 모델도 넘지 못했다.
2. 시장이 "구조적으로 약한 구간"은 존재한다
→ 비인기마 중 "실력 있는데 과소평가된 말"을 구분하는 건 가능.
3. 배당률의 역설
→ 피쳐로 쓰면 AUC 0.74까지 올라가지만, 실전에는 쓸 수 없다(사후 정보).
→ 배당률 없이도 기수·훈련량·과거성적만으로 유의미한 수익을 낼 수 있다.
4. "정확도"와 "수익"은 다른 차원이다
→ C모델(AUC 0.74)은 홀드아웃에서 유의하지 않고,
→ 배당 제외 모델(AUC 0.64)이 유일하게 홀드아웃에서 유의했다.
5. 모델의 가치는 "예측"이 아니라 "필터"에 있다
→ 이길 말을 맞히는 게 아니라, 시장이 놓친 후보를 효율적으로 걸러내는 도구.

7.5 한계와 다음 과제

한계:

1. 홀드아웃 83건 · 8주 · 1회 관측 — 우연 가능성 배제 불가
2. test ROI의 CI가 0 포함 — 장기적으로 확실히 플러스인지 미확인
3. 고배당 3건 제거 시 적자 전환 — 소수 사건 의존 구조 잔존
4. 서울 한정 — 부경은 재학습 필요하고, 재학습해도 유의성 미달
5. 결측치 처리 구현 차이 — 원본 코드 vs 재구현 간 미세 차이 존재

다음 과제:

1. 붕괴모델 조합 전략(ROI +36.4%)의 홀드아웃 검증
2. 배당구간 필터를 valid에서 먼저 고르는 재설계
3. 3~6개월 추가 데이터 확보 후 반복 검증
4. 실시간 배당 확보 합법 경로 조사 (가능하다면)
5. 인기마붕괴: 피쳐 축소(q만 or 소수) 버전의 실전 가치 재평가

부록 A. 재현 코드 경로

경로	내용
src/model_selection_validation/	다크호스/인기마붕괴 재현, 부트스트랩, 홀드아웃, 통합분류기, q ablation
src/c_model_validation/	C모델 재현, 검증, 부경 전이
src/busan_validation/	부경 기초비교, 시나리오 A/B
src/darkhorse_final/	배당구간 필터, 인사이트, 붕괴 조합, 배분전략
src/upset_with_odds/	C모델 원본 파이프라인 (08~14)
results/final_validation/	계보1 결과 전체
results/c_model_validation/	C모델 결과
results/busan_validation/	부경 결과
results/darkhorse_final/	다크호스 완결 결과
results/upset_A/	인기마붕괴 결과, q ablation

부록 B. 용어 사전

용어	뜻
AUC (ROC-AUC)	분류기의 판별력. 0.5=무작위, 1.0=완벽. "이길 말과 질 말을 구분하는 능력"
Lift@10%	상위 10% 예측의 적중률 ÷ 전체 평균 적중률. 1.0이면 무작위와 동일
ROI	(총회수 - 총투자) / 총투자 x 100%. +면 이익, -면 손해
95% 신뢰구간 (CI)	"95% 확률로 진짜 값이 이 범위 안". 0(or 1)을 포함하면 유의하지 않음
부트스트랩	데이터를 복원추출로 반복 뽑아 결과 변동폭을 추정하는 방법
홀드아웃	모델 선택에 전혀 안 쓰고 마지막에 1회만 평가하는 데이터
q	배당률의 역수(1/winOdds). 시장이 추정한 암묵적 승률
pop_pct	경주 내 인기 백분위 (배당 기준). 0에 가까울수록 인기마
upset_B	비인기마(pop_pct>=0.50)가 3착 이내 입상한 사건
upset_A	인기마(pop_pct<=0.25)가 기대 이하 성적을 낸 사건
파리뮤추얼	배당이 배팅 참여자 금액 비율로 결정되는 방식.

	마사회 방식
연승	3착 이내 입상에 베팅. 단승(1착)보다 배당 낮고 적중률 높음
Max Drawdown	수익 최고점에서 최저점까지의 낙폭. 위험 지표
Cohen's d	두 그룹 평균 차이를 표준편차로 나눈 효과크기. 0.2=작음, 0.5=중간, 0.8=큼

부록 c. 전체 배당구간 필터 그리드 (q 제외 모델, 28개 조합)

필터	Top%	베팅	적중	적중률	평균배당	ROI	P(수익)	유의
전체 (필터 없음)	5%	176	42	23.9%	4.8	+28.6%	87%	
전체 (필터 없음)	10%	352	81	23.0%	5.1	+11.5%	73%	
전체 (필터 없음)	20%	705	160	22.7%	5.1	+9.8%	79%	
전체 (필터 없음)	30%	1058	212	20.0%	5.1	-3.6%	32%	
plcOdds >= 3배	5%	93	21	22.6%	7.4	+99.6%	99%	✓
plcOdds >= 3배	10%	187	43	23.0%	7.8	+67.8%	100%	✓
plcOdds >= 3배	20%	375	81	21.6%	7.8	+66.7%	100%	✓
plcOdds >= 3배	30%	563	110	19.5%	7.7	+44.8%	100%	✓
plcOdds >= 5배	5%	56	14	25.0%	10.3	+205.4%	100%	✓
plcOdds >= 5배	10%	112	24	21.4%	10.6	+121.7%	100%	✓
plcOdds >= 5배	20%	224	43	19.2%	10.7	+116.2%	100%	✓
plcOdds >= 5배	30%	336	60	17.9%	10.5	+88.7%	100%	✓
plcOdds	5%	21	7	33.3%	14.9	+423.3%	100%	✓

>= 10배								
plcOdds >= 10배	10%	43	11	25.6%	15.4	+268.6%	100%	✓
plcOdds >= 10배	20%	87	19	21.8%	15.8	+253.9%	100%	✓
plcOdds >= 10배	30%	131	25	19.1%	15.7	+194.3%	100%	✓
plcOdds 3~10배	5%	71	14	19.7%	5.2	+6.6%	60%	
plcOdds 3~10배	10%	143	32	22.4%	5.2	+8.5%	69%	
plcOdds 3~10배	20%	287	62	21.6%	5.3	+10.5%	79%	
plcOdds 3~10배	30%	431	86	20.0%	5.2	+1.5%	53%	
plcOdds 5~15배	5%	46	9	19.6%	8.7	+78.7%	93%	
plcOdds 5~15배	10%	93	19	20.4%	8.4	+71.5%	98%	✓
plcOdds 5~15배	20%	186	34	18.3%	8.5	+55.9%	99%	✓
plcOdds 5~15배	30%	279	51	18.3%	8.4	+54.2%	100%	✓
plcOdds 5~20배	5%	52	13	25.0%	9.6	+184.8%	99%	✓
plcOdds 5~20배	10%	104	23	22.1%	9.4	+116.7%	100%	✓
plcOdds 5~20배	20%	209	41	19.6%	9.7	+100.5%	100%	✓
plcOdds 5~20배	30%	313	57	18.2%	9.5	+78.6%	100%	✓