

Git 데이터셋 vs 현재 v11 전처리 품질

상관 중복 · 문자열 수치화 · 표준화 · 결측/무한값 · 경주 보존을 같은 기준으로 직접 감사

최종 판정

현재 사용 중인 **revised_v11** 서울+부경 모델 행렬이 더 잘 전처리돼 있다. Git의 canonical 파일 프레임도 문자열 인코딩·결측 대치·모델별 스케일링을 학습구간에서 수행하지만, 상관 중복 제거가 구현돼 있지 않고 저장된 canonical 파일 자체는 아직 문자열과 결측을 가진 interim 자료다. Git의 v1~v8은 과거 재현 전용이며 v5~v8은 경주 일부 행 삭제로 사용 금지다.

1. 비교 기준

- **상관 중복:** train에서 $|\text{Pearson } r| \geq 0.95$ 및 거의 완전상관을 계산했다.
- **수치화:** 실제 모델 입력에 문자열 dtype이 남는지 확인했다.
- **표준화:** 연속형 train 열의 평균 0·표준편차 1 여부와 변환 적합 범위를 확인했다.
- **결측:** 모델 입력의 $\text{NaN} \cdot \pm\infty$ 를 전수 계산했다.
- **경주 무결성:** 일부 말만 행 삭제하는지, 시간순·경주 단위가 보존되는지 확인했다.

2. 핵심 직접 측정

항목	Git canonical	현재 v11	판정
형태	서울 interim + 실행 시 transformer	서울+부경 완성 모델 행렬	용도가 다름
모델 피 처	112개 등록 → OHE 후 554열	141열	단순 개수로 우열 판단 불가
문자열	원천 피처 13개, 변환 후 0개	저장 행렬 0개	둘 다 end-to-end 통과; v11은 즉시 사용 가능
결측/무 한값	train 원천 결측 100,754셀, 변환 후 NaN 0-∞ 0	전 split NaN 0-∞ 0	둘 다 모델 입력에서는 0
$ r \geq 0.95$	변환 전 숫자피처 25쌍; 제거 로직 없음	제거 전 16쌍 → 후 0쌍	v11 우세
거의 $r=1$	4쌍	0쌍	v11 우세 또는 동률
표준화	로지스틱은 train-fit StandardScaler; XGB/ranker는 의도적으로 미적용	연속/수치 127열 평균 0·표준편 차 1; 지시자/OHE는 원형 유지	둘 다 모델 목적에는 타 당, v11이 더 일관·명시 적
원핫 기 준열	모든 범주 유지	기준열 1개 제거	선형 다중공선성은 v11 우세

3. 상관관계 세부

Git train 상위 관계: chaksun1↔chaksun2 (1.000), buga1↔buga2 (1.000), buga1↔buga3 (1.000). 현재 v11 상위 잔존 관계: jk_winrate_z↔jk_winrate_pr (0.938), rating↔hr_prev_rating (0.928), jk_winrate↔te_jkName (0.912). v11은 train에서만 상관판정을 적합해 16쌍을 제거하고 $|r| \geq 0.95$ 잔존쌍을 0으로 만들었다. 이 결과는 manifest 기록뿐 아니라 저장 train 행렬을 다시 읽어 독립 계산했다.

4. Git 과거 v1~v8 파일 감사

버전	정책	행	문자열 열	결측셀	train $ r \geq .95$	경주 구조
v1_base	legacy_read_only	32,888	22	0	0	보존
v2_standard	legacy_read_only	32,888	22	0	0	보존
v3_minmax	legacy_read_only	32,888	22	0	0	보존
v4_robust	legacy_read_only	32,888	22	0	0	보존
v5_base_no_outlier	forbidden_model_input	4,176	21	0	2	깨짐
v6_standard_no_outlier	forbidden_model_input	4,176	21	0	2	깨짐
v7_minmax_no_outlier	forbidden_model_input	4,176	21	0	2	깨짐
v8_robust_no_outlier	forbidden_model_input	4,176	21	0	2	깨짐

문자열 열이 남아 있다는 사실만으로 전처리 실패라고 할 수는 없지만, 이 파일들은 별도 인코더 없이 직접 학습할 수 있는 완성 수치 행렬은 아니다. 특히 v5~v8은 이상치가 있는 말의 행만 제거해 같은 경주의 출전마 집합을 훼손하므로 현재 목적에 사용할 수 없다.

5. 중요한 공정성 제한

Git canonical은 “원천 interim + 학습 시 transformer”, v11은 “이미 변환된 행렬”이다. 따라서 파일 외형만 비교하지 않고 Git transformer를 실제 train에 적합해 OHE·대치·표준화 후 NaN/∞가 0인지 확인했다. 반대로 v11의 7개 test 경주는 착순 타깃이 0/NaN이라 경주 전체가 순위 평가에서 제외된다. 이는 피처 결측 문제는 아니지만 데이터 품질 제한으로 유지한다.

6. 결론과 권고

1. 현재 학습에는 `revised_v11_seoul_bugyeong_rank_clean_preprocessed` 를 유지한다.
2. Git에서는 dataset policy·feature registry·fail-closed 테스트 구조만 선별 이식한다.

3. Git canonical의 112개 피처를 재사용하려면 train-only 상관 pruning과 OHE 기준범주 제거를 추가한다.
4. v5~v8은 절대 신규 모델 입력으로 복귀시키지 않는다.