

확률모델 핵심 용어와 수식

“95% 수준에서 확인되지 않았다” · validation · 시장 앵커 · Base Margin · ΔL

한눈에 보는 관계

① 시장확률 q

배당을 경주 내 확률로 정규화

② 앵커

모델 출발점을 $\log(q)$ 로 고정

③ Base Margin

트리가 시장의 잔차오류 $f(x)$ 를 학습

④ Validation

트리 수·모델·EDGE 문턱 선택

⑤ ΔL

시장보다 확률이 좋아졌는지 측정

⑥ 95% CI

그 개선·수익이 표본변동을 넘는지 판정

1. “95% 수준에서 확인되지 않았습니다”의 정확한 뜻

관심 대상이 ROI라면 귀무 기준은 $ROI = 0$ 이다. 표본 ROI를 $\hat{\theta}$ 라 하고 95% 신뢰구간을 $[L, U]$ 라 하면 현재 프로젝트 판정은 다음과 같다.

수익 확인: $L > 0$

손실 확인: $U < 0$

양·음 어느 쪽도 미확정: $L \leq 0 \leq U$

“확인되지 않았다”는 “효과가 0이다” 또는 “전략이 반드시 손실이다”라는 뜻이 아니다. 관측 표본 만으로는 양의 수익과 0 또는 음의 수익을 충분히 구분할 만큼 오차 범위가 좁지 않다는 뜻이다.

빈도주의 95% 신뢰구간의 엄밀한 의미는 “같은 데이터 생성·추정 절차를 무한히 반복하면 그렇게 만든 구간 약 95%가 고정된 참값을 포함한다”이다. 계산 후의 특정 구간에 참값이 들어갈 확률이 95%라고 직접 말하는 것은 엄밀한 빈도주의 해석이 아니다.

일자 블록 부트스트랩

1. 서로 다른 경주일 $d_1, \dots, d_D$ 를 복원추출한다.
2. 선택된 날짜 안의 모든 베팅을 함께 가져와 ROI^b를 계산한다.
3. $b=1, \dots, 5000$ 을 반복한다.
4. $CI_{95} = [ROI \text{의 } 2.5\text{백분위}, ROI \text{의 } 97.5\text{백분위}]$

이번 8~15배 예

validation 고정 정책의 test ROI는 +9.79%지만 CI는 [-46.31%, +74.21%]이다. 0을 포함하므로 양의 점추정은 있지만 수익은 95% 수준에서 확인되지 않았다. 부트스트랩에서 ROI가 양수였던 비율도 60.88%로 95%에 미달한다.

2. Validation이란 무엇인가

validation은 정답을 보면서 모델·하이퍼파라미터·정책을 선택하는 중간 기간이다. test는 그 선택이 끝난 뒤 한 번 평가하는 기간이다.

시간 순서

Train: 모델 파라미터 학습
Validation: 모델/트리 수/L2/EDGE 문턱 선택
Test: 선택을 고정한 최종 표본외 평가

필수 조건: $\max(\text{date_train}) < \min(\text{date_validation}) < \min(\text{date_test})$

이번 실행에서는 validation ΔLL 이 조건부 로짓 +0.005312, Base Margin +0.021833, 앙상블 +0.017756였기 때문에 Base Margin을 선택했다. test에서 앙상블 숫자가 더 좋아도 사후에 승자

를 바꾸지 않았다.

validation을 여러 번 보고 계속 모델을 고치면 그 기간도 사실상 train이 된다. test도 여러 차례 확인하면 더 이상 깨끗한 최종시험이 아니다. 현재 test는 이미 반복 관찰됐기 때문에 이번 결론은 탐색적 재검증이다.

3. 시장 앵커(anchor)란 무엇인가

앵커는 모델이 시장을 버리고 처음부터 새 확률을 만드는 대신, **시장확률을 출발점으로 고정하고 시장이 놓친 부분만 수정**하게 하는 구조다.

말 i 의 배당을 o_i 라 할 때 원시 역배당:	$a_i = 1 / o_i$
경주 내 정규화 시장확률:	$q_i = a_i / \sum_j a_j$
시장 앵커 모델의 점수:	$\eta_i = \log(q_i) + f(x_i)$
경주 내 최종 승리확률:	$p_i = \exp(\eta_i) / \sum_j \exp(\eta_j)$
따라서	$\sum_i p_i = 1$

$f(x)=0$ 이면 $p=q$ 여서 모델은 시장과 완전히 같다. $f(x)>0$ 이면 시장이 해당 말의 비시장 피쳐 정보를 과소평가했다고 모델이 수정하고, $f(x)<0$ 이면 과대평가했다고 수정한다.

여기서 배당은 일반 입력 피쳐가 아니라 계수가 1로 고정된 **offset**이다. 따라서 트리는 시장이 이미 설명한 인기도를 다시 처음부터 학습하는 대신 시장의 잔차오류에 집중한다.

4. Base Margin이란 무엇인가

boosting에서 **base margin**은 첫 번째 트리를 만들기 전 각 관측치가 이미 가지고 있는 초기 원점수(raw score)다. 일반 모델은 이를 0이나 전체 평균으로 시작하지만, 우리 모델은 말 i 의 초기 점수를 $\log(q_i)$ 로 둔다.

초기값: $\eta_i^{(0)} = \log(q_i)$
 t번째 확률: $p_i^{(t)} = \text{softmax_race}(\eta^{(t)})_i$
 승자표시: $y_i \in \{0,1\}$
 gradient: $g_i = y_i - p_i$
 hessian 근사: $h_i = p_i(1-p_i)$
 트리 앞의 Newton 보정값: $w_{\text{leaf}} = \sum_{i \in \text{leaf}} g_i / (\sum_{i \in \text{leaf}} h_i + \lambda)$
 갱신: $\eta_i^{(t+1)} = \eta_i^{(t)} + \text{learning_rate} \times w_{\text{leaf}}$
 최종: $\eta_i = \log(q_i) + \sum_t \text{learning_rate} \times \text{tree}_t(x_i)$

조건부 로짓 앵커가 $f(x) = \beta^T x$ 인 선형 수정이라면, Base Margin은 $f(x)$ 를 여러 얇은 트리로 만들어 비선형 효과와 상호작용을 표현한다. 예를 들어 "비 오는 날 × 특정 거리 × 선행형"처럼 한 번 수씩 더해서는 표현하기 어려운 조합을 분기 구조로 잡을 수 있다.

이번 모델은 validation에서 트리 수 **188개**를 선택했고, 그 뒤 train+validation을 합쳐 같은 188개로 다시 적합한 후 test를 예측했다.

5. ΔLL (델타 로그우도)이란 무엇인가

한 경주 r의 실제 승자를 w_r 라 하면 시장과 모델이 실제 승자에게 준 확률의 로그를 비교한다.

시장 로그우도: $LL_{\text{market}} = \sum_r \log(q_r, w_r)$
 모델 로그우도: $LL_{\text{model}} = \sum_r \log(p_r, w_r)$

경주당 $\Delta LL = (LL_{\text{model}} - LL_{\text{market}}) / R$
 $= (1/R) \sum_r [\log(p_r, w_r) - \log(q_r, w_r)]$
 $= \text{LogLoss}_{\text{market}} - \text{LogLoss}_{\text{model}}$

ΔLL 뜻

> 0 모델이 실제 승자에게 시장보다 평균적으로 더 높은 로그확률을 부여했다.

= 0 시장과 같은 정보량이다.

ΔLL 뜻

< 0 시장보다 확률분포가 나빠졌다.

이번 Base Margin 수치

validation ΔLL 은 **+0.021833/경주**였고, 고정 후 test ΔLL 은 **+0.013083/경주**, 95% CI는 **[+0.006614, +0.019647]**였다. CI 전체가 0보다 커서 시장 대비 확률정보 개선은 95% 기준으로 확인됐다.

$\exp(\Delta LL)-1$ 로 보면 실제 승자에 대한 기하평균 우도비 개선은 약 **1.32%/경주**다. 이것은 ROI 1.32%라는 뜻이 아니다.

6. 가장 흔한 혼동

잘못된 해석	정확한 해석
ΔLL 이 양수면 돈을 번다	확률분포가 더 정확하다는 뜻일 뿐, 공제·배당·선택·분산을 넘었다는 보장은 없다.
95% 미확정이면 전략이 무효다	효과가 없을 수도 있고 표본이 부족할 수도 있다. 점추정·CI 폭·표본 수를 함께 본다.
validation 성능이 최종 성능이다	validation은 선택용이다. 최종 성능은 고정된 test 또는 새 미래 OOS에서 측정한다.
앵커 모델은 배당을 일반 피처로 학습한다	여기서는 $\log(q)$ 를 계수 1의 고정 offset으로 사용하고 비시장 피처로 잔차만 학습한다.
Base Margin은 단순 절편이다	각 말마다 다른 시장 $\log(q)$ 를 초기 raw score로 주는 벡터형 출발점이다.

7. 이번 프로젝트에서의 최종 문장

Base Margin 시장 앵커는 시장보다 확률분포를 유의하게 개선했다. 그러나 8~15배·EDGE 상위 5%를 포함한 현재 베팅 결과의 절대 ROI는 95% 수준에서 아직 확인되지 않았다. 확률정보 우위와 수익성 우위는 별개의 검정이다.