

시장은 얼마나 틀리는가, 그리고 그 차이를 어떻게 검증하는가

이 문서는 일반 ML 교과서가 아니라, 지금까지 만든 데이터·모델·EDGE·7승식 백테스트 결과를 사용자가 직접 읽고 비판할 수 있게 만드는 프로젝트 전용 교재다.

서울+부경 56,456행

5,343경주

비배당 학습피쳐 141개

착순모델 6개

전처리 검증 PASS

0. 이 교재를 읽는 법

본문은 세 종류의 문장을 구분한다. 이 구분을 지키면 “그럴듯한 해석”이 “검증된 결과”로 둔갑하는 것을 막을 수 있다.

확인 사실

파일·코드·로그·CSV·JSON에서 직접 확인한 값. 예: v11의 고상관 피쳐 제거 후 상관계수 0.95 초과 쌍은 0개다.

해석

확인 사실을 바탕으로 한 설명. 예: CatBoost의 NDCG 순위는 “상위권 배열”에 유리하다는 뜻이지 수익 순위가 아니다.

가설

아직 새 OOS 구간에서 확인되지 않은 연구 아이디어. 예: 8-15배 다크호스 구간은 표본 확대 전까지 후보 전략이다.

용어 규칙

OOS(Out-of-Sample)처럼 생소한 말은 처음 등장할 때 영문·한글·실무 의미를 함께 쓰고, 17장 용어집에서 다시 찾을 수 있다.

현재 결론: 시장확률보다 낮은 log loss를 만든 시장 앵커 모델은 존재한다. 그러나 검증에서 정책을 고정한 뒤 test에 적용한 7승식 수익 중 95% 신뢰구간 하한이 0을 넘은 전략은 없다. “정보 우위 일부 확인”과 “수익성 확인”은 서로 다른 주장이다.

1. 프로젝트의 정확한 연구 질문

1.1 예측 프로젝트가 아니라 시장오류 연구다

질문은 단순히 “1등 말을 잘 맞히는가?”가 아니다. 시장이 최종 배당으로 표현한 확률 q 와 우리가 비시장 피처에서 얻은 정보가 결합된 확률 p 를 비교해, 시장이 반복적으로 놓치는 조건을 찾는 것이다.

연구 질문 = (비시장 정보가 시장 log loss를 줄이는가?) $\wedge$ (그 개선이 비용·분산을 이기고 OOS ROI로 이어지는가?)

첫 조건은 확률예측의 정보량 문제이고, 둘째 조건은 의사결정과 시장구조 문제다. 첫 조건이 참이어도 적중 배당이 낮거나 오차가 tail에 집중되면 둘째는 거짓일 수 있다.

1.2 분석 단위

- **행:** 한 경주의 한 출전마.
- **그룹:** 같은 race_id에 속한 모든 말. 착순과 확률은 이 그룹 안에서만 의미가 있다.
- **시간:** 과거→미래 순서. 미래 경주의 결과나 최종 pool 정보가 학습에 들어가면 성능이 아니라 누수다.
- **사건:** 단승, 연승, 복승, 쌍승, 삼복승, 삼쌍승, 복연승 각각의 적중 조합.

1.3 성공의 층위

층위	검증 질문	대표 지표	현재 상태
착순	말의 상대 순서를 잘 배열하는가?	NDCG@5, Spearman, 순위 MAE	모델별 차이 확인
확률	경주별 확률이 실제 빈도와 맞는가?	Log loss, Brier, calibration	시장 앵커 Δ LL 양수
EDGE	시장보다 나은 확률차를 찾는가?	p-q, EV, edge-적중 상관	일부 정보 개선
수익	정책 고정 후 돈이 남는가?	ROI, 95% CI, MDD, Sharpe	7승식 모두 미확인
배치	새로운 미래에도 재현되는가?	새 untouched OOS, 용량·시장충격	아직 충족 안 됨

2. 데이터 한 행에서 학습행렬까지

원본·참조 데이터



시점 안전 결합



문자열 수치화



결측·상관·스케일링



경주 그룹 학습

2.1 최신 기준 데이터

분할	기간	행	경주	경마장 경주 수	수치·유한값
train	20230805-20250511	33,416	3,158	서울 1,891 / 부경 1,267	PASS
valid	20250517-20251227	11,345	1,084	서울 641 / 부경 443	PASS
test	20251228-20260809	11,695	1,101	서울 635 / 부경 466	PASS

train이 valid보다 먼저, valid가 test보다 먼저 끝나는 엄격한 시간분할이다. test 1,101경주 중 착순이 0/결측인 7경주는 순위평가에서 경주 전체를 제외한다. 완전한 1..N이 아닌 동물·gap 경주는 NDCG 같은 순위평가에는 포함될 수 있지만 exact top3 계산에는 제외한다.

2.2 문자열은 어떻게 숫자가 되었나

- **One-hot encoding**: 성별·날씨·부담조건처럼 범주 수가 제한적인 값은 범주별 0/1 열로 바꾼다.
- **Target encoding(TE)**: 기수·조교사·마주처럼 범주가 많은 값은 과거 승률의 평활 추정치로 바꾼다. v11 train은 같은 날짜 결과를 먼저 보지 않도록 날짜 블록 전체를 인코딩한 뒤 그 날짜 결과로 history를 갱신한다.
- valid/test TE는 train 결과로 만든 mapping만 사용한다. valid/test의 실제 착순으로 mapping을 갱신하지 않는다.

$$TE(\text{category } c) = (\text{wins}_{\text{past},c} + \alpha \cdot \text{prior}) / (\text{starts}_{\text{past},c} + \alpha), \quad \alpha=20$$

2.3 결측값은 삭제와 같은 말이 아니다

결측(missing)은 값이 관측되지 않았다는 상태다. 무조건 행을 버리면 출전 이력이 짧은 말이 체계적으로 사라질 수 있다. v11은 학습구간에서 정한 대체값과 함께 __missing 표시 피처를 사용해 “값이 없다”는 정보 자체를 보존한다. 최종 학습행렬의 NaN과 infinite 값은 모두 0개다.

2.4 스케일링과 경주 내 상대피처

표준화는 train 평균 μ 와 표준편차 σ 로 $z=(x-\mu)/\sigma$ 를 만든다. __pr는 경주 안의 percentile rank다. 나이 5세라는 절대값과 그 경주에서 상대적으로 나이가 많은지를 동시에 표현할 수 있다. 트리 모델은 스케일에 둔감하지만 신경망 최적화는 스케일에 민감하므로 일관된 변환이 필요하다.

2.5 상관 피쳐 축소

train 피쳐만으로 Pearson $|r| \geq 0.95$ 인 쌍을 찾고 대표 피쳐를 남겼다. 축소 전 16쌍, 축소 후 0쌍이다. 이는 “비슷한 정보 중복”을 줄이는 절차이지 인과변수를 골랐다는 뜻은 아니다. 비선형 중복은 Pearson 검사만으로 제거되지 않을 수 있다.

2.6 학습 입력에서 제외된 정보

배당·시장확률·착순 결과·최종 pool은 모델 피쳐에서 제외됐다. winOdds, plcOdds, q, ord, finish_order, winAmt, totalAmt 등이 명시적 제외 목록에 있다. 배당은 학습 뒤 시장 기준확률과 EDGE·백테스트에만 사용한다.

3. 확률·배당·시장확률

3.1 decimal odds와 내재확률

decimal odds O 가 8.0이면 1원을 걸어 적중할 때 원금 포함 8원을 받는다는 뜻이다. 단순 역수 $1/O$ 는 내재확률이지만, 같은 경주에서 합하면 수수료·반올림 때문에 1이 아닐 수 있다.

$$r_i = 1/O_i, \quad q_i = r_i / \sum_{j \in \text{race}} r_j, \quad \sum q_i = 1$$

시장확률 q 는 각 말 역배당을 경주 내에서 정규화한 상대 승리확률이다. 최종 배당금 자료에는 통상 수수료가 반영되어 있으므로 실제 환급액을 사용할 때 수수료를 다시 빼면 이중 차감이다.

3.2 score, probability, odds는 다르다

- **score**: 모델이 정렬을 위해 내놓는 임의 척도. 2.3이 1.7보다 좋다는 순서는 있지만 “23%”라는 뜻은 아니다.
- **probability**: 0~1이고 경주 내 합이 1인 승리 가능성 추정.
- **odds**: 적중 시 지급배수. 확률 자체가 아니라 시장가격이다.

3.3 Softmax

$$p_i = \exp(s_i/T) / \sum_{j \in \text{race}} \exp(s_j/T)$$

Softmax는 점수를 경주별 확률로 바꾼다. T 는 temperature다. T 가 작으면 1위 말에 확률이 몰리고, 크면 평평해진다. T 는 validation에서만 정해야 한다. 최신 확률합 검증의 최대 오차는 $4.441e-16$ 이다.

3.4 Logit과 log-odds

$$\text{logit}(p)=\log(p/(1-p)), \quad \text{sigmoid}(z)=1/(1+e^{-z})$$

logit은 0~1 확률을 $-\infty \sim +\infty$ 의 직선 축으로 바꾼다. 단, 경주처럼 다항 선택인 경우에는 개별 말의 binary logit보다 $\log(q)$ 와 경주별 softmax가 자연스럽다.

4. 착순 학습과 Learning-to-Rank

Learning-to-Rank(LTR)는 숫자 하나를 맞히는 대신 같은 그룹의 항목을 올바른 순서로 배열하는 학습이다. 검색에서 query/문서 관계가 경마에서는 경주/출전마 관계가 된다.

접근	학습 단위	대표 loss	경마에서 장점	주요 한계
Pointwise	말 1두	착순백분위 회귀	단순·빠른 기준선	경주 상대구조를 loss가 직접 모름
Pairwise	같은 경주의 말 2두	RankNet logistic loss	누가 앞서는지 직접 학습	전체 순서의 일관 확률을 보장하지 않음
Listwise	경주 전체 순서	Plackett-Luce likelihood	전체착순과 조합확률 연결	구조 가정과 완전순서 필요
Metric-aware	교환되는 말쌍	LambdaRank/YetiRank	NDCG 상위권에 학습 집중	출력 score는 보정확률이 아님

4.1 착순을 relevance로 바꾸는 이유

LTR 라이브러리는 큰 label을 “더 관련 있음”으로 본다. 착순은 1이 가장 좋으므로 경주 최대착순에서 실제 착순을 빼 $\text{relevance}=\text{max_order}-\text{finish_order}$ 로 뒤집는다. 모든 착순을 사용하므로 1등 말 binary 분류가 아니다.

4.2 경주 그룹을 쪼개면 왜 틀리는가

말 A와 B가 같은 경주일 때만 비교가 의미 있다. A가 서울 1,200m에서 3등이고 B가 다른 날 부경 1,800m에서 2등이라는 사실만으로 B가 A보다 우수하다고 직접 pair를 만들 수 없다. 그래서 race_id group/qid를 학습과 평가에 전달한다.

4.3 상위 3등 지표 두 종류

$$\begin{aligned} \text{Ordered exact} &= 1[(\text{예측}_1, \text{예측}_2, \text{예측}_3)=(\text{실제}_1, \text{실제}_2, \text{실제}_3)] \\ \text{Unordered exact} &= 1[\{\text{예측 top3}\}=\{\text{실제 top3}\}] \end{aligned}$$

첫 지표는 삼쌍승과 가까운 순서 민감 평가이고, 둘째는 삼복승과 가까운 집합 평가다. 둘은 난도가 크게 다르다.

5. 결과지표를 수식으로 읽기

5.1 NDCG@5

$$DCG@K = \sum_{k=1..K} (2^{rel_k-1}) / \log_2(k+1), \quad NDCG@K = DCG@K / IDCG@K$$

앞쪽 순위를 더 크게 가중하고, 이상적인 정렬 IDCG로 나눠 경주별 0~1에 가깝게 정규화한다. @5는 상위 5등 배열에 초점을 둔다. 0.778은 “77.8% 적중률”이 아니다.

5.2 Spearman 순위상관

$$\rho = \text{corr}(\text{rank}(\text{actual quality}), \text{rank}(\text{model score}))$$
$$\text{동률이 없을 때 } \rho = 1 - 6\sum d_i^2 / [n(n^2-1)]$$

+1이면 완전히 같은 순서, 0이면 단조 순서관계가 거의 없음, -1이면 역순이다. 프로젝트 코드는 좋은 착순이 큰 값이 되도록 -finish_order와 score의 상관을 경주별로 계산해 평균한다.

5.3 순위 MAE

$$\text{Rank MAE} = (1/n) \sum |\text{predicted_rank}_i - \text{finish_order}_i|$$

2.44라면 말 한 두당 예측 순위가 실제 착순과 평균 약 2.44칸 차이 난다는 뜻이다. 필드 크기가 다른 경주를 그대로 평균하므로, field-size별 MAE도 함께 보는 것이 더 안전하다.

5.4 Log loss와 ΔLL

$$LL = -(1/R) \sum_{\text{race } r} \log p_{\text{winner}(r)}$$
$$\Delta LL = LL_{\text{market}} - LL_{\text{model}}$$

실제 우승마에게 낮은 확률을 주면 큰 벌점을 준다. ΔLL>0이면 모델 log loss가 시장보다 낮아, 우승사건 확률분포에 추가정보가 있다는 뜻이다. 수익을 직접 뜻하지 않는다.

5.5 Brier score와 calibration

$$\text{Brier} = (1/N) \sum (y_i - p_i)^2$$

Calibration(확률보정)은 20%라고 예측한 집단이 장기적으로 약 20% 적중하는 성질이다. discrimination(순서를 가르는 능력)이 좋아도 calibration이 나쁘면 EDGE와 Kelly 금액이 왜곡된다.

5.6 Hit Rate

선택한 베팅 중 적중한 비율이다. 높은 hit rate가 높은 ROI를 보장하지 않는다. 70% 적중이어도 평균 환급이 너무 낮으면 손실이고, 삼쌍승은 hit rate가 낮아도 큰 환급 한 번으로 점추정 ROI가 요동칠 수 있다.

6. 여섯 착순 모델 집중 학습

모델마다 “어떤 오차를 중요하게 보는가”가 다르다. 같은 141개 피처를 넣어도 loss가 다르면 학습하는 질문이 달라진다.

6.1 Random Forest 순위 회귀

핵심: 서로 다른 부트스트랩 표본과 피처 부분집합으로 만든 결정나무 500개의 예측을 평균한다. 한 나무가 만든 우연한 규칙을 여러 나무의 평균으로 약화시키는 배깅(bagging) 모델이다.

$$\hat{y}(x) = (1/B) \sum_{b=1..B} T_b(x)$$

우리 구현: 분류기가 아니다. finish_percentile_target을 회귀하고, 낮은 예상 착순백분위가 좋은 말이므로 평가 때 부호를 뒤집어 점수로 사용했다. 500 trees, depth 14, min leaf 8, feature fraction 0.8이다.

프로젝트 영향: 비선형 임계값과 상호작용을 안정적인 기준선으로 제공한다. 그러나 손실이 경주 내부 NDCG나 쌍 비교를 직접 최적화하지 않으므로 “몇 등인가”의 절대 회귀 오차와 “같은 경주의 상대 순서”가 완전히 일치하지 않는다. 확률도 직접 출력하지 않는다.

해석 위험: impurity 기반 중요도는 연속값·분할 후보가 많은 변수에 유리할 수 있고, 상관 피처 사이에서 중요도가 분산된다.

6.2 XGBoost Ranker — LambdaMART 계열

핵심: 이전 나무의 오류 방향을 다음 나무가 보정하는 부스팅(boosting)이다. 경주를 query, 말을 document처럼 묶고, 말 두 마리의 순서를 바꿀 때 NDCG가 얼마나 변하는지에 비례한 가상 기울기 λ 를 만든다.

$$F_m(x) = F_{m-1}(x) + \eta h_m(x), \quad \lambda_{ij} \propto |\Delta NDCG_{ij}| \cdot \text{logistic}(\text{score difference})$$

우리 구현: objective=rank:ndcg, qid=race_id, NDCG@5 조기종료, 최대 2,000 rounds, 학습률 0.03, 깊이 6. 실제 선택 iteration은 448이다.

프로젝트 영향: 상위권 순서가 틀렸을 때 더 큰 학습 신호를 주어 Top-k와 NDCG에 목적이 잘 맞는다. 최신 test에서는 top1 적중률이 여섯 모델 중 가장 높지만, 그것이 최고 NDCG나 수익을 뜻하지는 않는다. 트리 점수는 확률이 아니므로 별도 정규화·보정이 필요하다.

6.3 LightGBM LambdaRank

핵심: 같은 LambdaRank 계열이지만, leaf-wise 방식으로 손실을 가장 많이 줄이는 잎을 우선 확장한다. 계산 효율이 높지만 작은 표본에서 깊은 국소 규칙을 만들 수 있다.

우리 구현: 경주별 group size를 명시하고 graded relevance를 학습했다. learning rate 0.03, leaves 127, min leaf 35, feature/bagging fraction 0.8, truncation level 16, 최대 3,000 rounds, 실제 best iteration 54이다.

프로젝트 영향: 학습·재학습 속도가 빨라 피쳐 실험과 기준선에 유리하다. 최신 test의 상위 3등 “순서까지 완전일치”는 여섯 모델 중 가장 높았지만 1.76%로 절대 수준은 낮고, unordered top3와 NDCG@5는 최고가 아니었다. 한 지표만 보고 최고 모델로 고르면 목적이 바뀐다.

6.4 CatBoost YetiRankPairwise

핵심: 경주 그룹 안에서 자동 생성된 말 쌍과 순위 metric 근사를 사용해 pairwise ranking을 학습하는 gradient boosting 모델이다. 이름의 “Cat” 때문에 이번 실행에서 원문자열을 직접 처리했다고 오해하면 안 된다.

우리 구현: 입력은 이미 숫자화된 141피처다. loss=YetiRankPairwise, eval=NDCG:top=5, depth 7, learning rate 0.03, 최대 2,500 iterations, 실제 best iteration 767이다.

프로젝트 영향: 검증 NDCG@5 1위라 사전에 주모델로 선택됐고 test NDCG@5도 1위였다. 즉 “경주 상위권 전체 배열 품질”의 대표 모델이다. 다만 test top1, ordered/unordered top3 모두 단독 1위는 아니다. 모델 선택의 기준과 사용 목적을 반드시 연결해야 한다.

6.5 Deep RankNet 앙상블

핵심: 같은 경주의 두 말 i, j 에 대해 실제로 i 가 앞서면 점수차 $s_i - s_j$ 가 양수가 되도록 학습한다.

$$P(i > j) = \sigma(s_i - s_j), \quad L_{ij} = \log(1 + \exp(-y_{ij}(s_i - s_j)))$$

우리 구현: 141→256→128→1 MLP, BatchNorm, GELU, dropout 0.20, AdamW, 60 epochs 이내 조기종료. 서로 다른 seed 3개를 학습해 점수를 평균했다. 동률을 제외한 경주 내 모든 쌍을 사용했다.

프로젝트 영향: 복잡한 연속 상호작용을 트리와 다른 형태로 학습해 모델 다양성을 준다. 최신 test에서 unordered top3 정확도가 7.79%로 최고였다. 반면 pairwise loss는 모든 쌍을 비슷하게 다루므로 상위 3등의 정확한 순서나 확률보정을 직접 보장하지 않는다.

6.6 Plackett-Luce Neural — listwise 전체작순

핵심: 1작을 전체 말 중 먼저 선택하고, 남은 말에서 2작을 선택하는 식으로 전체 순서의 확률을 곱한다. 점수 s 에 $\exp$ 를 적용한 strength를 쓴다.

$$P(\pi) = \prod_{k=1..n-1} \exp(s_{\pi k}) / \sum_{j=k..n} \exp(s_{\pi j})$$

우리 구현: RankNet과 같은 256→128 신경망이지만 loss는 전체 Plackett-Luce 음의 로그우도다. 완전한 1..N 작순 경주 3,125개만 학습하고 33개 비엄격 순서 경주는 제외했다.

프로젝트 영향: 전체 순서에 일관된 확률 모형을 제공해 exacta·trifecta 같은 순서형 조합 확률로 연결하기 자연스럽다. 그러나 기본 PL의 IIA 가정—두 말의 상대 선택비가 다른 말의 존재와 무관—은 pace 충돌이 강한 경마에서 틀릴 수 있다. 신경망 점수와 입력 상호작용만으로 이 구조적 가정이 사라지지는 않는다.

중요: 모델의 복잡성이 높다는 이유로 더 우수한 것이 아니다. CatBoost는 NDCG, RankNet은 unordered top3, LightGBM은 ordered top3에서 각각 다른 장점을 보였다. 배팅용 최종 확률은 순위지표뿐 아니라 log loss·calibration·OOS 정책검증까지 통과해야 한다.

7. Benter·시장 앵커·Base Margin

7.1 앵커(anchor)란

앵커는 모델이 처음부터 시장 전체를 다시 예측하지 않고 시장확률을 출발점으로 삼는 것이다. 시장은 기수·마필·정보·대중 판단을 이미 압축한 강한 기준선이다. 모델의 역할은 시장을 대체하는 것이 아니라 시장이 체계적으로 틀리는 잔차를 찾는 것이다.

7.2 조건부 로짓 결합

$$\eta_{ri} = \alpha \log(q_{ri}) + \beta^T x_{ri}, \quad p_{ri} = \text{softmax}_{r \in R}(\eta_{ri})$$

α 가 시장 신호의 온도를 조절하고 β 가 비시장 피처의 선형 보정을 담당한다. “배당을 일반 피처에 넣는다”와 달리 시장항의 역할이 식에 명시되어 있다.

7.3 Base Margin boosting

Base Margin은 boosting의 초기 raw score를 $\log(q)$ 로 고정하는 방식이다. 첫 예측이 시장확률이고, 각 나무가 residual correction을 더한다.

$$\eta^{(\theta)}_{ri} = \log q_{ri}$$

$$p^{(m)} = \text{softmax}(\eta^{(m)})$$

$$g_{ri} = y_{ri} - p_{ri}, \quad h_{ri} = p_{ri}(1 - p_{ri})$$

$$w_{\text{leaf}} = \Sigma g / (\Sigma h + \lambda), \quad \eta^{(m+1)} = \eta^{(m)} + \text{learning_rate} \cdot w_{\text{leaf}}$$

우리 구현은 validation에서 tree 수를 고르고, v11 Base Margin은 188 trees가 선택됐다. test ΔLL 은 +0.013083, 일자 블록 95% CI [+0.006614, +0.019647]였다. 따라서 해당 기간의 확률정보 개선은 확인됐지만, 동일 실행의 7승식 수익은 모두 미확인이다.

7.4 Benter 방식과 “같다”의 정확한 범위

Benter 논문이 강조한 원리는 (1) 경주 내 합 1인 기본 확률모형, (2) public probability와 fundamental information의 결합, (3) unseen race 평가, (4) 가치와 자금배분이다. 우리 시장 앵커는 이 원리를 현대적인 boosting/conditional-logit으로 구현한 **관련 방식**이다. Benter의 원래 데이터·계수·홍콩 pool 운영을 그대로 복제한 것은 아니다.

8. EDGE의 정확한 의미와 계산

8.1 확률 EDGE

$$\text{EDGE}_{\text{prob}} = p_{\text{model}} - q_{\text{market}}$$

모델이 18%, 시장이 12%라면 +6%p다. 이는 “6% 수익”이 아니다.

8.2 기대수익 EDGE

$$\text{EV per 1 unit} = p \cdot O - 1$$

decimal odds 8.0, $p=0.18$ 이면 $\text{EV}=0.18 \times 8 - 1 = +0.44$ 다. 그러나 p 의 오차, 최종 배당 변동, 베팅한도, 동시 조합 의존성은 이 한 식에 없다.

8.3 실제 적중 EDGE

$$\text{realized edge} = \text{return} - 1, \quad \text{return} = \text{dividend if hit else } 0$$

개별 베팅의 realized edge는 0/대형환급으로 매우 거칠다. 그래서 predicted EDGE와 realized return의 Spearman, bin별 calibration, 여러 경주를 묶은 ROI와 신뢰구간을 본다.

8.4 피처가 EDGE에 미치는 영향

단순 착순 중요도를 EDGE 중요도라고 부르면 안 된다. EDGE 영향은 시장 앵커 모델의 잔차수정 $f(x)$ 또는 $p_{model}-q$ 를 설명하는 SHAP/importance로 계산해야 한다. 즉 “왜 이 말이 빠른가”와 “왜 시장보다 높게 평가했는가”는 다른 질문이다.

EDGE contribution of feature $j \approx p(\eta+\phi_j) - p(\eta)$ (다른 말 softmax까지 함께 변환)

경주 softmax 때문에 한 말의 피처 기여는 그 말만의 독립 변화가 아니다. 한 말의 score 상승은 같은 경주의 다른 말 확률을 낮춘다.

9. 일곱 승식과 조합확률

승식	적중 사건	순서	확률 계산의 핵심
단승	선택 말 1착	해당 없음	$p(i \text{ wins})$
연승	선택 말이 지급권 내 착순	무관	필드·지급규칙별 place 확률
복승	선택 2두가 1·2착	무관	$P(i,j)+P(j,i)$
쌍승	i 1착, j 2착	중요	$P(i,j)$
삼복승	선택 3두가 1·2·3착	무관	6개 순열 확률 합
삼쌍승	i,j,k가 정확히 1·2·3착	중요	$P(i,j,k)$
복연승	선택 2두가 모두 지급권 내	무관	두 말의 공동 place 사건

9.1 Plackett-Luce/Harville 순차확률

$$P(i \text{ 1착}, j \text{ 2착}) = p_i \cdot p_j / (1-p_i)$$
$$P(i,j,k) = p_i \cdot p_j / (1-p_i) \cdot p_k / (1-p_i-p_j)$$

무순서 승식은 가능한 순열을 합한다. 몬테카를로는 이 순차선택을 수천 번 반복해 사건 빈도로 조합확률을 근사한다.

9.2 조합 EDGE에 필요한 데이터

조합확률만 있어서는 부족하다. 실제 베팅 가능한 시점의 각 조합별 시장 배당 또는 pool snapshot이 있어야 $p_{combo}-q_{combo}$ 와 Kelly를 계산할 수 있다. 최신 자료는 당첨 조합의 공식 환급 검증에는 강하지만, 패배한 모든 조합의 사전 배당이 완전하지 않아 일부 복합승식 분석은 “모형확률/실현환급 백테스트”이지 완전한 실시간 조합 EDGE 검증이 아니다.

10. 백테스트·ROI·Kelly·위험

10.1 ROI

$$ROI = (\text{총환급} - \text{총베팅액}) / \text{총베팅액} = \Sigma(\text{return} - \text{stake}) / \Sigma \text{stake}$$

ROI +10%는 베팅액 100원당 평균 10원이 남았다는 표본 결과다. 미래 기대수익이 +10%라고 확정하는 문장이 아니다.

10.2 MDD와 Sharpe

MDD = $\max_t((\text{peak equity before } t - \text{equity}_t)/\text{peak equity})$

Sharpe $\approx \text{mean}(\text{period returns})/\text{std}(\text{period returns}) \times \text{annualization}$

MDD(Max Drawdown)는 과거 고점에서 최대 몇 % 하락했는지다. **Sharpe Ratio**는 평균수익을 변동성으로 나눈 위험조정 수익이다. 베팅의 비정규·두꺼운 꼬리에서는 Sharpe만으로 안전성을 말하면 안 된다.

10.3 Kelly Criterion

$b=0-1, \quad f^*=(bp-(1-p))/b = (p0-1)/(0-1)$

Kelly는 장기 로그자산 성장률을 최대화하는 이론적 비중이다. 확률이 정확하다는 가정에 민감하므로 실무에서는 1/2, 1/4 Kelly와 상한을 둔다. $p0 \leq 1$ 이면 $f^* \leq 0$ 이므로 베팅하지 않는다.

10.4 왜 validation에서 정책을 잡아야 하나

EDGE 상위 10%, 20%, 30%, odds 8-15배 등 수많은 조합을 test에서 모두 보고 가장 좋은 것만 고르면 test가 사실상 학습자료가 된다. 임계값과 모델은 validation에서 고정하고 test에서는 한 번만 평가해야 한다.

10.5 30% 이상 ROI 경보

큰 ROI는 좋은 소식일 수 있지만, 먼저 (1) 결과/최종 pool 누수, (2) 한두 건의 대형환급 의존, (3) 다중비교, (4) 축퇴·오류 배당, (5) 시장충격·베팅한도 미반영을 확인한다.

11. OOS·검증·신뢰구간

11.1 OOS란 무엇인가

OOS(Out-of-Sample, 표본외)는 모델의 파라미터·전처리·피처선택·임계값 결정에 쓰지 않은 데이터에서 측정한 결과다. train을 안 썼다는 뜻만이 아니라, 선택 과정 전체에서 보지 않았어야 한다.

구간	하는 일	허용되는 결정	금지
Train	모델 학습	전처리 fit, 피처 생성, 모델 fit	valid/test 결과 사용
Validation	모델·온도·임계값 선택	best iteration, 정책 잠금	여러 번 보고 test에 맞춰 재선택
Test	최종 OOS 평가	고정 정책 실행	test 최고셀을 새 전략으로 선택
Future untouched	재현성 확인	사전등록 전략 1회 검증	이전 test 재사용을 pristine이라 부르기

11.2 현재 test를 어떻게 불러야 하나

v11 test는 원래 시간순 OOS였지만 지금까지 여러 후속 분석에서 반복 열람했다. 따라서 개별 실행의 산술은 test 결과이지만, 프로젝트 전체 관점에서는 더 이상 완전히 untouched한 최종확인 표본이라고 부르기 어렵다. 다음 강한 결론은 2026-08-09 이후 새 경주 블록에서 확인해야 한다.

11.3 95% 신뢰구간

동일한 데이터 생성과 표본추출 과정을 반복했을 때 이 방식으로 만든 구간의 약 95%가 참 모수를 포함하도록 설계된 범위다. “참값이 이 구간 안에 있을 확률 95%”라는 베이지안 문장과는 다르다.

ROI 95% CI = daily-block bootstrap quantile_{2.5%,97.5%}(ROI*)

경마 베팅은 같은 날의 주로·시장상태가 함께 움직일 수 있어 행 단위보다 일자 블록 bootstrap이 적절하다. ROI CI가 [-46%, +74%]면 점추정이 양수여도 손실과 큰 이익을 모두 배제하지 못하므로 “95% 수준에서 수익 확인 안 됨”이라고 쓴다.

11.4 다중비교

7승식×6모델×여러 EDGE 구간을 동시에 시험하면 우연한 최고값이 반드시 커진다. FDR, Bonferroni, White's Reality Check, PBO 같은 보정·과적합 진단이 필요하다. 가장 좋은 셀의 단일 CI만 제시하면 선택편향이 남는다.

12. 피처 중요도와 XAI

12.1 중요도는 인과효과가 아니다

Feature Importance는 모델이 예측할 때 해당 피처에 얼마나 의존했는지를 요약한다. “이 값을 바꾸면 실제 착순이 그만큼 변한다”는 인과 주장이 아니다.

12.2 방법별 차이

방법	무엇을 재나	장점	주의
Tree impurity	분할로 줄인 불순도	빠름	연속·고카디널리티 편향
Gain	분할 손실감소 합	부스팅과 자연스러움	상관 피처에 분산
Input weight	신경망 첫 층 절대가중치	간단	스케일·뒤층 상호작용 무시
Permutation	피처를 섞었을 때 성능하락	모델 불문	상관 피처에서 과소평가 가능
SHAP	기준예측 대비 국소 기여	개별 말 설명	조건부/상관 해석 주의

12.3 최신 CatBoost 착순 중요도 상위

순위	피처	중요도
1	hr_last_finpct	22.03%

순위	피쳐	중요도
2	clinic_30d	10.26%
3	age__pr	7.87%
4	rating__z	7.72%
5	hr_plcrate	7.33%
6	jk_plcrate	5.18%
7	tr_plcrate	3.02%
8	chulNo	2.89%
9	hr_rest_days	2.88%
10	wg_diff__pr	2.45%
11	ilsu	1.96%
12	wg	1.62%
13	wg_diff	1.30%
14	rating	1.28%
15	tr_winrate__z	1.24%

hr_last_finpct가 높다고 그 피쳐가 “EDGE 원인 1위”인 것은 아니다. 이 표는 착순 ranker 중요도다. EDGE 원인은 시장앵커의 residual correction 또는 시장대비 확률차를 대상으로 다시 계산해야 한다.

12.4 SHAP을 읽는 절차

- 어떤 출력—착순 score, win probability, market residual—을 설명하는지 확인한다.
- global mean |SHAP|와 특정 말 local SHAP을 구분한다.
- 부호가 확률에 미치는 영향은 경주 softmax 안에서 다시 계산한다.
- 상관 피쳐를 묶어 안정성을 비교한다.
- 시간·경마장·배당구간별로 방향이 반복되는지 확인한다.

13. 최신 결과를 직접 읽기

13.1 착순 모델 test 결과

모델	NDCG@5 ↑	Spearman ↑	Rank MAE ↓	Top1	Top3 순서완전	Top3 집합완전
CatBoost YetiRank	0.7780	0.4553	2.4400	30.07%	1.39%	7.24%
Deep RankNet	0.7752	0.4450	2.4671	31.17%	1.58%	7.79%
XGBoost Ranker	0.7732	0.4366	2.4918	31.54%	1.48%	7.33%
Plackett-Luce Neural	0.7719	0.4368	2.4818	29.07%	1.58%	7.42%
Random Forest	0.7684	0.4280	2.5118	30.44%	1.21%	7.33%
LightGBM LambdaRank	0.7685	0.4206	2.5385	30.35%	1.76%	6.86%

평가 가능 경주는 모델 표에서 1,094경주다. 전체 test 1,101경주와 다른 이유는 착순 0/결측 경주 7개를 경주 전체로 제외했기 때문이다. exact top3는 완전 1..N 착순 1,078경주에서 계산됐다.

13.2 검증에서 잠근 7승식 정책의 test 결과

승식	검증선택 모델	정책	베팅	적중률	ROI	일자블록 95% CI	수익확인
단승	Random Forest	top_10pct_edge	108	16.67%	-3.06%	[-51.28%, 53.23%]	미확인
연승	XGBoost Ranker	top_10pct_edge	103	45.63%	1.26%	[-26.41%, 29.55%]	미확인
복승	Random Forest	positive_edge	685	9.20%	-17.65%	[-41.32%, 9.54%]	미확인
쌍승	Random Forest	positive_edge	688	5.09%	-18.04%	[-51.42%, 25.37%]	미확인
삼복승	XGBoost Ranker	top_30pct_edge	324	4.63%	-24.54%	[-65.81%, 26.54%]	미확인
삼쌍승	Random Forest	positive_edge	752	0.53%	-66.52%	[-95.66%, -21.89%]	미확인
복연승	LightGBM LambdaRank	top_10pct_edge	108	9.26%	-53.61%	[-81.22%, -20.80%]	미확인

수익확인 열이 전부 미확인이다. 일부 ROI 점추정이 양수인 별도 모델/셀도 있었지만, test를 본 뒤 선택한 최고값은 사전 고정 전략의 증거가 아니다.

13.3 시장 앵커의 확률정보

모델	test 경주	시장 LL	모델 LL	ΔLL	95% CI
시장 앵커 조건부 로짓	1101	1.793694	1.779720	0.013974	[0.002318, 0.025063]
시장 앵커 Base Margin	1101	1.793694	1.780611	0.013083	[0.006614, 0.019647]
두 시장 앵커 앙상블	1101	1.793694	1.776500	0.017194	[0.009507, 0.025014]

Base Margin과 앙상블은 ΔLL CI 하한이 양수다. 시장확률보다 실제 우승마에 더 높은 확률을 배분하는 정보가 평균적으로 있었음을 지지한다.

13.4 시장 앵커의 베팅 결과

승식	모델	정책	베팅	적중률	ROI	95% CI	수익확인
단승	시장 앵커 Base Margin	top_10pct_edge	108	41.67%	-14.54%	[-35.54%, 6.77%]	미확인
연승	시장 앵커 Base Margin	top_10pct_edge	101	73.27%	-7.52%	[-17.01%, 2.38%]	미확인
복승	두 시장 앵커 앙상블	top_10pct_edge	108	31.48%	39.72%	[-3.30%, 84.45%]	미확인
쌍승	두 시장 앵커 앙상블	top_10pct_edge	108	19.44%	16.76%	[-31.05%, 67.62%]	미확인
삼복승	시장 앵커 Base Margin	top_20pct_edge	216	15.74%	-7.69%	[-39.63%, 26.52%]	미확인
삼쌍승	시장 앵커 Base Margin	top_10pct_edge	108	4.63%	-32.96%	[-86.74%, 32.35%]	미확인
복연승	두 시장 앵커 앙상블	top_10pct_edge	108	48.15%	15.93%	[-5.85%, 39.13%]	미확인

확률개선이 수익확정으로 이어지지 않았다. 이 차이가 프로젝트의 가장 중요한 현재 학습결과다.

13.5 8-15배 가설

과거 관찰을 버리지 않고 v11에서 재검증했다. validation에서 Base Margin EDGE 상위 5%의 절대 임계값 0.0188698을 잠근 뒤, test 8-15 배 말에 적용한 결과 94건 ROI +9.79%, 일자블록 95% CI [-46.31%, +74.21%]였다. 시장확률 상위 5% 동수 대조군은 -12.45%였지만, 전략 ROI의 불확실성이 커 수익전략으로 확정할 수 없다.

14. 모델이 프로젝트에 미친 영향

모델/층	프로젝트에서 답하는 질문	실제 기여	현재 한계
Random Forest	단순 비선형 기준선이 어디까지 가나?	안정적 benchmark, 일부 승식 정책 선택	race-aware loss 아님
XGBoost Ranker	상위 NDCG를 트리로 직접 높일 수 있나?	test top1 최고	확률 직접 출력 아님
LightGBM LambdaRank	빠른 metric-aware 실험이 가능한가?	ordered top3 최고	unordered/NDCG 최고 아님
CatBoost YetiRank	상위권 배열 대표모델은?	valid/test NDCG@5 최고	수익 최고를 보장 안 함
Deep RankNet	쌍 비교와 비선형 상호작용이 도움 되나?	unordered top3 최고, 모델 다양성	pair loss와 top-k/확률 불일치
PL Neural	전체 순서확률로 조합승식 연결 가능한가?	listwise likelihood 제공	IIA, complete order 제한
조건부 로짓 앵커	시장에 선형 잔차가 있나?	해석 가능한 시장보정	복잡한 잔차 한계
Base Margin	시장에 비선형 잔차가 있나?	Δ LL 양수 CI 확인	ROI 미확인, 과적합 통제 필요
양상블	서로 다른 오류를 평균하면 개선되나?	test Δ LL 최고	구성·가중치도 validation에서 잡아야 함

14.1 “최고 모델”은 질문마다 다르다

- 상위 5등 전체 배열: CatBoost YetiRank.
- 우승마 1등 적중: XGBoost가 test 최고지만 test 기반 사후선택임을 명시해야 한다.
- Top3 집합: Deep RankNet.
- Top3 정확한 순서: LightGBM.
- 시장보다 확률정보: 시장 앵커 양상블/Base Margin.
- 검증된 수익: 현재 없음.

14.2 다음 모델 연구의 우선순위

1. 새 untouched 시간블록 전까지 구조를 더 복잡하게 만들기보다 사전등록할 모델·정책 수를 줄인다.
2. 시장앵커의 잔차를 경마장·배당 8-15·pace conflict별로 train/validation에서만 모델링한다.
3. 조합승식은 조합별 pre-race odds/pool을 확보한 뒤 실제 EDGE를 계산한다.
4. 확률 calibration과 tail calibration을 rank metric과 별도 목적함수로 점검한다.
5. Kelly는 확률 오차를 반영한 shrinkage/fractional Kelly로 제한한다.

15. 보고서를 읽는 실전 절차

1. **데이터 신원**: 경로·SHA-256·기간·경마장·행/경주 수를 확인한다.
2. **피쳐 시간**: 각 피쳐가 베팅시점 이전에 알 수 있었는지 묻는다.
3. **분할**: train<valid<test인지, race_id 중복이 없는지 확인한다.
4. **학습 질문**: 회귀·pairwise·listwise·시장잔차 중 무엇을 최적화했는지 본다.
5. **확률**: score를 probability로 어떻게 바꿨고 합 1 검사를 했는지 본다.
6. **선택**: 모델·임계값·승식이 validation에서 잡겼는지 본다.
7. **결과**: 점추정뿐 아니라 CI·MDD·Sharpe·표본 수·최고환급 의존을 본다.
8. **시장비교**: 같은 경주·같은 베팅 수·같은 기간의 대조군인지 본다.
9. **한계**: 패배 조합의 사전배당, 시장충격, test 재사용 여부를 확인한다.

10. 결론 문장: “개선 확인”, “수익 미확인”, “배치 가능”을 섞지 않는다.

3문장 보고 규칙: ① 무엇을 어떤 OOS에서 측정했는가. ② 점추정과 불확실성은 얼마인가. ③ 그래서 어떤 주장까지 가능하고 무엇이 아직 불가능한가.

16. 계산 연습과 해설

문제 1 — 시장확률

세 말의 decimal odds가 2, 4, 8이라면 정규화 시장확률은?

▶ 해설 보기

문제 2 — EDGE와 EV

시장 $q=12\%$, 모델 $p=18\%$, $odds=8$ 이면?

▶ 해설 보기

문제 3 — ΔLL

시장 $LL=1.793694$, 모델 $LL=1.780611$ 이면 ΔLL 은?

▶ 해설 보기

문제 4 — Top3

실제 [A,B,C], 예측 [B,A,C]면 ordered/unordered exact는?

▶ 해설 보기

문제 5 — 신뢰구간

$ROI +9.79\%$, $95\% CI [-46.31\%, +74.21\%]$ 를 어떻게 쓰나?

▶ 해설 보기

문제 6 — 모델 선택

CatBoost NDCG가 최고면 그 모델로 무조건 베팅해야 하나?

▶ 해설 보기

17. 생소한 용어 사전

OOS	Out-of-Sample, 표본외. 모델·전처리·선택에 사용하지 않은 데이터에서의 평가.
Validation	검증구간. 모델, best iteration, 온도, EDGE 임계값 등 운영 선택을 정하는 데이터.
Test	검증에서 결정한 정책을 최종 평가하는 데이터. 반복해서 선택에 쓰면 더 이상 pristine test가 아니다.
Untouched	선택 과정에서 한 번도 결과를 보지 않은 상태. “파일을 수정하지 않았다”와 다른 뜻이다.
Baseline	새 방법이 실제로 나은지 비교하는 기준선. 이 프로젝트의 강한 baseline은 시장확률이다.
Anchor	앵커. 시장확률을 출발점으로 고정하고 모델이 잔차만 보정하는 구조.
Base Margin	부스팅 초기 raw score. 여기서는 $\log(q)$ 를 초기값으로 사용한다.
ΔLL	Delta Log Loss. 시장 LL-모델 LL. 양수면 모델 확률정보가 시장보다 좋다.
Likelihood	우도. 주어진 모델·파라미터가 실제 관측결과에 부여한 확률의 곱.
Log loss	실제 발생 사건에 준 확률의 음의 로그. 틀린 확신을 크게 벌한다.
Objective	목적함수. 학습 알고리즘이 줄이거나 늘리도록 설계된 수학적 목표.
Loss	손실함수. 예측이 정답에서 얼마나 나쁜지 나타내는 값. 평가 metric과 같을 수도, 근사일 수도 있다.
Gradient	기울기. 파라미터를 어느 방향으로 바꾸면 loss가 늘거나 줄지 나타내는 미분값.
Hessian	2차 미분 정보. 기울기의 변화율로 Newton형 업데이트 크기를 안정화한다.
Boosting	이전 약한 모델의 오류를 다음 모델이 순차 보정하는 앙상블 방식.
Bagging	다른 표본으로 병렬 학습한 모델을 평균해 분산을 줄이는 방식.
Ensemble	여러 모델을 결합한 예측. 서로 다른 오류가 상쇄될 때 유리하다.
Hyperparameter	학습 전에 정하는 설정. depth, learning rate, tree 수 등. validation에서 선택한다.
Early stopping	validation 성능이 일정 기간 개선되지 않으면 학습을 멈춰 과적합을 줄이는 절차.
Regularization	복잡한 모델에 벌점을 주거나 dropout 등을 써 과적합을 억제하는 방법.
Query/QID	LTR의 비교 그룹 식별자. 이 프로젝트에서는 race_id.
Pointwise	각 말을 독립 표본처럼 보고 값/등급을 예측하는 순위학습 접근.
Pairwise	같은 경주의 두 말 중 누가 앞서는지를 학습하는 접근.

Listwise	한 경주의 전체 순서 또는 순서분포를 한꺼번에 학습하는 접근.
LambdaRank	NDCG 같은 비연속 순위지표의 변화량을 반영한 가상 gradient로 학습하는 방법.
LambdaMART	LambdaRank gradient를 boosted regression trees(MART)에 적용한 모델.
Relevance	LTR에서 높을수록 위에 놓여야 하는 label. 착순을 뒤집어 만든다.
NDCG@5	상위 5개 위치를 더 중시하는 정규화 순위 품질 지표. 적중률이 아니다.
Spearman	두 순위의 단조 관계를 -1~+1로 나타낸 순위상관.
Rank MAE	예측순위와 실제착순의 절대 차이를 말 단위로 평균한 값.
Calibration	예측확률과 실제 장기빈도의 일치 정도.
Discrimination	좋은 말과 나쁜 말을 구분·정렬하는 능력. calibration과 다르다.
Softmax	경주 안의 score를 양의 값으로 바꿔 합 1의 확률로 정규화하는 함수.
Logit	확률 p를 $\log(p/(1-p))$ 로 바꾼 값. binary 확률의 선형화 축.
Residual	잔차. 실제와 기준예측의 차이. 시장앵커에서는 시장이 설명하지 못한 부분.
EDGE	모델확률과 시장확률/가격 사이의 유리한 차이. 확률 EDGE와 EV EDGE를 구분한다.
ROI	투입액 대비 순이익률. (환급-베팅액)/베팅액.
Hit Rate	베팅 중 적중 비율. 지급배수와 별개라 단독 수익지표가 아니다.
MDD	Max Drawdown. 누적자산 고점 대비 가장 큰 하락폭.
Sharpe Ratio	평균 초과수익을 변동성으로 나눈 위험조정 지표.
Kelly	예측확률과 odds로 장기 로그자산 성장률을 최대화하는 베팅비중 공식.
Bootstrap	관측 블록을 복원추출해 통계량의 표본분포와 신뢰구간을 근사하는 방법.
Confidence Interval	신뢰구간. 반복 표본추출에서 정해진 비율로 참값을 덮도록 만든 구간.
Data Leakage	예측시점에 알 수 없는 결과·미래정보가 학습 입력이나 선택 과정에 섞이는 문제.
Look-ahead Bias	미래 데이터를 과거 의사결정에 사용해 성능을 부풀리는 편향.
Overfitting	학습/탐색 표본의 우연한 패턴까지 외워 새 데이터 성능이 떨어지는 현상.
Preregistration	사전등록. test 결과를 보기 전에 모델·대상·임계값·지표를 문서로 고정하는 것.
Pari-mutuel	공동 pool에서 수수료를 제외한 금액을 적중자들이 나누는 배팅 구조.

Takeout	운영기관이 pool에서 공제하는 비율. 공식 최종환급에 이미 반영되면 재차감 금지.
IIA	Independence of Irrelevant Alternatives. 다른 선택지 변화가 두 선택지 상대비에 영향을 주지 않는다는 PL/logit 가정.
SHAP	예측을 기준값과 피처별 기여로 분해하는 XAI 방법. 연관 설명이지 인과증명은 아니다.
XAI	Explainable AI. 모델이 왜 특정 점수·확률을 냈는지 설명하는 방법군.

18. 근거와 더 읽을 자료

18.1 프로젝트 내부 1차 근거

- data/revised_v11.../preprocessing_manifest.json — 피처 141개, 제외열, TE·상관축소 규칙.
- preprocessing_validation.json — 기간·행·경주·결측·유한값·경마장 검증 PASS.
- src/training/train_full_rank_models.py — 여섯 모델의 실제 objective·group·architecture·metric 계산.
- models/revised_v11.../*/_model_manifest.json — 실제 best iteration·fit rows·device.
- outputs/reports/revised_v11.../logs/01~06 — 각 모델 학습 로그.
- model_metric_comparison.csv — 착순지표 원수치.
- market_anchor/delta_ll_metrics.csv — 시장 LL·모델 LL· Δ LL·CI.
- locked_policy_test_results.csv — validation 잠금 7승식 test 결과.

18.2 원 논문·공식 문서

1. Benter (1993), Computer based horse race handicapping and wagering systems — 학술 저장소 서지정보.
2. Benter 논문 PDF — fundamental/public probability 결합과 확률합 1 구조.
3. Breiman (2001), Random Forests.
4. XGBoost 공식 Learning-to-Rank 문서.
5. LightGBM 공식 LambdaRank 파라미터 문서.
6. CatBoost 공식 ranking objectives 문서.
7. Burges et al. (2005), RankNet.
8. Turner et al., PlackettLuce rankings.
9. Kelly (1956), A New Interpretation of Information Rate.

재현성: 이 HTML의 숫자표는 위 CSV/JSON을 실행 시점에 읽어 생성했다. `evidence_manifest.json`에 각 근거 파일의 SHA-256을 저장했고, `validation.json`에 목차 링크·필수용어·모델 수·내부 링크 검사를 기록했다.