

EDA 결과 보고서

EDA 결과 보고서

이 보고서의 흐름

1. **결측치** — 빈칸이 얼마나, 왜 있는지 (1~2장)
2. **이상치** — 극단적으로 튀는 값이 어디에 있는지 (3장)
3. **다중공선성** — 중복 정보를 가진 컬럼이 있는지 (4장)
4. **처리 방향** — 위 문제들을 어떻게 해결했는지 (5장)

대상: 서울 경마장 데이터 (~32,888행 × 156컬럼)

1. 결측치(빈칸) 현황

결측치란? 데이터에서 값이 비어있는 칸. 모델에 넣기 전에 채우거나 해당 컬럼을 제거해야 합니다.

Core code:

```
missing_count = df.isnull().sum()
missing_pct = (missing_count / len(df) * 100).round(2)
report = pd.DataFrame({"column": df.columns, "missing_pct": missing_pct})
report = report.sort_values("missing_pct", ascending=False)
```

구간	컬럼 수	의미
결측 0%	84개	빈칸 없음
0~10%	62개	약간 빈칸. 채워서 사용
10~30%	7개	원인 파악 필요
30% 이상	3개	특수 처리 또는 제거

결측 많은 컬럼 Top 10

#	컬럼	설명	결측률
1	jkhr_winrate	기수+마필 조합 승률	42.9%
2	hr_prev_rating	직전 경주 레이팅	33.7%
3	hr_winrate__z	승률 (z점수)	31.5%
4	rating__z	레이팅 (경주 내 z 점수)	26.7%
5	rating	마필 레이팅	26.5%
6	rating__pr	레이팅 (경주 내 백분위)	26.5%
7	hr_dist_winrate	같은 거리 승률	24.5%
8	hr_style_sd	각질 일관성	19.1%
9	style_vs_race	내 각질 - 경주 평균	10.0%
10	hr_style	각질 (선행형 /추입형 스타일)	10.0%

2. 왜 비어있나? (구조적 vs 랜덤)

Core code:

```
for col in high_missing_cols:
    for group_col in ["is_debut", "rank", "ageCond"]:
        group_missing = df.groupby(group_col)[col].apply(
            lambda x: x.isnull().mean() * 100
        )
        if group_missing.max() >= 90:
            classification = "structural"
            break
    else:
        classification = "random"
```

구조적 결측: 원래 값이 존재할 수 없어서 빈 것 (예: 데뷔전 말은 과거 성적이 없음)

랜덤 결측: 있어야 하는데 우연히 빠진 것

구조적 결측 (26개)

컬럼	설명	결측률	집중 그룹
jkhr_winrate	기수+마필 조합 승률	42.9%	is_debut=1 (100%)
hr_prev_rating	직전 경주 레이팅	33.7%	is_debut=1 (100%)
hr_winrate__z	승률 (z점수)	31.5%	is_debut=1 (100%)
rating__z	레이팅 (경주 내 z 점수)	26.7%	rank=국6등급 (100%)
rating	마필 레이팅	26.5%	rank=국6등급 (100%)
rating__pr	레이팅 (경주 내 백분위)	26.5%	rank=국6등급 (100%)
hr_dist_winrate	같은 거리 승률	24.5%	is_debut=1 (100%)
hr_style_sd	각질 일관성	19.1%	is_debut=1 (100%)
style_vs_race	내 각질 - 경주 평균	10.0%	is_debut=1 (100%)
hr_style	각질 (선행형 /추입형 스타일)	10.0%	is_debut=1 (100%)

랜덤 결측 (3개)

컬럼	설명	결측률
hr_rest_days__z	휴양일수 (z점수)	5.9%
hr_rest_days__pr	hr_rest_days__pr	5.8%
hr_rest_days	휴양일수	5.8%

3. 이상치(극단값) 탐지

Core code:

```
Q1 = train[col].quantile(0.25)
Q3 = train[col].quantile(0.75)
IQR = Q3 - Q1
lower = Q1 - 1.5 * IQR
upper = Q3 + 1.5 * IQR
```

```
is_outlier = (df[col] < lower) | (df[col] > upper)
# outlier rate > 30% -> skip (natural wide distribution)
```

이상치란? 다른 데이터와 동떨어진 극단적으로 크거나 작은 값.


예) 평균 휴양일 42일인데 868일 쉰 말.

탐지 방법 (IQR): $Q1 - 1.5 \times IQR$ 미만 또는 $Q3 + 1.5 \times IQR$ 초과 = 이상치

경마 데이터 주의점:


- 1착 상금은 국1등급(8.8억)과 국6등급(1,375만)이 64배 차이 → 이상치 아님, 등급 차이
- 이상치 비율 30% 초과 피쳐는 분포 자체가 넓은 것으로 판단하여 제거 대상에서 제외
- 이상치 제거/미제거 두 버전을 모두 제공 → 모델러가 비교 실험

Boxplot (상위 12개 피쳐)



빨간 점선 = IQR 경계. 경계 밖의 점들이 이상치입니다.

피쳐별 이상치 비율



이상치 상세 (상위 15개)

#	피쳐	설명	이상치 수	비율	제거?
1	clinic_30d	경주 전 30일 진료 건수	8,814	26.8%	O
2	hr_last_dist	직전 경주 거리 (m)	7,318	22.2%	O
3	birthday	생년월일 (YYYYMMDD)	6,202	18.9%	O
4	hr_dist_chg	직전 대비 거리 변화 (m)	5,746	17.5%	O
5	hr_rest_days	휴양일수	5,283	16.1%	O
6	ow_starts	마주 통산 출전 수	5,204	15.8%	O
7	hr_winrate__z	승률 (z점수)	5,196	15.8%	O
8	tr_starts	조교사 통산 출전 수	4,917	14.9%	O
9	wgBuda_m_chg	부담중량 증감	4,447	13.5%	O
10	jk_starts	기수 통산 기승 수	4,342	13.2%	O
11	hr_starts	마필 통산 출주 횟수	3,364	10.2%	O

#	피처	설명	이상치 수	비율	제거?
12	age	마필 연령 (세)	3,216	9.8%	O
13	hr_rest_ days__z	휴양일수 (z점수)	2,930	8.9%	O
14	n_run	출주두수 (이번 경주 출전 말 수)	2,765	8.4%	O
15	jkhr_star ts	기수+마필 조합 출전 횟수	2,553	7.8%	O

4. 중복 정보 (다중공선성)

Core code:

```
corr = df[numeric_features].corr()

# Extract pairs with |r| >= 0.8
for i in range(len(cols)):
    for j in range(i+1, len(cols)):
        if abs(corr.iloc[i, j]) >= 0.8:
            high_pairs.append((cols[i], cols[j], corr.iloc[i, j]))


sns.heatmap(corr, cmap="RdBu_r", center=0, vmin=-1, vmax=1)
```

다중공선성이란? 두 컬럼이 거의 같은 정보를 담고 있어서 하나만 남겨야 하는 것.

예) "1차 상금"과 "2차 상금"은 항상 비례 → 하나만 남기기.

기준: 상관계수 $|r| \geq 0.8$

상관관계 히트맵 (상위 40개 피쳐)



고상관 쌍 (총 62쌍, 상위 15개)

#	컬럼 A	컬럼 B	상관계수	제거 후보	이유
1	buga1	buga2	1.0000	buga2	중복
2	buga2	buga3	1.0000	buga3	중복
3	buga1	buga3	1.0000	buga3	중복
4	chaksun 1	chaksun 2	1.0000	chaksun 2	중복
5	chaksun 2	chaksun 5	0.9991	chaksun 5	중복
6	chaksun	chaksun	0.9991	chaksun	중복

#	컬럼 A	컬럼 B	상관계수	제거 후보	이유
	1	5		5	
7	chaksun 4	chaksun 5	0.9964	chaksun 5	중복
8	chaksun 1	chaksun 3	0.9955	chaksun 3	중복
9	chaksun 2	chaksun 3	0.9955	chaksun 3	중복
10	chaksun 2	chaksun 4	0.9920	chaksun 4	중복
11	chaksun 1	chaksun 4	0.9920	chaksun 4	중복
12	n_run	dusu	0.9910	dusu	결측 많음
13	hr_starts	hr_style_ n	0.9907	hr_starts	결측 많음
14	chaksun 3	chaksun 5	0.9906	chaksun 5	중복
15	rating	hr_prev_ rating	0.9871	hr_prev_ rating	결측 많음

5. 최종 처리 방향 요약

문제	처리	적용 결과
구조적 결측	0 채움 + 플래그 유지	rating_na 등으로 구분
랜덤 결측	train 중앙값 대입	valid/test에도 동일값 적용
이상치	IQR 기반 행 제거	v5~v8 = 이상치 제거 버전
다중공선성	한 쪽 컬럼 제거	134컬럼 → ~111컬럼

주의

- 모든 처리는 train set 기준으로 결정, valid/test에 동일 적용 (정보 누수 방지)
- 이상치 제거/미제거 두 트랙을 비교하여 모델 성능이 나은 쪽을 채택
- 트리 모델(RF, XGBoost)은 이상치에 강건하므로 v1(미제거)도 유효

KHUDA 3조 · EDA 결과 보고서 · 2026-08-16 22:23