

경주마 승률 예측 모델 및 배당률 비교 분석

결과 보고서

KHUDA · [조 번호] · [팀원 이름] · 2026. 08.

1. 프로젝트 개요

경마는 배당률이라는 형태로 대중의 예측이 실시간으로 집계되는 몇 안 되는 스포츠 도메인이다. 본 프로젝트는 말·기수·조교사·경주 당일 환경 정보를 바탕으로 경주마의 1착 확률을 예측하는 모델을 구축하고, 이 예측 확률을 배당률에서 환산한 시장의 암묵적 확률과 비교함으로써 데이터 기반 모델이 시장의 집단 판단을 뛰어넘을 수 있는지, 그리고 뛰어넘지 못한다면 그 이유는 무엇인지를 검증하는 것을 목표로 했다.

분석은 서울 경마장에서 2023년 8월부터 2026년 8월까지 시행된 32,888건의 출전 기록을 대상으로 했으며, 예측 대상은 각 출전마의 1착 여부(양성 비율 약 9.5%)이다. 데이터는 시점 순서에 따라 학습·검증·테스트 세 구간으로 분할하여, 미래 시점의 정보가 학습 과정에 유입되지 않도록 설계했다.

2. 기본 모델 구축 및 성능 비교

로지스틱 회귀, 랜덤포레스트, XGBoost 세 모델을 동일한 테스트 세트에서 평가했다. 배당률 및 배당률에서 파생된 값은 모델 입력에서 전부 제외하여, 모델이 시장 정보에 의존하지 않고 독립적으로 예측하도록 설계했다.

모델	Accuracy	Precision	Recall	F1(Macro)	ROC-AUC
로지스틱 회귀	0.3062	0.0952	0.7372	0.2867	0.5262
랜덤포레스트	0.7214	0.1971	0.6251	0.5629	0.7495
XGBoost	0.8903	0.2075	0.0531	0.5131	0.6846

표 1. 모델별 성능 비교 (테스트 세트 기준)

세 모델 중 랜덤포레스트가 ROC-AUC 0.7495로 가장 높은 판별력을 보여 최종 모델로 선정했다. 로지스틱 회귀는 재현율은 높았으나 정밀도가 극히 낮아 실제 활용 가치가 떨어졌고, XGBoost는 전체 정확도는 높았지만 소수 클래스인 1착을 거의 잡아내지 못하는 한계를 보였다. 이는 세 모델 모두에서 확인된 클래스 불균형 문제 (경주당 1착은 한 마리뿐이라는 구조적 특성)가 예측 성능에 상당한 영향을 미쳤음을 보여준다.

2.1 임계값(Threshold) 튜닝

랜덤포레스트의 예측 확률에 대해 기본값인 0.5 대신 여러 임계값 후보를 검증 세트에서 탐색했다.

Threshold	Precision	Recall	F1(Macro)
0.05	0.0973	0.9991	0.0904

Threshold	Precision	Recall	F1(Macro)
0.15	0.1050	0.9764	0.1888
0.25	0.1231	0.9235	0.3331
0.35	0.1504	0.8338	0.4536
0.45	0.1871	0.6884	0.5432
0.50	0.2087	0.5940	0.5750

표 2. 임계값별 성능 (일부 구간 발췌)

탐색 결과 F1(Macro) 기준으로는 기본값인 0.5가 가장 높은 성능을 보였다. 임계값을 낮출수록 재현율은 크게 개선되지만 정밀도가 급격히 하락하는 뚜렷한 상충 관계가 확인되어, 이후 분석에서는 기본 임계값을 그대로 사용했다.

2.2 변수 중요도 분석

모델 예측 확률과 시장 확률(배당률 환산값)의 차이, 즉 괴리가 상위 20%에 해당하는 출전 기록만 따로 모아 이 그룹의 변수 분포를 전체 데이터와 비교했다. 그 결과 직전 경주 성적, 말의 연령, 기수와 조교사의 최근 승률, 최근 14일간 훈련 횟수 등이 전체 평균과 가장 크게 벌어지는 변수로 나타났다. 이는 모델과 시장이 크게 엇갈리는 출전마일수록 최근 폼과 관련된 정보에서 유독 차이가 크다는 것을 시사한다.

2.3 군집화 분석

괴리 상위 20% 그룹을 K-means로 군집화한 결과, 실루엣 계수 기준 최적 군집 수는 2개였다. 두 군집 중 소수 군집(71건)은 국내 1~2등급의 고액 상금 경주에 출전한 말들로 구성되어 있었고, 다수 군집(2,099건)은 일반 등급 경주의 말들이었다. 즉 모델과 시장의 판단이 크게 갈리는 경주는 상금 규모, 다시 말해 경주의 등급에 의해 상당 부분 구분된다는 결과가 나왔다.

2.4 괴리 구간별 실제 승률 비교 — 핵심 검증

모델 확률과 시장 확률의 차이(괴리)를 10분위로 나누고, 각 구간에서 실제 승률이 둘 중 어느 쪽에 더 가까운지 집계했다. 이는 모델과 시장 중 어느 쪽의 판단이 실제 결과에 더 부합하는지를 가리는, 본 프로젝트에서 가장 중요한 검증 단계다.

괴리 구간	모델 평균 확률	시장 평균 확률	실제 승률
1 (가장 낮음)	0.1862	0.1058	0.0995
3	0.2767	0.0820	0.0737
5	0.3693	0.0946	0.0968
7	0.4536	0.0996	0.0912
9	0.5514	0.1048	0.1088

괴리 구간	모델 평균 확률	시장 평균 확률	실제 승률
10 (가장 높음)	0.6185	0.0948	0.0986

표 3. 괴리 10분위별 모델 확률· 시장 확률· 실제 승률 비교 (일부 구간 발췌)

모든 구간에서 실제 승률은 모델 확률보다 시장 확률에 훨씬 가깝게 나타났다. 모델의 예측 확률은 0.19~0.62 범위로 넓게 퍼져 있었던 반면, 시장 확률과 실제 승률은 모두 0.05~0.11 범위에 안정적으로 머물렀다. 이는 모델이 전반적으로 확률을 과대추정하고 있으며, 확률의 보정(calibration)이 필요함을 명확히 보여준다.

2.5 시장 편향(Favorite-Longshot Bias) 검증

해외 경마 시장에서는 인기마(배당률이 낮은 말)의 실제 승률이 시장 확률보다 높고, 비인기마는 반대로 낮게 나오는 경향이 잘 알려져 있다. 이 현상이 국내 서울 경마에서도 재현되는지 배당 구간별로 확인했다.

배당 구간	실제 승률	시장 확률	편향(bias)
1배대 미만	0.4970	0.5089	-0.0119
2~3배	0.3327	0.3307	+0.0021
3~5배	0.2202	0.2077	+0.0125
5~10배	0.1217	0.1142	+0.0075
10배 이상	0.0282	0.0319	-0.0037

표 4. 배당 구간별 실제 승률과 시장 확률 비교

분석 결과 인기마 구간의 편향은 -0.012, 비인기마 구간의 편향은 -0.004로 모두 크지 않았으며, 오히려 중간 구간(3~10배)에서는 시장이 살짝 과소평가하는 양의 편향이 관찰됐다. 종합하면 서울 경마 시장에서는 해외에서 흔히 보고되는 인기마-비인기마 편향이 뚜렷하게 나타나지 않았으며, 이는 시장이 상당히 효율적으로 가격을 형성하고 있다는 근거로 해석할 수 있다.

3. 추가 실험 1 — 확률 보정(Calibration)

기본 모델 분석에서 모델의 예측 확률이 실제 승률보다 전반적으로 부풀려져 있다는 문제가 확인되었다. 이에 따라 모델이 내놓는 확률값 자체를 실제 승률에 맞게 교정하는 실험을 진행했다. 이는 모델의 순위를 매기는 능력(누가 더 유력한지 가려내는 능력)이 아니라, 모델이 말하는 확률의 크기 자체가 믿을 만한지를 개선하는 작업이다.

구분	ROC-AUC	확률 오차(Cal_MAE)
보정 전 (Raw)	0.7495	0.3004
Platt Scaling 적용	0.7495	0.0121

구분	ROC-AUC	확률 오차(Cal_MAE)
Isotonic Regression 적용	0.7478	0.0298
시장 확률(배당률)	0.8168	0.1203

표 5. 확률 보정 전후 비교

Platt Scaling을 적용한 결과 확률 오차가 0.30에서 0.01 수준으로 25배가량 개선되어, 모델이 10%의 승률을 예측하면 실제로도 약 10%가 이기는 수준까지 확률의 신뢰도를 끌어올릴 수 있었다. 다만 이 보정은 확률값의 크기만 교정할 뿐 순위를 가려내는 능력(ROC-AUC)에는 영향을 주지 않았으며, 판별력 자체는 여전히 시장 (0.82)이 모델(0.75)보다 우위에 있었다. 따라서 모델이 제시하는 확률을 '기대 승률'로 해석하고자 한다면 보정 과정을 반드시 거쳐야 한다는 점이 이번 실험의 결론이다.

4. 추가 실험 2 — 모델과 시장의 결합

1차 모델의 예측 확률과 시장 확률을 함께 활용하면 각각의 장점을 살려 더 나은 성능을 낼 수 있을 것이라는 가설을 검증했다. 1차 모델의 예측 확률, 시장 확률, 그리고 둘의 차이(괴리)를 포함한 8개 변수로 2단계 모델을 다시 학습시켰다.

모델	ROC-AUC	확률 오차(Cal_MAE)
2단계 로지스틱 회귀	0.7081	0.3586
2단계 랜덤포레스트	0.7173	0.3546
2단계 XGBoost	0.7043	0.3522
1단계 랜덤포레스트(참고)	0.7495	0.3004
시장 확률 단독(참고)	0.8168	0.1203

표 6. 2 단계 모델 성능 비교

결과는 예상과 달리 2단계 모델의 최고 성능(ROC-AUC 0.717)이 1단계 모델(0.750)보다도 낮게 나타났으며, 시장 확률 단독(0.817)에는 여전히 크게 미치지 못했다. 2단계 모델의 변수 중요도를 살펴본 결과 시장 확률이 압도적인 비중을 차지했고, 1단계 모델의 예측 확률이 기여하는 정도는 미미했다. 이는 모델이 활용하는 과거 성적·훈련 정보를 베팅에 참여하는 대중 역시 이미 알고 베팅에 반영하고 있어, 모델이 추가로 제공할 수 있는 새로운 정보가 많지 않았기 때문으로 해석된다. 단순히 두 확률을 결합하는 방식으로는 시장을 넘어서기 어렵다는 것이 이번 실험의 결론이며, 이는 시장이 아직 반영하지 못한 정보나 시장이 상대적으로 비효율적인 구간을 찾는 접근이 필요하다는 다음 실험의 출발점이 되었다.

5. 추가 실험 3 — 이변(복병) 예측 모델

앞선 두 실험을 통해 '누가 1착 할지'를 직접 맞히는 접근으로는 시장을 넘어서기 어렵다는 점이 분명해졌다. 이에 따라 목표를 전환하여, 인기 하위 50%에 해당하는 비인기마이면서 실제로 1착을 차지한 경우를 '이변'으로 정의하고, 시장이 상대적으로 놓칠 가능성이 있는 이변을 예측하는 모델을 별도로 구축했다.

모델	Accuracy	Precision	Recall	F1(Macro)	ROC-AUC
랜덤포레스트 (이변예측)	0.6556	0.1935	0.5099	0.5271	0.6422
XGBoost (이변예측)	0.8454	0.2381	0.0793	0.5171	0.5821

표 7. 이변 예측 모델 성능

이변은 전체의 13.2%만 해당하는 희귀 사건인 만큼 ROC-AUC 0.64는 절대적으로 높은 수치는 아니지만, 완전히 무작위로 추측하는 경우(0.5)보다는 뚜렷하게 나은 판별력이다. 다만 이 실험에서 실질적으로 중요한 것은 전체 판별력보다, 모델이 높은 점수를 준 말들에서 실제 이변 적중률이 얼마나 높아지는가였다.

예측 점수 구간	이변 적중률	평균 배당률
0 (최하위)	0.0365	71.50배
3	0.0904	45.23배
6	0.1809	35.73배
9 (최상위)	0.2383	24.52배

표 8. 예측 점수 구간별 이변 적중률 (일부 구간 발췌)

모델이 가장 높은 점수를 부여한 상위 10% 그룹의 실제 이변 적중률은 23.8%로, 전체 평균 이변 비율 13.2% 대비 약 1.8배 높았다. 이 그룹의 평균 배당률이 24.5배였다는 점을 고려하면, 단순 기대값 계산상 100원을 투자했을 때 평균 583원이 회수되는 셈이다. 물론 실제 베팅에서는 변동성이 크므로 이 수치를 그대로 수익으로 해석할 수는 없으나, 무작위로 비인기마를 고르는 경우보다 유의미하게 나은 선택이 가능하다는 것을 보여준다.

변수 중요도를 살펴보면 이변은 특정 패턴에서 발생하는 경향이 있었다. 직전 경주에서 하위권에 머물렀던 말이 이번 경주에서 갑자기 상위권으로 도약하는 경우, 최근 14일간 훈련 횟수가 급증해 컨디션 회복 신호로 해석될 수 있는 경우, 그리고 입상률이 높은 기수가 비인기마에 탑승하는 경우에 이변이 상대적으로 자주 발생했다. 이는 대중이 '직전 성적이 나빴던 말은 이번에도 부진할 것'이라는 단순한 추론에 의존하는 반면, 모델은 기수 교체나 훈련량 변화 같은 세부 신호까지 반영해 판단한다는 것을 시사한다.

6. 종합 결론

본 프로젝트는 '경주마의 1착 여부를 직접 예측하는 모델이 배당률이라는 시장의 집단 판단을 능가할 수 있는가'라는 질문에서 출발했다. 결론부터 말하면, 직접적인 승부 예측에서는 모델이 시장을 넘어서지 못했다. 랜덤포레스트 모델의 판별력(ROC-AUC 0.75)은 시장 확률의 판별력(0.82)에 미치지 못했으며, 모델과 시장의 예측을 단순 결합하는 방식으로도 이 격차를 좁히지 못했다. 서울 경마 시장에서는 해외에서 보고되는 인기마-비인기마 편향 역시 뚜렷하게 나타나지 않아, 시장이 상당히 효율적으로 가격을 형성하고 있다는 근거가 확인되었다.

다만 이 과정에서 두 가지 실질적인 성과를 확인했다. 첫째, 모델이 산출하는 확률값 자체는 보정을 거치면 신뢰할 수 있는 수준으로 개선할 수 있다는 것이다. 둘째, 목표를 '승부 예측'에서 '시장이 놓치는 이번 탐지'로 전환했을 때는 모델이 실질적인 정보 이점을 제공할 수 있다는 것이다. 모델이 높은 점수를 준 비인기마 그룹은 전체 평균보다 1.8배 높은 이번 적중률을 보였으며, 이는 대중이 놓치기 쉬운 최근 폼 변화, 기수 교체, 훈련량 증가 같은 신호를 모델이 포착했기 때문으로 해석된다.

종합하면, 데이터 기반 모델은 시장 전체를 상대로 승부를 겨루는 방식보다는 시장이 상대적으로 비효율적인 좁은 영역, 즉 대중이 쉽게 간과하는 비인기마 구간에서 더 실질적인 가치를 지닌다는 것이 본 프로젝트의 핵심 결론이다.

7. 한계 및 향후 과제

본 분석은 서울 경마장의 약 3년치 데이터로 한정되어 있어 다른 경마장이나 더 긴 기간으로 일반화하기에는 한계가 있다. 또한 말의 부상이나 컨디션과 같이 데이터로 관측되지 않는 요인은 반영하지 못했다. 이번 예측 모델 역시 ROC-AUC 자체는 높지 않아 특정 경주의 결과를 확신 있게 예측하기보다는 확률적으로 유리한 후보를 걸러내는 보조 도구 수준으로 이해할 필요가 있다.

향후에는 각질(선행·추입 등 경주 스타일)이나 기수-마필 궁합과 같은 변수를 보강하고, 부산경남·제주 경마장으로 데이터 범위를 확장하여 이번 예측 모델의 재현성을 검증하는 작업이 이어질 필요가 있다.