

경주마 시장확률 보정 모델 최종 결과보고서

배당률을 '맞혀야 할 정확도'가 아니라
경주 단위 확률 기준선으로 재정의한 검증

핵심 결론

동결된 M2 모델은 Final Test에서 시장보다 낮은 Log Loss와 Brier score를 기록했다. 그러나 95% 구간이 0보다 큰 개선은 Log Loss에만 확인되어 엄격한 성공 기준은 충족하지 못했다. 경제성 기준을 만족한 선택은 0건이므로 공식 행동은 no_bet이다.

분석 범위 2023.08.05-2026.08.09 | 서울 경마 3,167개 정상 경주

보고서 작성일 2026.08.18

요약

판정: 부분적 초과성과, 배팅 비활성

M2는 시장 대비 Log Loss를 0.003902, Brier score를 0.000602 개선했다. 경주 대표본 부트스트랩에서 Log Loss 개선의 95% 구간은 [+0.001085, +0.006721]로 양수였다. Brier 개선 구간은 0을 포함했으므로 두 핵심 지표 모두에서 안정적으로 우월하다는 프로젝트 성공 조건은 미충족이다.

표 1. 프로젝트 의사결정 요약

질문	최종 답변	근거
시장보다 확률 예측이 좋은가?	부분적으로 예	M2 Log Loss 1.813446 < 시장 1.817348
개선이 통계적으로 안정적인가?	Log Loss만 예	Log Loss Δ 95% CI가 0 초과
승자 적중률도 더 높은가?	아니오	M2 37.48%, 시장 37.80%
수익 가능한 배팅 규칙인가?	아니오	Calibration/Test 모두 선택 0건
현재 운영 행동은?	no_bet	ROI 하한·최소 표본 조건 미충족

최종 모델 카드

- 모델 버전: m2_xgboost_sum_l005_t095_v1
- 구성: XGBoost 사전시장 모델 → 경주 내 합 정규화 → 시장확률과 기하결합($\lambda=0.05$) → 온도 보정($T=0.95$)
- 용도: 시장확률의 미세 보정과 연구용 확률 산출. 수익 보장 또는 배팅 권고 용도가 아님
- 현재 상태: 오프라인 재현 가능, 실시간 운영 미준비

1. 목표 재정의와 성공 기준

초기 프로젝트는 출전마별 1착 여부를 이진 분류하고 정확도·ROC-AUC로 모델과 배당률을 비교했다. 하지만 한 경주에서 우승자는 원칙적으로 한 마리이고, 배당률은 독립적인 이진 임계값이 아니라 경주 참가자 전체에 배분되는 확률 분포다. 따라서 ‘배당률보다 높은 정확도’는 경주 단위 확률 예측 품질이 시장의 암묵적 확률보다 좋은지로 재정의했다.

표 2. 프로젝트 목표 변경

구분	기존 정의	최종 정의
예측 단위	출전마 행별 이진 분류	race_id별 승자 확률 분포
시장 기준선	배당률/인기순위와 간접 비교	역배당률을 경주 내 정규화한 q_market
핵심 지표	Accuracy, ROC-AUC, F1	경주 Log Loss, 경주 Brier score
보조 지표	Precision, Recall	Top-1 accuracy, MRR
성공 판정	점수 단순 우위	시장-모델 손실 Δ 의 95% CI 하한 > 0
경제성	적중률에서 암시	별도 ROI·표본·부트스트랩 기준

1.1 핵심 지표의 해석

- 경주 Log Loss: 실제 우승마에 부여한 확률의 음의 로그. 자신 있게 틀린 예측을 크게 벌점한다.
- 경주 Brier score: 모든 출전마의 예측확률과 원-핫 우승 결과 간 제곱오차 합. 분포 전체의 정확성을 본다.
- 시장 대비 개선량 Δ = 시장 손실 - 모델 손실. Δ 가 양수면 모델이 좋다.
- Top-1 accuracy는 가장 높은 확률을 준 말이 이겼는지 보지만, 확률의 크기와 신뢰도는 평가하지 못하므로 보조 지표다.

엄격한 프로젝트 성공 조건

Final Test에서 Log Loss와 Brier score 모두 시장보다 낮고, 각 paired race bootstrap 95% CI의 하한이 0보다 커야 한다. 수익성은 이 조건과 독립적으로 검증하며, 확률 예측이 좋아도 no_bet일 수 있다.

2. 데이터, 품질 통제, 분할

원천 데이터는 56,648개 출전 행, 156개 열, 5,361개 경주다. 이 중 서울 32,888개 행을 표준 중간 데이터로 변환했다. 원본은 data/raw/final.csv.gz에 불변 보관하고 SHA-256으로 동일성을 관리한다.

표 3. 데이터 범위와 비정상 경주 정책

항목	규모	처리 원칙
전체 원천	56,648행 × 156열	원본 불변·해시 기록
서울 중간 데이터	32,888행 × 162열	서울 행 보존 후 파생열 재계산
정상 경주	3,167경주 / 32,838행	주 분석 포함
동착	4경주 / 39행	경주 전체 제외
우승자 없음	1경주 / 11행	경주 전체 제외

2.1 시간 순서 고정 분할

표 4. 경주 단위 시간 분할

구간	기간	경주	출전 행	용도
Train	2023.08.05-2025.05.11	1,891	19,617	전처리·모델 적합
Calibration	2025.05.17-2025.12.27	641	6,582	정규화·혼합·온도 선택
Final Test	2025.12.28-2026.08.09	635	6,639	동결 후 1회 평가
Excluded	비정상 경주 기간 내	5	50	주 분석 제외

동일 경주와 동일 날짜는 하나의 fold에만 속한다. Final Test는 모델·특징·정규화·혼합계수·온도 정책을 동결한 뒤 한 번만 열었으며, 결과를 본 뒤 조정하지 않았다.

2.2 누출 방지

- PRE_RACE 특징 112개만 허용하고, 알 수 없는 열은 기본 거부한다.
- 결과·착순·배당 파생 결과 같은 POST_RACE/MARKET/TARGET 열은 사전시장 모델 입력에서 제외한다.
- q_market은 일반 특징으로 학습시키지 않고, 경주 내 확률 기준선 및 후단 결합값으로만 사용한다.

표 5. 특징 역할별 사용 정책

역할	열 수	사전시장 모델 정책
PRE_RACE	112	허용
ID	12	식별·조인만 사용
POST_RACE	5	금지
MARKET	23	일반 특징 금지; q_market만 후단 사용
SPLIT / TARGET	1 / 2	분할·평가 전용
LEGACY / CONTROL	4 / 3	감사·품질 통제 전용

3. 전처리와 모델링

전처리 통계는 Train에서만 적합했다. 수치형은 0.5/99.5 백분위로 클리핑하고 중앙값 대체와 결측 지시자를 적용했다. 범주형은 최빈값 대체 후 최소 빈도 10의 원-핫 인코딩을 적용했다. 로지스틱 회귀에는 스케일링을 적용하고 XGBoost에는 적용하지 않았다.

표 6. 비교 모델 구성

구성	M0 시장	M1 로지스틱	M2 XGBoost
역할	기준선	해석 가능한 독립 모델	비선형 독립 모델
입력	종가 단승 배당	PRE_RACE 112개	PRE_RACE 112개
수치 특징	해당 없음	99개·스케일링	99개·비동질 스케일
범주 특징	해당 없음	13개 원-핫	13개 원-핫
주요 고정값	경주 내 합=1	L2, C=0.1	고정 권장 파라미터

3.1 시장확률과 최종 확률

- 1) 시장확률: $q_i = (1 / odds_i) / \sum_j (1 / odds_j)$. 각 경주의 합이 1이 되도록 오버라운드를 제거한다.
- 2) 독립 모델확률: 출전마별 raw score를 산출한 후 선택된 sum 정규화로 경주 합을 1로 맞춘다.
- 3) 기하결합: $p_{blend} \propto q_{market}^{(1-\lambda)} \times p_{model}^{\lambda}$, $\lambda=0.05$. 시장 95%, 독립 모델 5%의 보수적 보정이다.
- 4) 온도보정: $p_{final} \propto p_{blend}^{(1/T)}$, $T=0.95$. Calibration에서만 선택했다.

설계 의도

독립 모델이 시장을 대체하도록 강제하지 않는다. 강한 시장 기준선을 중심으로, 사전경주 특징이 제공하는 추가 신호만 작게 반영하는 보정 모델이다.

4. Calibration에서의 선택

표 7. 독립 확률의 Calibration 성능

확률	Log Loss	Brier	Top-1	해석
M0 시장	1.776036	0.762636	39.00%	강한 기준선
M1 독립	1.965904	0.817458	30.89%	시장보다 열위
M2 독립	1.976751	0.821722	29.64%	시장보다 열위

독립 모델은 시장을 단독으로 넘지 못했다. 따라서 12-14단계는 독립 확률을 경주 분포로 정규화하고 시장과 소량 결합한 뒤 온도를 조정하는 순서로 진행했다. 모든 선택은 Calibration의 경주 Log Loss를 우선 기준으로 했으며 Test에는 접근하지 않았다.

표 8. 후단 보정 정책 선택

단계	후보/탐색	M1 선택	M2 선택	결정 근거
12 정규화	sum, logit-softmax	sum	sum	Calibration Log Loss
13 시장 결합	λ grid	0.05	0.05	최소 Log Loss
14 온도 보정	T grid	0.95	0.95	최소 Log Loss

표 9. Calibration 최종 후보 성능

Calibration 최종	Log Loss	Brier	Top-1	시장 대비
M0 시장	1.776036	0.762636	39.00%	기준
M1 결합·T=0.95	1.773767	0.761996	38.38%	차선 후보
M2 결합	1.775286	0.762541	38.22%	Log Loss 개선
M2 결합·T=0.95	1.773358	0.762075	38.22%	최종 후보

동결 결정

Final Test 개봉 전에 19개 정책·모델·보고서 파일을 해시로 동결했다. 배포 후보는 m2_xgboost_sum_l005_t095_v10이다.

5. Final Test 결과

동결된 정책을 635개 경주·6,639개 출전 행의 Final Test에 한 번 적용했다. 아래 표의 Δ 는 시장 손실-모델 손실이며, 양수일수록 모델이 좋다.

표 10. Final Test 성능

모델	Log Loss	Brier	Top-1	MRR	시장 대비 LL Δ
M0 시장	1.817348	0.777920	37.80%	0.5722	—
M1 최종	1.814938	0.777907	37.80%	0.5718	+0.002409
M2 최종	1.813446	0.777318	37.48%	0.5702	+0.003902




그림 1. 시장과 최종 모델의 핵심 손실 비교. 축은 작은 차이를 보기 위해 절단되어 있다.

수치 해석

M2의 Log Loss는 시장보다 약 0.21%, Brier score는 약 0.08% 낮다. 반면 Top-1은 시장보다 0.315%p 낮다. 즉 이 모델의 이점은 승자 한 마리를 더 자주 고르는 데 있지 않고, 우승확률 분포 전체를 조금 더 정교하게 조정하는 데 있다.

6. 불확실성: 경주 단위 paired bootstrap

경주 내부 출전마의 상관을 보존하기 위해 행이 아니라 race_id를 단위로 635개 경주를 복원추출했다. 시장과 모델의 동일 경주 차이를 함께 재표본화했으며, 5,000회·seed 42의 95% percentile 구간을 계산했다.

표 11. 시장 대비 개선량의 부트스트랩 결과

모델·지표	점추정 Δ	95% CI	P(모델 우위)	하한>0
M1 Log Loss	+0.002409	[-0.000463, +0.005223]	94.72%	아니오
M1 Brier	+0.000013	[-0.001070, +0.001077]	50.24%	아니오
M2 Log Loss	+0.003902	[+0.001085, +0.006721]	99.48%	예
M2 Brier	+0.000602	[-0.000483, +0.001687]	84.88%	아니오
M2 Top-1	-0.003150	[-0.009449, +0.003150]	9.68%	아니오



그림 2. 점은 시장 대비 개선량, 선은 95% 구간이다. 0 오른쪽이 모델 우위다.

최종 통계 판정

M2의 Log Loss 개선은 표본 변동을 고려해도 양수로 지지된다. Brier 개선은 점추정상 양수지만 구간이 0을 포함한다. 따라서 '두 핵심 지표 모두 안정적으로 시장을 능가'하는 엄격한 성공 기준은 충족하지 못했다.

7. 경제성 평가와 행동 정책

확률 예측력과 수익성은 분리해 평가했다. 기대우위 $\text{expected_edge} = p_{\text{final}} \times \text{closing_odds} - 1$ 로 정의하고, Calibration에서 5%·10%·15% 임계값을 탐색했다. 활성화 조건은 최소 100건, ROI>0, 경주 단위 bootstrap 95% ROI 하한>0이다.

표 12. 종가 배당 기반 경제성 진단

구간	최대 기대우위	평균 추정 공제율	5/10/15% 선택	정책
Calibration	-8.48%	19.91%	모두 0건	no_bet
Final Test	-3.47%	19.90%	모두 0건	기술적 확인만

공식 행동: no_bet

가장 큰 기대우위조차 Calibration -8.48%, Final Test -3.47%로 0보다 작았다. 이는 시장확률보다 소폭 좋은 확률 추정이 약 20%의 공제율을 넘어 양의 기대수익으로 이어지지 않았음을 뜻한다.

7.1 해석상의 제한

- 사용한 배당은 사후에 확정된 종가다. 실제 의사결정 시점의 스냅샷이 아니므로 실행 가능한 전략 검증이 아니다.
- 배당 변동, 전송 지연, 베팅 거절, 풀 충격, 최소 베팅금과 체결 가능성을 모델링하지 않았다.
- 수익률은 희귀한 고배당 적중과 다중 임계값 탐색에 민감하다.
- 본 결과는 연구·교육용이며 금융 또는 도박 권고가 아니다.

7.2 왜 no_bet도 유효한 결과인가

모델의 가장 중요한 운영 기능 중 하나는 행동하지 않아야 할 때를 구분하는 것이다. 현재 데이터에서 무리하게 임계값을 낮춰 베팅 건수를 만드는 것은 Calibration으로 정책을 선택한다는 원칙과 양의 ROI 하한 조건을 위반한다. 따라서 0건 선택은 실패한 코드가 아니라 사전에 정한 위험 통제가 정상 작동한 결과다.

8. 예측 출력 계약과 운영 준비도

18단계에서 모델 버전 m2_xgboost_sum_l005_t095_v1의 출력 스키마를 고정했다. 유효한 경주의 확률 합은 1이어야 하며, entry_id는 고유해야 한다. 결과 열은 입력에서 금지되고, 불안정한 경주는 prediction_rejected로 처리한다. 현재 유효한 예측의 행동은 모두 no_bet이다.

표 13. 예측 출력 스키마

그룹	필드
추적성	model_version, prediction_time, odds_snapshot_time, race_start_time, odds_source
경주·출전 식별	race_id, entry_id, hrNo, hrName, winOdds_snapshot
확률	q_market, p_premarket, p_final, market_delta, break_even_prob
경제성·순위	expected_edge, pred_rank
행동·거절	action, rejection_reason

8.1 현재 운영 차단 조건

- 타임스탬프가 포함된 실제 사전경주 배당 스냅샷
- 공식 경주 시작시각과 완전한 출전 목록
- 스키마 드리프트 및 거절 경주 모니터링

위 조건이 충족되기 전에는 live_readiness=false다. 또한 실시간 배당을 확보하더라도 데이터 드리프트·확률합·누락 출전·스냅샷 지연을 감시하고, 정책 변경은 새 Calibration 구간에서 재검증한 뒤 별도 버전으로 배포해야 한다.

9. 한계, 다음 실험, 최종 권고

9.1 주요 한계

- 서울 경마 약 3년만 분석했으므로 다른 경마장·시기·시장 상태에 대한 외적 타당성이 제한된다.
- 시장확률은 종가 배당 기반이다. 실제 예측 시점의 정보 집합과 일치하지 않는다.
- M2의 개선 폭은 작다. Log Loss에서는 안정적이지만 Brier와 Top-1에서는 확정적 우위를 보이지 못했다.
- 비정상 경주는 주 분석에서 제외했다. 동착을 확률적으로 처리하는 별도 목적함수는 다루지 않았다.
- 공제율을 넘는 양의 기대우위가 없어 경제적 실행 가능성은 입증되지 않았다.

9.2 권장 후속 순서

표 14. 다음 개발 순서

우선순위	과제	완료 조건
1	실제 사전 배당 스냅샷 수집	예측시각·배당시각·시작시각 완전성 99%+
2	시간 이동 재검증	새 비공개 기간에서 동일 방향의 LL Δ 확인
3	특징 시점 감사 강화	모든 특징의 available_at 자동 검증
4	경마장 외적 검증	부경/제주에서 독립 평가
5	확률 모델 개선	Calibration에서 LL·Brier 동시 개선
6	경제성 재검증	100건+ 및 ROI 95% CI 하한>0

최종 권고

연구 모델로는 유지하되 베팅 기능은 비활성화한다. 다음 목표는 현재 Test에 맞춘 추가 튜닝이 아니라, 새로운 시점 데이터와 실제 사전 배당 스냅샷에서 Log Loss 개선의 재현성과 경제적 실행 가능성을 독립적으로 검증하는 것이다.

부록 A. 재현성과 산출물

프로젝트 문서와 코드는 다음 고정된 흐름을 따른다. 모든 경로는 프로젝트 루트 기준이다.

표 A-1. 주요 근거 파일

영역	대표 산출물
프로젝트 지침	PROJECT_GUIDELINES.md
원천·중간 데이터	data/raw/final.csv.gz, data/interim/seoul_entries.csv.gz
데이터 정책	data/manifests/dataset_policy.json, feature_registry.json, split_manifest.json
동결·평가	data/manifests/pre_final_test_freeze.json, final_test_evaluation.json
실험 보고서	reports/experiments/stage_12_normalization.json ... stage_18_prediction_contract.json
예측 계약	data/manifests/prediction_output_schema.json
실행 안내	README.md, SETUP.md, TESTING.md

A.1 검증 명령

PowerShell

```
.\scripts\run_tests.ps1
```

Python

```
python -m unittest discover -s tests -v
```

19단계 기준 11개 테스트 모듈, 72개 테스트가 통과했다. 데이터 무결성, 경주 분할, 특징 레지스트리, 모델 정책, 최종 평가, 부트스트랩, 백테스트, 예측 계약과 문서 구성이 회귀 테스트 대상이다.

A.2 보고서 판독 규칙

- 손실 지표는 낮을수록 좋다.
- 시장 대비 Δ 는 시장 손실-모델 손실이므로 양수일수록 좋다.
- 점추정과 통계적 지지를 구분한다. 95% CI가 0을 포함하면 안정적 우위로 판정하지 않으며, 확률 우위와 수익성 우위를 동일시하지 않는다. Final Test로 동결 정책을 수정하지 않는다.

부록 B. 단계별 완료 내역

표 B-1. 프로젝트 20단계 이행 요약

단계	완료 내용
1-4	원천 데이터 고정, 서울 데이터 표준화, 품질·경주 정책, 시간 분할
5-7	특징 레지스트리, 누출 방지, Train-only 전처리 기반
8-11	M0 시장 기준선, M1 로지스틱, M2 XGBoost, 비교 기반
12	경주 내 확률 정규화 선택
13	시장-모델 기하결합 λ 선택
14	온도 T 선택 및 최종 후보 확정
15	동결 후 Final Test 1회 평가
16	경주 단위 paired bootstrap
17	종가 배당 경제성 검증 및 no_bet 정책
18	예측 출력 계약과 운영 차단 조건
19	README·설치·테스트 문서 및 72개 회귀 테스트
20	최종 결과보고서 통합·검증

본 보고서는 1차 결과보고서의 결론을 덮어쓰지 않는다. 목표 재정의 이후 생성된 정책·모델·평가 산출물을 기준으로 작성한 최종본이며, 1차 보고서는 연구 방향 전환의 이력으로 별도 보존한다.