

KHUDA 10기 토이프로젝트 3조

배당률 포함 이변 예측 모델 보고서

배당률을 피처로 활용하면 이변 예측이 얼마나 개선되는가 — A/B/C 비교 실험

0. 세 줄 요약

- 배당률(q)을 피처에 포함시킨 모델(C)이 배당률 단독(A)보다 이변 예측 성능이 높다 (AUC 0.742 vs 0.737).
- C 모델 상위 5% 선별 베팅 시 ROI +25.9% (수수료 반영 후). 부트스트랩 1,000회 중 81%에서 수익 발생.
- 다만 95% 신뢰구간이 0을 포함하여, 통계적으로 '확실한 수익'이라 단정하기는 어렵다. 정보 가치는 존재하나 표본 확대가 필요.

1. 이 실험의 배경

1.1 이전 실험 요약

우리 프로젝트의 첫 번째 시도는 '배당률을 제외하고 1착을 예측하여 시장을 이기는 것'이었다. 결과는 실패 — 시장(배당률) ROC-AUC 0.81 대 모델 0.75. 어떤 전처리(이상치 제거, 스케일링, 고상관 제거)를 해도 시장을 넘지 못했다.

그래서 목표를 바꿨다. '시장을 이기겠다'가 아니라 '시장이 놓치는 이변을 배당률과 함께 잡겠다'.

1.2 이 실험의 핵심 질문

"배당률(q)을 피처로 포함시키면, 배당률 단독보다 이변을 더 잘 잡을 수 있는가?"

즉, 배당률이 '대략적인 인기도'를 알려주고, 나머지 피처(마필 상태, 기수, 훈련량 등)가 '같은 배당대 안에서 진짜 이길 말'을 세분화해줄 수 있는지를 검증한다.

2. 실험 설계

2.1 타겟 정의

upset = 1 if (pop_pct >= 0.5) AND (win == 1)

pop_pct >= 0.5 = 경주 내 배당률 순위 하위 50% (비인기마). win == 1 = 실제 1착.

비인기마만을 학습 대상으로 사용. 인기마는 이번 대상이 아니므로 제외.

2.2 세 가지 모델 비교

모델	피쳐	의미
A (베이스라인)	q (배당률 암묵적 확률) 1개	배당률만으로 이변을 얼마나 잡나?
B (기존)	말/기수/환경 피쳐 ~86개 (배당률 완전 제외)	배당률 없이 이변을 잡을 수 있나?
C (결합)	q + 말/기수/환경 피쳐 ~87개	배당률에 피쳐를 더하면 더 잘 잡나?

2.3 전처리

단계	처리	비고
1. 필터링	서울 + 비인기마 (pop_pct>=0.5)	56,648 → 17,392행
2. 결측치	구조적→0, 랜덤→train 중앙값	rating, hr_winrate 등 26개 컬럼
3. 다중공선성	배당률 14개→q만, 고상관 23개 제거	상관 0.8+ 쌍에서 한쪽 삭제
4. 인코딩	범주형 13개 → LabelEncoder	rank, track, weather 등
5. 스케일링	StandardScaler (train fit)	로지스틱 회귀를 위해
6. 분할	시간순 6:2:2	train 60% / valid 20% / test 20%

2.4 왜 배당률 파생 14개 중 q만 남겼나

14개 컬럼 간 상관계수를 계산한 결과, q와 나머지 13개의 |r|이 대부분 0.9 이상이었다. 사실상 같은 정보의 다른 표현이므로, 가장 깨끗한 형태인 q(오버라운드 제거 후 정규화, 경주 내 합=1)만 대표로 사용.

2.5 분할 정보

Fold	행 수	비율	upset 비율	기간
train	10,425	60%	2.95%	2023-08 ~ 2025-05

valid	3,439	20%	2.70%	2025-05 ~ 2025-12
test	3,528	20%	2.66%	2025-12 ~ 2026-08

3. 모델 성능 비교

test 3,528행, 기저율 2.66% (94마리가 실제 이변).

피쳐셋	모델	AUC	F1-Macro	Precision	Recall
A (q only)	LR	0.7369	0.4909	0.0628	0.5426
A (q only)	RF	0.6113	0.4434	0.0390	0.4468
B (no odds)	LR	0.6485	0.4326	0.0439	0.5851
B (no odds)	RF	0.6572	0.5268	0.0909	0.0638
C (q + features)	LR	0.7060	0.4785	0.0576	0.5532
C (q + features)	RF	0.7420	0.5462	0.0977	0.1809

핵심 결과:

- C(결합) AUC = 0.7420 > A(배당률만) = 0.7369 > B(피쳐만) = 0.6572
- C vs A 개선: +0.0051 — 피쳐가 배당률 위에 추가 정보를 제공
- A > B — q 하나가 피쳐 86개보다 강력. 시장 효율성 재확인
- RF가 LR보다 우수 — 비선형 관계(훈련량×휴식일 교호작용 등)를 포착

4. 비인기마 배당 구간별 A vs C

핵심 질문: '고배당(비인기) 구간에서 C가 A보다 더 잘 잡는가?'

배당률만으로는 같은 고배당 구간 안에서 말을 구분 못한다. 피쳐가 추가 정보를 제공하는지 확인.

구간	마리 수	기저율	A 적중률	C 적중률	C-A	C Lift
10-20x	640	0.0641	0.0938	0.1016	+0.0078	1.59x
20-40x	1285	0.0272	0.0467	0.0467	+0.0000	1.71x

40x+	1520	0.0079	0.0099	0.0132	+0.0033	1.67x
------	------	--------	--------	--------	---------	-------

해석: 10~20배 구간에서 C가 A보다 +0.78%p 우위. 40배+ 구간에서도 +0.33%p. 고배당일수록 '배당률만으로는 부족하고, 피처(훈련량, 기수 컨디션 등)가 추가 정보를 제공'한다는 가설을 지지.

5. 수익률(ROI) 시뮬레이션

5.1 전략 설명

C 모델이 '이변 확률 높다'고 예측한 상위 N%에만 단승 베팅. winOdds에는 이미 ~20% 공제율이 반영되어 있으므로, 아래 ROI는 수수료 차감 후 실질 수익률이다.

5.2 세 가지 베팅 전략

전략	방식	장점
Flat	모든 베팅에 동일 금액	단순, 비교 기준
Proportional	확률 높을수록 비례해서 더 많이	자신 있는 곳에 집중
Kelly (Half)	기대값 기반 최적 비율 계산	수학적 최적, 장기 수익 극대화

Kelly 공식: $f^* = (p \times b - 1) / (b - 1)$, Half-Kelly = $f^* / 2$

p = 모델 예측 이변 확률, b = winOdds

기대값이 음수이면 Kelly = 0 (베팅하지 않음) → 자동으로 나쁜 베팅 걸러냄

5.3 결과 (test set 3,528건)

Top%	베팅 수	적중	적중률	평균 배당	ROI
5%	176	17	0.097	13.4	+25.9%
10%	352	27	0.077	14.8	+7.3%
15%	529	41	0.077	15.8	+11.3%
20%	705	53	0.075	17.0	+18.0%
30%	1058	60	0.057	19.0	-8.3%

무작위 비인기마 베팅 ROI: -26.5% (비교 기준)

모델 상위 20%까지는 수익, 30%부터 손실 전환.

6. 신뢰구간 — 이 결과를 얼마나 믿을 수 있나

부트스트랩 1,000회 복원추출로 ROI 분포를 만들어 95% 신뢰구간을 계산.

Top%	Flat 중위값	95% CI 하한	95% CI 상한	P(수익)	Kelly P(수익)
5%	+24.6%	-26.0%	+92.9%	80.6%	82.8%
10%	+6.2%	-28.1%	+51.2%	61.1%	65.7%
15%	+10.4%	-21.6%	+46.6%	74.6%	77.1%
20%	+18.1%	-11.8%	+51.2%	86.9%	88.3%

해석:

- 95% CI 하한이 전부 음수 → '100% 수익 보장'은 아님
- P(수익) 80%+ (Top 5%) → 돈 벌 가능성이 손해 볼 가능성보다 4배 높음
- Top 20%의 P(수익) = 87% → 가장 안정적
- 표본 부족(3,528건)이 근본 원인. 3~5년 데이터로 재검증 필요

정직하게 말하면:

- 선별 능력은 확실하다 — 적중률 2.66% → 9.7% (상위 5%), Lift 3.6배
- 수익성은 '가능성 있음'이지 '확정'이 아니다
- 학술적으로는 '정보 가치(edge)가 존재하나 유의수준 5%를 달성하지 못함'

7. 어떤 변수가 중요했나

순위	피쳐	중요도
1	q	0.1914
2	tr_winrate_z	0.0260
3	train_runs_14_z	0.0234
4	ow_starts	0.0228
5	rating_z	0.0211
6	ilsu	0.0211

7	ow_resid	0.0202
8	tr_winrate	0.0199
9	jk_plcrate	0.0192
10	wg_z	0.0190

q(배당률 확률)의 순위: 1위

q가 상위권 → 배당률이 이번 예측에서 여전히 핵심 정보. 나머지 피쳐들은 그 위에 정밀도를 더하는 역할.

해석: 마필의 최근 상태(직전 착순, 훈련량, 휴식일)가 핵심. 시장은 통산 성적에는 잘 반응하지 않, 최근 컨디션 변화는 덜 반영 → 모델이 잡아낸 틈.

8. 팀원 실험(배당률 제외)과의 비교

항목	팀원 실험	이번 실험
배당률 피쳐	전부 제외	q 포함
타겟	upset_B (비인기마 입상)	upset (비인기마 1착)
Best AUC	0.6420 (RF)	0.7420 (RF)
Lift@10%	1.72	—(적중률 기준 3.6x)
수익 배당	연승(plcOdds)	단승(winOdds)
수익 결론	CI가 0 포함 → 불확실	P(수익)=81% - 가능성 있음
불균형 처리	적용 시 전부 나빠짐	balanced 적용 (기본)
핵심 발견	RF가 부스팅을 이김	배당률+피쳐 결합 > 배당률 단독

공통 발견: RandomForest가 가장 안정적. 신호가 약한 문제에서 부스팅보다 배깅이 나옴.

차이점: 배당률을 넣으면 AUC가 0.64 → 0.74로 크게 올라감. 배당률은 이번 예측의 '기반'이고, 피쳐는 그 위에 '정밀도'를 더하는 구조.

9. 한계

1. 표본 부족 — test 3,528행 중 이번 94건. ROI 신뢰구간이 넓은 근본 원인.
2. 단승만 봄 — 연승(입상) 타겟으로 바꾸면 적중 수가 3~4배 늘어 CI가 좁아질 것.
3. 고배당 1건 의존 — 팀원 보고서와 동일한 문제. 260배급 적중 하나가 ROI를 지배.

- 배당률 확정 시점 — winOdds는 경주 마감 후 확정. 실전에서는 베팅 시점과 확정 시점에 차이가 있을 수 있음.
- 서울만 — 부경에서도 같은 결과가 나오는지 미확인.

10. 결론 및 다음 할 일

10.1 핵심 발견 3가지

- 배당률+피처 결합(C)이 배당률 단독(A)보다 이번 예측이 우수하다.
- 모델 상위 5~20% 선별 베팅 시 ROI 양수 가능 (수수료 반영 후).
- 모델의 역할: '모든 경주에서 이기겠다'가 아니라 '시장이 놓치는 비인기마를 필터링하는 도구'.

10.2 다음 할 일

- 연승(plcOdds) 타겟으로 재실험 → 적중 수 3~4배 증가, CI 안정화
- 인기마 붕괴 모델과 조합 → '붕괴 위험 높은 경주에서만 다크호스 베팅'
- 고배당 1건 제거 로버스트니스 체크 추가
- 피처 엔지니어링: 최근 3경주 트렌드, 기수 최근 폼, 트랙별 궁합

부록 A. 실행 코드

```
from sklearn.ensemble import RandomForestClassifier
```

```
# 1) 비인기마만 추출
```

```
df = df[df["pop_pct"] >= 0.5]
```

```
# 2) 피처 정의 (q 포함, 배당률 나머지 13개 제외)
```

```
C_features = [c for c in df.columns if c not in EXCLUDE_COLS]
```

```
# EXCLUDE: ID, 결과, 라벨, 배당률13개, fold
```

```
# 3) 학습
```

```
model = RandomForestClassifier(  
    n_estimators=300, max_depth=10, min_samples_leaf=20,  
    class_weight='balanced', random_state=42, n_jobs=-1)  
model.fit(X_train, y_train)
```

```
# 4) 예측 → 순위만 사용
```

```
proba = model.predict_proba(X_test)[: , 1]
top_20pct = test.nlargest(int(len(test)*0.2), 'proba')
```

5) ROI 계산 (winOdds에 공제율 이미 반영)

```
roi = (top_20pct['upset'] * top_20pct['winOdds']).sum() / len(top_20pct) - 1
```

부록 B. 실험 수치 전문

B.1 모델 비교 (test 3,528 / 기저율 2.66%)

feature_set	model	n_features	Accuracy	Precision	Recall	F1_Macro	ROC_AUC
A (q only)	LR	1	0.772109	0.062808	0.542553	0.490926	0.736911
A (q only)	RF	1	0.691610	0.038961	0.446809	0.443382	0.611275
B (no odds)	LR	86	0.649660	0.043930	0.585106	0.432631	0.648468
B (no odds)	RF	86	0.958050	0.090909	0.063830	0.526769	0.657226
C (q + features)	LR	87	0.746882	0.057586	0.553191	0.478464	0.706028
C (q + features)	RF	87	0.933673	0.097701	0.180851	0.546197	0.741983

B.2 베팅 전략 비교

strategy	top_pct	n_bets	n_wins	hit_rate	avg_odds	total_bet	total_return	profit	ROI	
avg_bet_winners	avg_bet_losers	n_kelly_positive	avg_kelly_fraction							
Flat	5%	176	17	0.0966	13.4	176.0	221.5	45.5	25.9	NaN
NaN	NaN	NaN								
Flat	10%	352	27	0.0767	14.8	352.0	377.6	25.6	7.3	NaN
NaN	NaN	NaN								
Flat	15%	529	41	0.0775	15.8	529.0	589.0	60.0	11.3	NaN
NaN	NaN	NaN								
Flat	20%	705	53	0.0752	17.0	705.0	832.1	127.1	18.0	NaN
NaN	NaN	NaN								
Flat	30%	1058	60	0.0567	19.0	1058.0	969.8	-88.2	-8.3	NaN
NaN	NaN	NaN								
Proportional	5%	176	17	0.0966	13.4	176.0	224.1	48.1	27.3	1.022
0.998	NaN	NaN								
Proportional	10%	352	27	0.0767	14.8	352.0	384.0	32.0	9.1	1.029
0.998	NaN	NaN								
Proportional	15%	529	41	0.0775	15.8	529.0	595.5	66.5	12.6	1.022
0.998	NaN	NaN								
Proportional	20%	705	53	0.0752	17.0	705.0	831.7	126.7	18.0	1.020
0.998	NaN	NaN								
Proportional	30%	1058	60	0.0567	19.0	1058.0	1009.7	-48.3	-4.6	
1.066	0.996	NaN		NaN						

Kelly (Half)	5%	176	17	0.0966	13.4	176.0	225.6	49.6	28.2	NaN
NaN	176.0		0.2466							
Kelly (Half)	10%	352	27	0.0767	14.8	352.0	386.8	34.8	9.9	NaN
NaN	352.0		0.2327							
Kelly (Half)	15%	529	41	0.0775	15.8	529.0	597.8	68.8	13.0	NaN
NaN	529.0		0.2220							
Kelly (Half)	20%	705	53	0.0752	17.0	705.0	835.9	130.9	18.6	NaN
NaN	705.0		0.2133							
Kelly (Half)	30%	1058	60	0.0567	19.0	1058.0	1014.4	-43.6	-4.1	NaN
NaN	1058.0		0.1993							

B.3 신뢰구간

	top_pct	flat_median	flat_CI_low	flat_CI_high	flat_profit_prob	kelly_median	kelly_CI_low	kelly_CI_high	kelly_profit_prob
5%	24.6	-26.0	92.9	80.6	27.7	-24.4	95.4	82.8	
10%	6.2	-28.1	51.2	61.1	8.6	-26.6	54.7	65.7	
15%	10.4	-21.6	46.6	74.6	12.1	-20.4	48.6	77.1	
20%	18.1	-11.8	51.2	86.9	18.1	-11.6	51.0	88.3	