

전처리 보고서 (배당률 포함 버전)

데이터 전처리 보고서 (배당률 포함 버전)

이 버전의 특징

기존 전처리(배당률 제외)와 달리, **배당률 대표 피처(q)**를 포함시킨 버전입니다.
이변(비인기마 1착) 예측 모델에 사용하기 위한 전처리입니다.

단계	처리	결과
1	서울 + 비인기마 필터링	56,648행 → ~17,000행
2	결측치 처리	구조적 → 0, 랜덤 → train 중앙값
3	다중공선성 제거	배당률 14개→q만 + 고상관 23개 제거
4	범주형 인코딩	13개 문자 컬럼 → LabelEncoder
5	스케일링	StandardScaler (train 기준)
6	데이터 분할	시간순 6:2:2
7	타겟 생성	upset = (비인기마) & (1착) → 1

1 데이터 필터링

1-1. 서울 경마장만

구분	행 수
원본 (final.csv)	56,648
서울만	32,888

1-2. 비인기마만 (pop_pct >= 0.5)

왜 비인기마만?

- 타겟이 "이변"(비인기마가 1착)이므로, 인기마는 이번 대상 자체가 아님
- 인기마 행을 포함하면 타겟 비율이 ~7%로 너무 낮아짐
- 비인기마만 사용하면 타겟 비율 ~14%로 불균형이 완화됨
- "비인기마 중에서 진짜 이길 말을 골라내는" 명확한 문제 정의

구분	행 수	upset 비율
서울 전체	32,888	~7%
비인기마만 (pop_pct >= 0.5)	~17,000	~14%

```
df = pd.read_csv("final.csv", low_memory=False)
df = df[df["meet"] == "서울"]
df["upset"] = ((df["pop_pct"] >= 0.5) & (df["win"] == 1)).astype(int)
df = df[df["pop_pct"] >= 0.5] # longshots only
```

2 결측치 처리

유형	처리	대상 컬럼 (대표)
구조적 결측 (원래 값이 없는 게 정상)	0으로 채움	rating, hr_winrate, hr_plcrate, hr_style, jkhrr_winrate 등 26개
랜덤 결측 (있어야 하는데 누락)	train 중앙값	hr_rest_days 등 소수

유형	처리	대상 컬럼 (대표)
범주형 결측	"MISSING"	weather, track 등
<pre># Structural: value being absent IS the information for col in ["rating", "hr_winrate", "hr_plcrate", ...]: df[col] = df[col].fillna(0) # Random: use train median (no leakage) medians = df.loc[train_mask, remaining_cols].median() df[remaining_cols] = df[remaining_cols].fillna(medians)</pre>		

3 다중공선성 (고상관 피처) 제거

3-1. 배당률 14개 → q 하나만

왜 q만 남기나?

- 배당률 파생 14개 컬럼은 서로 상관계수 0.9 이상 (거의 같은 정보)
- q = 오버라운드 제거 후 정규화된 암묵적 확률 (경주 내 합=1)
- 가장 "깨끗한" 형태의 시장 확률이므로 대표로 선정

남긴 것	제거한 것 (13개)
q (시장 확률)	winOdds, plcOdds, p_raw, logit_q, log_q, pop_rank, is_fav, book_sum, takeout, pl_harville, pl_disc, q_plc

3-2. 기존 피처 고상관 쌍 제거 (23개)

제거	남김	이유
chaksun2~5	chaksun1	비례 관계 (상관 0.99+)
buga2, buga3	buga1	동일 비례
dusu	n_run	거의 동일 값
hr_prev_rating	rating	상관 0.99 + 결측 더 많음
hr_last_finpct	hr_last_ord	같은 정보 다른 표현

제거	남김	이유
hr_last_wg	wg	체중 거의 안 변함
__pr 컬럼 9개	__z 컬럼	z점수와 백분위 중복
기타 3개	-	상관 0.97+

```
# Drop odds (keep only q)
odds_drop = ["winOdds", "plcOdds", "p_raw", "logit_q", ...]
df = df.drop(columns=odds_drop)
```

```
# Drop high-correlation pairs
corr_drop = ["chaksun2", "chaksun3", ..., "hr_last_wg", ...]
df = df.drop(columns=corr_drop)
```

4 범주형 인코딩 (문자 → 숫자)

모델은 숫자만 입력받을 수 있으므로, 문자형 컬럼을 정수로 변환합니다.

LabelEncoder: 각 고유값에 정수 부여. 트리 모델에 적합 (순서 무관).

컬럼	예시 값	변환 후
rank	"국6등급"	→ 5
track	"건조 (3%)"	→ 0
weather	"맑음"	→ 3
sex	"수"	→ 2
rating_na	"True"	→ 1

```
from sklearn.preprocessing import LabelEncoder
```

```
for col in cat_cols: # 13 columns
    df[col] = df[col].fillna("MISSING").astype(str)
    le = LabelEncoder()
    le.fit(df[col].unique())
    df[col] = le.transform(df[col])
```

5 스케일링 (StandardScaler)

StandardScaler: (값 - 평균) / 표준편차 → 평균=0, 분산=1로 변환

로지스틱회귀가 피쳐 간 스케일 차이에 민감하므로 적용.

RF는 스케일 무관하지만, 동일 데이터로 두 모델을 비교하기 위해 통일.

핵심 원칙	설명
train으로만 fit	평균/표준편차를 train에서 계산
전체에 transform	같은 기준을 valid/test에도 적용
누수 방지	valid/test의 통계를 쓰면 미래 정보가 학습에 섞임
<pre>from sklearn.preprocessing import StandardScaler scaler = StandardScaler() scaler.fit(df.loc[train_mask, num_cols]) # train only! df[num_cols] = scaler.transform(df[num_cols]) # apply to all</pre>	

6 데이터 분할 (시간순 6:2:2)

Fold	비율	용도	기간 (예상)
train	60%	모델 학습	2023-08 ~ 2025-05
valid	20%	threshold 탐색	2025-05 ~ 2025-12
test	20%	최종 평가 + ROI	2025-12 ~ 2026-08

절대 섞으면 안 됨! 과거 데이터로 학습 → 미래 데이터로 평가.

섞으면 "미래 경주 결과를 보고 과거를 예측"하는 꼴이 되어 성능이 부풀려짐.

```
# Boundaries on rcDate — same race never splits across folds
df = df.sort_values("rcDate")
df["fold"] = assign_time_split(df, date_col="rcDate", ratios=(0.6, 0.2, 0.2))
```

7 타겟(y) 정의: upset

조건	upset	의미
비인기마(pop_pct >= 0.5) AND 1착 (win=1)	1	이변 발생 (시장이 틀림)
그 외	0	이변 아님

비인기마만 대상이므로, upset=1 비율은 약 14% (6~7:1 불균형).
class_weight='balanced'로 불균형 대응.

전처리 전후 비교

	전처리 전 (final.csv)	전처리 후
행 수	56,648	~17,000 (서울 비인기마만)
컬럼 수	156	~90 (식별자/결과 /고상관 제거 후)
배당률	14개 컬럼	q 하나만 포함
결측치	29개 컬럼 5%+	0 (전부 처리)
범주형	문자열 13개	정수 변환 완료
스케일	제각각	StandardScaler 적용
분할	없음	6:2:2 시간순
타겟	win (전체 9.5%)	upset (비인기마 내 14%)

이전 전처리(배당률 제외)와의 차이:

- **q 포함:** 배당률 대표 피처를 모델 입력으로 사용
- **비인기마만:** 전체 32,888행 대신 절반만 사용
- **타겟 변경:** win(1착) → upset(비인기마 1착)
- 이유: "시장을 이기겠다"가 아니라 "시장이 놓치는 이변을 배당률과 함께 잡겠다"

KHUDA 3조 · 전처리 보고서 (배당률 포함) · 2026-08-22 18:41