

revised_v5 이후 데이터 전처리 개선 보고서

최종 상태

종단 검증 결과는 **PASS**다.

검사 항목	Train	Validation	Test
원본 행 수	19,617	6,582	6,639
전처리 후 행 수	19,617	6,582	6,639
전체 열 숫자형	PASS	PASS	PASS
NaN	0	0	0
무한값	0	0	0
entry_id 코드 고유성	PASS	PASS	PASS
원본 타깃 정렬 보존	PASS	PASS	PASS
원본 재변환과 저장값 일치	PASS	PASS	PASS

확인된 원본 문제

- revised_v5는 146개 열이며 분할마다 일부 열의 dtype이 달랐다.
- jkNo는 train/valid에서 문자열, test에서 숫자형이었다.
- owNo와 trNo도 분할에 따라 문자열/숫자형이 달랐다.
- 모델 후보 121개 중 ageCond만 실제 문자열 피쳐였다.
- 기존 축소 데이터의 42개 모델 피쳐는 숫자형이었지만 학습 기준 스케일링이 적용되지 않았다.
- 기존 학습 코드에서는 연속형 hr_style을 범주형 코드로 다시 변환했다. 새 파이프라인에서는 숫자형 연속 피쳐로 처리한다.

적용한 전처리

- train/valid/test 스키마와 열 순서를 검사했다.
- 중복 행과 중복 entry_id, 이진 타깃 조건을 검사했다.
- 누수 결과 식별자 열을 모델 피쳐에서 제외했다.
- 120개 숫자 피쳐를 엄격하게 숫자로 변환했다. 변환 불가능 값이 있으면 즉시 실패하도록 했다.
- 무한값을 결측값으로 치환하도록 정의했다.
- 숫자 피쳐에 train 기준 median imputation을 적용했다.
- 숫자 피쳐에 train 기준 StandardScaler를 적용했다.

8. ageCond에는 train 기준 최빈값 대체와 one-hot encoding을 적용했다. 미등록 범주는 오류 없이 0 벡터로 처리한다.
9. race_id, entry_id, hrName은 추적용 숫자 코드로 변환했지만 모델 피처에서는 제외했다.
10. 원본 문자열 식별자는 EDGE 시장 데이터 연결을 위해 별도 metadata 파일로 보존했다.
11. 전처리 후 숫자형, NaN, 무한값, 행 수, 키 고유성, 스케일 통계와 재변환 일치를 검사했다.

전처리기는 **train 데이터에만 적합**했고 valid/test에는 변환만 적용했다.

출력 구조

전체 revised_v5

data/revised_v5_preprocessed/

- 숫자 원천 피처: 120개
- ageCond one-hot 피처: 8개
- 최종 모델 피처: 128개
- train 숫자 피처 최대 절대 평균: $1.200e-15$
- train 숫자 피처 표준편차의 최대 오차: $4.441e-16$

EDGE 0.5% 축소 데이터

data/edge_top_005_preprocessed/

- 최종 모델 피처: 42개
- 전체 전처리 데이터에서 동일 열을 파생
- CSV 재저장에 따른 최대 절대 반올림 차이: $8.881784197001252e-16$
- 허용오차 $1e-15$ 에서 세 분할 모두 일치

실제 학습·예측 테스트

전처리 완료된 42개 피처를 추가 형변환 없이 직접 읽어 LambdaRank와 binary LightGBM 모델을 새로 학습했다.

항목	결과
모델 입력 피처	42
테스트 예측 행	6,639
유한값 예측	6,639 / 6,639
EDGE 저장 행	6,639
Test ROC-AUC	0.7618233514
Test 1위 적중률	0.3181102362
상위 10% EDGE ROI	-0.0250

ROI는 전처리 성공 여부를 판정하는 지표가 아니다. 데이터·모델 종단 검증은 모든 구조 및 유한값 검사 통과 여부로 판정했으며 결과는 PASS다.

근거 파일

- data/revised_v5_preprocessed/preprocessing_validation.json
- data/edge_top_005_preprocessed/preprocessing_validation.json
- outputs/reports/preprocessing/end_to_end_validation.json
- outputs/reports/preprocessing/revised_v5_preprocessing.log
- outputs/reports/preprocessing/edge_subset_preprocessing.log
- outputs/reports/preprocessing/preprocessed_model_training.log
- outputs/reports/preprocessing/end_to_end_validation.log