


revised_v5 전체 최종 보고서

생성일: 2026-08-18 · 고정된 시간 순서 분할 · 일반 모델의 입력에서 시장 확률/배당률 제외

1. 데이터, 전처리 및 무결성

- 총 32,838행, 3,167경주. Train 19,617행/1,891경주, Validation 6,582행/641경주, Test 6,639행/635경주다.
- 세 분할은 동일 스키마이며 결측치와 중복 entry_id가 없고, 모든 경주에 우승마가 정확히 한 두 있다.
- 단순 범주형은 One-Hot, tool_set은 31개 장구류 Multi-Hot, 기수·조교사·마주·등급은 과거 경주만 이용한 스무딩 Target Encoding이다.
- race_id는 그룹 평가용, entry_id·hrName은 식별용으로만 보존했다. meet·fold·wgBudamBigo·중복 track은 제거했다.
- 전처리 후 146개 열, 일반 모델 학습 입력은 121개 열이다.


2. 시각적 데이터 점검



Chronological data split

이 그림은 자료가 시간 순서대로 Train·Validation·Test로 한 번만 분리됐음을 보여 준다 파란 Train으로 과거 패턴을 학습하고, 주황 Validation으로 반복 횟수·혼합 비중을 고르며, 녹색 Test는 마지막까지 잠가 둔 최종 평가 구간이다 세 막대가 겹치지 않으므로 미래 경주의 결과나 통계가 과거 학습에 직접 들어가는 누수를 줄인다 오른쪽 행 수 막대는 Train이 더 크고 Validation·Test가 비슷한 규모임을 보여 준다


다만 날짜 분할만으로 모든 피처의 시간 누수가 자동으로 사라지는 것은 아니므로, Target Encoding도 과거 경주만 사용하도록 별도로 처리했다.



Model comparison

왼쪽은 모든 test 행을 대상으로 한 ROC-AUC, 오른쪽은 각 경주에서 최고 EDGE 말 한 두를 남긴 뒤 상위 10%인 64회만 선택했을 때의 원시 ROI다 ROC-AUC는 우승마를 전반적으로 더 높은 순위에 두는 능력이고, ROI는 특정 선택 규칙과 배당 결과가 결합된 수익률이라 단위와 목적이 다르다 점선 시장 기준보다 일반 모델 ROC-AUC가 낮다는 사실과, 일부 모델의 양 (+) ROI가 동시에 나타날 수 있다


이는 작은 선택 표본이나 고배당 적중의 영향 때문일 수 있으므로, 오른쪽 양수 막대를 장기 수익 증명이나 모델의 절대 우위로 읽으면 안 된다.



Test-set EDGE diagnostics

세 패널은 같은 64회 선택 결과를 서로 다른 관점에서 분리해 보여 준다 ROI는 실제 배당을 포함한 수익률, 평균 실현 EDGE는 선택 말들이 시장 예상보다 실제로 더 자주 이겼는지, 상관은 큰 예측 EDGE를 준 말일수록 시장 예상보다 더 잘 뛰었는지를 뜻한다 예를 들어 ROI가 높아도 실현 EDGE나 상관이 약하면 우연한 배당 적중에 민감할 수 있다 반대로 실현 EDGE가 양수여도 수수료와 배당 구조 때문에 ROI가 음수일 수 있다


따라서 세 막대를 하나의 점수로 합치지 말고, 방향성과 표본 수 64회를 함께 읽어야 한다.



General-model selection-range comparison

여섯 일반 모델의 저장된 test 예측에서 경주당 최고 EDGE 말 한 두만 고른 뒤, 그 후보를 EDGE 순으로 상위 10%·20%·30%까지 넓혀 계산한 원시 ROI다 선택 범위를 넓히면 표본은 64회에서 127회, 191회로 커지지만 평균 EDGE는 낮아진다 따라서 상위 10%의 큰 양수 ROI가 20%·30%에서도 유지되는지 확인하면 특정 소수 경주에만 의존했는지 판단할 수 있다

이 그림은 수수료를 차감하지 않은 단일 Test 기간의 결과이며, 시간 순서 반복 검증이나 실제 배팅 한도를 반영하지 않는다 막대의 부호 변화는 모델 신호와 수익률이 선택 범위에 민감하다는 경고로 읽어야 한다.



Five-fold race-group validation

이 그림은 최종 Validation·Test를 건드리지 않고 원래 Train 기간의 1,891경주를 경주 단위로 다섯 묶음으로 나눈 LightGBM rank+binary 검증 결과다 막대 하나는 한 묶음을 검증용으로 두고 나머지 네 묶음으로 새로 학습한 결과이며, 점선은 다섯 결과의 평균이다 ROC-AUC·PR-AUC·top-1 적중률이 fold마다 다르게 나타나므로 평균만으로 안정성을 과장하지 않도록 한다

같은 경주의 말은 같은 fold에 묶여 경주 단위 누수는 막지만, GroupKFold가 시간 순서를 보장하지는 않는다 또한 시장 배당률을 입력·평가에 쓰지 않았으므로 이 그림은 ROI나 미래 수익성 검증이 아니라 확률·순위 성능의 내부 변동성 점검이다.

3. 일반 모델의 최종 테스트 결과

시장 기준은 ROC-AUC 0.8122, PR-AUC 0.3303이다.

Model	Valid ROC-AUC	Test ROC-AUC	Test PR-AUC	Top-10% ROI	Mean realized EDGE	EDGE-realized corr.	Bets
Deep listwise ensemble	0.7636	0.7710	-	-8.6%	-0.0191	-0.0071	64
Plackett-Luce hybrid	0.7515	0.7684	0.2738	+23.3%	0.0424	0.0471	64
LightGBM rank+binary	0.7637	0.7552	-	+45.0%	0.0585	0.0357	64
CatBoost ordered	0.7501	0.7508	0.2637	+13.3%	0.0030	0.0257	64
Random Forest	0.7467	0.7507	-	+55.0%	0.0229	0.0369	64
XGBoost	0.7415	0.7419	0.2531	+55.0%	0.0203	0.0210	64

ROC-AUC는 전체 순위 분별력, PR-AUC는 우승마 탐지 성능, EDGE는 모델 확률-시장 확률, ROI는 선택 베팅의 과거 실현 수익률이다. 따라서 서로 다른 단위를 합산해 단일 순위로 만들지 않았다.

모델별 상세 성능

학습 로그와 지표 JSON에 실제로 기록된 값만 수록했다. 어떤 모델에 동일한 지표가 기록되지 않은 경우에는 “—”로 표시했으며, 이를 0 또는 성능 저하로 해석하면 안 된다.

Model	Train ROC	Valid ROC	Valid PR	Valid F1	Test ROC	Test PR	Test F1	Test calibration MAE	Test top-1 hit	Avg winner probability	Best iteration	Decision threshold
Random Forest	0.8663	0.7467	—	—	0.7507	—	—	—	—	—	—	—
XGBoost	—	0.7415	0.2593	0.3120	0.7419	0.2531	0.2989	—	—	—	71	0.5362
LightGBM rank+binary	—	0.7637	—	—	0.7552	—	—	0.0070	0.2976	0.1748	—	—
CatBoost ordered	—	0.7501	0.2562	—	0.7508	0.2637	—	—	—	—	200	—
Deep listwise ensemble	—	0.7636	—	—	0.7710	—	—	0.0056	0.3307	0.1861	—	—

Model	Train ROC	Valid ROC	Valid PR	Valid F1	Test ROC	Test PR	Test F1	Test calibration MAE	Test top-1 hit	Avg winner probability	Best iteration	Decision threshold
Plackett-Luce hybrid	—	0.7515	—	—	0.7684	0.2738	—	—	—	—	—	—

모델별 EDGE 백테스트 진단

상위 10%는 test 635경주에서 각 경주의 최고 EDGE 말 1두만 남긴 뒤 64회를 선택한 규칙이다. Positive-EDGE ROI는 모든 양(+) EDGE 경주 선택의 ROI이므로 top-10% ROI와 표본 및 의미가 다르다.

Model	Top-10% bets	Mean predicted EDGE	Mean realized EDGE	Top-10% ROI	Positive-EDGE races	Positive-EDGE ROI	EDGE-realized corr.
Random Forest	64	0.1098	0.0229	55.0%	634	-0.2185	0.0369
XGBoost	64	0.1186	0.0203	55.0%	634	-0.2519	0.0210
LightGBM rank+binary	64	0.2280	0.0585	45.0%	634	-0.0005	0.0357
CatBoost ordered	64	0.1130	0.0030	13.3%	634	-0.2502	0.0257
Deep listwise ensemble	64	0.2484	-0.0191	-8.6%	634	-0.0259	-0.0071
Plackett-Luce hybrid	64	0.2568	0.0424	23.3%	634	0.0967	0.0471

상위 10%·20%·30% 선택 범위 비교

여섯 일반 모델의 저장된 test 예측을 같은 규칙으로 다시 계산했다. 이는 수수료를 차감하지 않은 단일 test의 원시 ROI이며, 수익성이 확인됐다는 결론이 아니다. 선택 범위를 넓힐수록 높은 EDGE를 가진 극소수만 골랐을 때의 결과가 유지되는지 확인한다.

Model	Selection range	Bets	Mean predicted EDGE	Mean realized EDGE	Raw test ROI	Win rate
Random Forest	Top 10%	64	0.1098	0.0229	55.0%	4.7%
Random Forest	Top 20%	127	0.1022	0.0038	-17.9%	3.1%
Random Forest	Top 30%	191	0.0973	0.0084	-6.2%	3.7%
XGBoost	Top 10%	64	0.1186	0.0203	55.0%	4.7%
XGBoost	Top 20%	127	0.1101	0.0032	-3.7%	3.1%
XGBoost	Top 30%	191	0.1044	0.0012	-23.5%	3.1%
LightGBM rank+binary	Top 10%	64	0.2280	0.0585	45.0%	17.2%
LightGBM rank+binary	Top 20%	127	0.1940	0.0212	-9.7%	12.6%


Model	Selection range	Bets	Mean predicted EDGE	Mean realized EDGE	Raw test ROI	Win rate
LightGBM rank+binary	Top 30%	191	0.1754	0.0234	14.6%	12.0%
CatBoost ordered	Top 10%	64	0.1130	0.0030	13.3%	3.1%
CatBoost ordered	Top 20%	127	0.1058	0.0016	-17.9%	3.1%
CatBoost ordered	Top 30%	191	0.1008	0.0065	-8.4%	3.7%
Deep listwise ensemble	Top 10%	64	0.2484	-0.0191	-8.6%	12.5%
Deep listwise ensemble	Top 20%	127	0.2105	0.0177	17.6%	14.2%
Deep listwise ensemble	Top 30%	191	0.1881	0.0330	9.1%	15.2%
Plackett-Luce hybrid	Top 10%	64	0.2568	0.0424	23.3%	20.3%
Plackett-Luce hybrid	Top 20%	127	0.2227	0.0407	26.7%	18.1%
Plackett-Luce hybrid	Top 30%	191	0.1998	0.0241	-0.3%	15.7%

재학습 설정

아래는 재실행에 사용한 기본 설정이다. 조기 종료가 적용된 모델은 실제 최적 반복 횟수를 바로 위 상세 성능 표에 별도로 기록했다.

Model	Learning form	Rerun configuration
Random Forest	Binary classifier	300 trees; depth 8; min leaf 20; balanced class weight; seed 42
XGBoost	Binary logistic	up to 2,000 rounds; lr 0.03; depth 6; early stopping 100; hist; seed 42
LightGBM rank+binary	LambdaRank + binary blend	up to 3,000 rounds each; lr 0.03; early stopping 150; rank/binary blend; isotonic calibration
CatBoost ordered	Ordered boosting classifier	up to 3,000 iterations; lr 0.03; depth 7; L2 5; early stopping 150; seed 42
Deep listwise ensemble	Race-wise softmax	5 seeds; 100 epochs maximum; lr 0.002; AdamW; temperature calibration
Plackett-Luce hybrid	Listwise + Bradley-Terry	50 epochs; lr 0.001; AdamW; hybrid objective; seed 42

4. 피처·성과 해석 및 검증 기준



All-model feature-importance consensus

왼쪽은 여섯 모델의 평균 순위 점수, 오른쪽은 모델별 순위 점수다. 여러 열에서 진하게 나타나고 top-20 횟수가 많은 변수는 특정 알고리즘 하나에만 의존하지 않는 반복 신호다.

기존처럼 Random Forest와 LightGBM의 원시 중요도만 나란히 두면, 두 모델의 편향과 서로 다른 단위(Gini, gain)에 영향을 받는다 이 보고서는 최종 일반 모델 6개 모두의 feature_importance_full.csv를 사용한다 각 모델에서 1위=1, 최하위=0이 되도록 순위 점수로 정규화하고 평균을 냈다 따라서 이 그림은 서로 다른 중요도 단위를 합산한 것이 아니라 모델 간 반복성을 보는 보수적 요약이다

신경망의 입력 가중치 중요도는 예측을 바꿨을 때의 기여도가 아니므로, 인과효과나 절대적 영향도로 해석하면 안 된다.

5. 최종 결과 정리와 인사이트

핵심 결과

- **승률·순위 예측:** Deep listwise ensemble이 일반 모델 중 가장 높은 Test ROC-AUC(0.7710)와 경주당 1위 적중률(33.1%)을 기록했다. 다만 시장 기준 ROC-AUC 0.8122보다 낮으므로, 시장 확률을 단독으로 대체할 근거는 부족하다.
- **시장 대비 신호:** Plackett-Luce hybrid는 평균 실현 EDGE(+0.0424)와 EDGE-실현 상관(+0.0471)이 가장 높았다. 모델이 시장보다 높게 평가한 말들이 평균적으로 시장 예상보다 조금 더 잘 뛰는 방향성은 확인했지만, 상관값 자체는 작다.
- **상위 10% 원시 ROI:** Random Forest와 XGBoost가 각각 +55.0%, LightGBM이 +45.0%를 기록했다. 모두 경주당 1두, 총 64회 선택, 수수료 미차감이라는 같은 규칙에서 산출한 단일 Test 기간의 값이다.

결과에서 읽을 수 있는 점

상위 10% ROI가 높다는 사실만으로 모델이 안정적인 수익 신호를 냈다고 보기는 어렵다. Random Forest는 선택 범위를 10%에서 20%·30%로 넓히자 +55.0%에서 -17.9%·-6.2%로, XGBoost는 +55.0%에서 -3.7%·-23.5%로 바뀌었다. 소수의 높은 EDGE 사례 또는 고배당 적중에 결과가 크게 좌우될 수 있다는 뜻이다.

반면 Plackett-Luce는 상위 10% ROI가 +23.3%, 평균 실현 EDGE가 양수이고 EDGE-실현 상관도 양수여서 시장 대비 방향성을 살펴볼 후보로 볼 수 있다. 그러나 이 역시 64회 선택의 단일 Test 결과이므로 운영 성과로 확정하지 않는다. 다음 단계의 판단은 수수료·배팅 한도·유효 배당률을 적용한 여러 시간 구간 검증이 추가된 뒤에만 가능하다.

LightGBM의 5-fold 경주 그룹 검증은 평균 ROC-AUC 0.7457 ± 0.0115 로 경주 묶음에 따른 순위 성능 변동 범위를 보여 준다. 이 값은 확률·순위 모델의 내부 안정성을 점검한 결과이며, ROI나 미래 수익성을 검증한 결과는 아니다. 따라서 이 보고서에서는 예측 성능, 시장 대비 EDGE, 선택 규칙별 ROI를 서로 다른 근거로 분리해 해석한다.

EDGE·ROI의 해석과 검증 기준

EDGE = 모델의 경주 내 정규화 확률 - 시장의 정규화 확률이다. 실현 $EDGE = win - \text{시장 확률}$ 이다. 기본 $ROI = win \times \text{단승 배당률} - 1$ 의 평균이며, 수수료를 반영하면 $win \times \text{단승 배당률} \times (1 - \text{수수료율}) - 1$ 이다.

EDGE 지표 해석 기준

- **평균 실현 EDGE**는 선택한 말들이 실제로 시장 예상보다 더 자주 이겼는지를 나타낸다. 양수일수록 선택 집합 전체가 시장 예상보다 좋았다는 의미다.
- **EDGE-실현 상관**은 모델이 더 큰 EDGE를 준 말일수록 실제로 시장 예상보다 더 잘 뛰었는지를 나타낸다. 양수라도 0에 가까우면 신호의 구별력은 약하다.
- **Positive-EDGE ROI**는 예측 EDGE가 0보다 큰 모든 경주 후보를 선택했을 때의 ROI다. 상위 10% ROI와 달리 많은 후보를 포함하므로, 두 값의 차이는 선택 규칙이 결과에 얼마나 민감한지 보여 준다.
- 높은 예측 EDGE는 모델의 주장일 뿐이다. 확률이 과대추정되었거나 배당률·수수료를 이길 만큼의 차이가 아니라면 높은 EDGE도 손실로 이어질 수 있다.

상위 10% 선택 규칙의 표본 한계

일반 모델 test에서 Random Forest·XGBoost의 상위 10% ROI는 각각 +55.0%, LightGBM은 +45.0%였지만, 모두 64회 선택의 단일 구간 결과다 선택 범위를 20%·30%로 넓힌 일반 모델 비교는 3번 표와 그래프에 수록했으며, 예를 들어 Random Forest는 +55.0% → -17.9% → -6.2%, XGBoost는 +55.0% → -3.7% → -23.5%로 변한다

따라서 상위 10%는 추가 검토가 필요한 후보 규칙일 뿐, 자동으로 높은 수익률을 보장하지 않는다.

5-fold 경주 그룹 검증

최종 Test는 그대로 잠가 둔 채, 원래 Train 기간의 1,891경주만 5개 묶음으로 나눴다 매 fold마다 4개 묶음(약 1,512~1,513경주)으로 LightGBM rank+binary를 새로 학습하고, 남은 1개 묶음(약 378~379경주)에서 평가했다 한 경주의 말들은 항상 같은 fold에 있어 경주 단위 정보가 학습·검증에 나뉘지 않는다

범주형 코드는 매 fold의 학습 데이터로만 다시 만들었고, 시장 확률·배당률·결과 누수 열은 입력에서 제외했다.

이 검증은 **분류·랭킹 성능의 안정성**을 확인하는 절차라서 ROI를 계산하지 않는다. ROI에는 같은 시점에 알 수 있는 시장 배당률과 배팅 규칙이 추가로 필요하다. 또한 GroupKFold는 경주 그룹을 나눈 검증이지 미래 날짜만으로 순방향 평가하는 walk-forward가 아니다.

LightGBM rank+binary 5-fold 결과

평균 ROC-AUC는 0.7457 ± 0.0115 , 평균 PR-AUC는 0.2578 ± 0.0262 , 평균 top-1 적중률은 0.2861 ± 0.0220 다. 다섯 fold의 OOF(각 행이 자신을 학습에 쓰지 않은 모델의 예측) 통합 ROC-AUC는 **0.7454**, OOF PR-AUC는 **0.2518**다.

Fold	Train rows	Valid rows	Train races	Valid races	Rank weight	Rank best iter.	Binary best iter.	ROC-AUC	PR-AUC	Calibration MAE	Top-1 hit rate
1	15,688	3,929	1,512	379	0.5000	333	126	0.7434	0.2276	0.0198	0.2639
2	15,695	3,922	1,513	378	0.1500	27	96	0.7441	0.2648	0.0147	0.2857
3	15,695	3,922	1,513	378	0.2000	86	92	0.7529	0.2680	0.0104	0.2804
4	15,695	3,922	1,513	378	0.3000	52	95	0.7289	0.2360	0.0194	0.2778
5	15,695	3,922	1,513	378	0.3500	47	73	0.7594	0.2925	0.0156	0.3228

fold 4의 ROC-AUC 0.7289와 fold 5의 0.7594처럼 차이가 존재한다. 평균이 하나의 고정된 성능을 보장하는 것이 아니라, 경주 묶음 구성에 따라 성능이 흔들릴 수 있음을 보여 준다. 이 표는 여섯 모델 전체를 다시 비교하는 표가 아니라, 3번의 최종 Test 결과를 보완하는 LightGBM rank+binary의 내부 안정성 검증이다.

6. 예상 질문과 해석 안내

아래는 보고서 수치를 읽을 때 자주 생길 수 있는 혼동을 미리 해소하기 위한 참고 사항이다.

모델별 표에 기록된 지표 범위

공통 비교표에는 여섯 모델에 공통으로 기록된 지표만 넣었고, 상세 성능·EDGE 진단·학습 설정 표에는 각 모델이 실제로 저장한 모든 지표를 추가했다. 예를 들어 calibration MAE와 top-1 적중률은 LightGBM·Deep에서만 기록됐고, F1은 XGBoost에서만 기록됐다. 기록되지 않은 값은 “—”로 남겼으며 임의로 계산하거나 0으로 취급하지 않았다.

순위 합의형 피쳐 중요도 산출 방식

Random Forest의 Gini, 부스팅 모델의 gain, CatBoost의 prediction-change, 신경망의 입력 가중치는 원시 단위가 달라 직접 평균하면 왜곡된다. 그래서 6개 일반 모델 각각의 내부 순위를 0~1로 정규화하고 평균·모델별 열지도를 제시했다. 이는 반복적으로 나타나는 예측 신호를 찾는 방법이며 인과적 중요도는 아니다.

상위 10%·20%·30%의 선택 규칙

각 경주에서 최고 EDGE 말 1두만 남긴 뒤 그 후보들을 EDGE 내림차순으로 정렬한다. 상위 10%는 64회, 20%는 127회, 30%는 191회를 선택한다. 이 범위별 일반 모델 원시 ROI는 3번 표·그래프에 제시했다. 4번의 5-fold 검증은 시장 데이터와 ROI가 아닌 확률·순위 성능의 안정성을 점검하는 별도 절차다.

7. 산출물 목록

모델별 JSON 지표, test 예측 CSV, 피쳐 중요도 CSV, 저장 모델 파일은 `models/v5/`에 보존되어 있다. 이 보고서와 원본 그래프·비교 CSV·5-fold 원자료는 `outputs/reports/`에 보존되어 있다.