

비시장 경마 1등 확률 예측 모델 — 중간보고서

작성일: 2026-08-18

목표: 현재 시장 배당률의 1등 예측력(ROC-AUC 약 0.82)에 최대한 근접하는 비시장 모델 구축

1. 실험 원칙

- 목표 변수는 `win` (1등 여부)이다.
- `train`으로 학습하고 `valid`에서만 모델·피처를 비교했다. `test`는 아직 성능 평가에 사용하지 않았다.
- 현재 경주의 배당·배팅금액·인기 및 결과·라벨 컬럼은 피처에서 제외했다.
 - 제외 예시: `winAmt`, `plcAmt`, `totalAmt`, `log\_winAmt`, `liq\_per\_horse`, `gap\_h`, `gap\_d`, `ord`, `fin\_rank`, `place`, `resid`, `upset\_\*`.
- `hrNo`, `jkNo`, `trNo`, `owNo`는 숫자가 아닌 식별자이므로 범주형 문자열로 처리해야 한다.

주의: `hr\_resid`, `hr\_last\_poppct`처럼 **과거 시장 판단을 바탕으로 만들어진 역사 파생변수**는 현재 시장 배당률은 아니지만, 완전히 시장 독립적인 정보도 아니다. 아래 95개 피처 결과는 이 변수를 포함한다.

2. 핵심 질문

초기 가설은 “시장보다 적은 수의 핵심 피처만 사용하면 더 좋은 일반화 성능을 낼 수 있다” 였다. 그러나 v1 XGBoost 실험에서는 피처를 늘릴수록 중간 구간까지 성능이 개선됐다.

이는 이상한 결과가 아니다. 시장도 단일 정보가 아니라 말의 기량, 최근 폼, 기수·조교사, 거리 적성, 부담중량, 각질, 훈련 상태 등 여러 약한 신호를 결합한다. XGBoost는 관련 신호가 추가될 때 잡음 피처를 상대적으로 덜 사용하면서 비선형 상호작용을 활용할 수 있다.

다만 피처가 많다는 사실 자체가 성능을 보장하지는 않는다. 동일 `valid`에서 많은 조합을 탐색하면 그 검증 구간에 과적합될 수 있으므로, 최종 선택은 마지막에 한 번만 `test`로 확인해야 한다.

3. v1: 핵심 피처 실험

3.1 30개 핵심 비시장 피처

모델	피처 수	Valid ROC-AUC
----	------	---------------

XGBoost	30	0.722476
Random Forest	30	0.721994

동일 피처에서는 XGBoost가 근소하게 우세해 이후 주요 탐색 모델로 사용했다.

3.2 피처 제거 실험

XGBoost에서 30개 핵심 피처를 하나씩 제거한 결과, 27개에서 국소 최대값이 나왔다.

피처 수	Valid ROC-AUC
30	0.722476
27	0.724186
20	0.720003
10	0.679453

30개 이하에서는 불필요하거나 중복된 피처를 일부 제거하는 것이 약간 유리했지만, 20개부터는 성능이 지속적으로 하락했다.

3.3 피처 확장 실험

말의 과거 성적, 경주 내 상대 수준, 기수·조교사 성적, 훈련·휴양, 각질·페이스, 마주·조합 정보를 순차적으로 추가했다.

피처 수	Valid ROC-AUC
43	0.729743
50	0.728185
65	0.751003
95	**0.752933**
100	0.750367

현재 v1의 가장 높은 검증 성능은 95개 피처 XGBoost, ROC-AUC 0.752933이다.

시장 기준선 약 0.82와의 차이는 약 0.0671이다. 시장을 따라잡지는 못했지만, 30개 모델 대비 약 +0.0305 개선됐다.

4. 피처 수가 늘어도 성능이 오르는 이유

1. ****약한 신호의 합산 효과****: 단일 피처의 영향이 작아도, 여러 조건이 함께 맞을 때 우승 확률을 설명할 수 있다.
2. ****경주 내 상대 비교의 중요성****: 절대 기량보다 같은 경주에 출전한 다른 말 대비 레이팅·승률·부담중량·훈련량이 중요하다.
3. ****상호작용****: 거리, 말의 각질, 선행마 수, 기수·말 조합 등은 단독보다 결합될 때 의미가 생긴다.

4. ****트리 모델의 특성****: XGBoost는 필요 없는 피처를 항상 적극적으로 사용하지 않으며, 유용한 분할이 있는 피처를 선택할 수 있다.

따라서 “시장보다 피처가 적어야 한다” 는 가설은 현재 데이터에서는 지지되지 않았다. 더 적은 피처보다 사전 이용 가능하고, 누수가 없으며, 서로 보완적인 피처 구성이 중요하다.

5. v2~v8 비교 결과와 해석

초기 비교 중 식별번호를 숫자로 처리한 오류가 발견돼, 아래 표는 이를 범주형으로 수정한 뒤의 값이다. 이전의 v2·v6·v8 고점은 최종 수치로 사용하지 않는다.

버전	권장 모델	Valid ROC-AUC	해석
v2	Logistic Regression	0.514084	전체 표본 기준. 선형 모델은 약함.
v3	KNN	0.529184	전체 표본 기준. KNN은 약함.
v4	Logistic Regression	0.723182	사용자 판단에 따라 제외.
v5	XGBoost	0.738386	이상치 제거로 표본이 작아 참고용.
v6	Logistic Regression	0.669148	이상치 제거로 표본이 작아 참고용.
v7	KNN	0.342615	이상치 제거로 표본이 작아 참고용.
v8	Logistic Regression	0.666617	사용자 판단에 따라 제외.

표본 축소 주의

v5~v8은 이상치 제거가 적용돼 다음과 같이 표본 수가 크게 줄었다.

구분	Train 행 수	Valid 행 수
v1~v4	19,637	6,591
v5~v8	3,772	315

따라서 v5~v8은 valid 우승 사례 수가 적어 점수 변동성이 크다. 이 버전들의 수치는 보조 참고용으로만 사용하고, 모델 선택의 주 기준은 v1의 XGBoost 결과로 둔다.

6. 결론

1. 현재 가장 유망한 모델은 **v1 + XGBoost + 약 95개 사전 피쳐**다.
2. v1의 최고 검증 ROC-AUC는 **0.752933**이며, 시장 약 0.82에는 아직 미달한다.
3. 핵심 피쳐 20~30개만 사용한다는 초기 가설보다, 누수 없이 사전 이용 가능한 폭넓은 피쳐를 함께 쓰는 편이 더 좋았다.
4. Random Forest와 KNN은 현재 구성에서 XGBoost보다 약했다.
5. v5~v8은 이상치 제거로 표본이 지나치게 줄어 주 모델 선택의 근거로 쓰기 어렵다.

7. 다음 단계

1. 95개 피쳐에서 ``hr_resid``, ``hr_last_poppct`` 등 과거 시장 파생 피쳐를 제거한 **완전 시장 독립 모델**을 별도로 측정한다.
2. v1의 95개 모델을 고정한 뒤, ``train + valid``로 재학습하고 보류해 둔 ``test``에서 단 한 번 최종 평가한다.
3. ROC-AUC뿐 아니라 경주별 1위 적중률, 확률 보정(calibration), 고확률 말의 실제 승률을 함께 확인한다.
4. 시장 확률과 모델 확률의 차이가 큰 경주를 분석해, 시장이 놓치는 조건과 모델이 과신하는 조건을 찾는다.