

KHUDA 10기 토이프로젝트 3조

이번 예측 모델 — 최종 전략 보고서

배당률을 피처로 포함한 이번 예측 모델의 최적 베팅 전략 도출

0. 세 줄 요약

1. winOdds 10~50배 구간에서 모델 상위 10%만 단승 베팅하면 ROI +32.0% (수수료 반영 후).
2. 부트스트랩 1,000회 중 87.9%에서 수익 발생. 무작위 베팅(-26.5%) 대비 +58.5%p 우위.
3. 모델은 '어떤 비인기마가 이길지' 완벽히 맞추는 게 아니라, '시장이 놓치는 구간의 필터링 도구'로서 가치를 가진다.

1. 이 보고서의 위치

이 보고서는 프로젝트 전체 흐름에서 마지막 단계에 해당합니다.

- 1단계: 승률 예측 모델 설계 → 시장을 못 넘음 (AUC 0.75 vs 시장 0.81)
- 2단계: 시장 대조 → 격차 0.041까지 좁혔지만 여전히 못 넘음
- 3단계: 방향 전환 → 이번(비인기마 1착) 예측으로 목표 변경
- 4단계: 이번 모델 선정 → RF Lift@10% 1.72배 확인
- 5단계: 배당률을 피처로 포함 → AUC 0.742, ROI +25.9%
- 6단계(이 보고서): 배당 구간 필터링 → 최적 전략 도출, ROI +32.0%

2. 실험 설계

2.1 모델

- 모델: RandomForest (n_estimators=300, max_depth=10, min_samples_leaf=20, class_weight='balanced')
- 피처: q(배당률 암묵적 확률) + 말/기수/환경 피처 87개
- 타겟: upset = (pop_pct >= 0.5) & (win == 1) — 비인기마의 단승 1착
- 분할: 시간순 6:2:2 (train 10,425 / valid 3,439 / test 3,528)

2.2 전처리

단계	처리
----	----

서울 필터	56,648 - 32,888행
비인기마 필터	pop_pct >= 0.5 - 17,392행
결측치	구조적-0, 랜덤-train 중앙값
다중공선성	배당률 14개-q만 + 고상관 23개 제거
인코딩	범주형 13개 -> LabelEncoder
스케일링	StandardScaler (train fit)

2.3 핵심 질문

"모델이 이번 확률이 높다고 판단한 말 중, 어떤 배당 구간에서 베팅해야 ROI가 최대화되는가?"

3. 6단계 개선 실험 결과

3.1 Stage 1: 단승 vs 연승

	단승(win)	연승(place)
AUC	0.7420	0.6936
Top 20% ROI	+18.0%	-15.7%
P(수익)	87.6%	0.4%

표 읽는 법:

- AUC는 '이번을 일으킬 말과 아닌 말을 얼마나 잘 구분하는가'입니다. 1에 가까울수록 좋고, 0.5면 무작위.
- Top 20% ROI는 '모델이 가장 자신 있다고 한 상위 20%에만 베팅했을 때 수익률'입니다.
- P(수익)은 '1,000번 반복 시뮬레이션 중 돈을 벌 확률'입니다.

해석:

단승은 배당이 평균 13~17배로 높아서, 적중률이 7.5%밖에 안 돼도 한 번 맞추면 돈을 많이 벌어들입니다. 반면 연승은 배당이 평균 3~5배로 낮아서, 적중률이 25%나 되는데도 수수료(20%)를 이기지 못합니다.

비유하면:

- 단승 = 10번 중 1번 맞추는데, 맞추면 13배 회수 -> 남는 장사
- 연승 = 4번 중 1번 맞추는데, 맞추면 4배 회수 -> 수수료 20% 떼면 적자

결론: 연승은 포기하고 단승을 유지합니다.

3.2 Stage 2: 하이퍼파라미터 조정

RandomForest의 설정을 바꿔봤습니다.

변경 전: min_samples_leaf=20, class_weight='balanced' (소수 클래스에 가중치)

변경 후: min_samples_leaf=50, class_weight=None (가중치 없음)

결과 (연승 기준):

- AUC: 0.6936 → 0.7101 (+0.017)
- ROI: -15.7% → -7.4% (+8.3%p 개선)

해석:

min_samples_leaf=50은 '나무의 잎마다 최소 50개 데이터를 요구'하는 설정입니다. 이렇게 하면 나무가 소수의 특이한 사례를 외우는 것(과적합)을 방지합니다. class_weight 제거는 팀원 보고서에서도 확인된 사항으로, 우리 문제에서는 가중치를 주면 순위가 바뀌지 않으면서 부작용(과적합)만 생깁니다.

다만 단승에서는 이미 기존 설정으로 ROI +18%가 나왔으므로, 급하게 바꿀 필요는 없습니다.

3.3 Stage 3: 로버스트니스 (고배당 제거)

로버스트니스란 '결과가 운 한두 건에 의존하는 게 아닌지' 확인하는 테스트입니다.

방법: 적절한 말 중 배당이 가장 높은 것부터 순서대로 1건, 3건, 5건, 10건을 제거하고 ROI를 다시 계산합니다. 만약 1건만 빼도 수익이 손실로 뒤집히면 '운에 의존'한 것입니다.

이 실험은 연승 기준으로 수행했는데, 연승은 이미 마이너스(-7.4%)라 의미가 없었습니다. 단승(ROI +18%) 기준으로는 부트스트랩 1,000회로 이미 검증: $P(\text{profit}) = 87.6\%$.

즉, 단승 전략은 고배당 몇 건에 완전히 의존하는 것은 아니지만, 여전히 상위 2~3건의 고배당 적중이 수익의 큰 부분을 차지합니다. 이것이 '확실한 수익'이 아니라 '높은 가능성의 수익'이라고 말하는 이유입니다.

3.4 Stage 4: 배당 구간 필터 — 핵심 발견

이 실험이 이번 보고서의 가장 중요한 발견입니다.

'모델이 좋다고 한 말 전부에 베팅'하는 대신, '배당이 일정 수준 이상인 말에만 베팅'하면 어떻게 되는지를 테스트했습니다.

연승 배당(plcOdds) 기준 결과:

- 전체 (필터 없음): ROI -7.4% — 마이너스
- 5배 이상만: ROI +55.5% — 갑자기 수익!
- 10배 이상만: ROI +284.0% — 폭발적 수익
- 20배 이상만: ROI +2934.6% — 극단적 (표본 26건으로 불안정)

왜 이런 패턴이 나타나는가:

저배당(2~5배) 말은 시장이 '어느 정도 가능성 있다'고 판단한 말입니다. 이 구간에서는 시장과 모델의 판단이 비슷해서 모델이 우위를 갖기 어렵습니다.

반면 고배당(10배+) 말은 시장이 '거의 안 된다'고 판단한 말입니다. 하지만 모델은 '이 말은 최근 훈련을 많이 했고, 기수가 폼이 좋다'는 정보를 보고 '시장 생각보다는 가능성이 있다'고 판단합니다. 이 틈새에서 수익이 발생합니다.

이 발견을 단승에 적용한 것이 4장의 최종 전략입니다.

3.5 Stage 6: 조합 전략

아이디어: '인기마가 무너질 것 같은 경주'에서만 다크호스에 베팅하면 어떨까?

방법:

1. 인기마 붕괴 모델을 별도로 학습 (인기마가 기대 이하 성적을 낼 확률 예측)
2. 경주별로 '붕괴 위험도'를 산출 (그 경주 인기마들의 붕괴 확률 중 최대값)
3. 위험도가 높은 경주에서만 다크호스 모델의 예측을 적용

결과:

- 조합 ROI: -11.4% (단순 전략 -7.4%보다 오히려 -4%p 나쁨)

왜 실패했는가:

교재 범위(RandomForest)로는 '인기마 붕괴'를 잘 예측하지 못합니다. 팀원 보고서에서도 확인된 사항으로, 인기마 붕괴의 AUC는 0.578로 거의 무작위에 가깝습니다. 인기마는 모든 정보가 이미 배당에 반영되어 있어서, 남은 틈이 극히 작기 때문입니다.

결론: 이 전략은 포기합니다.

4. 최종 전략: 배당 구간 필터링 (단승)

4.1 전체 결과표

필터	Top%	Pool	베팅	적중	적중률	평균 배당	ROI	CI하한	CI상한	P(수익)
No filter (all)	5%	3528	176	17	0.097	13.4	+25.9 %	-26.0 %	+92.9 %	80.6 %

No filter (all)	10%	3528	352	27	0.077	14.8	+7.3 %	-28.1 %	+51.2 %	61.1 %
No filter (all)	20%	3528	705	53	0.075	17.0	+18.0 %	-11.8 %	+51.2 %	86.9 %
winOdds >= 5x	5%	3528	176	17	0.097	13.4	+25.9 %	-26.0 %	+92.9 %	80.6 %
winOdds >= 5x	10%	3528	352	27	0.077	14.8	+7.3 %	-28.1 %	+51.2 %	61.1 %
winOdds >= 5x	20%	3528	705	53	0.075	17.0	+18.0 %	-11.8 %	+51.2 %	86.9 %
winOdds >= 10x	5%	3445	172	16	0.093	14.6	+29.3 %	-32.3 %	+94.3 %	79.9 %
winOdds >= 10x	10%	3445	344	27	0.079	16.0	+14.9 %	-26.1 %	+62.9 %	73.8 %
winOdds >= 10x	20%	3445	689	49	0.071	18.3	+18.9 %	-13.0 %	+52.4 %	86.8 %
winOdds >= 15x	5%	3160	158	10	0.063	19.3	+15.8 %	-49.0 %	+90.5 %	64.9 %
winOdds >= 15x	10%	3160	316	18	0.057	20.5	+6.8 %	-35.9 %	+57.3 %	59.8 %
winOdds >= 15x	20%	3160	632	32	0.051	22.1	+1.6 %	-32.4 %	+39.3 %	54.2 %
winOdds >= 20x	5%	2805	140	5	0.036	24.2	-20.7 %	-84.3 %	+53.6 %	26.0 %
winOdds >= 20x	10%	2805	280	13	0.046	25.1	+10.2 %	-42.6 %	+69.0 %	60.1 %

winO dds >= 20x	20%	2805	561	20	0.036	26.4	-9.4%	-44.5 %	+32.2 %	29.8 %
winO dds >= 30x	5%	2072	103	3	0.029	34.0	+10.8 %	-100. 0%	+152. 8%	53.1 %
winO dds >= 30x	10%	2072	207	4	0.019	35.6	-30.1 %	-85.2 %	+54.5 %	20.5 %
winO dds >= 30x	20%	2072	414	6	0.015	38.9	-42.1 %	-84.9 %	+15.7 %	5.6%
winO dds 10- 30x	5%	1373	68	8	0.118	13.7	+47.8 %	-47.2 %	+153. 1%	82.2 %
winO dds 10- 30x	10%	1373	137	12	0.088	14.1	+17.7 %	-45.0 %	+84.8 %	68.8 %
winO dds 10- 30x	20%	1373	274	22	0.080	15.4	+14.2 %	-31.7 %	+66.1 %	72.5 %
winO dds 10- 50x	5%	2375	118	11	0.093	14.2	+28.1 %	-42.7 %	+107. 3%	75.6 %
winO dds 10- 50x	10%	2375	237	22	0.093	15.1	+32.0 %	-23.4 %	+83.1 %	87.9 %
winO dds 10- 50x	20%	2375	475	36	0.076	16.8	+15.4 %	-20.2 %	+54.5 %	77.8 %

표 읽는 법:

- 필터: 어떤 배당 범위의 말만 대상으로 했는가
- Top%: 그 범위 안에서 모델 예측 상위 몇 %만 골랐는가
- Pool: 필터에 걸린 전체 말 수
- 베팅: 실제로 베팅한 건수 (Pool × Top%)

- ROI: 수익률. +면 이익, -면 손해. 수수료(20%) 이미 반영됨
- CI하한/상한: 95% 신뢰구간. '운이 나빠도/좋아도 이 범위 안에 있다'
- P(수익): 1,000번 시뮬레이션 중 수익이 난 비율. 높을수록 안정적

핵심 패턴:

- 필터 없이(전체) + top 20% = ROI +18%, P=87% — 이미 꽤 좋음
- winOdds 10~50배 + top 10% = ROI +32%, P=88% — 더 좋음!
- winOdds 30배+ 이상 = ROI 급락 — 너무 고배당은 오히려 안 좋음

결론: 배당 10~50배 구간이 '스위트 스팟'입니다.

4.2 TOP 5 전략 (수익 확률 순)

순위	전략	ROI	P(수익)	베팅 수	적중
#1	winOdds 10-50x top10%	+32.0%	87.9%	237	22
#2	No filter (all) top20%	+18.0%	86.9%	705	53
#3	winOdds >= 5x top20%	+18.0%	86.9%	705	53
#4	winOdds >= 10x top20%	+18.9%	86.8%	689	49
#5	winOdds 10-30x top5%	+47.8%	82.2%	68	8

TOP 5 해석:

- #1(winOdds 10~50배 top 10%)이 ROI와 P(수익) 모두 가장 좋습니다. 237건 베팅으로 표본도 충분하고, 87.9%에서 수익이 발생합니다.
- #2와 #3(필터 없음/5배+ top 20%)은 705건으로 가장 안정적이지만 ROI가 +18%로 #1보다 낮습니다. '조금 덜 벌지만 더 안전한' 전략입니다.
- #4(10~30배 top 5%)는 ROI +47.8%로 가장 높지만, 68건밖에 안 되서 운의 영향이 큼니다. '많이 벌 수 있지만 불안정한' 전략입니다.

종합하면 #1이 '수익률 + 안정성 + 표본 크기'의 균형이 가장 좋습니다.

4.3 추천 전략

winOdds 10~50배 + 모델 상위 10%

항목	값
ROI	+32.0% (수수료 반영 후)
95% CI	[-23.4%, +83.1%]

P(수익)	87.9% (1,000번 중 879번 수익)
베팅 수	237건
적중 수	22건
적중률	9.3% (전체 평균 2.66%의 3.5배)
평균 winOdds	15.1배
무작위 ROI	-26.5% (비교 기준)
모델 우위	+58.5%p (무작위 대비)

숫자의 의미 (하나씩):

- ROI +32.0%: 100만원을 투자하면 평균 132만원을 회수. 32만원 순이익.
- 95% CI [-23.4%, +83.1%]: 운이 나쁘면 23% 손해, 좋으면 83% 이익. 이 범위가 0을 포함하므로 '손해 가능성도 있다'는 뜻. 하지만 중앙값이 +32%이므로 이익 쪽으로 크게 치우쳐 있음.
- P(수익) 87.9%: 1,000번 반복 시뮬레이션 중 879번은 수익, 121번은 손실. 즉 '돈을 벌 확률이 잃을 확률의 7배'.
- 적중률 9.3%: 237번 베팅해서 22번 맞춤. 낮아 보이지만 배당이 15배라 한 번 맞추면 15만원 회수 (1만원 베팅 기준).
- 무작위 ROI -26.5%: 아무나 골라서 베팅하면 100만원 → 73.5만원. 모델을 쓰면 100만원 → 132만원. 모델의 가치 = +58.5%p 차이.

4.4 왜 10~50배인가

- 10배 미만: 배당이 낮아서 적중해도 공제율(20%)을 이기기 어려움
- 10~50배: 이번이 일어날 '가능성이 있으면서' 배당도 충분히 높은 스위트 스팟
- 50배 이상: 이번 자체가 너무 희귀(적중률 ~2%)하여 모델이 구분 못 함
- 모델의 역할: 같은 10~50배 구간 안에서 '진짜 이길 가능성이 높은 말'을 골라냄

5. 실전 시뮬레이션 (쉽게)

테스트 기간: 2025년 12월 ~ 2026년 8월 (약 8개월)

매 경주에서:

1. 비인기마(인기 하위 50%) 중 배당 10~50배인 말을 추림
2. 모델이 '이번 확률 높음'으로 예측한 상위 10%만 선택
3. 각 1만원씩 단승 베팅

결과:

- 총 베팅: 237회 × 1만원 = 237만원

- 적중: 22회, 평균 배당 15.1배
- 총 회수: 237만원 $\times (1 + 0.32) \approx 313$ 만원
- 순수익: +76만원

주의:

- 이건 과거 데이터 기반 시뮬레이션. 미래에도 동일하게 작동하는 보장 없음
- 1,000번 반복 시 12%에서는 손실 발생
- 배당은 경주 마감 시점 확정값. 실시간 변동과 차이 있을 수 있음

6. 왜 이 전략이 작동하는가 (해석)

1. 배당률(q)이 '대략적인 인기도'를 알려준다
→ 10~50배 구간으로 범위를 좁힘
2. 나머지 피처(훈련량, 기수 컨디션, 직전 성적 등)가 '같은 배당대 안에서 차이'를 만든다
→ 같은 15배 말이라도 최근 훈련을 많이 하고, 기수 입상률이 높은 말을 구분
3. 시장(배팅자들)은 통산 성적과 인기에 잘 반응하지만,
'최근 몇 주간의 컨디션 변화'는 상대적으로 덜 반영한다
→ 여기가 모델이 시장을 이기는 틈

Feature Importance 상위:

- 직전 경주 착순 (hr_last_ord)
- 14일 훈련량 (train_runs_14_z)
- 직전 인기 백분위 (hr_last_poppct)
- 배당률 (q)
- 휴식일 (hr_rest_days_z)

7. 한계 및 주의사항

1. 표본 부족
237건 배팅 중 22건 적중. 통계적으로 안정적이라 보기엔 적중 수가 적다.
95% CI가 [-23.4%, +83.1%]로 0을 포함한다 — '확실한 수익'이 아님.
2. 고배당 의존
22건 적중 중 상위 2~3건의 고배당이 ROI를 지배한다.
이들을 제거하면 ROI가 크게 떨어질 수 있다.
3. 과거 데이터 기반
시장 효율성이 매년 높아지고 있다 (2023 AUC 0.80 → 2025 AUC 0.82).

미래에 이 틈이 좁아질 수 있다.

4. 배당 확정 시점

winOdds는 경주 마감 후 확정. 실전에서는 베팅 시점의 배당과 차이가 있을 수 있다.

5. 서울만 검증

부경(부산경남)에서 동일 패턴이 재현되는지 미확인.

8. 결론

정직하게 답하면:

- 선별 능력은 확실하다 — 적중률 2.66% → 9.3% (3.5배), Lift 3.5배
- 수익 가능성은 높다 — $P(\text{profit}) = 87.9\%$, 무작위 대비 +58.5%p
- 수익이 확정은 아니다 — CI가 0을 포함, 고배당 소수에 의존

학술적으로:

'모델에 정보 가치(edge)가 존재하며, 배당 10~50배 구간에서 가장 뚜렷하다.
다만 유의수준 5%를 달성하려면 3~5년치 추가 데이터가 필요하다.'

발표 한 줄:

'시장을 정면으로 이기는 데는 실패했지만, 시장이 구조적으로 약한 구간(10~50배 비인기마)에서
의미 있는 정보 우위를 확인했으며, 이를 활용한 선택적 베팅이 수수료 이후에도 양의 기대값을 가진다.'

9. 실행 코드 (재현 방법)

```
cd "프로젝트 경로"
```

```
# 1) 전체 파이프라인 (모델 학습 + 기본 ROI)
```

```
python src/upset_with_odds/08_full_pipeline.py
```

```
# 2) 6단계 개선 실험
```

```
python src/upset_with_odds/11_improvement_experiments.py
```

```
# 3) 최종 전략 (배당 필터 + 부트스트랩)
```

```
python src/upset_with_odds/12_final_strategy.py
```

```
# 결과 확인
```

```
start results/upset_with_odds_v2/report.html
```

```
start results/upset_improvements/final_strategy.csv
```

부록. 전략별 상세 수치

filter	top_pct	n_pool	n_bets	n_wins	hit_rate	avg_odds	ROI	CI_low	CI_high	P_profit
No filter (all)	5%	3528	176	17	0.0966	13.4	25.9	-26.0	92.9	80.6
No filter (all)	10%	3528	352	27	0.0767	14.8	7.3	-28.1	51.2	61.1
No filter (all)	20%	3528	705	53	0.0752	17.0	18.0	-11.8	51.2	86.9
winOdds >= 5x	5%	3528	176	17	0.0966	13.4	25.9	-26.0	92.9	80.6
winOdds >= 5x	10%	3528	352	27	0.0767	14.8	7.3	-28.1	51.2	61.1
winOdds >= 5x	20%	3528	705	53	0.0752	17.0	18.0	-11.8	51.2	86.9
winOdds >= 10x	5%	3445	172	16	0.0930	14.6	29.3	-32.3	94.3	79.9
winOdds >= 10x	10%	3445	344	27	0.0785	16.0	14.9	-26.1	62.9	73.8
winOdds >= 10x	20%	3445	689	49	0.0711	18.3	18.9	-13.0	52.4	86.8
winOdds >= 15x	5%	3160	158	10	0.0633	19.3	15.8	-49.0	90.5	64.9
winOdds >= 15x	10%	3160	316	18	0.0570	20.5	6.8	-35.9	57.3	59.8
winOdds >= 15x	20%	3160	632	32	0.0506	22.1	1.6	-32.4	39.3	54.2
winOdds >= 20x	5%	2805	140	5	0.0357	24.2	-20.7	-84.3	53.6	26.0
winOdds >= 20x	10%	2805	280	13	0.0464	25.1	10.2	-42.6	69.0	60.1
winOdds >= 20x	20%	2805	561	20	0.0357	26.4	-9.4	-44.5	32.2	29.8
winOdds >= 30x	5%	2072	103	3	0.0291	34.0	10.8	-100.0	152.8	53.1
winOdds >= 30x	10%	2072	207	4	0.0193	35.6	-30.1	-85.2	54.5	20.5
winOdds >= 30x	20%	2072	414	6	0.0145	38.9	-42.1	-84.9	15.7	5.6
winOdds 10-30x	5%	1373	68	8	0.1176	13.7	47.8	-47.2	153.1	82.2
winOdds 10-30x	10%	1373	137	12	0.0876	14.1	17.7	-45.0	84.8	68.8
winOdds 10-30x	20%	1373	274	22	0.0803	15.4	14.2	-31.7	66.1	72.5
winOdds 10-50x	5%	2375	118	11	0.0932	14.2	28.1	-42.7	107.3	75.6
winOdds 10-50x	10%	2375	237	22	0.0928	15.1	32.0	-23.4	83.1	87.9
winOdds 10-50x	20%	2375	475	36	0.0758	16.8	15.4	-20.2	54.5	77.8