

KHUDA 10기 토이프로젝트 3조

이번 예측 모델 — 완결 보고서

배당률 포함 이번 예측 + 최적 전략 + 이번마 인사이트 + 배분 전략

0. 핵심 결론 (세 줄)

- winOdds 10~50배 구간에서 모델 상위 10%만 균등 단승 베팅 시 ROI +32.0% (수수료 반영 후).
부트스트랩 1,000회 중 87.9%에서 수익 발생.
- 이번마의 공통점: 젊고, 최근 훈련 많이 하고, 조교사가 좋고, 직전에도 기대 이상 성적.
3가지 유형 확인 — 데뷔형 / 베테랑 복귀형 / 신예 깜짝형.
- 배분 전략(Kelly, EV비례 등)은 균등 대비 +0~1%p 차이로 의미 없음.
'어디에 베팅하느냐'가 '얼마를 베팅하느냐'보다 훨씬 중요.

1. 모델 성능 — A/B/C 비교

모델	피처	AUC	의미
A (배당률만)	q 1개	0.7369	배당률 하나로 74% 구분
B (피처만)	86개 (배당률 제외)	0.6572	배당률 없으면 66%로 하락
C (결합)	q + 86개 = 87개	0.7420	배당률+피처가 가장 좋음

숫자 읽는 법:

AUC(Area Under Curve)는 '이번을 일으킬 말과 아닌 말을 얼마나 잘 구분하는가'입니다.
0.5면 동전 던지기, 1.0이면 완벽. 0.742는 '꽤 괜찮은' 수준입니다.

핵심:

- C(0.742) > A(0.737): 피처를 더하면 배당률만 보는 것보다 약간 나아진다
- A(0.737) >> B(0.657): 배당률 정보가 압도적으로 중요. 86개 피처를 합쳐도 q 하나만 못함
- 결론: 배당률을 기반으로 깔고, 피처로 정밀도를 높이는 구조가 최적

2. 최적 베팅 전략

2.1 추천 전략

winOdds 10~50배 + 모델 상위 10% + 균등 베팅

항목	값	쉬운 설명
ROI	+32.0%	100만원 → 132만원. 32만원 순이익
P(수익)	87.9%	1,000번 반복 시 879번 수익, 121번 손실
95% CI	[-23.4%, +83.1%]	운 나쁘면 -23%, 좋으면 +83%
베팅 수	237건	약 8개월간 (test 기간)
적중 수	22건	237번 중 22번 맞춤
적중률	9.3%	전체 평균(2.7%)의 3.5배
평균 배당	15.1배	한 번 맞추면 15만원 회수 (1만원 기준)
무작위 ROI	-26.5%	아무나 고르면 이만큼 잃음

왜 '확실한 수익'이 아니라 '높은 가능성의 수익'인가:

95% CI가 [-23.4%, +83.1%]로 0을 포함합니다. 이는 통계적으로 '운이 아주 나쁘면 23% 손해도 가능하다'는 뜻입니다.
하지만 P(수익)=87.9%이므로 '돈 벌 확률이 잃을 확률의 7배'입니다.

학술적으로: '정보 가치(edge)가 존재하나 유의수준 5%를 달성하지 못함.
3~5년 추가 데이터로 검증 시 유의할 가능성 높음.'

2.2 왜 10~50배인가

10배 미만: 배당이 낮아서 적중해도 수수료(20%)를 이기기 어려움.
→ 시장이 '어느 정도 가능성 있다'고 본 말들이라 모델의 우위가 작음.

10~50배 (스위트 스팟): 이번이 일어날 '가능성이 있으면서' 배당도 충분히 높음.
→ 시장은 '거의 안 된다'고 봤지만, 모델은 '최근 훈련 많고 기수 좋다'는 정보로 '시장 생각보다는 가능성 있다'고 판단. 이 틈새에서 수익 발생.

50배 이상: 이번 자체가 너무 희귀(적중률 ~2%)해서 모델도 구분 못함.
→ 순수한 운의 영역. ROI 마이너스.

3. 이변마의 공통점 — 어떤 말이 이변을 만드는가

3.1 이변마 vs 비이변마 (피처 비교)

비인기마 3,528마리 중 이변을 일으킨 94마리와 그렇지 않은 3,434마리의 피처 평균을 비교했습니다. 차이가 큰 순서대로:

순위	피처	쉬운 설명	이변마가...	차이 크기
1	q	배당률 확률 (비 인기마 중 상대적 인기)	높음	+0.82 표준편차
2	clinic_30d	최근 30일 진료 건수	높음	+0.51
3	age_pr	연령 (경주 내 백분위)	낮음 (젊음)	-0.41
4	hr_last_resid	직전 경주에서 기대 대비 성적	높음 (잘 뛰었음)	+0.34
5	tr_resid	조교사 잔차 (기대 대비 성적)	높음 (좋은 조교사)	+0.33
6	tr_plcrate	조교사 통산 입상률	높음	+0.32
7	train_runs_14_z	14일 훈련 횟수	높음 (많이 훈련)	+0.31
8	hr_last_poppct	직전 경주 인기 백분위	낮음 (직전엔 더 인기)	-0.29

해석 — 이변마의 전형적 프로필:

'비인기마 중에서도 상대적으로 배당이 낮은 쪽(q 높음)이고, 젊고(age 낮음), 최근 진료를 많이 받았고(컨디션 관리), 직전 경주에서도 기대 이상으로 뛰었으며(hr_last_resid 높음), 좋은 조교사가 관리하고(tr_resid, tr_plcrate 높음), 최근 훈련을 많이 했는데(train_runs_14 높음), 이번에 왠지 인기가 떨어진 말(hr_last_poppct가 더 높았음 = 직전엔 더 인기였음)'

한 문장: 실력과 컨디션은 좋은데 시장이 '최근 부진'이나 '인기 하락'에 과잉 반응한 말.

3.2 이변마의 3가지 유형 (K-means 군집화)

이변을 일으킨 말 495마리(전체 데이터)를 K-means로 군집화한 결과, 3개 유형으로 나뉘었습니다 (최적 k=3, 실루엣 계수 0.072).

유형	크기	핵심 특징	해석
데뷔형	49마리 (10%)	is_debut=1, is_new_horse=1	첫 출전인데 바로 이김.

			시장이 정보 부족으로 과소평가.
베테랑 복귀형	192마리 (39%)	조교사/기수/마주 경험 많음 (tr_starts, jk_starts UP)	능력 있는 팀인데 최근 부진으로 인기 하락. 컨디션 회복 후 이변.
신예 깜짝형	254마리 (51%)	조교사/기수/마주 경험 적음 (tr_starts, jk_starts DOWN)	신진 세력의 깜짝 활약. 시장이 실적 부족으로 무시.

해석:

- 데뷔형(10%): '아직 뭘 적이 없어서 시장이 판단 못 함' → 정보 비대칭
이 유형은 모델도 잡기 어려움 (과거 성적이 아예 없으니까).
하지만 데뷔전임에도 모델이 높은 점수를 준 경우 = 훈련 데이터가 좋다는 신호.
- 베테랑 복귀형(39%): 가장 모델이 잘 잡는 유형.
시장은 '최근 성적 부진'에 과잉 반응하지만, 모델은 '조교사가 좋고 훈련량도 유지 중'을 봄.
→ 발표 포인트: '시장이 최근 부진에 과잉 반응할 때 기회가 생긴다'
- 신예 깜짝형(51%): 가장 많은 유형이지만 가장 예측 어려움.
'아직 안 알려진 실력자'를 사전에 포착하기 어렵기 때문.

3.3 의사결정나무 — 이변 규칙

RandomForest(87개 피쳐)는 정확하지만 해석 불가능합니다.
의사결정나무(depth=4)로 '해석 가능한 규칙'을 뽑았습니다.

나무의 첫 번째 분기:

- $q > 0.25$ (z점수) → 이변 가능성 UP
- $q \leq 0.25$ → 이변 가능성 DOWN

해석: '같은 비인기마 중에서도 배당률 확률이 상대적으로 높은 말'에서 이변이 더 많다.
즉, '극비인기'(50배+)보다 '약간 비인기'(10~20배)에서 이변이 더 잘 일어남.
→ 이것이 10~50배 필터가 작동하는 이유.

DT AUC = 0.7065 (RF 0.742보다 낮지만, 규칙이 보이니까 '왜'를 설명할 수 있음)

3.4 배당 구간별 이변마 프로필

피쳐	10~15배 이변마	15~30배 이변마	30~50배 이변마	50배+ 이변마
----	------------	------------	------------	----------

q (배당률)	매우 높음 (+2.15)	높음 (+0.43)	낮음 (-0.44)	매우 낮음 (-0.89)
clinic_30d (진료)	+0.67	+0.79 (최고)	+0.55	+0.34
age (연령)	젊음 (-0.42)	약간 젊음	보통	늙은 편 (+0.32)
hr_last_resid (직전)	보통	보통	+0.12	+0.21 (최고)
tr_resid (조교사)	+0.18	+0.19	보통	+0.37 (최고)

구간별 해석:

- 10~15배 이변: '원래 실력 있는데 살짝 인기에서 빠진 말'
q가 매우 높음 = 비인기마 중에서도 가장 인기 있는 쪽.
젊고 최근 진료도 받음. 가장 '안전한' 이변.
- 15~30배 이변: 진료 건수가 가장 높음.
'컨디션 관리를 열심히 한 말'. 준비된 이변.
- 50배+ 이변: 조교사 잔차와 직전 잔차가 가장 높음.
'실력 있는 조교사가 관리하는 무명마'.
가장 예측 어렵지만, 맞추면 보상이 큼.

4. 배분 전략 — 얼마씩 걸어야 하나

모델이 선택한 237건에 총 1,000단위를 배분하는 6가지 방법을 비교했습니다.

전략	방식	Test ROI	Max 베팅	Min 베팅
Flat (균등)	모두 같은 금액	+32.0%	4.22	4.22
EV-비례	기대값(확률×배당) 비례	+32.7%	8.63	2.59
확률-비례	예측확률 비례	+32.7%	4.94	3.87
Kelly	최적 수학 공식 기반	+32.9%	4.95	3.66
구간별 (50/30/20)	상/중/하 차등	+30.7%	6.33	2.53
Top-heavy (70/30)	상위 20%에 집중	+31.1%	14.89	1.58

결론: 모든 전략이 +30.7% ~ +32.9%로 거의 동일합니다.

왜 차이가 안 나는가:

모델의 예측확률이 0.02~0.08 범위에 몰려있어서,

비례 배분을 해도 실제 배팅 크기 차이가 미미합니다.
(Max 8.63 vs Min 2.59 → 고작 3배 차이)

실전 권장:

균등 배팅(Flat)을 사용하세요. 가장 단순하고, 과적합 위험이 없고,
ROI도 복잡한 전략과 사실상 동일합니다.

핵심 인사이트:

'어디에 배팅하느냐(종목 선택)'가 '얼마를 배팅하느냐(자금 배분)'보다
압도적으로 중요합니다. 종목 선택에서 이미 알파가 결정됩니다.

5. 종합 — 프로젝트 전체 스토리

- 1단계: '시장을 이기겠다' → 실패 (AUC 0.75 vs 시장 0.81)
- 2단계: '왜 못 이기지?' → 시장이 매우 효율적임을 확인
- 3단계: '방향 전환' → 시장 전체가 아니라, 시장이 '틀리는 구간'만 노리자
- 4단계: '이변 예측' → 배당률(q)을 포함시키니 AUC 0.742
- 5단계: '최적 전략' → 10~50배 구간 필터, ROI +32%, P(profit) 88%
- 6단계: '왜 작동?' → 이변마 분석. 젊고/훈련多/조교사好인데 시장이 과소평가한 말
- 7단계: '배분은?' → 균등이 최적. 복잡한 공식은 불필요

한 줄 결론:

'시장을 정면으로 이기는 건 불가능하지만, 시장이 구조적으로 약한 구간(10~50배 비인기마)에
서
실력 있는데 인기에서 밀려난 말을 골라내면 수수료 이후에도 양의 기대값을 가진다.'

6. 한계

- 1. 표본: 237건 중 22건 적중. CI가 0을 포함 → '확실한 수익' 아님.
- 2. 고배당 의존: 상위 2~3건의 고배당 적중이 ROI의 큰 부분 차지.
- 3. 과거 데이터: 미래에도 동일하게 작동하는 보장 없음.
- 4. 서울만: 부경(부산경남)에서 재현 미확인.
- 5. 군집화 품질: 실루엣 0.07로 군집이 뚜렷하지 않음 (이변 원인이 다양하기 때문).

7. 재현 코드

전체 파이프라인

python src/upset_with_odds/08_full_pipeline.py # 모델 학습 + 기본 ROI

python src/upset_with_odds/11_improvement_experiments.py # 6단계 개선

```
python src/upset_with_odds/12_final_strategy.py # 배당 필터 최종 전략
python src/upset_with_odds/14_upset_insight_and_allocation.py # 인사이트 + 배분
```