

KHUDA 10기 토이프로젝트 3조

파트 1

시장이라는 벽

배당률이라는 대중의 집단 예측을
데이터 모델이 넘어설 수 있는가

데이터셋 구축 · 전처리 · 세 각도의 모델링 · 문헌 대조

한국마사회 서울 경주 2023.08 – 2026.08

2026년 8월

0. 이 보고서를 읽는 법

0.1 한 문단 요약

경마의 배당률은 수만 명이 자기 돈을 걸어 만든 확률 추정치입니다. 우리는 그것을 데이터 모델이 넘어설 수 있는지 물었고, **세 가지 각도** — 변별력·확률 품질·수익성 — 로 나누어 도전했습니다. 셋 다 넘지 못했습니다. 그러나 이것을 실패로만 읽으면 이 프로젝트의 절반을 놓칩니다. 문헌을 확인해보니 시장을 이겨 실제로 돈을 번 유일한 검증 사례조차 **모델 단독 정확도는 시장보다 낮았습니다**. 문제는 성능이 아니라 무엇을 재고 있었는가였습니다.

0.2 이 보고서가 답하는 것

이 문서는 파트 1입니다. 네 가지 질문에 답합니다.

1. 데이터를 어떻게 모으고 어떻게 다듬었는가 — 그리고 그 선택이 결과를 어떻게 바꿨는가
2. 세 각도의 모델은 각각 무엇을 어떻게 측정했고 어떤 결과가 나왔는가
3. 우리가 못 넘은 벽을 선행 연구는 어떻게 다뤘는가
4. 그래서 질문을 어떻게 바꿔야 하는가 — 파트 2로 넘어가는 근거

파트 2(이번 탐지 모델)는 별도 보고서로 다룹니다. 이 보고서의 마지막 장이 그 출발점입니다.

0.3 읽는 순서

경마를 처음 접하신다면 **1장부터 순서대로** 읽으시면 됩니다. 1장만 읽어도 나머지를 따라올 수 있게 썼습니다. 배경을 이미 아신다면 **4장(세 각도의 도전)** 과 **7장(왜 이기지 못하는가)** 이 본론입니다. 숫자만 빠르게 확인하고 싶으시면 **5.1절 요약표** 한 장이면 됩니다.

이 보고서에서 수익률(ROI) 수치를 쓰지 않는 이유

수익률은 고배당 적중 한두 건에 크게 흔들립니다. 실제로 같은 코드·같은 데이터로 재현 실험을 했을 때 판별 성능(AUC)은 0.3% 안에서 움직였지만 수익률은 훨씬 크게 요동쳤습니다. 자세한 근거는 8.1절에 있습니다.

그래서 이 보고서는 **성능 지표만** 인용하고 수익률 수치는 신지 않습니다. 숫자를 낮춰 부르는 것이 아니라, 우리가 가진 표본으로 말할 수 있는 만큼만 말하려는 것입니다.

1. 왜 경마인가

예측 모델을 만드는 대부분의 문제에는 비교 대상이 없습니다. 매출을 예측하든 이탈을 예측하든, 우리가 재는 것은 “정답을 얼마나 맞혔나” 하나뿐입니다.

경마는 다릅니다. **매 경주마다 수만 명이 자기 돈을 걸어 만든 확률 추정치가 이미 존재합니다.** 그것도 실시간으로 갱신되어 숫자로 공개됩니다. 그래서 질문이 하나 더 생깁니다 — 그 기준선을 넘을 수 있는가.

이 장은 그 “기준선”이 정확히 무엇인지 설명합니다. 경마를 한 번도 본 적 없어도 따라올 수 있게 썼습니다.

1.1 배당률은 주최측이 매긴 가격이 아닙니다

가장 먼저 버려야 할 오해입니다. 해외 스포츠 도박에서 흔한 방식은 **북메이커**가 자기 판단으로 배당을 정하고 손님과 업체가 맞붙는 구조입니다. 업체가 틀리면 업체가 손해를 봅니다.

한국 경마는 **파리뮤추얼(pari-mutuel)** 방식입니다. 프랑스어로 “서로(mutuel) 내기(pari)”라는 뜻입니다. 참가자들이 낸 돈을 한 통에 모으고, 주최측이 정해진 몫을 먼저 떼어간 뒤, 남은 돈을 맞힌 사람들끼리 나눠 갖습니다.

여기서 핵심이 나옵니다

주최측은 결과에 아무 이해관계가 없습니다. 누가 이기든 자기 몫은 이미 챙겼기 때문입니다.

따라서 배당률은 **사람들이 어디에 얼마를 걸었는지의 결과일 뿐**입니다. 배당률이 낮다는 것은 “많은 사람이 그 말을 유력하다고 봤다”는 뜻입니다.

즉 배당률은 그 자체로 **수만 명의 판단을 합산한 예측치**입니다. 우리가 이 보고서에서 “시장”이라고 부르는 것이 바로 이것입니다.

1.2 배당률을 확률로 뒤집기

배당률 8.0배는 “1을 걸면 8을 받는다”는 뜻입니다. 확률로 바꾸려면 그냥 뒤집으면 됩니다.

$$\text{암묵 확률} = 1 / \text{배당률}$$

$$\text{배당 8.0배} \rightarrow 1 / 8.0 = 0.125 = 12.5\%$$

사람들이 이 말에 판돈의 12.5%를 걸었다는 뜻이고, 곧 “집단이 보기에 이 말의 우승 확률이 대략 12.5%”라는 의미입니다.

1.3 그런데 확률을 다 더하면 1 이 넘습니다

한 경주에 나온 모든 말의 암묵 확률을 더해보면 1.0이 아니라 1.25쯤 나옵니다. 이상해 보이지만 당연합니다. **주최측이 약 20%를 먼저 떼어갔기 때문**입니다.

우리 데이터 실측 (서울 경주 test 637경주)	값
경주별 $\Sigma(1 / \text{배당률})$ 평균	1.2484
경주별 $\Sigma(1 / \text{배당률})$ 중앙값	1.2497
환급률 = $1 / 1.2497$	약 80.0%
공제율	약 20.0%

표 1-1. 오버라운드 실측. 이 초과분이 주최측 몫이다.

이 초과분을 **오버라운드(overround)** 라고 부릅니다. 확률로 쓰려면 전체로 나눠 합이 1이 되게 맞춰야 하는데, 그렇게 정규화한 값을 이 보고서에서 **시장 확률 q** 라고 부릅니다.

$$q = (1 / O) / S \quad (S = \text{그 경주의 모든 } 1/O \text{ 합})$$

$$\text{배당 6.0배, 경주 전체 } S = 1.25 \rightarrow q = 0.1667 / 1.25 = 13.3\%$$

이 한 줄이 프로젝트 전체의 벽입니다

시장은 이 말의 우승 확률을 13.3%로 보는데, 실제로 돈을 벌려면 **16.7%** 는 넘어야 합니다. 그 사이 3.4%포인트가 주최측이 가져간 몫입니다.

일반화하면 기대수익이 양수이려면 다음 조건이 필요합니다.

$$p/q > S \quad \text{— 우리 데이터에서 } S \approx 1.25$$

즉 “**시장보다 조금 더 정확하다**”로는 **안 됩니다**. 특정 말에 대해 시장보다 25% 더 높게 봐야 하고, 그 판단이 실제로 맞아야 합니다.

1.4 그래서 ‘시장을 이긴다’는 두 가지 뜻입니다

이 구분을 놓치면 프로젝트 전체의 결론이 뒤집힙니다.

구분	묻는 것	재는 방법
(A) 정확도로 이긴다	모델이 시장보다 잘 맞는가	ROC-AUC · Log Loss 비교
(B) 경제적으로 이긴다	시장에 정보를 엮어 수익이 나는가	결합 후 기대수익 · 실전 검증

표 1-2. '시장을 이긴다'의 두 가지 의미.

우리는 처음에 **(A)만 재고 있었습니다**. 모델 AUC가 시장보다 낮으니 실패라고 판단했습니다. 그런데 6장에서 보듯 문헌 기준으로 이것은 성립하지 않는 판정입니다. 실제로 수익을 낸 검증 사례조차 (A)에서는 시장에 졌기 때문입니다.

2. 데이터

2.1 어떻게 모았나

한국마사회 공공데이터 API **11종** 에서 3년치를 수집했습니다. 경주 정보, 출전마 정보, 기수·조교사 성적, 훈련 기록, 진료 기록, 배당률 등이 서로 다른 API로 흩어져 있어 이를 하나의 출전 단위 테이블로 합쳤습니다.

항목	내용
출처	한국마사회 공공데이터 API 11종
기간	2023.08.05 – 2026.08.09 (약 3년)
원천 규모	56,648 출전행 × 156열 · 5,361경주
모델링 대상	서울 32,888행 · 3,167 정상 경주
단위	1행 = 한 경주에 출전한 말 한 마리

표 2-1. 데이터 개요.

수집 코드는 저장소의 [src/0_데이터수집/](#)에 있습니다. 서비스 키는 코드에 넣지 않고 별도 파일로 분리해 저장소에 올라가지 않도록 막았습니다.

2.2 무엇이 들어 있나

156개 열은 성격에 따라 크게 다섯 갈래로 나뉩니다.

갈래	예	쓸 수 있나
식별자	hrNo 마번 · jkNo 기수번호 · rcDate 경주일	조인·분할에만
경주 조건	거리 · 트랙 상태 · 등급 · 출주두수 · 날씨	예
말·기수·조교사 이력	과거 승률 · 최근 성적 · 휴식일 · 훈련량	예
시장 정보	winOdds 단승 배당 · plcOdds 연승 배당 · 발매금액	제한적
결과	착순 · win 1착 여부 · 상금	타깃으로만

표 2-2. 열의 다섯 갈래.

2.3 무엇을 뺐나 — 누수 방지 세 가지 원칙

예측 모델에서 가장 흔하고 가장 조용한 실패가 **정보 누수(leakage)** 입니다. 실제로는 알 수 없었던 정보를 모델이 보게 되면, 검증 점수는 훌륭한데 실전에서는 아무 쓸모가 없습니다. 이 프로젝트는 세 가지 원칙을 정하고 지켰습니다.

- 1. 경주 결과와 사후 정보를 피처에 넣지 않는다.** 착순·상금·기록은 경주가 끝나야 알 수 있습니다. 이것들이 들어가면 “결과로 결과를 맞히는” 셈이 됩니다.
- 2. 현재 경주의 배당·베팅 정보를 기본 피처에 넣지 않는다.** 이 프로젝트의 핵심 제약입니다. 배당률을 피처로 쓰면 “시장을 베껴 시장과 비교하는” 자기모순이 됩니다.
- 3. 시간순으로만 자른다.** 무작위로 섞으면 미래 경주로 학습해 과거 경주를 맞히는 상황이 됩니다. 3.4 절에서 자세히 다룹니다.

다만 **2번 원칙에는 의도된 예외** 가 있습니다. 4.3절(확률 품질)과 파트 2의 이변 모델은 배당률에서 뽑은 시장 확률을 명시적으로 사용합니다. 이때는 “시장을 베끼는” 것이 아니라 **시장을 출발점으로 삼아 그 위에 얹는** 것이 목적이기 때문에 원칙이 달라집니다. 어느 실험이 배당률을 썼는지는 4장 각 절에 명시했습니다.

2.4 실측 요약

모델을 만들기 전에 데이터가 말하는 기본 사실을 확인했습니다.

항목	값	의미
경주당 평균 출주두수	10.46두	무작위로 찍으면 9.56%
실제 1착 비율	9.56%	양성 클래스가 매우 적음
우승마 평균 배당	8.10배	평균은 고배당에 끌려감
우승마 중앙값 배당	4.30배	실제 감각은 이쪽에 가까움
환급률	약 80%	아무 전략 없이 걸면 -20%

표 2-3. 서울 경주 test 637경주 · 6,650출전 실측.

이 표에서 읽어야 할 두 가지

① **아무 전략 없이 걸면 평균 -20%입니다.** 이것이 모든 베팅 전략의 출발선입니다. 본전을 맞추는 것만으로도 이미 20%의 우위가 필요합니다.

② **양성 비율이 9.56%로 매우 적습니다.** 이런 상황에서 정확도(accuracy)는 무의미합니다. “전부 아니다”라고만 답해도 90%를 맞히기 때문입니다. 그래서 이 보고서는 정확도 대신 ROC-AUC와 Log Loss 같은 지표를 씁니다.

3. 전처리 — 무엇을 어떻게 다듬었나

156개 열을 그대로 모델에 넣을 수는 없습니다. 비어 있는 값이 있고, 튀는 값이 있고, 서로 거의 같은 말을 하는 열이 있습니다. 이 장은 그것들을 어떻게 처리했는지, 그리고 **왜 그렇게 처리했는지**를 설명합니다.

3.1 결측치 — 빈칸에도 종류가 있습니다

결측률 5% 이상인 열을 전수 조사했더니, 빈칸이 생긴 이유가 두 가지로 뚜렷하게 갈렸습니다.

종류	왜 비어 있나	예	처리
구조적 결측	존재할 수 없어서 빈칸	<code>hr_winrate</code> — 데뷔전 말은 과거 승률이 없음	0으로 채움
랜덤 결측	기록이 누락되어 빈칸	<code>hr_rest_days</code> — 휴식일 기록 일부 누락	train 중앙값

표 3-1. 결측치 두 종류와 처리 방식.

이 구분이 중요한 이유는, **구조적 결측을 중앙값으로 채우면 거짓 정보를 만들기 때문**입니다. 데뷔전 말의 과거 승률을 “평균적인 말의 승률”로 채우면, 모델은 그 말이 평범한 실적을 가졌다고 믿게 됩니다. 실제로는 실적이 없는 것인데 말입니다.

실측에서 `is_debut=1`인 행의 100%가 `hr_winrate`, `hr_plcrate`, `hr_resid`에서 결측이었습니다. 패턴이 완벽하게 일치했으므로 구조적 결측으로 분류하고 0으로 채웠습니다. 범주형 열의 빈칸은 **MISSING**이라는 별도 범주로 두어, “값이 없다”는 사실 자체를 정보로 남겼습니다.

문헌이 제안하는 더 나은 방법

6장에서 다룰 Benter는 과거 기록이 없어 확률을 낼 수 없는 말을 **unratable**로 표시하고, **시장 확률을 그대로 부여한 뒤** 나머지 말의 확률을 다시 정규화합니다.

“시장의 판단에 이의를 제기할 정보가 없으니 그대로 받아들인다”는 원칙입니다. 우리는 0으로 채웠는데, 문헌 기준으로는 시장 확률을 대입하는 편이 맞습니다. 개선 여지로 남깁니다.

3.2 이상치 — 자를 것인가 누를 것인가

이상치 처리에는 두 갈래가 있고, 우리 팀은 **둘 다 써봤습니다**. 결과가 크게 달라졌기 때문에 이 절은 특히 중요합니다.

방식	무엇을 하나	장점	치명적 부작용
IQR 행 삭제	$Q1 - 1.5 \cdot IQR \sim Q3 + 1.5 \cdot IQR$ 밖의 행을 통째로 제거	극단값 영향 제거	같은 경주의 일부 말만 남음
원저라이즈	0.5 ~ 99.5 백분위로 값을 눌러 담음	행이 사라지지 않음	극단값 정보 일부 손실

표 3-2. 이상치 처리 두 방식.

IQR 행 삭제가 경주 구조를 깨뜨립니다

경마에는 “**한 경주에 우승마가 정확히 하나**” 라는 강한 제약이 있습니다. 그런데 행 단위로 이상치를 지우면 10두가 출전한 경주에서 7두만 남는 일이 생깁니다.

그러면 그 경주는 더 이상 온전한 경주가 아닙니다. 경주 단위 확률 평가도, 배당 기반 검증도 성립하지 않습니다.

이 때문에 이상치를 제거한 버전(v5~v8)은 **신규 모델 학습·확률 평가·백테스트에 사용 금지**로 명시해 두었습니다. 과거 실험 재현용으로만 남겨둔 상태입니다.

3.3 다중공선성 — 같은 말을 하는 열 걷어내기

수치형 피처의 상관행렬을 그리고 $|r| \geq 0.8$ 인 쌍을 전부 뽑았습니다. VIF(분산팽창계수)도 함께 확인했습니다. 그 결과 **23개 열**을 제거 목록에 올렸습니다.

대표적인 예가 상금 계열입니다. `chaksun1`부터 `chaksun5`까지 1~5착 상금이 각각 열로 있는데, 이들은 경주 등급 하나로 거의 결정되므로 서로 0.9 이상의 상관을 보입니다. 이런 열을 모두 남기면 트리 모델이 같은 정보를 반복해서 쪼개게 되고, 선형 모델에서는 계수가 불안정해집니다.

배당률 계열에서도 같은 일이 벌어집니다. 단승 배당에서 파생된 열이 14개나 되는데 (`p_raw`, `logit_q`, `log_q`, `pop_rank`, `is_fav`, `book_sum` 등) 서로 거의 같은 정보입니다. 배당률을 쓰는 실험에서는 **정규화된 시장 확률 `q` 하나만 남기고** 나머지를 제거했습니다.

3.4 시간순 분할 — 무작위로 섞으면 안 되는 이유

이 프로젝트에서 가장 지키기 쉬우면서 동시에 가장 자주 실수하는 부분입니다.

데이터를 무작위로 섞어 나누면 **미래 경주로 학습해 과거 경주를 맞히는** 상황이 됩니다. 실전에서는 절대 불가능한 조건이므로 성능이 부풀려집니다.

경마는 시간이 흐르면서 말도 기수도 바뀌고, 시장의 정확도 자체도 달라집니다. 그래서 rcDate(경주일) 오름차순으로 정렬한 뒤 **60 : 20 : 20** 으로 잘랐습니다.

구간	용도	언제 여는가
train (60%)	모델 학습	언제든
valid (20%)	피처·하이퍼파라미터 선택	선택할 때마다
test (20%)	최종 성능 확인	마지막에 단 한 번

표 3-3. 세 구간의 역할.

분할에는 한 가지 규칙을 더 걸었습니다. **같은 경주일의 행은 절대 서로 다른 구간으로 갈라지지 않습니다.** 누적 비율이 경계를 넘는 첫 날짜를 잘라내는 지점으로 삼아, 날짜 단위로 통째로 배정했습니다. 같은 경주가 학습과 평가에 쪼개져 들어가면 그것도 누수이기 때문입니다.

test를 한 번만 여는 것이 왜 중요한가

test 점수를 보고 모델을 고치면, 그 순간부터 test는 더 이상 “미래 성능의 추정치”가 아닙니다. 사실상 두 번째 valid가 되어버립니다.

4.3절의 확률 품질 실험은 이 원칙을 가장 엄격하게 지켰습니다. 모델·피처·정규화·혼합계수·온도를 **모두 동결한 뒤 test를 단 한 번 열었고, 결과를 본 뒤 아무것도 조정하지 않았습니다.**

3.5 전처리 8 가지 버전

이상치 제거 여부(2가지) × 스케일링 방식(4가지)을 조합해 **8개 버전** 을 만들었습니다. 모델마다 요구하는 전처리가 다르기 때문입니다.

버전	이상치	스케일링	주 용도
v1_base	미제거	없음	트리 모델 (RF · XGBoost · LightGBM)

버전	이상치	스케일링	주 용도
v2_standard	미제거	Standard	로지스틱 회귀 · SVM
v3_minmax	미제거	MinMax	신경망 계열
v4_robust	미제거	Robust	극단값이 있는 선형 모델
v5~v8	IQR 제거	v1~v4와 동일	신규 학습 금지 · 재현 확인용

표 3-4. 전처리 8버전. 트리 모델은 스케일링이 필요 없어 v1을 쓴다.

3.6 그런데 사람마다 다르게 했습니다

이 절은 이 보고서에서 가장 중요한 방법론 서술입니다. 발표에서 “왜 세 결과를 나란히 비교하지 않느냐”는 질문이 나온다면 답은 여기 있습니다.

위에 정리한 팀 공용 전처리를 **세 각도 중 어느 것도 그대로 쓰지 않았습니다**. 목표가 달랐기 때문입니다.

	입력	이상치	범주형	분할 단위	배당률
팀 공용	원천 → 서울	IQR 삭제	Label	행 60:20:20	전부 제외
변별력	팀 공용 v1~v8	버전에 따름	Label	행 60:20:20	전부 제외
확률 품질	원천 → 자체	원저라이즈	One-Hot	경주 단위	출발점으로 사용
수익성	원천에서 재시작	안 함	Label	행 6:2:2	q 만 피쳐로

표 3-5. 세 각도의 전처리 차이.

왜 통일하지 않았나 — 통일할 수 없었습니다

팀 공용 전처리는 배당률 14개 열을 전부 제거합니다. “배당률 없이 1착을 맞힌다”가 목표였기 때문입니다.

그런데 확률 품질 실험은 시장 확률을 **출발점**으로 삼고, 수익성 실험은 시장 확률 **q**를 **핵심 피쳐**로 씁니다. 배당률이 제거된 데이터로는 애초에 실험이 성립하지 않습니다.

이상치와 분할 단위도 마찬가지입니다. 경주 단위 확률을 평가하려면 경주가 온전해야 하므로 행을 지우는 IQR 방식을 쓸 수 없고, 행 단위 분할도 쓸 수 없습니다.

결론: 세 각도는 애초에 다른 데이터로 학습한 다른 모델입니다. 지표가 다른 것에 더해 전처리까지 다르므로, 세 숫자를 한 표에 놓고 순위를 매기는 것은 무의미합니다.

4. 세 각도의 도전

1차 모델링에서 시장에 완패한 뒤, 팀은 “시장을 이긴다”가 무엇을 뜻하는지부터 다시 물었습니다. 그 결과 하나의 질문이 **세 개의 다른 질문**으로 갈라졌습니다.

각도	묻는 것	주 지표	담당
① 변별력	1착을 가장 잘 골라내는가	ROC-AUC · PR-AUC	박준석 · 홍정의 · 이종원
② 확률 품질	시장보다 정확한 확률을 내는가	Race Log Loss · Brier	김찬진
③ 수익성	돈이 되는 구간이 있는가	기대우위 · Lift	박준석

표 4-1. 세 각도의 정의.

세 각도는 서로를 대체하지 않습니다. **변별력이 높다고 확률이 정확한 것도 아니고, 확률이 정확하다고 돈이 되는 것도 아닙니다.** 이 셋을 구분한 것이 이 프로젝트의 방법론적 성과입니다.

4.1 각도 ① — 변별력

“이 말이 1등 할 확률이 높은지 낮은지를 잘 구분하는가.” 가장 직관적인 질문이고, 가장 먼저 던진 질문입니다.

4.1.1 1차 모델링 — 세 모델 비교

로지스틱 회귀, 랜덤포레스트, XGBoost 세 가지를 같은 데이터에서 학습해 test에서 비교했습니다.

모델	Accuracy	Precision	Recall	F1 (Macro)	ROC-AUC
로지스틱 회귀	0.3062	0.0952	0.7372	0.2867	0.5262
랜덤포레스트	0.7214	0.1971	0.6251	0.5629	0.7495
XGBoost	0.8903	0.2075	0.0531	0.5131	0.6846

표 4-2. 1차 모델링 결과 (test set).

이 표를 정확도만 보고 읽으면 안 됩니다

XGBoost의 Accuracy가 0.8903으로 가장 높지만 Recall이 0.0531입니다. 1착 말 100마리 중 5마리밖에 못 잡

았다는 뜻입니다. “거의 전부 1착이 아니다”라고 답해서 정확도를 올린 것이지, 실용성이 없습니다.

로지스틱 회귀는 반대입니다. Recall 0.7372로 잘 잡아내지만 Precision이 0.0952입니다. 1착이라고 지목한 말 100마리 중 10마리만 맞습니다.

랜덤포레스트가 균형을 잡았습니다. ROC-AUC 0.7495로 판별력이 가장 높고 F1도 가장 좋습니다. 이후 실험의 기준 모델이 되었습니다.

분류 임계값도 valid에서 탐색했습니다. 0.05~0.15 같은 낮은 값에서는 Recall이 0.99까지 오르지만 Precision이 0.10 아래로 급락합니다. F1(Macro) 기준 최적은 0.5였습니다.

4.1.2 2 차 — 피처를 줄이면 좋아진다는 가설이 뒤집히다

초기 가설은 이랬습니다 — “**시장보다 적은 수의 핵심 피처만 쓰면 더 좋은 일반화 성능이 나올 것이다.**” 군더더기를 걷어내면 신호가 선명해질 거라는 흔한 직관입니다. 실험으로 확인해봤습니다.

실험	피처 수	valid ROC-AUC	관찰
핵심 피처	30개	약 0.7224	출발점
하나씩 제거	27개	국소 최대	중복 피처 일부 제거는 유리
더 줄이기	20개 이하	지속 하락	가설과 반대
순차 확장	95개	0.752933	최고점. 30개 대비 +0.0305

표 4-3. 피처 수 실험 (v1 · XGBoost · valid 기준).

가설이 뒤집혔습니다. **피처를 늘릴수록 좋아졌습니다.** 다만 이것은 이상한 결과가 아닙니다.

- 1. 약한 신호의 합산.** 단일 피처의 영향이 작아도, 여러 조건이 함께 맞을 때 우승 확률을 설명합니다. 시장 역시 단일 정보가 아니라 말의 기량·최근 폼·기수·거리 적성·부담중량·훈련 상태를 모두 합친 결과입니다.
- 2. 경주 내 상대 비교.** 절대 기량보다 “같은 경주에 나온 다른 말 대비” 레이팅·승률·훈련량이 중요합니다. 상대 비교 피처를 추가하자 성능이 올랐습니다.
- 3. 상호작용.** 거리·각질·선행마 수·기수와 말의 조합은 단독보다 결합될 때 의미가 생깁니다. 트리 기반 모델은 이런 비선형 상호작용을 활용할 수 있습니다.

그럼에도 **시장 기준선과의 차이는 여전히 0.06 안팎**이었습니다. 피처를 30개에서 95개로 세 배 늘려 얻은 개선이 0.0305인데, 남은 격차가 그 두 배입니다. **피처 개수의 문제가 아니었다**는 것이 이 실험의 결론입니다.

4.1.3 3차 — 랭킹 학습 도입

세 번째 시도에서 접근을 바꿨습니다. 말 하나하나에 대해 “이 말이 이길까?”를 이진 분류하는 대신, **경주 하나를 통째로 놓고 출전마들의 상대 순서를 학습** 하는 방식을 도입했습니다. 정보검색에서 온 랭킹 학습(Learning-to-Rank) 계열입니다.

여섯 가지 모델을 비교했고, 그중 **수업에서 다룬 세 가지**를 여기 싣습니다. 나머지 셋(Deep listwise ensemble, Plackett-Luce hybrid)은 커리큘럼 밖이라 제외했습니다.

모델	valid ROC-AUC	test ROC-AUC	test PR-AUC
LightGBM rank+binary	0.7637	0.7552	—
CatBoost ordered	0.7501	0.7508	0.2637
Random Forest	0.7467	0.7507	—

표 4-4. 3차 모델링 — v5 데이터셋. PR-AUC는 일부 모델에서 기록되지 않았다.

이 표에서 읽어야 할 두 가지

- ① **LightGBM은 valid 1위였다가 test에서 밀렸습니다.** valid 0.7637로 여섯 모델 중 가장 높았는데 test에서는 0.7552로 3위가 됐습니다. **검증에서 좋았던 것이 실전에서 유지되지 않는다**는 전형적인 사례입니다.
- ② **CatBoost와 Random Forest는 사실상 동점입니다.** test 0.7508 대 0.7507, 차이가 0.014%p입니다. 순위를 매기는 것 자체가 의미 없는 수준입니다.

LightGBM을 **경주 단위 5-fold**로 다시 검증하면 **0.7457 ± 0.0115** 가 나옵니다. 단일 분할의 test 점수(0.7552)보다 낮고 표준편차가 0.0115이므로, 실제 성능은 대략 0.734 ~ 0.757 사이로 보는 것이 타당합니다.

그래도 진전은 있었습니다. 시장과의 격차가 **1차 0.063에서 3차 0.057로** 좁혀졌습니다. 다만 좁혀졌을 뿐 넘지는 못했습니다.

4.1.4 변별력 정리

	최고 ROC-AUC	시장과의 격차
시장 (배당률)	0.8126	—
1차 · RandomForest	0.7495	0.0631
2차 · XGBoost 95피쳐	0.7529 (valid)	—
3차 · LightGBM	0.7552	0.0574
결합 (시장 + 모델)	0.8135	+0.0009

표 4-5. 변별력 중합. 세 번의 시도 모두 시장 단독에 미치지 못했다.

표를 읽을 때 주의할 두 가지

① **2차의 격차는 비워졌습니다.** 2차 수치는 valid 기준이고 나머지는 test 기준이라 같은 선상에 놓을 수 없습니다. 2차 보고서는 시장 기준선을 반올림한 0.82로 잡아 격차를 0.067로 기록했는데, 실측 0.8126을 쓰면 0.0597이 됩니다.

② **3차 전체로는 0.0416까지 좁혀졌습니다.** 다만 그 값은 우리가 제외한 모델 (Deep listwise ensemble, test 0.7710) 기준입니다. 수업에서 다룬 세 모델 중 가장 좋은 LightGBM으로는 0.0574입니다.

마지막 줄이 중요합니다. **시장에 모델을 얹으면 0.8126에서 0.8135로 아주 조금 올라갑니다.** 모델이 시장에 없는 정보를 아예 갖고 있지 않은 것은 아니라는 뜻입니다. 다만 그 양이 0.001 수준입니다. 이 관찰이 다음 각도로 이어집니다.

4.2 각도 ② — 확률 품질

이 절은 ‘**시장보다 조금 더 좋은 확률을 만들 수 있는가**’라는 질문을 데이터 고정부터 R4 도전자 동결까지 27단계로 추적합니다. 초기에는 시장을 대체할 독립 모델을 만들었고, 실패를 확인한 뒤 시장을 앵커로 삼는 보정 모델로 전환했습니다. 마지막에는 확률 품질을 해치지 않는 범위에서 Top-1을 개선하는 보수적 게이트까지 확장했습니다.


이 절의 결론을 먼저 읽기

최초 동결 모델 M2는 Final Test에서 시장보다 낮은 Race Log Loss와 Brier를 기록했지만 Top-1은 시장보다 2경주 적었습니다.

후속 R4는 Calibration에서 시장의 1위를 14경주만 바꿔 순적중을 2경주 늘렸고, 두 확률 손실도 시장보다 악화시키지 않았습니다.

그러나 R4는 기존 Final Test에 다시 적용하지 않았습니다. 따라서 R4는 최종 승자가 아니라 frozen_pending_future_holdout 상태의 연구 도전자입니다.

확률 품질 연구의 27단계 개발 흐름



선택과 평가를 분리하고, 결과를 본 뒤 기준을 바꾸지 않는 구조

그림 4.2-1. 확률 품질 연구의 1~27단계 개발 흐름.

4.2.1 평가 질문과 수학적 기준

한 경주의 우승자는 원칙적으로 한 마리이고, 출전마 확률의 합은 1이어야 합니다. 그래서 출전마마다 독립적으로 0/1을 맞히는 정확도만으로는 확률의 품질을 평가할 수 없습니다. **Race Log Loss**는 실제 우승마에게 준 확률이 낮을수록 큰 벌점을 주고, **Race Brier**는 모든 출전마 확률과 실제 결과의 제곱 오차를 경주별로 합산합니다. Top-1은 가장 높은 확률을 준 말이 우승했는지를 세는 보조지표입니다.

지표	계산 관점	좋은 방향	역할
Race Log Loss	$-\log(\text{실제 우승마 확률})$ 의 경주 평균	낮을수록 좋음	자신 있게 틀린 예측을 강하게 벌점
Race Brier	경주 내 모든 말의 확률 제곱오차 합	낮을수록 좋음	확률 분포 전체의 정확성
Top-1 accuracy	경주별 유일 1순위의 적중 비율	높을수록 좋음	순위 관점의 보조지표

표 4.2-1. 확률 품질 평가 지표. 손실 개선량 Δ 는 '시장 손실 - 모델 손실'로 정의한다.

$\Delta \text{LogLoss}$ = 시장 Race Log Loss - 모델 Race Log Loss, ΔBrier = 시장 Race Brier - 모델 Race Brier, $\Delta \text{Top-1}$ = 모델 Top-1 - 시장 Top-1입니다. 세 값 모두 양수가 모델 우위를 뜻하도록 방향을 통일했습니다. 이 정의는 21단계 이후 후보 필터에도 그대로 사용됩니다.

4.2.2 1~7 단계 — 비교 가능한 데이터부터 만들다

모델보다 먼저 한 일은 평가의 바닥을 고정하는 것이었습니다. 원본을 변경 불가능한 기준으로 만들고, 경주 일부 행을 임의로 삭제하지 않으며, 결과를 알 수 없는 시점의 피처만 허용했습니다. 이 일곱 단계가 뒤의 모든 수치를 비교 가능하게 만들었습니다.

단계	수행 내용	결과와 근거
1	원본 CSV 고정과 checksum 기록	56,648행·156열·5,361경주를 data/raw/final.csv.gz로 고정하고 압축·해제 SHA-256을 기록
2	서울 데이터 추출	서울 32,888행·3,172경주를 한 행도 버리지 않고 interim으로 분리
3	upset_B 오류 수정	legacy 라벨을 격리하고 longshot·longshot_win을 정식 정의로 재계산
4	경주·시장확률 무결성 검사	정상 3,167경주를 식별하고 공동우승 4·무우승 1경주는 경주 전체 제외; q_market 합 1 검증
5	시간순 split manifest	Train 1,891경주, Calibration 641경주, Test 635경주; 같은 경주·날짜는 절대 분리하지 않음
6	v5~v8 폐기	행 단위 IQR 삭제가 완전한 경주 구조를 깨뜨리므로 신규 모델 입력을 fail-closed로 금지
7	feature registry	112개 PRE_RACE 피처만 허용; MARKET·POST_RACE·TARGET·LEGACY는 입력 차단

표 4.2-2. 1~7단계: 데이터와 누수 통제의 고정 과정.

경주·날짜 단위 시간순 분할

비정상 5경주·50두는 경주 전체 제외

TRAIN	CALIBRATION	FINAL TEST
1,891경주 · 19,617두	641경주 · 6,582두	635경주 · 6,639두
2023.08.05–2025.05.11	2025.05.17–2025.12.27	2025.12.28–2026.08.09

Train은 학습, Calibration은 정책 선택, Final Test는 동결 후 단 한 번의 평가에만 사용

그림 4.2-2. 경주·날짜 단위 시간순 분할과 각 구간의 역할.

왜 경주 전체를 보존했나

경마에는 '한 경주에 우승마가 정확히 하나'라는 구조가 있습니다. 한두 마리의 행만 지우면 확률합·순위·손실함수가 모두 다른 문제가 됩니다.

따라서 이상치가 있는 말을 삭제하는 대신 Train 분위수로 값을 누르고, 공동우승·무우승·불완전 경주는 경주 전체를 제외했습니다.

4.2.3 8~14 단계 — 독립 모델의 실패를 시장 보정으로 바꾸다

8단계부터 실제 확률 모델을 만들었습니다. 전처리기는 Train 또는 각 walk-forward 학습 구간에만 적용했고, 시장 확률은 독립 모델의 피처가 아니라 비교 기준과 후단 결합값으로만 사용했습니다.

단계	수행 내용	핵심 결과
8	Train 전용 전처리	수치형 99개 clipping·중앙값·결측지시자, 범주형 13개 최빈값·저빈도 통합·one-hot
9	M0 시장 baseline	Calibration Race Log Loss 1.776036, Brier 0.762636로 강한 기준선 확인
10	M1 Logistic	Log Loss 1.965904, Brier 0.817458; 시장보다 크게 악화
11	M2 XGBoost	Log Loss 1.976751, Brier 0.821722; Train 1.532825 대비 Calibration 악화로 과적합 신호
12	경주 확률 정규화 선택	Train OOF 770경주에서 sum 방식이 logit softmax보다 M1·M2 모두 우수
13	시장과 기하 혼합	$p \propto q^{(1-\lambda)} \cdot m^\lambda$, M2의 $\lambda=0.05$ 선택: 시장 95%, 모델 5%
14	Temperature Scaling	T=0.95 선택, Calibration Log Loss 1.773358; 순서는 유지하고 분포만 약간 날카롭게 조정

표 4.2-3. 8~14단계: 독립 확률 모델에서 시장 앵커 모델로의 전환.

9~11단계의 결론은 단순했습니다. 배당을 보지 않은 M1과 M2는 시장보다 훨씬 나빴습니다. 그러나 실패를 폐기하지 않고 '시장 확률을 기준으로 작은 잔차만 보정한다'는 문제로 바꿨습니다. 13단계가 선택한 $\lambda=0.05$ 는 모델 의견을 5%만 허용한다는 뜻입니다. 모델이 시장보다 어떤 말을 2배 높게 보더라도 최종 반영 배율은 약 $2^{0.05}=1.035$, 즉 3.5%에 불과합니다.

시장 확률을 대체하지 않고 보정하는 M2 확률 파이프라인




그림 4.2-3. M2 시장확률 보정 파이프라인.

정규화·혼합·온도의 역할은 서로 다릅니다

합 정규화는 같은 경주 안에서 확률합을 1로 만들고, 기하 혼합 λ 는 시장과 모델의 상대 영향력을 조정합니다.

온도 T 는 확률을 뽀족하거나 평평하게 만들지만 경주 내 순서를 바꾸지 않습니다. 따라서 Top-1 개선은 T 가 아니라 독립 모델의 순위 또는 시장 결합 방식에서 나와야 합니다.

4.2.4 15~20 단계 — 한 번의 Test 와 보수적인 판정

14단계 정책을 고른 뒤 모델, 전처리기, split, feature registry, 정규화, λ , T , 평가 코드 19개 파일의 SHA-256을 먼저 기록했습니다. 그 뒤에만 2025-12-28~2026-08-09의 Final Test 635경주를 열었습니다.

단계	수행 내용	핵심 결과
15	Final Test 최초 1회 평가	M2 Log Loss 1.813446, Brier 0.777318로 시장보다 개선; Top-1 238/635로 시장 240/635보다 2경주 적음
16	race_id paired bootstrap	5,000회·seed 42; Log Loss CI는 0 위, Brier와 Top-1 CI는 0 포함
17	경제적 벡테스트	Calibration 최대 기대우위 -8.48%, Test -3.47%; 5·10·15% 임계값 선택 0건 → no_bet
18	예측 출력 schema	시점·배당 snapshot·확률합·완전 출전명단 계약과 경주 전체 rejection 규칙 구현
19	테스트·README	원본 해시, 누수 차단, split, 확률합, 일회 Test 잠금, no_bet을 자동 회귀 테스트로 고정
20	최종 결과보고서	M2는 연구용 확률 보정기로 유지; 두 손실 모두의 안정적 우위와 실전 수익성은 미확정

표 4.2-4. 15~20단계: 동결 평가에서 운영 통제까지.

최초 Final Test 635경주: 확률 손실은 개선, 1순위 적중은 하락




그림 4.2-4. 최초 Final Test에서 시장과 M2의 세 지표 비교.

점 추정에서는 M2가 시장보다 Log Loss를 0.003902, Brier를 0.000602 낮췄습니다. 하지만 Top-1은 37.48%로 시장의 37.80%보다 0.315%p 낮았습니다. 즉 M2는 우승마를 더 자주 고른 모델이 아니라, 전체 확률 분포를 아주 조금 다듬은 모델입니다.




그림 4.2-5. Final Test 경주 단위 paired bootstrap의 점 추정과 95% 신뢰구간.

엄격한 성공 조건을 사후에 낮추지 않았다

Race Log Loss 개선의 95% CI는 [+0.001085, +0.006721]로 0보다 컸습니다. 반면 Brier CI [-0.000483, +0.001687]와 Top-1 CI [-0.009449, +0.003150]는 0을 포함했습니다.

사전에 정한 기준은 두 확률 손실의 신뢰구간 하한이 모두 0보다 큰 것이었습니다. 따라서 결론은 'Log Loss 개선은 지지되지만 안정적 종합 우위는 미확정'입니다.

17단계는 확률 개선과 돈을 버는 능력이 다르다는 사실을 수치로 확인했습니다. 평균 공제율은 Calibration 19.90%, Test 19.89%였고, M2의 조정폭으로는 손익분기점을 넘는 후보가 한 건도 생기지 않았습니다. 그래서 운영 행동은 모델 성능과 별도로 no_bet으로 고정했습니다.

4.2.5 21~27 단계 — 확률을 해치지 않고 Top-1 을 높일 수 있는가


기존 Final Test 결과를 본 뒤 새로운 질문이 생겼습니다. M2의 확률 품질 장점을 유지하면서 시장보다 우승마를 더 자주 1순위로 고를 수 있는가. 이미 열린 Final Test를 다시 튜닝에 쓰면 안 되므로, 21단계에서 데이터 경계와 성공 기준부터 새로 동결했습니다.

단계	수행 내용	핵심 결과
21	Top-1 제약 정책 동결	$\Delta \text{LogLoss} - \Delta \text{Brier} \geq 0$ 후보만 통과, 그중 $\Delta \text{Top-1}$ 최대화; 기존 Test는 설명 전용
22	시장-M2 불일치 분석	Train OOF+Calibration 1,411경주의 50.32%에서 1위 불일치; 시장만 적중 242, M2만 적중 116
23	경주 그룹 랭킹 계약	race_id 연속 그룹, 우승마 relevance 1, 112개 PRE_RACE 피쳐, 시간순 4-fold 무결성 고정
24	R2 pairwise ranker	Calibration Top-1 193/641로 M2보다 +3경주지만 시장보다 -54경주; 단독 대체 근거 없음
25	랭커 확률 변환	$\text{softmax}(\text{score}/T)$, $T_{\text{rank}}=0.65$; 유효 분포지만 시장 대비 Log Loss -0.191283, Brier -0.057196
26	시장 유지/교체 게이트	threshold 0.65, λ_{switch} 0.30; 실제 시장 1위 14경주만 변경해 247→249경주
27	동일 기준 비교·사전 동결	R0-R3-R4가 확률 제약 통과; Top-1 최대 R4를 미래 검증 도전자로 동결

표 4.2-5. 21~27단계: 확률 비열화 제약 아래 Top-1 확장.

22단계에서 중요한 사실이 드러났습니다. 시장과 M2가 다른 말을 1위로 고른 710경주에서 시장만 맞은 경우가 M2만 맞은 경우보다 126경주 많았습니다. 독립 모델을 무조건 믿는 전략은 구조적으로 손해였습니다. 따라서 기본 행동은 시장 유지, 충분한 증거가 있을 때만 랭커를 신뢰하는 게이트가 필요했습니다.

R4의 원칙: 시장을 기본값으로 두고, 근거가 강한 경주만 제한적으로 뒤집는다



Calibration 641경주 중 gate action 33경주 → 실제 Top-1 교체 14경주 → 유리 5 · 해로움 3 · 둘 다 실패 6 → 순 +2경주

그림 4.2-6. R4 시장 유지/교체 게이트의 의사결정 흐름.

R2는 '실제 우승마 점수 > 나머지 말 점수'를 직접 학습하는 XGBoost pairwise ranker입니다. Calibration에서 기존 M2보다 Top-1을 3경주 늘렸지만 시장에는 54경주 뒤졌습니다. 확률로 바꾼 뒤에도 손실이 크게 나빠 단독 후보에서는 탈락했습니다. R2의 역할은 시장을 대체하는 것이 아니라, 시장을 뒤집을 만한 경주를 찾는 보조 신호였습니다.

26단계의 게이트는 Train OOF 불일치 경주 383개로 학습했습니다. Calibration 불일치 329경주에서 ROC-AUC 0.5986, Average Precision 0.2228로 분류력 자체는 강하지 않았습니다. 그래서 threshold 0.65 이상인 33경주만 R2 영향을 허용했고, 실제 Top-1이 달라진 경주는 14개뿐이었습니다. 그중 R4만 맞은 변경 5개, 시장만 맞은 변경 3개, 둘 다 실패 6개로 순효과는 +2경주였습니다.




그림 4.2-7. 27단계 Calibration 후보들의 Top-1 정확도와 확률 제약 통과 여부.

후보	Log Loss ↓	Brier ↓	Top-1	시장 대비	제약
R0 시장	1.776036	0.762636	247/641	기준	통과
R1 기준 M2	1.976751	0.821722	190/641	-57경주	탈락
R2 랭커	1.967320	0.819832	193/641	-54경주	탈락
R3 고정 혼합	1.773358	0.762075	245/641	-2경주	통과
R4 적응 게이트	1.774241	0.762298	249/641	+2경주	통과·선택

표 4.2-6. 27단계 동일 Calibration 641경주 비교. 고유 Top-1 동물 규칙을 적용했다.

왜 Log Loss가 가장 좋은 R3가 아니라 R4인가

후보 선택 순서는 먼저 $\Delta\text{LogLoss}$ 와 ΔBrier 가 음수인 후보를 제거하고, 통과 후보 중 Top-1을 최대화하는 것입니다.

R3는 손실이 가장 낮지만 시장보다 2경주 적게 맞혔습니다. R4는 손실이 시장보다 낮으면서 Top-1을 2경주 늘렸기 때문에 사전 규칙에 따라 선택됐습니다.

정확도만 최대화한 후보는 252/641로 +5경주였지만 Log Loss와 Brier가 모두 악화되어 탈락했습니다. 이 제약이 확률 품질을 지키는 안전장치입니다.

4.2.6 27 단계가 남긴 최종 상태

항목	동결 값
challenger_id	r4_gate_ranker_t065_gate065_l030_v1
랭커 확률 온도	T_rank = 0.65
게이트 임계값	threshold = 0.65
교체 경주의 랭커 영향	lambda_switch = 0.30
기본 행동	keep_market, lambda_race = 0
Top-1 동물 처리	p_final 내림차순 → q_market 내림차순 → entry_id 오름차순
상태	frozen_pending_future_holdout
운영 행동	기존 챔피언 유지 · no_bet

표 4.2-7. 27단계에서 고정된 R4 연구 도전자 계약.

R4는 Calibration에서 요구한 세 점추정 조건을 동시에 만족한 첫 후보입니다. 그러나 이 수치는 후보 선택에 사용된 같은 Calibration에서 나온 값입니다. 기존 Final Test는 21~27단계의 피쳐·threshold·lambda·후보 선택에 사용하지 않았고 R4에도 다시 적용하지 않았습니다. 따라서 현재 문서가 말할 수 있는 최대치는 '시장 우위 가능성을 가진 동결 도전자를 만들었다'입니다.

독립적인 최종 증명과 회고적 증거를 구분한다

공식 성공에는 2026-08-09 이후 첫 500개 적격 서울 경주에서 $\Delta\text{Top-1} > 0$, paired bootstrap 하한 > 0 , exact McNemar $p < 0.05$, $\Delta\text{LogLoss} - \Delta\text{Brier} \geq 0$ 이 모두 필요합니다.

새 데이터 수집이 어렵다면 기존 기간을 nested walk-forward로 재구성해 강한 회고적 근거를 만들 수 있습니다. 다만 이미 전체 기간 결과를 본 이상 이를 독립적인 미래 Test라고 부를 수는 없습니다.

4.2.7 무엇을 배웠나

첫째, 시장은 제거해야 할 잡음이 아니라 가장 강한 사전확률입니다. 독립 모델 M1·M2·R2는 모두 시장 단독보다 크게 나빴습니다. 둘째, 작은 확률 개선과 높은 Top-1, 경제적 수익은 서로 다른 목표입니다. M2는 손실을 낮췄지만 Top-1과 수익성은 개선하지 못했습니다. 셋째, 시장을 이기는 가장 현실적인 구조는 전 경주를 대체하는 모델이 아니라 **‘시장 유지’를 기본값으로 둔 선택적 교정기**였습니다. R4가 641경주 중 실제 순위를 14번만 바꾼 이유입니다.

27단계의 성과는 시장을 이겼다고 선언한 것이 아닙니다. 데이터 경계를 지키면서 실패한 독립 모델을 시장 보정 모델로 바꾸고, 다시 확률 비열화 제약을 가진 Top-1 게이트로 발전시킨 재현 가능한 연구 절차를 완성한 것입니다. 숫자보다 중요한 결과는 ‘무엇을 최적화하고, 어느 데이터에서 선택하며, 어디까지를 결론으로 허용할 것인가’를 명시적으로 분리한 데 있습니다.

재현 근거: `data/manifests/*, reports/experiments/stages_8_11_summary.md, stage_12_summary.md~stage_27_summary.md, PROJECT_GUIDELINES.md 27-29절`.

4.3 각도 ③ — 수익성

확률이 조금 더 정확하다는 것과 그것으로 돈을 벌 수 있다는 것은 다른 이야기입니다. 세 번째 각도는 그 간극을 직접 찼습니다.

4.3.1 넘어야 할 선

1장에서 본 조건을 다시 씁니다.

$$\text{기대수익 } EV = p \times O - 1 > 0 \Leftrightarrow p/q > S \approx 1.25$$

특정 말에 대해 시장보다 25% 높게 봐야 하고, 그 판단이 실제로 맞아야 한다

그런데 4.2절에서 확인한 **우리 모델이 시장 확률을 조정한 평균 폭은 0.00291**입니다. 시장이 10%로 본 말을 12.5%로 올려야 하는데, 실제로는 10.3%로 올리는 수준입니다.

4.3.2 기대우위 검증

기대우위를 $\text{expected_edge} = p_{\text{final}} \times \text{종가배당} - 1$ 로 정의하고, calibration 구간에서 상위 5% · 10% · 15% 임계값을 탐색했습니다. 베팅을 활성화하는 조건은 사전에 세 가지로 정해졌습니다.

- 최소 100 건 이상의 베팅 기회가 있을 것
- 수익률이 0 보다 클 것

- 경주 단위 부트스트랩 95% 하한이 0 보다 클 것

구간	가장 큰 기대우위	활성화 조건 충족
Calibration	-8.48%	0건
Final Test	-3.47%	0건

표 4-10. 종가 배당 기반 경제성 진단.

가장 유리한 조건에서조차 기대우위가 음수였습니다. 시장 확률보다 소폭 좋은 확률 추정이 약 20%의 공제율을 넘어 양의 기대수익으로 이어지지 않았다는 뜻입니다.

공식 행동 정책은 `no_bet` 으로 확정되었습니다.

4.3.3 왜 no_bet 도 유효한 결과인가

모델의 가장 중요한 운영 기능 중 하나는 **행동하지 않아야 할 때를 구분하는 것** 입니다.

현재 데이터에서 무리하게 임계값을 낮춰 베팅 건수를 만드는 것은, calibration으로 정책을 선택한다는 원칙과 양의 하한 조건을 동시에 위반합니다. **0건 선택은 실패한 코드가 아니라 사전에 정한 위험 통제가 정상 작동한 결과입니다.**

덧붙여, 이 검증은 **사후에 확정된 종가 배당** 을 사용했습니다. 실제 의사결정 시점의 스냅샷이 아니므로 실행 가능한 전략 검증이 아닙니다. 배당 변동·전송 지연·베팅 거절·폴 충격·최소 베팅금은 모델링하지 않았습니다. **실제 성과는 이보다 나쁩니다.**

4.3.4 그런데 한 곳에서 신호가 나왔습니다

전 구간에서 수익이 나지 않는다는 것을 확인한 뒤, 질문을 좁혔습니다 — **“전부 이길 필요 없다. 시장이 약한 구간만 찾으면 되지 않나?”**

목표를 “1착 맞히기”에서 **“시장이 과소평가한 말 골라내기”** 로 바꿨습니다. 비인기마(인기 하위 50%)의 1착을 이번으로 정의하고 예측했더니 이런 결과가 나왔습니다.

	값	해석
ROC-AUC	0.6422	판별력 자체는 1차 모델보다 낮음
전체 이변 비율	13.2%	기저율
상위 10% 그룹의 이변 비율	23.8%	1.81배

표 4-11. 방향 3 — 이번 예측 초기 실험.

판별력이 낮는데 왜 의미가 있나

ROC-AUC 0.6422는 1차 모델의 0.7495보다 **낮습니다**. 그런데도 이 결과가 중요한 이유는, 우리가 재는 것이 “전부 맞히기”가 아니라 **“위쪽 10%를 얼마나 잘 골라내는가”**로 바뀌었기 때문입니다.

전체 평균 13.2%인 이번이 모델이 지목한 상위 10%에서는 23.8%로 나타났습니다. **모델의 가치가 예측이 아니라 필터에 있다**는 첫 신호입니다.

이 발견이 파트 2의 출발점입니다.

5. 결과 — 셋 다 벽에 부딪혔다

5.1 세 각도 요약

각도	가장 좋았던 결과	시장 대비	판정
① 변별력	LightGBM ROC-AUC 0.7552	시장 0.8126	미달
② 확률 품질	Log Loss 개선 CI 하한 > 0	Brier는 0 포함	부분 달성
③ 수익성	가장 큰 기대우위 -3.47%	공제율 20%	__미달 · no_bet__

표 5-1. 세 각도의 최종 판정.

요약하면 **정확도로도 못 이겼고, 확률 품질은 절반만 이겼고, 돈은 되지 않았습니다.** 다만 세 번째 줄을 “실패”로만 읽으면 안 됩니다. 4.3.3절에서 봤듯 **no_bet**은 사전에 정한 위험 통제가 정상 작동한 결과입니다.

그런데 완전한 0은 아니었습니다

시장 단독 ROC-AUC 0.8126, 시장 + 모델 결합 0.8135.

모델이 시장에 없는 정보를 아예 갖고 있지 않은 것은 아닙니다. 다만 그 양이 0.001 수준입니다.

확률 품질에서도 마찬가지입니다. Log Loss 개선의 신뢰구간 하한이 0을 넘었다는 것은 **우연이 아닌 개선이 실제로 있었다**는 뜻입니다. 문제는 그 크기가 공제율 20%를 넘기에 턱없이 작다는 것입니다.

5.2 왜 나란히 비교할 수 없나

발표에서 가장 자주 받을 질문이 “그래서 셋 중 뭐가 제일 좋았나요?”일 것입니다. 답은 **“비교할 수 없습니다”** 이고, 이유는 세 가지입니다.

- 1. 지표가 다릅니다.** ROC-AUC 0.7552 와 Log Loss 1.813446 과 기대우위 -3.47%는 단위도 방향도 다른 숫자입니다. 한 표에 놓고 순위를 매길 수 없습니다.
- 2. 전처리가 다릅니다.** 3.6 절에서 본 대로 이상치 처리·범주형 인코딩·분할 단위·배당률 취급이 모두 다릅니다. 애초에 다른 데이터로 학습한 다른 모델입니다.

3. 묻는 질문이 다릅니다. “잘 골라내는가”와 “확률이 정확한가”와 “돈이 되는가”는 서로를 함의하지 않습니다. 6 장에서 보듯 **잘 골라내지 못하는 모델이 돈을 벌 수도 있습니다.**

이것이 이 프로젝트의 방법론적 성과입니다. 처음에는 “모델이 시장보다 정확한가”라는 하나의 질문이라고 생각했는데, 실제로는 **세 개의 독립적인 질문**이었습니다.

5.3 부수적으로 확인된 것 — 한국 경마의 시장 효율성

모델을 만드는 과정에서 시장 자체에 대해서도 알게 된 것이 있습니다. 경마 문헌에서 가장 오래 연구된 현상인 **Favorite-Longshot Bias(FLB)** 를 우리 데이터에서 확인했습니다.

FLB는 “사람들이 인기마를 과소평가하고 비인기마를 과대평가하는 경향”을 말합니다. 복권을 사는 심리와 비슷하게, 낮은 확률에 큰 보상이 걸리면 사람들이 실제 확률보다 더 많이 겁니다. 해외 경마에서는 이 편향이 뚜렷하게 관찰됩니다.

배당 구간	편향 (실제 승률 - 시장 확률)	해석
1배대 (인기마)	-0.012	약간 과대평가
10배 이상 (비인기마)	-0.004	약간 과대평가
3~10배 구간	양의 방향	오히려 시장이 과소평가

표 5-2. 배당 구간별 편향.

한국 서울 경마에서는 전형적인 FLB가 거의 나타나지 않습니다. 인기마와 비인기마의 편향이 모두 -0.01 수준으로 작고 방향도 같습니다. 즉 시장이 상당히 효율적이라는 뜻이고, 우리가 못 이긴 이유의 일부이기도 합니다.

게다가 시장은 **해가 갈수록 더 정확해지고 있습니다.** 배당률만으로 계산한 ROC-AUC가 2023년 0.8031에서 2025년 0.8193으로 올랐습니다. 우리 test 구간이 가장 효율적인 시기라는 뜻입니다.

6. 문헌조사 — 남들은 어땠나

세 각도가 모두 막힌 뒤, 팀은 선행 연구를 뒤졌습니다. 목적은 두 가지였습니다 — “**이게 원래 안 되는 일인가**”와 “**우리가 뭘 잘못 재고 있나**”.

두 번째 질문의 답이 이 프로젝트의 방향을 바꿨습니다.

6.1 ‘경마 예측 모델’은 하나가 아닙니다

문헌을 훑으면서 알게 된 첫 번째 사실입니다. “경마 예측 모델”이라는 말은 하나의 대상을 가리키지 않습니다. **서로 다른 다섯 개의 계층**이 있고, 각 계층은 푸는 문제도 평가 기준도 다릅니다.

계층	무엇을 하는가	우리 위치
① 레이팅 · 속도 지수	과거 경주의 질을 하나의 수치로 압축	일부 피쳐로 존재
② 경주 단위 확률 모형	한 경주 안에서 확률 합이 1이 되게 추정	여기
③ 랭킹 학습(LTR)	경주를 질의로 보고 출전마의 상대 순서를 학습	3차에서 도입
④ 시장 결합	모델 확률과 시장 확률을 결합	여기 (초기)
⑤ 실행 시스템	베팅 금액 · 주문 시각 · 시장 충격 관리	비어 있음

표 6-1. 경마 예측 문헌의 다섯 계층.

우리는 **계층 ②와 ④의 초기 단계**에 있습니다. 방법론의 방향은 문헌과 같지만, 결합 방식이 단순하고, 평가 지표가 다르며, **실행 계층이 통째로 비어 있습니다**.

6.2 경주 단위여야 하는 이유

계층 ②의 원전은 Bolton & Chapman이 1986년 Management Science에 실은 논문입니다. 200경주를 대상으로 말·기수 특성을 다항 로짓으로 모형화한 최초의 본격 연구입니다.

$$p_i = \exp(u_i) / \sum \exp(u_j)$$

각 말에 점수 u 를 매기고 경주 전체로 나눠 합이 1이 되게 한다

왜 말마다 따로 이진분류하면 안 되나

경마에는 “**한 경주에 우승마가 정확히 하나**”라는 강한 제약이 있습니다.

말마다 따로 “이 말이 이길까?”를 이진분류로 예측하면 **이 제약이 손실 함수에 들어가지 않습니다**. 학습이 끝난 뒤 나눠서 합을 1로 맞추는 것은 사후 처리일 뿐, 모델은 학습 중에 경쟁 구조를 보지 못합니다.

우리 1차·2차 모델이 정확히 이 방식이었습니다. 4.2절의 확률 품질 실험에서 경주 단위 평가로 넘어간 것이 이 지적에 대한 답입니다.

흥미로운 것은 1990년대 통계학과 2010년대 기계학습이 서로 다른 이름으로 같은 곳에 도착했다는 점입니다. Benter가 2003년에 쓴 다항 프로빗의 최대우도 추정 절차는, 오늘날 **listwise Learning-to-Rank** 라고 부르는 것과 사실상 같습니다. 우리가 3차에서 도입한 방식이 바로 그것입니다.

6.3 Benter — 유일하게 검증된 수익 사례

문헌 전체에서 **실제 운용으로 수익을 검증한 사례는 사실상 하나**입니다. William Benter가 1994년에 공개한 홍콩 경마 시스템입니다.

항목	내용
운용 기간	5년
성과	다섯 시즌 중 네 시즌 흑자
손실 시즌	초기 자본의 약 20% 손실
핵심 방법	편더멘털 모델 확률과 시장 확률의 로그 공간 결합

표 6-2. Benter 시스템 요약.

그가 쓴 결합식은 우리 것과 구조가 같습니다.

$$c_i \propto \exp(\alpha \cdot \log f_i + \beta \cdot \log q_i) = f_i^\alpha \times q_i^\beta$$

f = 모델 확률, q = 시장 확률, 경주 안에서 다시 정규화

확률이 아니라 **로그 확률** 을 쓰는 이유는 Benter의 표현대로 “그 변환이 더 잘 맞기” 때문입니다. 곱셈 구조가 되면서 각 정보원의 기여를 지수 하나로 조절할 수 있게 됩니다.

6.3.1 두 독립 계산이 같은 값에 도달했습니다

우리 프로젝트는 서로 다른 데이터 분할, 다른 모델, 다른 결합 방식으로 두 번 계산했는데 결과가 사실상 같았습니다.

	시장 지수 β	모델 지수 α
문헌 기준 (Benter)	≈ 1.0	상황에 따라
우리 계산 ①	≈ 1.0	0.05
우리 계산 ②	≈ 1.0	0.05 ~ 0.14

표 6-3. 결합 계수. $\lambda=0.05$, $T=0.95$ 를 지수로 변환하면 $\beta=(1-\lambda)/T$, $\alpha=\lambda/T$.

이 숫자가 이미 답을 말하고 있습니다

$p_{\text{final}} \propto q^{1.0} \times f^{0.05}$ — 시장 확률을 그대로 쓰고 모델은 0.05제곱만큼만 곱한다는 뜻입니다.

모델이 시장보다 **2배** 높게 본 말이 있다고 합시다. 최종 확률에 반영되는 배율은 $2^{0.05} = 1.035$, 즉 **3.5%** 입니다.

공제율 장벽 25%를 넘으려면 모델이 시장보다 얼마나 높게 봐야 하는지 역산해보면, **비현실적인 수준** 이 나옵니다. 이것이 4.3절에서 **no_bet**이 나온 구조적 이유입니다.

6.4 결정적 발견 — 단독 정확도는 시장보다 낮았습니다

이 절이 이 보고서 전체에서 가장 중요합니다. **우리 프로젝트의 판정 기준을 바꾸기 때문입니다.**

Benter는 두 모델을 비교했습니다. 하나는 9개 변수를 쓴 펀더멘털 모델, 다른 하나는 신문 예사가 48명의 픽을 점수화해 집계한 것입니다. **단독 성능은 비슷했는데, 시장에 었었을 때 늘어나는 가치는 정 반대였습니다.**

중요한 것은 모델 **단독** 성능이 아니라, **시장에 었었을 때 늘어나는 양** 입니다. Benter는 이것을 ΔR^2 로 잰습니다.

그리고 결정적으로 — **그의 수익 모델조차 단독 정확도는 시장보다 낮았습니다.** 5년간 실제로 돈을 번 시스템이 그랬습니다.

그래서 우리 판정이 틀렸습니다

우리는 “모델 AUC 0.7552 < 시장 0.8126 이므로 실패”라고 판단했습니다. **문헌 기준으로 이 판정은 성립하지 않습니다.**

물어야 했던 것은 “모델이 시장보다 정확한가”가 아니라 **“모델이 시장에 없는 정보를 갖고 있는가”**였습니다.

5.1절에서 본 “시장 0.8126 → 결합 0.8135”가 바로 그 답입니다. 양이 작을 뿐, **0은 아닙니다.**

Benter는 평가 지표도 다르게 씁니다. ROC-AUC가 아니라 **pseudo-R²** 를 쓰는데, “아무것도 모르고 찍었을 때” 대비 얼마나 나아졌는지를 0~1로 표현합니다.

$$R^2 = 1 - L(\text{모델}) / L(\text{균등 추측})$$

우리 데이터: $R^2(\text{시장}) = 1 - 1.817348 / 2.342001 = 0.2240$

6.5 국내 연구와 우리의 위치

국내 선행 연구 세 편을 확인했습니다. **공통점이 하나 있습니다 — 전부 시장 배당률을 기준으로 쓰지 않습니다.** 순위 예측 자체가 목표라서 “시장을 이기는가”를 묻지 않습니다.

이 점에서 우리 프로젝트는 **국내 선행 연구보다 한 걸음 앞서 있습니다.** 우리는 처음부터 시장을 기준으로 놓고 비교했고, 그래서 “못 이겼다”는 결론을 얻을 수 있었습니다. 기준선을 놓지 않으면 애초에 이 질문 자체가 나오지 않습니다.

독립적으로 같은 신호를 찾았습니다

2024년 국내 논문이 SHAP으로 뽑은 상위 변수에 **출발훈련 횟수**와 **질병 진단횟수**가 들어 있습니다.

우리 데이터의 **train_runs_14**와 **clinic_30d**에 정확히 대응하고, 우리 3차 모델의 합의형 피쳐 중요도에서도 각각 **5위**와 **15위**입니다.

서로 모르는 두 팀이 독립적으로 같은 신호를 찾아냈다는 뜻이고, **우리 피쳐 설계가 틀리지 않았다는 방증**입니다.

7. 왜 이기지 못하는가 — 여덟 개의 벽

문헌과 우리 실측을 대조해 원인을 여덟 가지로 정리했습니다. **앞의 넷은 구조적이라 바꾸기 어렵고, 뒤의 넷은 설계로 고칠 수 있습니다.**

7.1 구조적 원인 — 우리가 어찌할 수 없는 것

① 정보 비대칭 — 부분집합이 합집합을 이길 수 없습니다

시장 확률은 베팅에 참여한 수만 명이 가진 정보를 **전부 합친** 결과입니다. 우리 모델이 쓰는 정보는 그 안에 **포함됩니다**. 마방 분위기, 당일 컨디션, 내부 정보처럼 데이터에 없는 신호가 시장에는 들어가 있습니다.

Benter도 같은 말을 합니다 — 통계 모형에 실용적으로 포함할 수 없는 유효한 정보가 존재하며, 따라서 어떤 모형도 언제나 불완전하다는 것입니다.

	ROC-AUC
시장 단독	0.8126
모델 단독	0.7166
시장 + 모델 결합	0.8135

표 7-0. 서울 경주 test 637경주 실측. 모델을 얹어 얻는 것은 0.0009.

② 공제율 장벽이 우리 신호보다 훨씬 큼니다

	값
넘어야 할 선 (p / q)	1.25
우리 모델의 평균 조정 폭	0.00291
예시	시장 10% → 12.5%로 올려야 하는데 실제로는 10.3%

표 7-1. 공제율 장벽과 우리 신호의 크기 비교.

넘어야 할 높이와 우리가 뛴 높이의 차이가 두 자릿수 배수입니다.

③ 시장 규모가 작아 실행이 어렵습니다

파리뮤추얼에서는 **내가 건 돈이 그 말의 배당을 낮춥니다**. 우위를 찾더라도 그것을 현금화하는 과정

에서 스스로 우위를 지워버리는 구조입니다.

항목	경주당 평균
단승 발매금액	약 3,708만 원
전체 발매금액	약 30억 원

표 7-2. 서울 경주 test 637경주 실측. 단승 풀이 전체의 1.2% 수준이다.

따라서 무한한 자금이 있어도 기대 이익을 최대로 만드는 베팅액에 **상한이 존재합니다**. Benter는 이것을 베팅 비율 문제와 별개의 핵심 과제로 다뤘습니다.

④ 시장은 시간이 갈수록 효율적으로 변합니다

5.3절에서 본 대로 배당률 단독 ROC-AUC가 2023년 0.8031에서 2025년 0.8193으로 올랐습니다.

Benter는 1994년 보고서 결론에서 스스로 경고했습니다 — 지금이 이런 시스템의 황금기이고, 컴퓨터 핸디캐퍼가 늘어나면 시장이 그런 예측에 대해 효율적으로 바뀔 것이라고. 그리고 수익은 **먼저 움직인 사람**에게 돌아갔고 앞으로도 그럴 것이라고.

7.2 설계 원인 — 고칠 수 있는 것

⑤ 평가 지표와 학습 손실이 어긋나 있습니다

여덟 개 중 가장 큰 항목입니다. 우리 모델은 세 곳에서 목적이 불일치합니다 — 학습은 이진 분류로 하고, 평가는 경주 단위로 하고, 판정은 정확도로 했습니다.

“모델 AUC < 시장 AUC 이므로 실패”라는 판정이 문헌 기준으로 성립하지 않는다는 것을 6.4절에서 봤습니다. **더 복잡한 알고리즘이 아니라 문제 정의를 바꾸는 일**입니다.

⑥ 종가를 보고 판단하지만 종가를 예측하지는 않습니다

이 문제는 두 방향으로 동시에 작동합니다.

- **낙관 편향** — 종가를 입력으로 쓴 검증은 실제로는 알 수 없었던 정보를 쓴 것입니다. 성과가 부풀려집니다.
- **실행 실패** — 출발 5 분 전에 유리해 보이던 말이, 막판 자금이 몰리면 종가에서는 불리해집니다. 베팅은 이미 끝난 뒤입니다.

실전 우위를 얻으려면 **두 개의 오차를 동시에 견뎌야 합니다**.

⑦ 모델이 확률 분포를 날카롭게 만들어 기회를 지웁니다

모델을 섞으면 확률 분포가 뽕족해집니다. 인기마를 더 인기마로 만드는 방향입니다.

	시장 단독	결합 후	방향
평균 엔트로피	1.8193	1.7931	낮아짐 = 뽕족해짐
최고확률 평균	0.3697	0.3788	높아짐

표 7-3. 결합 전후의 확률 분포 변화.

문제는 **시장이 이미 과신하고 있는 구간에서도 이 일이 일어난다**는 점입니다. 모델이 시장의 편향을 교정하는 것이 아니라 증폭하는 셈입니다.

⑧ 결측 처리가 문헌과 다릅니다

3.1절에서 언급한 대로, 첫 출전마처럼 과거 기록이 없는 말의 결측을 우리는 0으로 채웠습니다. Benter는 이런 말을 **unratable**로 표시하고 **시장 확률을 그대로 부여**한 뒤 나머지를 재정규화합니다. “시장의 판단에 이의를 제기할 정보가 없으니 그대로 받아들인다”는 원칙입니다.

7.3 여덟 개의 크기 비교

구분	원인	고칠 수 있나
구조적	① 정보 비대칭	불가
구조적	② 공제율 장벽	불가
구조적	③ 시장 규모	불가
구조적	④ 효율성 상승	불가
설계	⑤ 평가 지표와 학습 손실 불일치	가능 · 최우선
설계	⑥ 종가 예측 부재	가능 · 차순위
설계	⑦ 분포 날카로움	가능
설계	⑧ 결측 처리	가능

표 7-4. 여덟 개의 벽. ⑤와 ⑥이 값이 가장 크다.

⑤와 ⑥ 둘 다 더 복잡한 알고리즘이 아니라 문제 정의를 바꾸는 일입니다. 이것이 파트 2로 넘어가는 직접적인 근거입니다.

8. 인사이트 — 질문을 바꾼다

8.1 재현 실험이 알려준 것

결론을 정리하기 전에 짚어야 할 것이 있습니다. 이 프로젝트의 코드를 **같은 데이터로 다시 돌려봤습니다**. 결과는 다음과 같았습니다.

검사 항목	결과
입력 데이터	원본과 sha256 완전 일치
같은 환경 2회 실행	완전 동일 — 코드는 결정적
리눅스 ↔ 윈도우	완전 동일 — 이식성 있음
scikit-learn 버전을 바꾸면	결과가 달라짐

표 8-1. 2026-08-23 재현성 검증.

환경	같은 실험의 ROC-AUC
보고서에 실린 값	0.741983
scikit-learn 1.7.2 · 1.8.0	0.743686
scikit-learn 1.9.0	0.744294

표 8-2. 라이브러리 버전에 따른 차이. 데이터·코드·random_state는 모두 동일.

AUC는 0.3% 안에서 움직이는데 수익률은 훨씬 크게 흔들렸습니다

판별 성능 자체는 거의 같은데 수익 지표만 크게 뒤집혔습니다. 이것이 뜻하는 바는 하나입니다 — **결론이 고배당 적중 한두 건에 좌우된다**.

그래서 이 보고서는 수익률 수치를 신지 않습니다. 4.3절에서 본 “신뢰구간이 0을 포함한다”는 이야기를, 이번에는 **재현 실험이 직접 보여준 셈**입니다.

RandomForest는 부트스트랩으로 트리를 만들기 때문에, 시드를 고정해도 라이브러리 내부 구현이 바뀌면 뽑히는 표본이 달라집니다. 저장소의 requirements.txt가 버전을 ==로 못박고 있는 이유입니다.

8.2 세 가지 깨달음

깨달음 ① — 우리는 잘못된 질문을 재고 있었습니다

“모델이 시장보다 정확한가”는 **틀린 질문**이었습니다. 옳은 질문은 “**모델이 시장에 없는 정보를 갖고 있는가**”입니다.

시장 0.8126에서 결합 0.8135로, 아주 조금이지만 **0은 아닙니다**. 5년간 실제로 수익을 낸 Benter의 모델조차 단독 정확도는 시장보다 낮았습니다.

깨달음 ② — 전체를 이기려 하면 공제율에 막힙니다

1장에서 본 조건이 이 프로젝트 전체를 지배합니다. $p/q > 1.25$. 특정 말에 대해 **시장보다 25% 높게** 봐야 하는데, 우리 모델의 평균 조정 폭은 0.00291이었습니다.

그런데 이 조건은 **경주 전체에 대해 성립할 필요가 없습니다**. 특정 구간, 특정 유형의 말에 대해서만 성립해도 됩니다. 이 관찰이 다음 깨달음으로 이어집니다.

깨달음 ③ — 모델의 가치는 예측이 아니라 필터에 있습니다

4.3.4절에서 이미 신호가 나왔습니다. 목표를 “1착 맞추기”에서 “**시장이 과소평가한 말 골라내기**”로 바꿨더니, 판별력 자체는 오히려 떨어졌는데(ROC-AUC 0.6422) 상위 10% 그룹의 적중률은 전체 평균의 **1.81배**가 나왔습니다.

전체 순서를 잘 맞추는 것과, 위쪽 10%를 잘 골라내는 것은 **다른 능력**입니다. 그리고 베팅에 필요한 것은 후자입니다.

이것이 평가 지표를 바꿔야 하는 이유이기도 합니다. ROC-AUC는 전체 순서를 다 보는 지표라서 하위권을 잘 정렬한 것도 점수에 들어갑니다. **우리가 실제로 쓰는 건 상위 5~20%뿐입니다**.

8.3 그래서 파트 2로

파트 1에서 얻은 것을 정리하면 파트 2의 설계가 그대로 나옵니다.

파트 1에서 배운 것	파트 2에서 바꿀 것
전체를 이기려 하면 공제율에 막힌다	시장이 약한 구간만 노린다
ROC-AUC는 하위권까지 본다	Lift@k% 를 주 지표로 쓴다
1착 예측은 시장이 이미 잘한다	이번 을 타깃으로 삼는다
결론이 소수 사례에 좌우된다	신뢰구간 을 항상 함께 본다

표 8-3. 파트 1 → 파트 2.

파트 2의 질문

“이 말이 이긴다”가 아니라 “이 구간의 이 말들을 주목하라”

시장 전체와 정면으로 겨루는 대신, 시장이 구조적으로 약한 지점을 찾아 그곳만 봅니다. 이변을 정의하고, 이변에 영향을 주는 피처를 찾고, 이변 탐지 모델을 만드는 과정이 파트 2입니다.

그리고 파트 1이 남긴 경고를 그대로 안고 갑니다 — **표본이 얇으면 수익성은 단정할 수 없습니다.**

부록 A. 용어

용어	뜻
파리뮤추얼	참가자들의 판돈을 모아 주최측 몫을 댄 뒤 맞힌 사람끼리 나누는 방식
오버라운드	한 경주의 $\Sigma(1/\text{배당률})$. 1을 넘는 초과분이 주최측 몫
시장 확률 q	$1/\text{배당률}$ 을 경주 합이 1이 되게 정규화한 값
공제율	주최측이 떼는 비율. 우리 데이터에서 약 20%
ROC-AUC	양성 하나와 음성 하나를 뽑았을 때 양성에 더 높은 점수를 줄 확률
PR-AUC	정밀도-재현율 곡선 아래 넓이. 양성이 드물 때 ROC-AUC보다 민감
Race Log Loss	실제 우승마에 준 확률의 음의 로그. 자신 있게 틀리면 크게 벌점
Race Brier	모든 출전마의 예측확률과 결과 간 제곱오차. 분포 전체를 봄
Lift@k%	상위 k% 안의 적중률 ÷ 전체 적중률
pop_pct	인기 백분위. 작을수록 인기마
fin_pct	착순 백분위. 클수록 뒤쪽
온도 보정	확률 분포의 뽀족한 정도를 조정하는 후처리. T가 작으면 뽀족해짐
부트스트랩	표본을 복원추출로 다시 뽑아 반복해 신뢰구간을 얻는 방법

부록 B. 재현 방법

이 보고서의 모든 수치는 저장소의 코드로 재현할 수 있습니다.

절	코드
3장 전처리	src/1_전처리/01~07
4.1 변별력 (1차)	src/2_승률모델/01~05
4.1 변별력 (2차)	src/3_시장대조/비시장모델/01~06
4.1 변별력 (3차)	결과만 보관 — 코드 미제출
4.2 확률 품질	src/3_시장대조/시장확률보정/
4.3 수익성	src/4_이변모델/01~10

표 B-1. 절별 재현 코드 위치.

재현 시 반드시 지킬 것

- ① 라이브러리 버전을 맞추세요. `requirements.txt`의 `==`를 풀지 마세요. 8.1절에서 본 대로 scikit-learn 버전이 다른 RandomForest 결과가 달라집니다.
- ② `pandas`는 3.x를 쓰지 마세요. 일부 스크립트가 실패합니다. 2.3.3에서 검증했습니다.`
- ③ `test`는 한 번만 여세요. 결과를 보고 설정을 바꾸면 그 숫자는 더 이상 미래 성능의 추정치가 아닙니다.