

KHUDA 10 기 토이프로젝트 3 조

파트 2

이번 모델

시장이 약한 구간만 찾는다

“이 말들을 주목하라”

이번의 정의 · 영향 피쳐 · 탐지 모델 · 사전 등록 검증

한국마사회 서울 경주 2023.08 – 2026.08

2026 년 8 월

0. 이 보고서를 읽는 법

0.1 한 문단 요약

파트 1 에서 시장을 정면으로 이기는 데 실패한 뒤 질문을 바꿨습니다 — “**전부 이길 필요 없다. 시장이 약한 구간만 찾자.**” 그 결과 **선별력은 확인됐습니다**. 세 사람이 독립적으로 상위 10%에서 1.7~1.8 배의 Lift 를 얻었습니다. **그러나 수익성은 확인되지 않았습니**다. 사전 등록 검증에서는 시장 통제군에 네 정책 모두 졌습니다.

0.2 파트 1 과의 관계

파트 1 의 결론이 이 보고서의 출발점입니다. 세 각도로 도전했는데 셋 다 막혔고, 그 실패에서 하나의 관찰이 남았습니다.

파트 1 에서 배운 것	파트 2 에서 바꾼 것
전체를 이기려 하면 공제율(20%)에 막힌다	시장이 약한 구간만 노린다
ROC-AUC 는 하위권까지 본다	Lift@k% 를 주 지표로 쓴다
1 착 예측은 시장이 이미 잘한다	이번 을 타깃으로 삼는다
결론이 소수 사례에 좌우된다	신뢰구간 을 항상 함께 본다

표 0-1. 파트 1 → 파트 2.

파트 1 4.3.4 절에서 이미 첫 신호가 나왔습니다. 목표를 “1 착 맞히기”에서 “**시장이 과소평가한 말 골라내기**”로 바꿨더니 판별력 자체는 떨어졌는데(ROC-AUC 0.6422) 상위 10% 그룹의 적중률이 전체 평균의 **1.81 배** 가 나왔습니다.

0.3 차례

장	제목	무엇이 있나
1	이번이란 무엇인가	두 종류이고 서로 반대다 · 정의가 셋으로 갈렸다

2	네 사람이 각자 접근했다	누가 무엇을 물었나
3	지표 — 무엇으로 재는가	왜 ROC-AUC 가 아니라 Lift 인가
4	갈래 A · 전유림	Cohen's d 로 두 유형이 정반대임을 확인
5	갈래 B · 박준석	배당률 1 개 vs 피쳐 86 개 · 모델 8 종 · 개선 실험 6 단계
6	갈래 C · 김찬진	두 유형 분리 · 잠금 test · 수익 부트스트랩
7	갈래 D · 사전 등록 검증	결론이 뒤집히다 · NO-GO
8	결과 종합	선별력 확인 · 수익성 세 겹으로 부정
9	인사이트	일곱 가지
10	한계와 다음 단계	어디까지 믿을 수 있나
부록	A 용어 · B 자료 목록 · C 재현 시 지킬 것	

표 0-2. 차례.

0.4 읽는 순서

1 장 이 이 보고서에서 가장 중요합니다. 이번이 무엇인지, 그리고 **왜 한 종류가 아닌지** 를 다룹니다. 이걸 놓치면 뒤의 숫자가 서로 안 맞아 보입니다.

숫자만 빠르게 보시려면 **8 장 결과 종합** 이면 됩니다. **7 장** 은 이 프로젝트에서 방법론적으로 가장 값진 부분입니다. 직접 재현하실 분은 **부록 C** 를 먼저 보시면 함정 다섯 개를 피할 수 있습니다.

이 보고서에서도 수익률 수치를 쓰지 않습니다

파트 1 8.1 절과 같은 이유입니다. 여기에 더해 파트 2 에는 더 강한 근거가 생겼습니다 — **배당 295.7 배 적중 한 건** 이 상위 5~50% 구간의 수익을 통째로 끌어올렸고, 그 한 건을 빼면 대부분 음수가 됩니다.

게다가 **사전 등록 검증에서는 시장 통제군에 졌습니다**. 7 장에서 다룹니다.

1. 이변이란 무엇인가

“이변”은 일상어라 정의 없이 쓰면 사람마다 다른 것을 가리킵니다. 이 프로젝트에서도 실제로 그랬고, 그 차이를 정리하는 것이 1 장의 목적입니다.

1.1 인기마와 비인기마

배당률이 낮은 말이 **인기마**입니다. 사람들이 돈을 많이 걸었다는 뜻입니다. 우리 데이터에는 이걸 백분위로 만든 `pop_pct` 가 있습니다. **값이 클수록 비인기마**입니다.

그리고 시장은 꽤 정확합니다 — 인기 순서대로 실제 승률이 깔끔하게 내려갑니다. 최상위 인기 구간이 **26.6%**, 최하위가 **1.2%**입니다.

1.2 이변은 두 종류이고, 서로 반대입니다

이것이 파트 2 의 첫 번째이자 가장 중요한 발견입니다.

	다크호스	인기마 붕괴
무엇인가	무시당한 말이 잘 뛴다	유력한 말이 무너진다
누구에게 묻나	비인기마에게만	인기마에게만
방향	시장이 과소평가	시장이 과대평가

표 1-1. 두 유형.

합쳐서 하나로 학습하면 신호가 상쇄됩니다

전유림님이 Cohen's d 로 두 유형의 특징을 비교했더니 같은 피처의 **부호가 정반대**였습니다.

`hr_last_pop_pct`(직전 경주 인기 백분위)를 보면 — 다크호스는 **+0.630**, 인기마 붕괴는 **-0.687** 입니다.

다크호스는 “직전에 인기 없던 말”, 인기마 붕괴는 “직전에 인기였던 말”입니다. 두 집단을 한 라벨로 묶으면 모델이 이 신호를 배울 수 없습니다. **반드시 나눠서 각각 모델을 만들어야 합니다.**

1.3 그런데 정의가 세 가지로 갈렸습니다

이 프로젝트의 가장 큰 정리 대상입니다. 세 사람이 각자 다르게 정의했고, 그래서 **Lift 숫자를 직접 비교할 수 없습니다.**

누가	다크호스 정의	기저율
전유림	<code>pop_pct - fin_pct ≥ 0.667</code> (95 백분위)	2.3%
박준석	<code>pop_pct ≥ 0.5</code> & 1 착	9.6%
김찬진	<code>pop_pct ≥ 0.5</code> & 입상(3 착 이내)	13.5%

표 1-2. 세 가지 다크호스 정의.

무엇이 다른가

유림님은 분포에서 임계값을 뽑았습니다. `pop_pct - fin_pct`의 절댓값 95 백분위(0.667)를 기준으로 삼았고, 인기와 결과의 **괴리 크기**를 봅니다.

준석님과 찬진님은 임계값을 고정했습니다. 비인기마(하위 50%) 중 잘 댄 말입니다. 다만 **준석님은 1 착**, **찬진님은 입상(3 착 이내)**입니다.

기저율이 9.6% 대 13.5%로 다르므로 **Lift 1.72 와 1.82 를 나란히 놓을 수 없습니다.** 같은 모델이라도 기저율이

낮을수록 Lift 를 올리기 어렵습니다.

인기마 붕괴는 상대적으로 합의가 있습니다. 준석님·찬진님 모두 같은 정의를 씁니다 — $pop_pct \leq 0.25$ 이면서 $fin_pct \geq 0.50$, 즉 **인기 상위 25%가 착순 하위 50%로** 떨어진 경우입니다. 저장소 데이터의 $upset_A$ 열과 100% 일치합니다.

1.4 왜 이걸 예측하려 하는가

파트 1 에서 확인한 대로, 기대수익이 양수이려면 모델 확률이 시장 확률의 약 1.25 배를 넘어야 합니다. 그런데 **이 조건이 경주 전체에 대해 성립할 필요는 없습니다.**

$p/q > 1.25$ — 특정 구간에서만 성립해도 된다

시장이 구조적으로 약한 지점을 찾으면 전체를 이기지 않아도 된다

그리고 이번마는 **배당이 높습니다**. 시장이 무시한 말이므로 적중 시 보상이 큼니다. 적중률이 낮아도 기대값이 양수가 될 여지가 생깁니다.

1.5 그런데 왜 어려운가

이번 예측이 1 착 예측보다 **구조적으로 더 어렵습니다**. 세 가지 이유가 있습니다.

1. **정의상 드물다**. 다크호스는 13.5%, 인기마 붕괴는 25.4%, 유림님 정의로는 **2.3%** 입니다. 양성이 적으면 학습할 사례가 적습니다.
2. **시장이 무시한 데는 이유가 있습니다**. 4.2 절에서 보듯 다크호스는 “직전에 부진했고 레이팅 낮고 나이 많은 말”입니다. **시장의 판단이 대체로 옳습니다**. 우리는 그 안에서 예외를 찾아야 합니다.
3. **이번의 상당 부분이 우연입니다**. 출발 실패 · 진로 방해 · 그날의 컨디션 — 데이터에 없는 요인이 큼니다. 특히 인기마 붕괴가 그렇습니다(6.4 절).

그래서 **ROC-AUC 0.64 를 “실패”로 읽으면 안 됩니다**. 이 문제에서 그 정도면 상위 10%를 1.8 배 잘 골라낸다는 뜻이고, 그것이 우리가 필요한 전부입니다. 3 장에서 지표 이야기를 먼저 하는 이유입니다.

2. 네 사람이 각자 접근했습니다

파트 1의 세 각도와 마찬가지로 파트 2도 한 사람의 작업이 아닙니다. 네 갈래가 서로 다른 질문을 던졌고, 그래서 결과를 합칠 때 주의가 필요합니다.

	누가	무엇을 물었나	데이터
A	전유림	이번이란 무엇이고 어떤 특징이 있나	서울+부경 56,648
B	박준석	배당률을 피쳐로 넣으면 맞힐 수 있나	서울 원천
C	김찬진	두 유형을 나눠 엄격히 검증하면 어떤가	서울 32,888
D	이종원 · Codex	중배당 구간이 정말 유망한가	서울+부경 VALID

표 2-1. 파트 2의 네 갈래.

D가 특별합니다

A · B · C는 “이번을 얼마나 잘 골라내는가”를 물었습니다. **D는 “그 선별이 시장보다 나은가”**를 물었습니다.

그리고 **결과를 보기 전에 프로토콜을 해시로 잠갔습니다**. 이 차이가 결론을 바꿨습니다. 7장에서 다룹니다.

2.1 네 갈래가 서로를 보완합니다

따로 진행됐지만 결과적으로 **하나가 다른 하나의 전제를 검증하는 구조**가 됐습니다.

	무엇을 세웠나	누가 받았나
A → B·C	두 유형이 정반대이니 나눠야 한다	찬진님이 실제로 나눠 모델링
B → D	중배당 구간이 유망하다	Codex가 사전 등록으로 검증 → 기각

B → C	배당률이 피쳐보다 강하다	찬진님이 Core/History+ 로 재확인
C → 전체	수익성은 한 건에 달려 있다	모든 결론에 신뢰구간 병기

표 2-2. 갈래 간 연결.

특히 B → D 가 이 프로젝트의 성숙도를 보여줍니다. 동료의 관찰을 그냥 받아들이지도, 무시하지도 않고 검증 가능한 형태로 만들어 정면으로 시험했습니다.

2.2 데이터

	내용
원천	한국마사회 서울 경주 · 2023.08 ~ 2026.08
전체 출주 기록	서울 32,888 행 (서울+부경 56,648 행 중)
분할	시간순 60 / 20 / 20 — 무작위 분할은 미래 정보 누출
다크호스 학습 대상	비인기마만 ($\text{pop_pct} \geq 0.5$) · 학습 10,425 행 · test 3,528 행
인기마 붕괴 학습 대상	인기마만 ($\text{pop_pct} \leq 0.25$) · 학습 5,597 행 · test 1,902 행

표 2-3. 데이터 요약.

부분집합만 학습에 쓰는 것이 핵심입니다. 전체를 쓰면 5.6 절에서 보듯 성능이 무너집니다.

3. 지표 — 무엇으로 재는가

파트 1 은 ROC-AUC 와 Race Log Loss 를 썼습니다. 파트 2 는 다릅니다. **문제가 바뀌면 잣대도 바뀌어야 합니다.**

3.1 ROC-AUC 를 버려야 하는 이유

ROC-AUC 는 “양성 하나와 음성 하나를 뽑았을 때 모델이 양성에 더 높은 점수를 줄 확률”입니다. 0.5 가 무작위, 1.0 이 완벽입니다.

우리 최고 모델이 **0.6420** 입니다. 실패처럼 보입니다. 그런데 이 숫자는 **전체 순서를 다 보는 지표** 라서 하위권을 잘 정렬한 것도 점수에 들어갑니다.

우리가 실제로 쓰는 건 상위 5~20%뿐입니다

베틱은 모델이 가장 확신하는 몇 마리에만 합니다. **400 등과 3,000 등의 순서가 맞는지는 아무 상관이 없습니다.**

그런데 ROC-AUC 는 그 순서까지 점수에 반영합니다. 실제 사용 방식과 지표가 어긋나 있는 것입니다.

3.2 Lift — 실제로 의미 있는 숫자

$$\text{Lift@k\%} = (\text{상위 k\% 안에서의 적중률}) \div (\text{전체 적중률})$$

1.0 이면 무작위와 같다. 1.72 는 72% 더 잘 골랐다는 뜻

상위 10%를 골랐더니 적중률이 23.3%였고 전체 적중률은 13.55%였습니다. **1.72 배** 입니다. 실무에서 바로 쓸 수 있는 숫자입니다.

같은 모델인데 **AUC 는 “별로”, Lift 는 “괜찮음”** 이라고 말합니다. 둘 다 맞습니다. 전체 순서는 별로고 상위권 선별은 괜찮습니다. 우리가 필요한 건 후자입니다.

3.3 PR-AUC — 보조 지표

Precision-Recall AUC 는 양성이 드물 때 ROC-AUC 보다 민감합니다. **기저율이 그대로 기준선** 이 되는 것도 편합니다 — 다크호스는 0.1355 가 무작위 수준이고, 우리 모델은 0.2093 으로 **1.55 배** 입니다.

Lift 가 특정 k 에서 우연히 좋은 건 아닌지 확인하는 용도로 함께 봅니다.

3.4 정리 — 세 지표의 역할

지표	역할	어떻게 보나
Lift@k%	주 지표	실제 베팅할 비율로 k 를 잡는다
PR-AUC	보조	상위권 전반의 품질. Lift 의 교차 확인
ROC-AUC	참고만	다른 연구와 비교할 때만. 절대값으로 판단 금지

표 3-1. 파트 2 의 평가 체계.

신뢰구간을 반드시 붙이세요

test 3,528 행 중 양성이 478 개뿐입니다. 상위 10%면 352 마리에 적중 82 건입니다. **이 정도 표본에서 나온 숫자는 흔들립니다.**

부트스트랩(복원추출로 다시 뽑아 2,000 회 반복)으로 구간을 잡으면 Lift@10%가 **[1.41, 2.02]** 입니다. 하한이 1 을 넉넉히 넘으므로 선별력은 확실합니다.

4. 갈래 A · 전유림 — 이변을 정의하고 특징을 뽑다

모델을 만들기 전에 “이변마는 일반마와 실제로 다른가”를 확인했습니다. 다르지 않다면 예측 자체가 성립하지 않기 때문입니다.

4.1 방법 — Cohen's d

두 집단의 피쳐 평균 차이를 Cohen's d로 잰습니다. “평균 차이를 표준편차로 나눈 값”이라 **단위가 다른 피쳐끼리도 비교** 할 수 있습니다.

$$d = (\text{평균 A} - \text{평균 B}) / \text{합동표준편차}$$

0.2 작음 · 0.5 중간 · 0.8 큼

4.2 다크호스의 특징

피쳐	Cohen's d	다크호스	일반마
hr_last_popvct 직전 인기 백분위	+0.630	0.682	0.484
hr_last_finpct 직전 착순 백분위	+0.630	0.675	0.479
hr_last_ord 직전 착순	+0.591	7.48	5.65
age_z 나이	+0.490	—	—
jk_winrate_z 기수 승률	-0.481	—	—
age 나이	+0.419	4.28	3.76
rating_pr 레이팅 백분위	-0.435	0.367	0.503

표 4-1. 다크호스 vs 일반마.

읽으면 이렇습니다 — 다크호스는 “직전 경주에서 인기 없었고 부진했던, 나이 많고 레이팅 낮은 말”입니다. 기수 승률도 낮습니다.

시장이 이 말들을 낮게 본 이유가 데이터에 그대로 보입니다. 모델이 찾아야 하는 것은 “그럼에도 잘 뛴 말”이라, 문제가 어려운 이유이기도 합니다.

4.3 인기마 붕괴 — 부호가 뒤집힙니다

피쳐	Cohen's d	붕괴	일반마
<code>is_fav</code> 1 인기 여부	+0.705	0.297	0.090
<code>hr_last_poppct</code> 직전 인기 백분위	-0.687	0.279	0.495
<code>hr_winrate_z</code> 통산 승률	+0.687	0.627	-0.022
<code>hr_plcrate</code> 통산 입상률	+0.612	0.472	0.307
<code>hr_winrate_pr</code> 통산 승률 백분위	+0.607	0.632	0.474
<code>hr_last_finpct</code> 직전 착순 백분위	-0.590	0.305	0.489
<code>hr_last_ord</code> 직전 착순	-0.568	3.98	5.74

표 4-2. 인기마 붕괴 vs 일반마.

같은 피쳐, 반대 부호

`hr_last_poppct` — 다크호스 **+0.630**, 인기마 붕괴 **-0.687**

`hr_last_finpct` — 다크호스 **+0.630**, 인기마 붕괴 **-0.590**

`hr_last_ord` — 다크호스 **+0.591**, 인기마 붕괴 **-0.568**

세 피쳐 모두 크기는 비슷한데 방향이 정반대입니다. 다크호스는 “직전에 못했던 말”, 인기마 붕괴는 “직전에 잘했던 말”입니다.

두 집단을 한 라벨로 묶으면 이 신호가 서로 지웁니다. 1.2 절에서 말한 “합치면 상쇄된다”가 바로 이 숫자입니다.

4.4 이 갈래가 남긴 것

모델 성능이 아니라 **문제 설계** 를 바꿨습니다. 이후 준석님·찬진님이 두 유형을 나눠서 모델링한 근거가 여기서 나왔습니다.

5. 갈래 B · 박준석 — 배당률을 피처로 넣다

5.1 원칙에 예외를 뒀습니다

파트 1의 핵심 제약은 “현재 경주의 배당·베팅 정보를 피처에 넣지 않는다” 였습니다. 배당률을 쓰면 “시장을 베팅해 시장과 비교하는” 자기모순이 되기 때문입니다.

그런데 이번은 다릅니다. “**시장이 틀리는 경우**”를 찾는 문제라, 시장이 무엇을 어떻게 보고 있는지를 모델이 알아야 합니다. 그래서 의도적으로 예외를 뒀습니다.

5.2 배당률 14 개를 1 개로 줄였습니다

배당률에서 파생된 열이 14 개나 있었습니다 — `winOdds plcOdds p_raw logit_q log_q pop_rank is_fav book_sum takeout pl_harville pl_disc q_plc` 등입니다.

상관계수를 계산했더니 **q**와 나머지 13 개의 **|r|**이 대부분 **0.9 이상**이었습니다. 사실상 같은 정보의 다른 표현입니다. 가장 깨끗한 형태인 **q(오버라운드 제거 후 경주 내 합이 1 이 되게 정규화)** 하나만 남겼습니다.

기존 피처에서도 고상관 쌍 **23 개**를 제거했습니다. 결과적으로 156 개 열이 약 90 개로 줄었습니다.

5.3 피처셋 세 가지 — 이 실험이 핵심입니다

배당률의 기여를 정확히 재기 위해 세 가지를 나눠 비교했습니다.

피처셋	구성	test ROC-AUC	해석
A 배당률만	q 1 개	0.7369	배당률 하나로 74% 구분
B 피처만	86 개 (배당률 완전 제외)	0.6572	배당률 없으면 66%로 하락
C 결합	q + 86 개 = 87 개	0.7420	둘 다 쓸 때 가장 좋음

표 5-1. 피처셋 A/B/C 비교. 이번 예측 기준.

이 표가 파트 2 에서 가장 많은 것을 말합니다

① **배당률 1 개가 피쳐 86 개보다 낮습니다.** 0.7369 대 0.6572 입니다. 말·기수·조교사·훈련·전개 정보를 86 개나 모아도 배당률 하나를 못 이깁니다.

② **피쳐가 배당률 위에 더하는 것은 +0.0051 뿐입니다.** 0.7369 에서 0.7420 으로 올라갑니다.

파트 1 의 “정보 비대칭 — 부분집합이 합집합을 이길 수 없다”가 **이번 문제에서도 똑같이 성립합니다.** 시장은 우리 데이터에 없는 것을 알고 있습니다.

다만 **+0.0051 이 0 은 아닙니다.** 그리고 배당 구간별로 나눠보면 **고배당 구간일수록 C 와 A 의 격차가 벌어집니다** — 10~20 배 구간에서 +0.78%p, 40 배 이상에서도 +0.33%p 입니다.

해석하면 “**배당률만으로는 같은 고배당 구간 안에서 말을 구분하지 못하고, 그때 피쳐가 추가 정보를 제공한다**” 는 뜻입니다. 이것이 이번 모델의 존재 이유입니다.

5.4 모델 8 종 비교

네 종류에 무작위 기준선을 더해 비교했습니다. 무작위 기준선은 “아무 정보도 없을 때 어떤 값이 나오는지”를 알려줍니다 — 이게 없으면 “0.62 면 좋은 건가?”를 판단할 수 없습니다.

모델	ROC-AUC	PR-AUC	L@5%	L@10%	L@20%
무작위 기준선	0.4881	0.1344	1.09	1.07	0.95
로지스틱 회귀	0.6195	0.1928	1.72	1.59	1.55
랜덤포레스트 (d12)	0.6420	0.2093	2.01	1.72	1.61
XGBoost (d3)	0.6205	0.2058	1.89	1.70	1.49
LightGBM	0.6034	0.1803	1.34	1.38	1.35

표 5-2. 다크호스 예측. test 3,528 행 · 기저율 13.55%.

랜덤포레스트가 6 개 지표 중 5 개에서 1 위 입니다. 특히 Lift@5%가 2.01 — 상위 5%(176 마리)의 적중률이 27.3%로 무작위(13.55%)의 두 배입니다.

왜 LightGBM 이 꼴찌인가

LightGBM 은 **leaf-wise** 방식입니다. 가장 이득이 큰 잎을 골라 그쪽만 계속 쪼갭니다. 데이터가 많으면 효율적인데, **표본이 적으면 특정 소수 구간을 파고들다가 그 구간의 잡음까지 외웁니다.**

XGBoost 는 level-wise(깊이 단위로 고르게)라 조금 낮지만 순차 학습이라는 근본 성질은 같습니다. 그래서 랜덤포레스트와 로지스틱 사이에 애매하게 걸쳐 있습니다.

부스팅이 랜덤포레스트에 진 이유는 구조적입니다

표 형태 데이터에서는 보통 부스팅이 최강입니다. Kaggle 상위권이 대부분 그렇습니다. **그런데 이 문제에서는 랜덤포레스트가 이겼습니다.**

이유는 두 가지입니다 — **표본이 적고(학습 10,425 행), 신호가 약합니다(AUC 0.64).** 이런 조건에서 순차 학습은 오답을 고치려다 잡음을 외웁니다.

반면 랜덤포레스트는 나무들이 **서로 다른 실수** 를 하고, 평균낼 때 그 실수가 상쇄됩니다. 신호는 모든 나무가 공통으로 잡으니 남습니다.

5.5 결정적 설정 — min_samples_leaf

선정된 설정은 `n_estimators=600` · `max_depth=12` · `min_samples_leaf=50` 입니다. 그리고 `class_weight` 는 지정하지 않았습니다.

깊이를 3 부터 12 까지 바꿔봤는데 **test 성능 차이가 0.001 수준** 이었습니다. 결정적인 것은 깊이가 아니라 **min_samples_leaf=50** 입니다 — **앞마다 최소 50 개를 요구하니 나무가 아무리 깊어져도 한두 사례를 외우는 일이 구조적으로 막힙니다.**

5.6 하지 말아야 할 것 두 가지

① 불균형 처리 — 전부 나빠졌습니다

양성 비율이 13.5%면 불균형 데이터입니다. 교과서적 처방은 양성에 가중치를

주거나(**class_weight='balanced'**) 양성을 복제하는 것(SMOTE)입니다. 세 모델에 전부 적용해봤습니다.

모델	기본	balanced	차이
랜덤포레스트	0.6381	0.6264	-0.0117
로지스틱 회귀	0.6195	0.6196	+0.0001
XGBoost	0.5293	0.4945	-0.0348

표 5-3. 불균형 처리 전후 test ROC-AUC. XGBoost 는 무작위(0.5) 아래로 떨어졌다.

이유를 풀면 이렇습니다.

- 가중치를 주면 모델이 양성 쪽으로 예측을 밀어냅니다. **확률값 전체가 위로 이동합니다.**
- 그런데 우리는 “이 말이 양성이나”를 판정하지 않습니다. **확률 순서대로 줄 세워 위에서 몇 마리만 뽑습니다.**
- 전체를 똑같이 위로 밀면 순서는 안 바뀝니다.** 지표가 좋아질 이유가 없습니다.
- 대신 부작용은 생깁니다 — 소수의 양성 사례에 과도한 비중이 실리면서 그 사례들의 특이한 성질까지 학습합니다.

② 전체 데이터로 학습 — 신호가 사라집니다

“데이터가 적으니 전체 32,888 행을 다 쓰면 낫지 않을까?” 당연한 생각이라 실험했습니다.

학습 범위	test ROC-AUC	판정
부분집합 + 다크호스 라벨	0.6419	채택

전체 + 1 착 라벨	0.6303	나쁘지 않음
전체 + 다크호스 라벨	0.4599	붕괴

표 5-4. 학습 범위 실험.

세 번째가 왜 무너지는가

전체 데이터에서 다크호스 라벨은 대부분 0 입니다. **인기**라는 정의상 전부 0 이니까요.

그러면 모델은 **P(비인기하다)** 를 학습하게 됩니다. 정작 우리가 알고 싶은 것은 **P(잘 뵈었다 | 비인기하다)** 인데 말입니다.

모델이 배운 것 : 이 말이 비인기마인가 → 쓸모없음

우리가 원하는 것 : 비인기마 중 누가 뛰는가

두 번째(전체 + 1 착 라벨)가 0.6303 으로 나쁘지 않은 것도 흥미롭습니다. 일반 승률 모델을 만든 다음 비인기마 구간에서만 순위를 보는 방식도 가능하다는 뜻입니다. 다만 부분집합 전용 모델이 더 낫습니다.

5.7 어떤 변수가 중요했나

순위	피처	뜻
1	<code>train_runs_14_z</code>	최근 2 주 조교 횟수 (표준화)
2	<code>hr_last_ord</code>	직전 경주 착순
3	<code>hr_last_poppct</code>	직전 경주 인기 백분위
4	<code>hr_rest_days_z</code>	휴식일
5	<code>rating_z</code>	레이팅
6~10	<code>hr_plcrate</code> · <code>tr_winrate_z</code> · <code>wg_diff_z</code> · <code>wgBudam_z</code> · <code>hr_style_sd</code>	입상률 · 조교사 · 체중 변화 · 부담중량 · 각질 변동

표 5-5. 다크호스 모델 피처 중요도 상위 10.

상위 5 개가 전부 마필의 최근 상태를 나타내는 변수입니다. 해석하면 이렇습니다 — 시장은 말의 통산 성적과 명성에는 잘 반응하지만, **최근 몇 주간의 조교량 변화와 컨디션 회복은 상대적으로 덜 반영합니다.** 우리 모델이 잡아낸 게 바로 그 틈입니다.

3 위의 `hr_last_poppct` 가 특히 흥미롭습니다. **“전에는 인기마였는데 지금은 아닌 말”** 을 골라내는 변수입니다. 시장이 최근 부진에 과잉 반응했을 가능성을 포착합니다.

5.8 개선 실험 6 단계 — 5 가지가 실패했습니다

단계	무엇을 시도했나	결과
1	타깃을 place(입상)로 바꾸고 연승 배당으로 계산	실패 · 수익 악화
2	<code>min_samples_leaf</code> 튜닝 + balanced 제거	실패 · 개선 없음
3	고배당 적중 제거 로버스트니스 검사	실패 · 전 조건 음수
4	배당 구간 필터 (10 배 이상)	성공
5	피처 추가 (<code>hr_trend_3</code> · <code>jk_recent_form</code>)	실패
6	붕괴 + 다크호스 조합	실패

표 5-6. 개선 실험 6 단계.

여섯 중 다섯이 실패했습니다. 이 사실을 발표에서 함께 말하면 성공한 하나(배당 구간 필터)의 신뢰도가 오히려 올라갑니다.

3 단계 로버스트니스 — 가장 중요한 실패

고배당 적중 제거	ROI	양수인가
0 건 (원래)	-7.43%	아니오
1 건	-8.34%	아니오
3 건	-9.94%	아니오
5 건	-11.29%	아니오
10 건	-14.50%	아니오

표 5-7. 고배당 적중을 하나씩 빼면, 다섯 조건 모두 음수.

적중한 말 중 배당이 가장 높은 것부터 순서대로 빼면 수익이 계속 나빠집니다. 그리고 애초에 0 건일 때도 음수입니다. 이 표가 파트 2의 수익성 결론을 사실상 결정합니다.

6. 갈래 C · 김찬진 — 두 유형을 나눠 엄격히 검증하다

가장 통제가 엄격한 실험입니다. 세 가지를 **사전에 고정** 했습니다 — 시간순 train/valid/test, **test 1 회 평가**, test 확인 후 재튜닝 금지. 설정을 해시(7076b518...)로 잠갔습니다.

6.1 피쳐셋을 둘로 나눴습니다

피쳐셋	허용	제외
Core	말·기수·조교사·훈련·전개	당일 시장 · 결과 · 식별자 · 과거 시장 파생
History+	위 + 과거 시장 파생	당일 시장 · 결과 · 식별자

표 6-1. Core 는 과거 시장 정보까지 뺀 순수 조건이다.

“**과거 시장 파생**” 이란 `hr_last_poppct`(직전 인기 백분위)처럼 **과거 경주의 배당에서 나온 정보** 를 말합니다. 당일 배당은 아니지만 시장의 판단이 간접적으로 들어간 값입니다.

6.2 valid 선정

선정 기준은 **valid Lift@10%**, 동률이면 PR-AUC 입니다. 랜덤포레스트는 24 개 조합을 200 그루로 선별한 뒤 선택 조합을 600 그루로 재학습하고 **5 개 시드로 안정성을 확인** 했습니다.

타깃	피쳐셋	선정 모델	ROC-AUC	Lift@10	5 시드 Lift@10
다크호스	core	rf_d8_leaf30_mfsqrt	0.648	1.954	1.767 ± 0.067
다크호스	history_plus	rf_d6_leaf100_mf0.5	0.656	1.933	1.938 ± 0.084
인기마 붕괴	core	rf_d8_leaf100_mf0.5	0.611	1.530	1.530 ± 0.014
인기마 붕괴	history_plus	logit_c0.1	0.600	1.651	1.651 ± 0.000

표 6-2. valid 선정 결과. 5 시드 표준편차가 작아 안정적이다.

6.3 잠금 test — 단 한 번

타깃	피쳐셋	모델	ROC-AUC	기저율	상위 10%	Lift@10
다크호스	Core	RF d8 leaf30	0.647	13.5%	24.7%	1.82

다크호스	History+	RF d6 leaf100	0.649	13.5%	23.3%	1.72
인기마 붕괴	Core	RF d8 leaf100	0.574	25.4%	34.7%	1.37
인기마 붕괴	History+	Logistic C=0.1	0.582	25.4%	35.8%	1.41

표 6-3. 동결 후 단 한 번 연 test 결과.

여기서 두 가지가 나옵니다

① 과거 시장 정보를 빼도 성능이 안 떨어집니다. 다크호스에서 Core 1.82 vs History+ 1.72 로 **오히려 Core 가** 낮습니다.

파트 1 에서 v5 의 시장 피쳐 5 개를 뺐더니 성능이 올랐던 것과 **같은 패턴** 입니다. 시장 정보를 베끼는 것이 도움이 안 된다는 증거가 프로젝트 안에서 두 번 나왔습니다.

② 인기마 붕괴가 훨씬 어렵습니다. Lift 1.37 대 1.82 입니다.

6.4 왜 인기마 붕괴가 더 어려운가

8. **표본이 적습니다.** 학습 데이터 5,597 행으로 다크호스의 절반입니다.
9. **인기마는 정보가 많이 반영돼 있습니다.** 1 인기마는 모두가 주목합니다. 부상 소문·조교 상태·기수 교체까지 배당에 이미 들어가 있어 남은 틈이 작습니다.
10. **붕괴는 대부분 우연입니다.** 출발 실패·진로 방해·그날 컨디션 — 데이터로 잡히지 않는 요인이 큼니다.

그래도 **Lift@10% 부트스트랩 신뢰구간이 [1.21, 1.75]** 로 하한이 1 을 넘습니다. **신호는 있습니다. 다만 약합니다.**

6.5 변수 성격도 다릅니다

다크호스에서 1 위였던 조교량이 인기마 붕괴에서는 4 위이고, 대신 **나이와 휴식일이 앞으로** 나옵니다.

상위 5 개 피쳐	
다크호스	<code>train_runs_14_z · hr_last_ord · hr_last_poppct · hr_rest_days_z · rating_z</code>
인기마 붕괴	<code>age_pr · hr_rest_days_z · rating_z · train_runs_14_z · wg_diff_z</code>

표 6-4. 두 모델의 피쳐 중요도.

방향도 반대입니다 — 다크호스는 “조교량이 늘어난 말”을 찾고, 인기마 붕괴는 “오래 쉬었고 나이가 있는데 조교량도 적은 말”을 찾습니다. **두 모델이 다른 것을 보고 있다는 증거이고, 하나로 합치면 안 되는 이유이기도 합니다.**

6.6 수익성 — 한 건에 달려 있습니다

상위 퍼센트별로 수익을 계산하고 경주를 군집 단위로 **5,000 회 부트스트랩** 했습니다.

누적 구간	베팅	적중률	Lift	95% 신뢰구간	최고 1 건 제거
상위 1%	35	40.0%	2.95	0 포함	양수
상위 2%	70	31.4%	2.32	0 포함	음수
상위 5%	176	25.6%	1.89	0 포함	음수
상위 10%	352	24.7%	1.82	0 포함	음수
상위 20%	705	22.8%	1.69	0 포함	음수
상위 30%	1,058	20.0%	1.48	0 포함	음수
상위 50%	1,764	18.3%	1.35	0 포함	음수
전체	3,528	13.5%	1.00	0 포함	음수

표 6-5. 다크호스 Core. 연승 배당 1 단위 베팅 기준.

적중률이 깔끔하게 내려가는 것이 오히려 좋은 신호입니다

40.0% → 31.4% → 25.6% → 24.7% → 22.8% → 20.0% → 18.3% → 13.5%

모델이 매긴 점수 순서가 **실제 확률 순서와 잘 맞아떨어진다** 는 뜻입니다. 선별력이 우연이 아니라는 강한 증거입니다.

그런데 수익은 다릅니다. 모든 구간에서 95% 신뢰구간이 0 을 포함하고, **배당 295.7 배 적중 한 건** 을 빼면 상위 1%를 뺀 전 구간이 음수가 됩니다.

찬진님 본인의 결론이 이렇습니다 — **“수익성보다 랭킹 모델의 선별력 검증 완료로 해석하는 편이 타당하다.”**

6.7 고정 운영 규칙까지 만들었습니다

valid 상위 10% 점수 임계값을 test 에 그대로 적용한 뒤, **같은 경주에서는 최고 점수 말 1 두만** 선택하는 규칙을 시험했습니다.

피처셋	베팅/경주	적중	적중률	95% 신뢰구간	최고 1 건 제거
core	323	79	24.5%	0 포함	음수
history_plus	304	72	23.7%	0 포함	음수

표 6-6. 실전 후보 규칙 — Core 점수 ≥ 0.192489 , 경주당 최고점 1 두.

적중률은 유지되지만 수익 판정은 같습니다. 그리고 여기 쓴 배당은 **사후에** 확정된 **종가** 라, 실제로 쓰려면 베팅 시점 스냅샷이 필요합니다.

7. 갈래 D · 사전 등록 검증 — 결론이 뒤집히다

이 장이 파트 2 에서 방법론적으로 가장 값진 부분입니다.

7.1 무엇을 검증했나

준석님 실험에서 **중배당 구간이 유망하다** 는 관찰이 나왔습니다. 이 가설을 폐기하지 않고 **사전 등록 실험** 으로 정면 검증했습니다.

	내용
대상	8~15 배 다크호스 구간
기간	VALID 2025-05-17 ~ 2025-12-27
비교 대상	같은 경주·같은 구간에서 같은 수 의 말을 시장확률 순으로 고른 통제군
정책	상위 10 · 20 · 30 · 40% 네 가지
통계	경주일 단위 부트스트랩 95% CI · Holm 다중비교 보정

표 7-1. 실험 설계.

7.2 통제군이 핵심입니다

“모델이 좋다”를 어떻게 증명하는가

이번 모델이 고른 말들의 적중률이 높다고 해서, 그게 **모델 덕분** 이라는 보장은 없습니다. 같은 구간에서 **시장확률 순으로만 골라도** 비슷하게 나올 수 있기 때문입니다.

그래서 **같은 경주 · 같은 8~15 배 구간 · 같은 마릿수** 를 시장확률 내림차순으로 고른 통제군을 만들고 정면 비교했습니다.

이것이 “시장보다 나은가”를 묻는 유일하게 올바른 방법입니다.

7.3 결과를 보기 전에 잠갔습니다

시각	무엇을
07:03:45	프로토콜 고정 — 목적 · 구간 · 분위수 · 통제 방식 · 다중비교 · 중단 규칙
07:08:11	결과 열을 읽기 전에 VALID 의 863 개 양의 EDGE 후보로 임계값을 한 번만 계산해 해시 잠금
잠금 이후	VALID 결과만 붙여 기술 진단을 계산. target 과 재사용 TEST 는 지표·임계값에 들어오지 않음
독립 재계산	분석 모듈을 import 하지 않은 검증기가 확률합·조인·임계값·ROI·CI·Holm·해시를 18/18 PASS 로 재현

표 7-2. 사전 등록 절차.

7.4 결론 — NO-GO

시장보다 나은 8~15 배 선별은 확인되지 않았습니다

네 정책(top10 · 20 · 30 · 40) 모두에서 동일 건수 시장확률 통제군보다 낮은 수익률과 적중률을 기록했습니다.

· paired 차이 네 개가 전부 음수

· 95% 신뢰구간 전부 0 을 포함

· Holm 0.05 통과 0 / 4

기계 판정 NO_GO, 권고 베팅액 0.

보고서에 이런 문장이 있습니다.

역사적 가설을 존중하는 것과 현재 증거를 긍정적으로 포장하는 것은 별개입니다.

그리고 이렇게 덧붙입니다 — “이번 프로토콜은 시장확률 순위 하위 50%라는 임의 조건을 추가하지 않았고, 이번 VALID 결과는 오히려 상위 EDGE 순위가 시장 q 순위보다 나았다는 주장을 지지하지 않는다.”

7.5 무엇을 배웠나

같은 데이터인데 결과를 보고 구간을 고르면 유망해 보이고, 미리 고정하고 통제군과 비교하면 사라집니다.

	결론
결과를 보고 구간 선택	중배당 구간이 유망하다
사전 등록 + 통제군 비교	NO-GO

표 7-3. 절차가 결론을 바꿨다.

파트 1 8.1 절의 “재현하면 숫자가 바뀐다”와 정확히 같은 이야기입니다. 그때는 라이브러리 버전이 원인이었고, 여기서는 분석 절차가 원인입니다. 둘 다 “모델이 틀렸다”가 아니라 “우리가 재는 방식이 결과를 만들었다”는 지적입니다.

8. 결과 종합

8.1 선별력 — 세 번 다 확인됐습니다

누가	정의	기저율	상위 10% 적중	Lift@10%	신뢰구간
박준석	비인기마 1 착	9.6%	—	1.72	[1.41, 2.02]
김찬진	비인기마 입상	13.5%	24.7%	1.82	—
박준석 (초기)	비인기마 1 착	13.2%	23.8%	1.81	—

표 8-1. 선별력. 정의가 달라 숫자를 직접 비교할 수는 없다.

세 사람이 독립적으로 1.7~1.8 배를 얻었습니다. 정의도 데이터 처리도 달랐는데 비슷한 크기가 나왔다는 것이 이 결과의 신뢰도를 높입니다.

8.2 수익성 — 세 겹으로 부정됐습니다

누가	무엇을 확인했나	결과
박준석	고배당 적중을 하나씩 제거	5 개 조건 모두 음수
김찬진	5,000 회 부트스트랩 신뢰구간	전 구간 0 포함
Codex	시장 통제군과 사전 등록 비교	네 정책 모두 패배 · NO-GO

표 8-2. 수익성 검증 세 갈래. 전부 부정적이다.

서로 다른 세 가지 방법으로 확인했는데 결론이 같습니다. 이 정도면 “표본이 부족해서 아직 모른다”가 아니라 “현재 데이터로는 수익성을 주장할 수 없다” 고 말해야 합니다.

8.3 왜 잘 맞히는데 돈이 안 되는가

파트 1 에서 이미 진단이 나와 있었습니다.

배당 구간별로 보면 **가장 많이 베팅한 3~5 배 구간이 최악** 입니다. 모델이 자신 있는 구간은 시장도 자신 있어 배당이 낮습니다.

5.3 절의 A/B/C 표가 같은 것을 말합니다 — **배당률 1 개가 피쳐 86 개보다 낮습니다**. 모델이 잘 맞는 구간은 시장도 잘 맞는 구간이고, 그래서 배당이 낮습니다.

우리만의 발견이 아닙니다

2017 년 국내 경륜 논문 이 이미 같은 결론을 기록해뒀습니다 — 예측률은 높았는데 이익이 안 났고, 이유가 **배당률이 낮은 경기만 잘 맞았기 때문** 이라는 것입니다.

2025 년 국내 경마 논문 도 같은 역전을 관찰했습니다. 랭킹 지표(NDCG 0.8895 · MAP 0.4204) 1 위였던 CatBoost 가 **실제 베팅 시나리오에서는 LightGBM · XGBoost 에 밀렸습니다**.

서로 모르는 세 팀이 같은 벽을 만났다는 뜻입니다.

8.4 이변마는 어떤 말인가

K-means 로 이변마를 군집화하고 의사결정나무로 규칙을 뽑았습니다. 세 유형이 나왔습니다.

유형	특징	해석
데뷔형	출전 이력이 거의 없고 거리 변화가 큼	시장이 평가할 근거가 없어 낮게 봄
베테랑 복귀형	기수·조교사 성적이 좋고 진료 이력 있음	부상 뒤 회복을 시장이 반영 못 함
신예 깜짝형	평균적 조건에서 시장 확률만 다소 높음	특별한 신호 없이 뚝고 들어옴

표 8-3. 이변마 세 유형 (K-means).

이변마와 일반마의 차이가 가장 큰 변수는 **q(시장 확률, 차이 0.818)** 입니다. 당연합니다 — 이변의 정의 자체가 인기도로 되어 있으니까요.

그 다음이 clinic_30d(최근 30 일 진료 횟수, 차이 0.511) 입니다. 이변마가 일반마보다 진료를 더 많이 받았습니다. 부상이나 컨디션 관리 이력이 시장에 덜 반영된다는 신호로 읽을 수 있습니다.

`train_runs_14`(최근 2 주 조교, +0.297)와 `hr_last_poppct`(직전 인기, -0.293)도 상위에 있어, 준석님·유림님 결과와 일치합니다.

9. 인사이트

9.1 이번은 두 종류이고 정반대입니다

유림님이 Cohen's d 로 보였고 찬진님이 모델로 확인했습니다. `hr_last_poppct` 의 부호가 **+0.630** 과 **-0.687** 로 뒤집힙니다.

	무엇을 찾나	Lift@10%	왜
다크호스	직전에 인기 없고 부진했던 말이 살아남	1.82	시장이 최근 부진에 과잉 반응
인기마 붕괴	인기였던 말이 무너짐	1.37	이미 정보가 반영돼 틈이 작음

표 9-1. 두 유형의 난이도 차이.

합쳐서 하나로 학습하면 안 됩니다. 이것이 파트 2 의 가장 실용적인 발견입니다.

9.2 배당률 1 개가 피쳐 86 개보다 낮습니다

준석님 A/B/C 실험이 보여준 것입니다 — A(**q** 1 개) 0.7369, B(피쳐 86 개) 0.6572.

파트 1 의 “정보 비대칭 — 부분집합이 합집합을 이길 수 없다” 가 이번 문제에서도 그대로 성립합니다.

다만 **결합했을 때 +0.0051** 이 남고, **고배당 구간일수록 그 값이 커집니다.** 이것이 이번 모델의 존재 이유입니다.

9.3 과거 시장 정보 없이도 됩니다

찬진님 Core(과거 시장 파생 전부 제외)가 History+ 보다 **오히려 나았습니다** (1.82 vs 1.72).

파트 1 에서 v5 의 시장 피쳐 5 개를 뺐더니 성능이 올랐던 것과 같은 패턴입니다. **시장 정보를 베끼는 것이 도움이 안 된다** 는 증거가 프로젝트 안에서 두 번 나왔습니다.

9.4 교과서 처방이 늘 맞지는 않습니다

불균형 처리(`class_weight='balanced'`)는 불균형 데이터의 표준 처방입니다. 그런데 **우리 문제에서는 전부 나빠졌습니다**. XGBoost 는 무작위 아래로 떨어졌습니다.

이유는 **우리가 확률값이 아니라 순서만 쓰기 때문** 입니다. 전체를 위로 밀면 순서는 안 바뀌고 부작용만 남습니다.

“왜 이 처방이 이 문제에 맞는가”를 먼저 묻지 않으면 성능을 깎아먹습니다.

9.5 문제를 바꾸는 것이 모델을 바꾸는 것보다 효과가 컸습니다

무엇을 바꿨나	얻은 것
피쳐 30 개 → 95 개 (파트 1)	+0.0305 (ROC-AUC)
학습 표본 +70%, 부경 추가 (파트 1)	+0.006 (쌍별 정확도)
시장 누수 피쳐 제거 (파트 1)	+0.0054
모델 8 종 비교 (파트 2)	+0.0225 (로지스틱 → RF)
목표를 “1 착”에서 “이번”으로	Lift 1.0 → 1.8

표 9-2. 무엇이 효과가 컸나.

앞의 넷은 **모델을 바꾼 것** 이고 마지막 하나는 **문제를 바꾼 것** 입니다. 효과의 크기가 자릿수로 다릅니다.

9.6 절차가 결론을 바꿉니다

7 장에서 본 대로입니다. 결과를 보고 구간을 고르면 유망해 보이고, 사전 등록하고 통제군과 비교하면 사라집니다.

이것은 데이터의 문제도 모델의 문제도 아닙니다. 분석 설계의 문제입니다. 그리고 고치는 방법이 명확합니다 — 미리 정하고, 통제군을 두고, 다중비교를 보정합니다.

9.7 그래서 결론은 여기까지입니다

파트 2의 결론

“이 말들을 주목하라” 까지입니다.

“이 말들에 걸어들라”가 아닙니다.

이변을 두 종류로 나누고 각각 모델을 만들면 상위 10%에서 1.8 배 더 잘 골라냅니다. 세 사람이 독립적으로 확인했고, 적중률이 40%에서 13.5%까지 깔끔하게 내려갑니다.

다만 그것으로 수익을 낼 수 있다는 증거는 없습니다. 세 가지 방법으로 검증했고 셋 다 부정적이었습니다.

10. 한계와 다음 단계

10.1 이 결과를 어디까지 믿을 수 있나

11. **표본이 작습니다.** test 3,528 행에 양성 478 건. 상위 10%면 352 건 중 적중 82 건입니다. 지표 하나가 0.02 쯤 흔들리는 건 정상이고, 모델 간 순위도 시드에 따라 바뀔 수 있습니다. 특히 인기마 붕괴는 RF(0.5768)와 XGBoost(0.5783)의 차이가 무의미한 수준입니다.
12. **수익성이 검증되지 않았습니**다. ROI 가 배당 295.7 배 적중 한 건에 전적으로 의존합니다. **실전 투입 판단의 근거로 쓸 수 없습니다.** 최소 3~5 년치로 다시 확인해야 합니다.
13. **서울 경마장만 봤습니**다. 부경에서도 같은 결과가 나오는지 확인하지 않았습니
다. 트랙 특성과 참가마 수준이 달라 결과가 다를 수 있습니다. 외부 검증 기회이기도 합니다.
14. **최근 20%가 test 입니**다. 시장 효율성이 해마다 올라가고 있어(2023 년 0.8031 → 2025 년 0.8193) test 구간이 가장 효율적인 시기입니다. 성능이 과소평가됐을 수도, 최근 패턴에만 맞은 것일 수도 있습니다.
15. **배당이 증가입니**다. 사후에 확정된 값이라 베팅 시점 정보가 아닙니다. 실행 가능한 전략 검증이 아닙니다.
16. **정의가 통일되지 않았습니**다. 다크호스가 세 가지로 갈려 Lift 를 직접 비교할 수 없습니다.

10.2 다음에 할 일

	무엇을	왜
1	정의를 하나로 통일	입상 기준(찬진님)을 권함 — 표본이 가장 크고 연승 배당과 짝이 맞음
2	베팅 시점 배당 저장	출발 5 분 전 스냅샷. 지금은 증가라 실행 검증이 아님
3	표본 확대	고배당 적중이 드물어 3~5 년치가 필요. 부경으로 외부 검증도 가능
4	사전 등록을 표준으로	7 장에서 본 대로 절차가 결론을 바꿈
5	walk-forward 검증	고정 분할이 아니라 시간을 밀어가며 반복 검증

표 10-1. 우선순위 순.

1~2 번이 가장 값이 큽니다. 정의 통일은 하루면 되고, 배당 스냅샷은 지금부터 모으기 시작하면 됩니다.

둘 다 더 복잡한 모델이 아니라 **데이터와 절차를 정리하는 일**입니다.

부록 A. 용어

용어	뜻
pop_pct	인기 백분위. 작을수록 인기마
fin_pct	착순 백분위. 클수록 뒤쪽
q	시장 확률. 1/배당률을 경주 합이 1 이 되게 정규화
다크호스	비인기마가 잘 뛰는 것. 정의가 셋으로 갈림 (1.3 절)
인기마 붕괴	$pop_pct \leq 0.25$ 인 말이 $fin_pct \geq 0.50$ 으로 떨어짐
Lift@k%	상위 k% 안의 적중률 ÷ 전체 적중률. 파트 2 의 주 지표
PR-AUC	정밀도-재현율 곡선 아래 넓이. 기저율이 무작위 기준선
Cohen's d	두 집단 평균 차이를 표준편차로 나눈 값. 0.5 면 중간
min_samples_leaf	나무의 잎마다 요구하는 최소 표본 수. 과적합 방지의 핵심
부트스트랩	복원추출로 다시 뽑아 반복해 신뢰구간을 얻는 방법
사전 등록	결과를 보기 전에 분석 절차를 고정하고 기록하는 것
Holm 보정	여러 가설을 동시에 검정할 때 우연한 양성을 줄이는 보정
통제군	비교 기준. 여기서는 같은 조건에서 시장확률 순으로 고른 집단

부록 B. 자료 목록

이 보고서가 인용한 원본은 [근거자료/](#) 에 있습니다.

파일	누가	내용
1_찬진_이변예측_최종분석.docx	김찬진	두 유형 분리 · 잠금 test · 수익 검증
근거자료/1_다크호스_8-15 배_사전등록검증.pdf	Codex	NO-GO 판정 · 통제군 비교
근거자료/2_이변피쳐_최종.pdf	Codex	이변 피쳐 연구 종합
근거자료/3_이변피쳐_전체.pdf	Codex	전체 피쳐 기준
근거자료/4_이변피쳐_선별재학습.pdf	Codex	선별 후 재학습
근거자료/5_이변피쳐_독립검증.pdf	Codex	독립 검증과 EDGE

근거자료/6_경주별_이변위험도.pdf	Codex	경주 단위 이변 위험도
근거자료/7_관진_모델선정_기록.md	김찬진	valid 선정 근거와 잠금 해시
근거자료/배당구간별_결과.csv	박준석	24 개 조합 전부
근거자료/개선실험_결과.csv	박준석	6 단계 중 5 가지 실패 기록
근거자료/로버스트니스_검증.csv	박준석	고배당 제거 시 5 조건 모두 음수

실행 코드는 저장소의 [3_이변모델/](#)에 있습니다.

폴더	누가	무엇
유립_이변정의/	전유림	이변 정의와 Cohen's d 분석 노트북
이변모델/	박준석	배당률 포함 이변 예측 (08 → 09 → 10)
이변모델_선정/	박준석	개선 실험 · 배당 구간 필터 · 배분 전략
관진_이변분석/	김찬진	두 유형 분리 · 사전 등록 · ROI 검증

부록 C. 재현 시 지킬 것

다섯 가지

- ① 부분집합으로 먼저 자르고 학습하세요. 전체로 하면 5.6 절처럼 무너집니다.
- ② `pop_pct` 와 배당률 계열을 전부 빼세요. 남으면 타깃 정의를 그대로 보는 셈이라 AUC 0.98 이 나옵니다.
- ③ `min_samples_leaf` 를 50 근처로. 기본값 1 이면 과적합됩니다.
- ④ `class_weight` 를 건드리지 마세요. 5.6 절 참고.
- ⑤ 시간순으로 분할하세요. 무작위 분할은 미래 정보 누출입니다.

그리고 **Lift** 로 평가하고, 부트스트랩 신뢰구간을 붙이고, 고배당 적중 몇 건을 빼도 결론이 유지되는지 확인하세요.